

Etapa 3 - Código

Alicia Bernádez, Omar Arzaga, Diego Medrano, Sebastián Alemán, Isaac Montaña

ETAPA 3

```
library(tidyverse)
```

Warning: package 'ggplot2' was built under R version 4.5.2

Warning: package 'readr' was built under R version 4.5.2

Warning: package 'purrr' was built under R version 4.5.2

Warning: package 'dplyr' was built under R version 4.5.2

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
```

```
-- Conflicts ----- tidyverse_conflicts() --
```

```
x dplyr::filter() masks stats::filter()
```

```
x dplyr::lag()     masks stats::lag()
```

```
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(lubridate)
```

```
library(ResourceSelection)
```

ResourceSelection 0.3-6

2023-06-27

```
library(pROC)
```

Warning: package 'pROC' was built under R version 4.5.2

Type 'citation("pROC")' for a citation.

Attaching package: 'pROC'

The following objects are masked from 'package:stats':

cov, smooth, var

```
datos <- read_csv(
  "baseeee_SIMA_limpia_4est_8cont_2022_2025.csv",
  locale = locale(encoding = "UTF-8"),
  show_col_types = FALSE
)

cat("Dimensiones:", nrow(datos), "filas x", ncol(datos), "columnas\n")
```

Dimensiones: 132936 filas x 21 columnas

```
cat("Columnas:", paste(names(datos), collapse = ", "), "\n\n")
```

Columnas: Fecha y hora, Estacion, Municipio, Año, CO, NO, NO2, NOX, O3, PM10, PM2.5, SO2, WD

```
# ---- 2. Preparación: estación ordenada por distancia a la refinería ----
datos <- datos %>%
  mutate(
    fecha = ymd_hms(`Fecha y hora`),
    Estacion = factor(Estacion, levels = c("SE3", "SE2", "NE", "GAR"))
  )

# ---- 3. Clasificación circular del viento en 16 rumbos ----
rumbos <- c("N", "NNE", "NE", "ENE", "E", "ESE", "SE", "SSE",
            "S", "SSO", "SO", "OSO", "O", "ONO", "NO", "NNO")

datos <- datos %>%
  mutate(
```

```

    sector = rumbos[((floor((WDR + 11.25) / 22.5)) %% 16) + 1],
    sector = factor(sector, levels = rumbos)
)

# ---- 4. Definición del umbral de episodio ----
# Umbral ABSOLUTO común a las 4 estaciones (P95 del conjunto),
# para que los momios sean comparables entre estaciones.
umbral_ep <- quantile(datos$S02, 0.95, na.rm = TRUE)

datos <- datos %>%
  mutate(episodio = as.integer(S02 > umbral_ep))

cat("Umbral de episodio (P95 global):", round(umbral_ep, 2), "ppb\n\n")

```

Umbral de episodio (P95 global): 11.1 ppb

```

# ---- 5. Verificación: tasa de episodios por estación ----
datos %>%
  group_by(Estacion) %>%
  summarise(
    n          = n(),
    episodios  = sum(episodio, na.rm = TRUE),
    tasa_pct   = round(100 * mean(episodio, na.rm = TRUE), 2),
    P50        = median(S02, na.rm = TRUE),
    P99        = quantile(S02, 0.99, na.rm = TRUE),
    razon_P99_P50 = round(P99 / P50, 2),
    .groups = "drop"
  )

```

```

# A tibble: 4 x 7
  Estacion      n episodios tasa_pct   P50   P99 razon_P99_P50
  <fct>      <int>      <int>   <dbl> <dbl> <dbl>         <dbl>
1 SE3      33977      3951   11.6   4.4  55.3          12.6
2 SE2      33240      1841    5.54   3.8  27.8           7.32
3 NE       33185       746    2.25   3.8  15.1           3.97
4 GAR      32534       49     0.15   3.3   7.4           2.24

```

```

# ---- 6. Verificación: distribución de rumbos (sin NAs) ----
cat("\nNAs en sector:", sum(is.na(datos$sector)), "\n")

```

NAs en sector: 0

```
table(datos$sector) %>% sort(decreasing = TRUE) %>% head(5)
```

```
   ESE    SE    E   SSE    NE
23655 19894 19633 12246  7951
```

Regresión logística direccional (SE3)

```
library(broom)
```

Warning: package 'broom' was built under R version 4.5.2

```
library(splines)

# ---- 1. Tasa cruda de episodios por rumbo en SE3 ----
tasa_sector_SE3 <- datos %>%
  filter(Estacion == "SE3") %>%
  group_by(sector) %>%
  summarise(
    n          = n(),
    episodios  = sum(episodio),
    tasa_pct   = round(100 * mean(episodio), 2),
    .groups    = "drop"
  ) %>%
  arrange(desc(tasa_pct))

print(tasa_sector_SE3, n = 16)
```

```
# A tibble: 16 x 4
  sector      n episodios tasa_pct
  <fct> <int>      <int>    <dbl>
1 E      3906         930    23.8
2 ESE    6002        1013    16.9
3 SE     5562         836    15.0
4 SSE    2536         351    13.8
5 ENE    2217         277    12.5
6 S      1070         106     9.91
```

7 NE	1595	116	7.27
8 SSO	547	37	6.76
9 NNE	1072	71	6.62
10 N	1161	75	6.46
11 SO	531	31	5.84
12 OSO	647	21	3.25
13 NNO	1842	37	2.01
14 ONO	1714	22	1.28
15 O	990	12	1.21
16 NO	2585	16	0.62

```
# ---- 2. Preparación del subconjunto SE3 ----
# Hora y mes entran como armónicos (seno/coseno): son variables
# circulares, igual que el viento.
d_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  mutate(
    sector    = relevel(sector, ref = "N"),
    Hora_sin  = sin(2 * pi * Hora / 24),
    Hora_cos  = cos(2 * pi * Hora / 24),
    Mes_sin   = sin(2 * pi * Mes / 12),
    Mes_cos   = cos(2 * pi * Mes / 12)
  )

# ---- 3. Modelo logístico ----
# WSR con spline: la relación con los episodios no es monótona
# (a viento muy bajo hay estancamiento; a viento alto, dispersión).
mod_se3 <- glm(
  episodio ~ sector + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos,
  data    = d_se3,
  family  = binomial
)

# ---- 4. Razones de momios por rumbo (IC de Wald al 95%) ----
or_sector <- tidy(mod_se3) %>%
  filter(str_detect(term, "^sector")) %>%
  mutate(
    Rumbo    = str_remove(term, "^sector"),
    OR       = round(exp(estimate), 2),
    IC_inf   = round(exp(estimate - 1.96 * std.error), 2),
    IC_sup   = round(exp(estimate + 1.96 * std.error), 2),
    p        = signif(p.value, 3)
  )
```

```

) %>%
select(Rumbo, OR, IC_inf, IC_sup, p) %>%
arrange(desc(OR))

print(or_sector, n = 15)

```

```

# A tibble: 15 x 5
  Rumbo    OR IC_inf IC_sup      p
  <chr> <dbl> <dbl> <dbl>   <dbl>
1 E      6.12   4.73   7.92 3.97e-43
2 ESE    2.58    2     3.33 4.38e-13
3 ENE    1.98   1.51   2.62 1.20e- 6
4 SSE    1.53   1.17   2.01 1.93e- 3
5 SE     1.51   1.17   1.96 1.55e- 3
6 S      1.14   0.83   1.56 4.3 e- 1
7 NE     1.08   0.79   1.47 6.34e- 1
8 NNE    1.06   0.75   1.5  7.43e- 1
9 SO     0.83   0.53   1.29 4.09e- 1
10 SSO   0.78   0.51   1.19 2.46e- 1
11 OSO   0.54   0.33   0.9  1.75e- 2
12 ONO   0.25   0.15   0.41 2.94e- 8
13 O     0.24   0.13   0.44 6.20e- 6
14 NNO   0.23   0.15   0.35 2.35e-12
15 NO    0.08   0.04   0.13 1.19e-19

```

```

# ---- 5. Ajuste global ----
cat("\nDevianza nula:      ", round(mod_se3$null.deviance, 1), "\n")

```

Devianza nula: 24426.5

```
cat("Devianza residual:", round(mod_se3$deviance, 1), "\n")
```

Devianza residual: 19809.3

```
cat("Pseudo-R2 McFadden:",
    round(1 - mod_se3$deviance / mod_se3$null.deviance, 3), "\n")

```

Pseudo-R2 McFadden: 0.189

```
cat("AIC: ", round(AIC(mod_se3), 1), "\n")
```

AIC: 19855.3

Validación cruzada espacial y falsación multi-contaminante

```
# ---- 1. Sector industrial colapsado ----
# Los 16 rumbos ya revelaron que el máximo está en E, con ENE y ESE
# elevados. Se agrupan en un solo factor binario para evitar celdas
# vacías en GAR (solo 49 episodios en total).
datos <- datos %>%
  mutate(
    sector_E = factor(
      if_else(sector %in% c("ENE", "E", "ESE"), "Este", "Resto"),
      levels = c("Resto", "Este")
    ),
    Hora_sin = sin(2 * pi * Hora / 24),
    Hora_cos = cos(2 * pi * Hora / 24),
    Mes_sin = sin(2 * pi * Mes / 12),
    Mes_cos = cos(2 * pi * Mes / 12)
  )

# ---- 2. Función: momio del sector este para cualquier contaminante ----
# El umbral es el P95 DENTRO de cada subconjunto, para que cada
# contaminante se compare contra su propia distribución.
or_este <- function(df, var) {
  d <- df %>%
    filter(!is.na(.data[[var]])) %>%
    mutate(y = as.integer(.data[[var]] > quantile(.data[[var]], 0.95)))

  if (sum(d$y) < 30) return(tibble(n = nrow(d), eventos = sum(d$y),
                                   OR = NA, IC_inf = NA, IC_sup = NA))

  m <- glm(y ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
           Mes_sin + Mes_cos,
           data = d, family = binomial)

  co <- tidy(m) %>% filter(term == "sector_EEste")

  tibble(
    n = nrow(d),
```

```

    eventos = sum(d$y),
    OR       = round(exp(co$estimate), 2),
    IC_inf   = round(exp(co$estimate - 1.96 * co$std.error), 2),
    IC_sup   = round(exp(co$estimate + 1.96 * co$std.error), 2)
  )
}

# ---- 3. Validación espacial: mismo modelo, las 4 estaciones ----
cat("=== S02: momio del sector Este por estación ===\n")

```

=== S02: momio del sector Este por estación ===

```

map_dfr(levels(datos$Estacion), function(e) {
  or_este(filter(datos, Estacion == e), "S02") %>%
    mutate(Estacion = e, .before = 1)
}) %>% print()

```

```

# A tibble: 4 x 6
  Estacion      n eventos      OR IC_inf IC_sup
  <chr>      <int>    <int> <dbl> <dbl> <dbl>
1 SE3       33977    1699  2.66  2.39  2.95
2 SE2       33240    1655  1.61  1.45  1.79
3 NE        33185    1660  1.02  0.88  1.18
4 GAR       32534    1510  1.25  1.09  1.43

```

```

# ---- 4. Falsación: otros contaminantes en SE3 ----
# Si el sector Este solo eleva el S02 y deja planos a los trazadores
# de tráfico y combustión urbana, la firma es de fuente puntual.
cat("\n=== SE3: momio del sector Este por contaminante ===\n")

```

=== SE3: momio del sector Este por contaminante ===

```

d_se3 <- filter(datos, Estacion == "SE3")

map_dfr(c("S02", "NOX", "NO", "CO", "PM10", "PM2.5", "O3"), function(v) {
  or_este(d_se3, v) %>% mutate(Contaminante = v, .before = 1)
}) %>% print()

```



```
# A tibble: 7 x 6
  Contaminante      n eventos      OR IC_inf IC_sup
  <chr>          <int>    <int> <dbl>  <dbl>  <dbl>
1 SO2           33977     1699  2.66   2.39   2.95
2 NOX           33682     1684  0.22   0.17   0.28
3 NO            33451     1670  0.22   0.17   0.29
4 CO            31741     1571  1.05   0.92   1.2
5 PM10          33684     1658  0.5    0.43   0.58
6 PM2.5         30686     1507  0.59   0.51   0.68
7 O3            33697     1567  0.9    0.8    1.02
```

Validación y ajuste de la regresión logística mod_SE3 (dirección de las emisiones de azufre)

```
# Modelo nulo para el modelo principal de 16 rumbos
mod_nulo_se3 <- glm(
  episodio ~ 1,
  data = d_se3,
  family = binomial
)

# Razón de verosimilitudes
anova(mod_nulo_se3, mod_se3, test = "Chisq")
```

Analysis of Deviance Table

Model 1: episodio ~ 1

Model 2: episodio ~ sector + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	33976	24426			
2	33954	19809	22	4617.2	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
# ROC y AUC
roc_se3 <- roc(
  d_se3$episodio,
  fitted(mod_se3),
  quiet = TRUE
)

auc(roc_se3)
```

Area under the curve: 0.8112

```
# Hosmer-Lemeshow
hoslem.test(
  d_se3$episodio,
  fitted(mod_se3),
  g = 10
)
```

Hosmer and Lemeshow goodness of fit (GOF) test

```
data: d_se3$episodio, fitted(mod_se3)
X-squared = 56.531, df = 8, p-value = 2.223e-09
```

Validación y ajuste del modelo de regresión logística mod

```
library(pROC)
library(ResourceSelection)

# Modelo principal
mod <- glm(
  episodio ~ sector_E + ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_se3,
  family = binomial
)
```

```
# -----
# 1. PRUEBA DE RAZÓN DE VEROSIMILITUDES
# -----

# Modelo nulo: solamente intercepto
mod_nulo <- glm(
  episodio ~ 1,
  data = d_se3,
  family = binomial
)

anova(mod_nulo, mod, test = "Chisq")
```

Analysis of Deviance Table

Model 1: episodio ~ 1


Model 2: episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	33976	24426			
2	33968	20718	8	3708.2	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
# -----  
# 2. Análisis de residuos  
# -----  
  
d_se3 <- d_se3 %>%  
  mutate(  
    prob_estimada = fitted(mod),  
    residuo_dev = residuals(mod, type = "deviance")  
  )  
  
plot(  
  d_se3$prob_estimada,  
  d_se3$residuo_dev,  
  pch = 16,  
  cex = 0.4,  
  xlab = "Probabilidad estimada",  
  ylab = "Residuo de devianza",  
  main = "Residuos de devianza vs probabilidad estimada"  
)  
  
abline(h = 0, lty = 2, col = "red")
```

Residuos de devianza vs probabilidad estimada



```
# -----  
# 3. Hosmer-Lemeshow  
# -----  
  
cat("\n=== HOSMER-LEMESHOW ===\n")
```

=== HOSMER-LEMESHOW ===

```
hl <- hoslem.test(  
  d_se3$episodio,  
  d_se3$prob_estimada,  
  g = 10  
)  
  
print(hl)
```

Hosmer and Lemeshow goodness of fit (GOF) test

data: d_se3\$episodio, d_se3\$prob_estimada
X-squared = 64.06, df = 8, p-value = 7.403e-11


```

# -----
# 4. ROC y AUC en muestra
# -----

roc_in <- roc(
  d_se3$episodio,
  d_se3$prob_estimada,
  quiet = TRUE
)

plot(
  roc_in,
  main = "Curva ROC del modelo logístico"
)

```



```

cat(
  "\nAUC en muestra:",
  round(as.numeric(auc(roc_in)), 3),
  "\n"
)

```

AUC en muestra: 0.783

La prueba de razón de verosimilitudes mostró que el modelo completo mejora significativamente frente al modelo nulo ($p < 0.001$). La curva ROC presentó un AUC de 0.783, indicando una capacidad razonable para distinguir entre horas con y sin episodios de SO₂. Por otro lado, la prueba de Hosmer-Lemeshow resultó significativa ($p < 0.001$), lo que indica diferencias entre los valores observados y las probabilidades estimadas. Debido al gran tamaño de la muestra, esta prueba puede ser sensible a desviaciones pequeñas, por lo que el resultado se interpreta en conjunto con el AUC y el objetivo inferencial del modelo.

PCA sobre la matriz química (técnica de interdependencia)

```
library(factoextra)
```

Warning: package 'factoextra' was built under R version 4.5.2

Welcome to factoextra!

Want to learn more? See two factoextra-related books at <https://www.datanovia.com/library/principal-component-methods>

```
# ---- 1. Matriz química completa en SE3 ----
# PCA exige casos completos. Se documenta cuántos se pierden y se
# verifica que la pérdida no elimine preferentemente los episodios.
mat_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  select(SO2, NO, NO2, NOX, CO, O3, PM10, `PM2.5`,
         sector_E, WSR, Hora, Mes, episodio)

completos <- mat_se3 %>% drop_na(SO2:`PM2.5`)

cat("Filas SE3:", nrow(mat_se3), "\n")
```

Filas SE3: 33977

```
cat("Casos completos:", nrow(completos),
    paste0("((", round(100 * nrow(completos) / nrow(mat_se3), 1), "%))"), "\n")
```

Casos completos: 27938 (82.2%)

```
cat("Episodios conservados:", sum(completos$episodio), "de",
    sum(mat_se3$episodio), "\n\n")
```

Episodios conservados: 3304 de 3951

```
# ---- 2. Transformación logarítmica ----
# ADVERTENCIA: log1p comprime la escala de los extremos. NO elimina
# outliers, pero sí reduce su influencia en la matriz de covarianzas.
# Sin esta transformación, PC1 quedaría dominado por unas pocas horas
# de SO2 extremo y no describiría la estructura general.
# Los episodios siguen siendo identificables en el espacio de componentes.
X <- completos %>%
  select(SO2:`PM2.5`) %>%
  mutate(across(everything(), log1p))

# ---- 3. PCA sobre variables estandarizadas ----
pca <- prcomp(X, scale. = TRUE)

# ---- 4. Varianza explicada ----
var_exp <- tibble(
  CP      = paste0("PC", 1:8),
  Var_pct = round(100 * pca$sdev^2 / sum(pca$sdev^2), 2),
  Acum_pct = round(cumsum(100 * pca$sdev^2 / sum(pca$sdev^2)), 2)
)
print(var_exp)
```

```
# A tibble: 8 x 3
  CP      Var_pct Acum_pct
  <chr>   <dbl>   <dbl>
1 PC1    48.6    48.6
2 PC2    19.4    68.0
3 PC3     9.69   77.7
4 PC4     9.21   86.9
5 PC5     6.36   93.3
6 PC6     3.69   97.0
7 PC7     2.97  100.0
8 PC8     0.05  100
```

```
# ---- 5. Cargas de los primeros 3 componentes ----
cargas <- as_tibble(pca$rotation[, 1:3], rownames = "Variable") %>%
```


```
mutate(across(where(is.numeric), ~ round(.x, 3)))
print(cargas)
```

```
# A tibble: 8 x 4
  Variable    PC1    PC2    PC3
  <chr>      <dbl> <dbl> <dbl>
1 SO2        0.029 0.604 -0.472
2 NO         -0.452 -0.141 -0.13
3 NO2        -0.437 -0.04  -0.337
4 NOX        -0.481 -0.089 -0.266
5 CO         -0.278 0.091  0.705
6 O3         0.319 0.458 -0.001
7 PM10       -0.351 0.367  0.228
8 PM2.5      -0.265 0.503  0.164
```

```
# ---- 6. Criterio de Kaiser ----
cat("\nComponentes con eigenvalor > 1:", sum(pca$sdev^2 > 1), "\n")
```

Componentes con eigenvalor > 1: 2

```
# ---- 7. Scree plot ----
fviz_eig(pca, addlabels = TRUE, barfill = "steelblue",
  main = "Varianza explicada por componente (SE3)")
```

Conglomerados sobre el espacio de componentes

```
library(cluster)
```

Warning: package 'cluster' was built under R version 4.5.2

```
# ---- 1. Puntuaciones de los 4 primeros componentes (86.9% varianza) ----
scores <- as_tibble(pca$x[, 1:4])

# ---- 2. Número de conglomerados: silueta sobre muestra ----
set.seed(2024)
muestra <- scores[sample(nrow(scores), 4000), ]

sil <- map_dfr(2:6, function(k) {
  km <- kmeans(muestra, centers = k, nstart = 20)
  tibble(k = k,
         silueta = round(mean(silhouette(km$cluster,
                                         dist(muestra))[, 3]), 3))
})
print(sil)
```

```
# A tibble: 5 x 2
```

	k	silueta
	<int>	<dbl>
1	2	0.418
2	3	0.262
3	4	0.264
4	5	0.255
5	6	0.239

```
# ---- 3. k-means sobre el conjunto completo ----
set.seed(2024)
km <- kmeans(scores, centers = 4, nstart = 25, iter.max = 50)
```

Warning: Quick-TRANSfer stage steps exceeded maximum (= 1396900)

Warning: Quick-TRANSfer stage steps exceeded maximum (= 1396900)

Warning: Quick-TRANSfer stage steps exceeded maximum (= 1396900)

```
cat("Iteraciones usadas:", km$iter, "de 50\n")
```

Iteraciones usadas: 5 de 50

```
cat("Varianza explicada por la partición:",
    round(100 * km$betweenss / km$totss, 1), "%\n\n")
```

Varianza explicada por la partición: 58.3 %

```
# ---- 4. Caracterización de cada conglomerado ----
# Se describen con las variables ORIGINALES, no con las transformadas.
perfil <- completos %>%
  mutate(grupo = factor(km$cluster)) %>%
  group_by(grupo) %>%
  summarise(
    n          = n(),
    pct        = round(100 * n() / nrow(completos), 1),
    SO2_med    = round(median(SO2), 2),
    NOX_med    = round(median(NOX), 2),
    CO_med     = round(median(CO), 2),
    PM25_med   = round(median(`PM2.5`), 1),
    O3_med     = round(median(O3), 1),
```

```

    WSR_med      = round(median(WSR), 1),
    pct_Este     = round(100 * mean(sector_E == "Este"), 1),
    pct_episod   = round(100 * mean(episodio), 1),
    .groups = "drop"
  ) %>%
  arrange(desc(SO2_med))

print(perfil, width = Inf)

```

```

# A tibble: 4 x 11
  grupo      n  pct SO2_med NOX_med CO_med PM25_med O3_med WSR_med pct_Este
  <fct> <int> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 1      4111 14.7  16.2  10.4  1.36    22    43    8.5   50.5
2 2      3352 12    4.4  51.8  1.94    28     5    3.6    6.2
3 3      7823 28    4.2  17.7  1.49    15    17    5.8   25.4
4 4     12652 45.3  4.1   8.1  1.11     9    26    8.5   42.7
  pct_episod
  <dbl>
1      72.2
2       1.4
3       0.9
4       1.7

```

```

# ---- 5. Razón SO2/NOX por grupo ----
# Indicador de firma: alta razón = azufre sin combustión vehicular.
perfil %>%
  mutate(razon_SO2_NOX = round(SO2_med / NOX_med, 3)) %>%
  select(grupo, SO2_med, NOX_med, razon_SO2_NOX, pct_Este, pct_episod) %>%
  print()

```

```

# A tibble: 4 x 6
  grupo SO2_med NOX_med razon_SO2_NOX pct_Este pct_episod
  <fct> <dbl> <dbl> <dbl> <dbl> <dbl>
1 1      16.2  10.4      1.56    50.5    72.2
2 2       4.4  51.8     0.085     6.2     1.4
3 3       4.2  17.7     0.237    25.4     0.9
4 4       4.1   8.1     0.506    42.7     1.7

```

diferencia de medianas por año y traducción a política pública

```
# ---- 1. Kruskal-Wallis por año: ¿difieren las 4 estaciones? ----
kw <- datos %>%
  group_split(Año) %>%
  map_dfr(function(d) {
    t <- kruskal.test(SO2 ~ Estacion, data = d)
    tibble(Año = unique(d$Año),
            chi2 = round(t$statistic, 1),
            gl   = t$parameter,
            p     = signif(t$p.value, 3))
  })
print(kw)
```

```
# A tibble: 4 x 4
  Año   chi2    gl      p
<dbl> <dbl> <int>   <dbl>
1 2022 3878.     3 0
2 2023 10338     3 0
3 2024 3799.     3 0
4 2025 1455.     3 3.63e-315
```

```
# ---- 2. Desplazamiento Hodges-Lehmann SE3 vs GAR, por año ----
# Estima la diferencia TÍPICA en ppb entre ambas estaciones, con IC.
# Es el análogo no paramétrico de la diferencia de medias, robusto
# a la fuerte asimetría del SO2.
hl <- datos %>%
  filter(Estacion %in% c("SE3", "GAR")) %>%
  group_split(Año) %>%
  map_dfr(function(d) {
    w <- wilcox.test(SO2 ~ Estacion, data = d,
                      conf.int = TRUE, exact = FALSE)

    tibble(
      Año      = unique(d$Año),
      Med_SE3  = median(d$SO2[d$Estacion == "SE3"]),
      Med_GAR  = median(d$SO2[d$Estacion == "GAR"]),
      Dif_HL   = round(w$estimate, 2),
      IC_inf   = round(w$conf.int[1], 2),
      IC_sup   = round(w$conf.int[2], 2),
      p        = signif(w$p.value, 3)
    )
  })
print(hl)
```

```
# A tibble: 4 x 7
  Año Med_SE3 Med_GAR Dif_HL IC_inf IC_sup p
  <dbl>   <dbl>   <dbl> <dbl> <dbl> <dbl> <dbl>
1 2022     4.8     3.4   1.3   1.3   1.4 0
2 2023     3.9     2.4   1.5   1.5   1.5 0
3 2024     4.1     3     1     1     1 0
4 2025     4.7     4.4   0.6   0.5   0.6 5.44e-207
```

```
# ---- 3. Lo que la mediana NO captura: horas de episodio por año ----
# Umbral ABSOLUTO (11.1 ppb) para que los años sean comparables.
horas <- datos %>%
  group_by(Año, Estacion) %>%
  summarise(horas_episodio = sum(episodio), .groups = "drop") %>%
  pivot_wider(names_from = Estacion, values_from = horas_episodio) %>%
  mutate(Exceso_SE3_vs_GAR = SE3 - GAR)
print(horas)
```

```
# A tibble: 4 x 6
  Año SE3 SE2 NE GAR Exceso_SE3_vs_GAR
  <dbl> <int> <int> <int> <int> <int>
1 2022 1245 518 278 10 1235
2 2023 689 307 120 20 669
3 2024 845 397 122 10 835
4 2025 1172 619 226 9 1163
```

```
# ---- 4. Indicador de política pública ----
# Horas/año de exposición aguda evitables si SE3 tuviera el
# comportamiento de la estación de control.
horas %>%
  summarise(
    exceso_total = sum(Exceso_SE3_vs_GAR),
    exceso_anual = round(mean(Exceso_SE3_vs_GAR)),
    dias_equiv_anual = round(mean(Exceso_SE3_vs_GAR) / 24, 1)
  ) %>%
  print()
```

```
# A tibble: 1 x 3
  exceso_total exceso_anual dias_equiv_anual
  <int> <dbl> <dbl>
1 3902 976 40.6
```

sensibilidad y figura principal

```
# ---- 1. Sensibilidad del umbral: ¿el momio del Este depende de P95? ----
sens <- map_dfr(c(0.90, 0.95, 0.99), function(q) {
  u <- quantile(datos$S02, q, na.rm = TRUE)
  map_dfr(c("SE3", "SE2", "NE", "GAR"), function(e) {
    d <- datos %>% filter(Estacion == e) %>% mutate(y = as.integer(S02 > u))
    if (sum(d$y) < 30) return(tibble(Estacion = e, OR = NA,
                                     IC_inf = NA, IC_sup = NA))
    m <- glm(y ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
              Mes_sin + Mes_cos, data = d, family = binomial)
    co <- tidy(m) %>% filter(term == "sector_EEste")
    tibble(Estacion = e,
            OR      = round(exp(co$estimate), 2),
            IC_inf  = round(exp(co$estimate - 1.96 * co$std.error), 2),
            IC_sup  = round(exp(co$estimate + 1.96 * co$std.error), 2))
  }) %>% mutate(Percentil = paste0("P", q * 100), umbral_ppb = round(u, 1),
                .before = 1)
})
print(sens, n = 12)
```

A tibble: 12 x 6

	Percentil	umbral_ppb	Estacion	OR	IC_inf	IC_sup
	<chr>	<dbl>	<chr>	<dbl>	<dbl>	<dbl>
1	P90	7.2	SE3	3.38	3.17	3.6
2	P90	7.2	SE2	1.43	1.33	1.53
3	P90	7.2	NE	1	0.89	1.13
4	P90	7.2	GAR	1.4	1.08	1.83
5	P95	11.1	SE3	3.19	2.96	3.44
6	P95	11.1	SE2	1.58	1.43	1.74
7	P95	11.1	NE	1.01	0.81	1.26
8	P95	11.1	GAR	1.08	0.54	2.16
9	P99	30.6	SE3	2.57	2.25	2.93
10	P99	30.6	SE2	1.75	1.37	2.24
11	P99	30.6	NE	0.86	0.3	2.5
12	P99	30.6	GAR	NA	NA	NA


```
# ---- 2. Figura principal: divergencia mediana vs episodios ----
comp <- hl %>%
  select(Año, Dif_HL) %>%
  left_join(select(horas, Año, Horas_SE3 = SE3), by = "Año")
```

```

coef <- max(comp$Horas_SE3) / max(comp$Dif_HL)

ggplot(comp, aes(x = Año)) +
  geom_col(aes(y = Horas_SE3), fill = "grey70") +
  geom_line(aes(y = Dif_HL * coef), colour = "firebrick", linewidth = 1.2) +
  geom_point(aes(y = Dif_HL * coef), colour = "firebrick", size = 3) +
  scale_y_continuous(
    name = "Horas de episodio en SE3 (barras)",
    sec.axis = sec_axis(~ . / coef,
                        name = "Diferencia de medianas SE3-GAR, ppb (línea)")
  ) +
  scale_x_continuous(breaks = 2022:2025) +
  labs(title = "La mediana anual no refleja la exposición aguda",
       subtitle = "SE3 (Cadereyta), umbral absoluto de episodio: 11.1 ppb",
       x = "Año") +
  theme_minimal(base_size = 12) +
  theme(axis.title.y.right = element_text(colour = "firebrick"))

```



```

# ---- Tabla geográfica para el reporte ----
geo <- tribble(
  ~Estacion, ~lat, ~lon, ~azimut, ~rumbo, ~dist_km,
  "SE3", 25.5844, -100.0011, 87.3, "E", 5.5,

```

```


"SE2",      25.6461, -100.0956, 113.7, "ESE", 16.4,
"NE",       25.7455, -100.2552, 119.6, "ESE", 35.7,
"GAR",      25.7997, -100.5878, 110.1, "ESE", 68.5
)

# ---- Figura clave: decaimiento del momio con la distancia ----
or_p95 <- tibble(
  Estacion = c("SE3", "SE2", "NE", "GAR"),
  OR        = c(3.19, 1.58, 1.01, 1.08),
  IC_inf    = c(2.96, 1.43, 0.81, 0.54),
  IC_sup    = c(3.44, 1.74, 1.26, 2.16)
)

left_join(gео, or_p95, by = "Estacion") %>%
  ggplot(aes(x = dist_km, y = OR)) +
  geom_hline(yintercept = 1, linetype = "dashed", colour = "grey40") +
  geom_errorbar(aes(ymin = IC_inf, ymax = IC_sup), width = 1.5) +
  geom_point(size = 3, colour = "firebrick") +
  geom_text(aes(label = Estacion), vjust = -1.2, size = 3.5) +
  labs(
    title = "El efecto direccional decae con la distancia a la refinерía",
    subtitle = "Razón de momios del sector Este sobre episodios de SO2 (P95 = 11.1 ppb)",
    x = "Distancia a la refinерía (km)",
    y = "Razón de momios (IC 95%)"
  ) +
  theme_minimal(base_size = 12)

```


El efecto direccional decae con la distancia a la refinería
Razón de momios del sector Este sobre episodios de SO₂ (P95 = 11)



validación y supuestos

```
library(pROC)
library(sandwich)
```

Warning: package 'sandwich' was built under R version 4.5.2

```
library(lmtest)
```

Loading required package: zoo

Warning: package 'zoo' was built under R version 4.5.2

Attaching package: 'zoo'

The following objects are masked from 'package:base':

as.Date, as.Date.numeric

```
library(psych)
```

Warning: package 'psych' was built under R version 4.5.2

Attaching package: 'psych'

The following objects are masked from 'package:ggplot2':

%+%, alpha

```
d_se3 <- datos %>% filter(Estacion == "SE3") %>%  
  mutate(dia = as.Date(fecha))  
  
# ---- 1. Errores estándar robustos agrupados por día ----  
mod <- glm(episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +  
  Mes_sin + Mes_cos, data = d_se3, family = binomial)  
  
rob <- coeftest(mod, vcov = vcovCL(mod, cluster = ~ dia))  
b <- rob["sector_EEste", "Estimate"]  
se <- rob["sector_EEste", "Std. Error"]  
  
cat("=== OR sector Este en SE3 ===\n")
```

=== OR sector Este en SE3 ===

```
cat("Ingenuo :", round(exp(coef(mod)["sector_EEste"]), 2), "\n")
```

Ingenuo : 3.19

```
cat("Agrupado :", round(exp(b), 2),  
  " IC95: [", round(exp(b - 1.96*se), 2), ", ",  
  round(exp(b + 1.96*se), 2), "]\n\n")
```

Agrupado : 3.19 IC95: [2.92 , 3.48]

```
# ---- 2. Capacidad discriminante ----
auc_in <- roc(d_se3$episodio, fitted(mod), quiet = TRUE)
cat("AUC en muestra:", round(as.numeric(auc_in$auc), 3), "\n")
```

AUC en muestra: 0.783

```
# ---- 3. Validación fuera de muestra: entrenar 2022-2024, probar 2025 ----
tr <- filter(d_se3, Año <= 2024)
te <- filter(d_se3, Año == 2025)

m_tr <- glm(episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
            Mes_sin + Mes_cos, data = tr, family = binomial)
p_te <- predict(m_tr, newdata = te, type = "response")

cat("AUC fuera de muestra (2025):",
    round(as.numeric(roc(te$episodio, p_te, quiet = TRUE)$auc), 3), "\n")
```

AUC fuera de muestra (2025): 0.764

```
cat("Error Brier:", round(mean((p_te - te$episodio)^2), 4), "\n")
```

Error Brier: 0.1065

```
cat("Tasa base 2025:", round(mean(te$episodio), 4), "\n\n")
```

Tasa base 2025: 0.1371

```
# ---- 4. Matriz de confusión con punto de corte = tasa base ----
corte <- mean(tr$episodio)
tab <- table(Predicho = p_te > corte, Real = te$episodio)
print(tab)
```

	Real	
Predicho	0	1
FALSE	5025	337
TRUE	2354	835

```
cat("\nSensibilidad:", round(tab[2,2] / sum(tab[,2]), 3),  
    "| Especificidad:", round(tab[1,1] / sum(tab[,1]), 3), "\n\n")
```

Sensibilidad: 0.712 | Especificidad: 0.681

```
# ---- 5. Supuestos del PCA ----  
cat("=== Adecuación muestral del PCA ===\n")
```

=== Adecuación muestral del PCA ===

```
cat("KMO global:", round(KMO(X)$MSA, 3), "\n")
```

KMO global: 0.623

```
bt <- cortest.bartlett(cor(X), n = nrow(X))  
cat("Bartlett: chi2 =", round(bt$chisq, 0), " p =", signif(bt$p.value, 3), "\n")
```

Bartlett: chi2 = 213445 p = 0

CBPF

```
library(openair)
```

Warning: package 'openair' was built under R version 4.5.2

Attaching package: 'openair'

The following object is masked from 'package:psych':

corPlot

```
# ---- Preparación al formato openair ----
d_oa <- datos %>%
  rename(date = fecha, ws = WSR, wd = WDR)

# ---- Percentiles equivalentes al umbral absoluto de 11.1 ppb ----
# openair calcula el percentil DENTRO de cada panel. Para que las cuatro
# estaciones se comparen contra el MISMO umbral en ppb, se le pasa a cada
# una el percentil que en su distribución corresponde a 11.1 ppb.
pct_eq <- datos %>%
  group_by(Estacion) %>%
  summarise(p = round(100 * mean(SO2 <= umbral_ep, na.rm = TRUE), 2),
    .groups = "drop")
print(pct_eq)
```


```
# A tibble: 4 x 2
  Estacion      p
  <fct>    <dbl>
1 SE3      88.4
2 SE2      94.5
3 NE       97.8
4 GAR      99.8
```

```
# ---- CBPF de SO2 en las tres estaciones con señal ----
# GAR se omite: su percentil equivalente supera 99.8 y no quedan
# suficientes horas para estimar la probabilidad.
for (e in c("SE3", "SE2", "NE")) {
  p <- pct_eq$p[pct_eq$Estacion == e]
  polarPlot(
    filter(d_oa, Estacion == e),
    pollutant = "SO2",
    statistic = "cpf",
    percentile = p,
    main = paste0("CBPF de SO2 en ", e,
      " (umbral 11.1 ppb, P", p, ")"),
    key.title = "Probabilidad"
  )
}
```

Warning: The following lattice/base graphical parameters will be converted to ggplot2 equivalents:

```
* `main` > `title`
```


CBPF de SO₂ en SE3 (umbral 11.1 ppb, P88.37)



Warning: The following lattice/base graphical parameters will be converted to ggplot2 equivalents:

```
* `main` > `title`
```


CBPF de SO₂ en SE2 (umbral 11.1 ppb, P94.46)



Warning: The following lattice/base graphical parameters will be converted to ggplot2 equivalents:

* `main` > `title`

CBPF de SO₂ en NE (umbral 11.1 ppb, P97.75)



Radial axis shows wind spd.


CPF at the 97.75th percentile (=11)

```
# ---- Falsación visual: CBPF de NOX en SE3 ----
# Mismo percentil que el SO2 para que ambos mapas sean comparables.
polarPlot(
  filter(d_oa, Estacion == "SE3"),
  pollutant = "NOX",
  statistic = "cpf",
  percentile = pct_eq$p[pct_eq$Estacion == "SE3"],
  main       = "CBPF de NOX en SE3 (misma probabilidad de referencia)",
  key.title  = "Probabilidad"
)
```

Warning: The following lattice/base graphical parameters will be converted to ggplot2 equivalents:

* `main` > `title`

BPF de NO_x en SE3 (misma probabilidad de referencia)



Radial axis shows wind spd.
CPF at the 88.37th percentile (=33)

```
# or_p95: valores del gradiente espacial para la Figura 1
or_p95 <- tibble(
  Estacion = c("SE3", "SE2", "NE", "GAR"),
  OR       = c(3.19, 1.58, 1.01, 1.08),
  IC_inf   = c(2.96, 1.43, 0.81, 0.54),
  IC_sup   = c(3.44, 1.74, 1.26, 2.16)
)

saveRDS(list(datos = datos, pca = pca, km = km, completos = completos,
             hl = hl, horas = horas, sens = sens, geo = geo,
             or_sector = or_sector, tasa_sector_SE3 = tasa_sector_SE3,
             or_p95 = or_p95),
         "objetos_etapa3.rds")

names(readRDS("objetos_etapa3.rds"))
```

```
[1] "datos"          "pca"            "km"             "completos"
[5] "hl"             "horas"          "sens"           "geo"
[9] "or_sector"      "tasa_sector_SE3" "or_p95"
```