

Etapa final - Código

Alicia Bernádez Omar Arzaga Diego Medrano
Sebastián Alemán Isaac Montaña

Preparación general

```
library(tidyverse)
library(lubridate)
library(ResourceSelection)
library(pROC)
library(splines)
library(broom)
library(factoextra)
library(cluster)
library(sandwich)
library(lmtest)
library(psych)
library(openair)
library(emmeans)
```

```
datos <- read_csv(
  "baseeee_SIMA_limpia_4est_8cont_2022_2025.csv",
  locale = locale(encoding = "UTF-8"),
  show_col_types = FALSE
)

cat("Dimensiones:", nrow(datos), "filas x", ncol(datos), "columnas\n")
```

Dimensiones: 132936 filas x 21 columnas

```
cat("Columnas:", paste(names(datos), collapse = ", "), "\n\n")
```

Columnas: Fecha y hora, Estacion, Municipio, Año, CO, NO, NO2, NOX, O3, PM10, PM2.5, SO2, WDR

```
# Fecha y estación
datos <- datos %>%
  mutate(
    fecha = ymd_hms(`Fecha y hora`),
    Estacion = factor(
      Estacion,
      levels = c("SE3", "SE2", "NE", "GAR")
    )
  )

# Clasificación circular del viento en 16 rumbos
rumbos <- c(
  "N", "NNE", "NE", "ENE", "E", "ESE", "SE", "SSE",
  "S", "SSO", "SO", "OSO", "O", "ONO", "NO", "NNO"
)

datos <- datos %>%
  mutate(
    sector = rumbos[((floor((WDR + 11.25) / 22.5)) %% 16) + 1],
    sector = factor(sector, levels = rumbos)
  )

# Umbral ABSOLUTO común a las cuatro estaciones:
# P95 global de SO2.
umbral_ep <- quantile(datos$SO2, 0.95, na.rm = TRUE)

datos <- datos %>%
  mutate(
    episodio = as.integer(SO2 > umbral_ep),

    # Sector oriental utilizado posteriormente
    sector_E = factor(
      if_else(
        sector %in% c("ENE", "E", "ESE"),
        "Este",
        "Resto"
      ),
    ),
```

```

    levels = c("Resto", "Este")
  ),

  # Variables temporales cíclicas
  Hora_sin = sin(2 * pi * Hora / 24),
  Hora_cos = cos(2 * pi * Hora / 24),
  Mes_sin  = sin(2 * pi * Mes / 12),
  Mes_cos  = cos(2 * pi * Mes / 12)
)

cat(
  "Umbral de episodio (P95 global):",
  round(umbral_ep, 2),
  "ppb\n\n"
)

```

Umbral de episodio (P95 global): 11.1 ppb

```

# Frecuencia y distribución de episodios por estación
resumen_estaciones <- datos %>%
  group_by(Estacion) %>%
  summarise(
    n = n(),
    episodios = sum(episodio, na.rm = TRUE),
    tasa_pct = round(100 * mean(episodio, na.rm = TRUE), 2),
    P50 = median(SO2, na.rm = TRUE),
    P99 = quantile(SO2, 0.99, na.rm = TRUE),
    razon_P99_P50 = round(P99 / P50, 2),
    .groups = "drop"
  )

print(resumen_estaciones)

```

```

# A tibble: 4 x 7
  Estacion      n episodios tasa_pct    P50    P99 razon_P99_P50
  <fct>      <int>      <int>    <dbl> <dbl> <dbl>         <dbl>
1 SE3      33977      3951    11.6    4.4  55.3          12.6
2 SE2      33240      1841     5.54    3.8  27.8           7.32
3 NE       33185       746     2.25    3.8  15.1           3.97
4 GAR      32534       49      0.15    3.3   7.4           2.24

```

```
cat("\nNAs en sector:", sum(is.na(datos$sector)), "\n")
```

```
NAs en sector: 0
```

```
table(datos$sector) %>% sort(decreasing = TRUE) %>% head(5)
```

```

ESE      SE      E      SSE      NE
23655 19894 19633 12246 7951

```

Interpretación. En este bloque se prepara la base utilizada en los análisis posteriores. Se cargan 132,936 registros con información de contaminantes, meteorología, estación y tiempo para 2022–2025. La dirección del viento se transforma en 16 sectores de 22.5°, respetando su naturaleza circular.

Para identificar episodios elevados de SO_2 se utiliza un único umbral absoluto de 11.1 ppb, correspondiente al percentil 95 global de las cuatro estaciones. El uso de un mismo umbral permite comparar directamente la frecuencia de episodios entre estaciones sin obligar a que cada estación tenga, por construcción, el mismo 5% de observaciones extremas.

Con este criterio, SE3 presenta la mayor frecuencia de episodios, seguida por SE2, NE y GAR. La relación P99/P50 también es mayor en SE3, lo que muestra que las diferencias entre estaciones son especialmente importantes en la parte alta de la distribución.

Regresión logística direccional en SE3

```

# Tasa cruda de episodios por rumbo
tasa_sector_SE3 <- datos %>%
  filter(Estacion == "SE3") %>%
  group_by(sector) %>%
  summarise(
    n = n(),
    episodios = sum(episodio),
    tasa_pct = round(100 * mean(episodio), 2),
    .groups = "drop"
  ) %>%
  arrange(desc(tasa_pct))

print(tasa_sector_SE3, n = 16)

```

```
# A tibble: 16 x 4
```

	sector	n episodios	tasa_pct	
	<fct>	<int>	<dbl>	
1	E	3906	930	23.8
2	ESE	6002	1013	16.9
3	SE	5562	836	15.0
4	SSE	2536	351	13.8
5	ENE	2217	277	12.5
6	S	1070	106	9.91
7	NE	1595	116	7.27
8	SSO	547	37	6.76
9	NNE	1072	71	6.62
10	N	1161	75	6.46
11	SO	531	31	5.84
12	OSO	647	21	3.25
13	NNO	1842	37	2.01
14	ONO	1714	22	1.28
15	O	990	12	1.21
16	NO	2585	16	0.62

```
# Preparación de SE3
d_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  mutate(
    sector = relevel(sector, ref = "N")
  )

# Modelo logístico de 16 rumbos
mod_se3 <- glm(
  episodio ~
    sector +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_se3,
  family = binomial
)

# Razones de momios por rumbo
or_sector <- tidy(mod_se3) %>%
  filter(str_detect(term, "^sector")) %>%
  mutate(
```

```

Rumbo = str_remove(term, "^sector"),
OR = round(exp(estimate), 2),
IC_inf = round(exp(estimate - 1.96 * std.error), 2),
IC_sup = round(exp(estimate + 1.96 * std.error), 2),
p = signif(p.value, 3)
) %>%
select(Rumbo, OR, IC_inf, IC_sup, p) %>%
arrange(desc(OR))

print(or_sector, n = 15)

```

```

# A tibble: 15 x 5
  Rumbo    OR IC_inf IC_sup      p
  <chr> <dbl> <dbl> <dbl> <dbl>
1 E      6.12  4.73  7.92 3.97e-43
2 ESE    2.58  2      3.33 4.38e-13
3 ENE    1.98  1.51  2.62 1.20e- 6
4 SSE    1.53  1.17  2.01 1.93e- 3
5 SE     1.51  1.17  1.96 1.55e- 3
6 S      1.14  0.83  1.56 4.3 e- 1
7 NE     1.08  0.79  1.47 6.34e- 1
8 NNE    1.06  0.75  1.5  7.43e- 1
9 SO     0.83  0.53  1.29 4.09e- 1
10 SSO    0.78  0.51  1.19 2.46e- 1
11 OSO    0.54  0.33  0.9  1.75e- 2
12 ONO    0.25  0.15  0.41 2.94e- 8
13 O      0.24  0.13  0.44 6.20e- 6
14 NNO    0.23  0.15  0.35 2.35e-12
15 NO     0.08  0.04  0.13 1.19e-19

```

```
cat("\nDevianza nula:", round(mod_se3$null.deviance, 1), "\n")
```

Devianza nula: 24426.5

```
cat("Devianza residual:", round(mod_se3$deviance, 1), "\n")
```

Devianza residual: 19809.3

```
cat(
  "Pseudo-R2 McFadden:",
  round(1 - mod_se3$deviance / mod_se3$null.deviance, 3),
  "\n"
)
```

Pseudo-R2 McFadden: 0.189

```
cat("AIC:", round(AIC(mod_se3), 1), "\n")
```

AIC: 19855.3

Pregunta que responde. ¿Cómo cambia la ocurrencia de episodios elevados de SO_2 en SE3 según la dirección del viento, controlando simultáneamente por velocidad del viento, hora del día y mes?

Interpretación. Las tasas crudas muestran un patrón direccional marcado: el Este presenta la mayor proporción de episodios, seguido por ESE y SE, mientras que varias direcciones occidentales presentan tasas considerablemente menores.

En la regresión logística se utiliza Norte como referencia. La velocidad del viento se incorpora mediante un spline natural de tres grados de libertad y la hora y el mes mediante términos seno/coseno. El resultado principal es el rumbo Este, con $OR = 6.12$ (IC95%: 4.73–7.92), lo que significa que, manteniendo comparables WSR, hora y mes, los momios de registrar un episodio son aproximadamente 6.1 veces los correspondientes al viento del Norte.

Un OR de 6.12 no significa que la concentración de SO_2 sea 6.12 veces mayor ni que la probabilidad aumente exactamente 6.12 veces. El OR compara momios.

Las direcciones ESE y ENE también presentan asociaciones superiores a la referencia, mientras que varias direcciones occidentales presentan asociaciones considerablemente menores. En conjunto, se observa una estructura direccional coherente: la asociación con episodios de SO_2 es mayor en el sector oriental y menor hacia el sector occidental.

La reducción de devianza respecto al modelo nulo indica que la incorporación de dirección, velocidad y controles temporales aporta información. El pseudo- R^2 de McFadden se interpreta como una medida relativa de mejora frente al modelo nulo, no como un R^2 lineal.

Hallazgo principal. Después de controlar por velocidad del viento, hora y mes, el sector oriental conserva la asociación más fuerte con los episodios elevados de SO_2 en SE3. Este resultado muestra asociación estadística y no identifica por sí solo una fuente causal específica.

Comparación de extremos relativos y contraste multicontaminante

Nota metodológica. En esta sección el umbral se calcula dentro de cada subconjunto analizado. Por ello, estos resultados describen **extremos relativos** dentro de cada estación o contaminante. No deben confundirse con la comparación espacial principal basada en el umbral absoluto común de 11.1 ppb.

```
# Función para evaluar el P95 propio de cada subconjunto
or_este <- function(df, var) {

  d <- df %>%
    filter(!is.na(.data[[var]])) %>%
    mutate(
      y = as.integer(
        .data[[var]] >
          quantile(.data[[var]], 0.95, na.rm = TRUE)
      )
    )

  if (sum(d$y) < 30) {
    return(
      tibble(
        n = nrow(d),
        eventos = sum(d$y),
        OR = NA,
        IC_inf = NA,
        IC_sup = NA
      )
    )
  }

  m <- glm(
    y ~
      sector_E +
      ns(WSR, 3) +
      Hora_sin + Hora_cos +
      Mes_sin + Mes_cos,
    data = d,
    family = binomial
  )

  co <- tidy(m) %>%
```



```

    filter(term == "sector_EEste")

  tibble(
    n = nrow(d),
    eventos = sum(d$y),
    OR = round(exp(co$estimate), 2),
    IC_inf = round(exp(co$estimate - 1.96 * co$std.error), 2),
    IC_sup = round(exp(co$estimate + 1.96 * co$std.error), 2)
  )
}

cat("=== S02: P95 propio de cada estación ===\n")

```

=== S02: P95 propio de cada estación ===

```

extremos_relativos_estacion <- map_dfr(
  levels(datos$Estacion),
  function(e) {
    or_este(
      filter(datos, Estacion == e),
      "S02"
    ) %>%
      mutate(Estacion = e, .before = 1)
  }
)

print(extremos_relativos_estacion)

```

```

# A tibble: 4 x 6
  Estacion      n eventos   OR IC_inf IC_sup
  <chr>      <int>   <int> <dbl> <dbl> <dbl>
1 SE3      33977   1699  2.66  2.39  2.95
2 SE2      33240   1655  1.61  1.45  1.79
3 NE       33185   1660  1.02  0.88  1.18
4 GAR      32534   1510  1.25  1.09  1.43

```

```

cat("\n=== SE3: P95 propio de cada contaminante ===\n")

```

=== SE3: P95 propio de cada contaminante ===

```

d_se3 <- datos %>%
  filter(Estacion == "SE3")

extremos_relativos_contaminante <- map_dfr(
  c("SO2", "NOX", "NO", "CO", "PM10", "PM2.5", "O3"),
  function(v) {
    or_este(d_se3, v) %>%
      mutate(Contaminante = v, .before = 1)
  }
)

print(extremos_relativos_contaminante)

```

```

# A tibble: 7 x 6
  Contaminante      n eventos    OR IC_inf IC_sup
  <chr>          <int>    <int> <dbl>  <dbl>  <dbl>
1 SO2            33977     1699  2.66   2.39   2.95
2 NOX            33682     1684  0.22   0.17   0.28
3 NO             33451     1670  0.22   0.17   0.29
4 CO             31741     1571  1.05   0.92   1.2
5 PM10           33684     1658  0.5    0.43   0.58
6 PM2.5          30686     1507  0.59   0.51   0.68
7 O3             33697     1567  0.9    0.8    1.02

```

Interpretación. En esta sección cada estación se compara contra su propio 5% de concentraciones más altas. Por tanto, los OR obtenidos describen la asociación del sector oriental con los extremos relativos de cada estación y no cuantifican directamente un gradiente espacial de episodios absolutos.

En SE3, el sector oriental presenta la asociación más fuerte con el P95 propio de SO_2 . SE2 también presenta una asociación positiva de menor magnitud, mientras que NE se aproxima a la ausencia de asociación. GAR debe interpretarse con cautela porque su P95 propio representa concentraciones mucho menores que el umbral absoluto común.

En el contraste multicontaminante de SE3, SO_2 presenta una asociación positiva marcada con el sector oriental, mientras que NOX, NO y material particulado presentan patrones diferentes y CO/O3 no muestran un incremento claramente definido.

Hallazgo principal. El patrón direccional de los extremos relativos de SO_2 difiere del observado en varios contaminantes adicionales. Esto aporta evidencia de una estructura direccional específica del contaminante de interés, pero no constituye por sí solo atribución causal de fuente.

Validación del modelo logístico de 16 rumbos

```
mod_nulo_se3 <- glm(  
  episodio ~ 1,  
  data = d_se3,  
  family = binomial  
)  
  
lrt_se3 <- anova(  
  mod_nulo_se3,  
  mod_se3,  
  test = "Chisq"  
)  
  
print(lrt_se3)
```

Analysis of Deviance Table

Model 1: episodio ~ 1

Model 2: episodio ~ sector + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	33976	24426			
2	33954	19809	22	4617.2	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
roc_se3 <- roc(  
  d_se3$episodio,  
  fitted(mod_se3),  
  quiet = TRUE  
)  
  
cat(  
  "\nAUC modelo 16 rumbos:",  
  round(as.numeric(auc(roc_se3)), 4),  
  "\n"  
)
```

AUC modelo 16 rumbos: 0.8112

```
hl_se3 <- hoslem.test(
  d_se3$episodio,
  fitted(mod_se3),
  g = 10
)

print(hl_se3)
```

Hosmer and Lemeshow goodness of fit (GOF) test

```
data: d_se3$episodio, fitted(mod_se3)
X-squared = 56.531, df = 8, p-value = 2.223e-09
```

Interpretación. La prueba de razón de verosimilitudes muestra que el modelo completo mejora significativamente respecto a un modelo con solo intercepto. El AUC de aproximadamente 0.811 indica buena capacidad para discriminar horas con y sin episodio.

Hosmer-Lemeshow resulta significativo, lo que señala desviaciones de calibración. Debido al tamaño de muestra, la prueba es muy sensible a diferencias pequeñas; por ello debe interpretarse junto con las demás verificaciones. El modelo se utiliza principalmente para estudiar asociaciones direccionales y no como sistema operativo de alerta.

Modelo simplificado: sector oriental frente al resto en SE3

```
mod <- glm(
  episodio ~
    sector_E +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_se3,
  family = binomial
)

mod_nulo <- glm(
  episodio ~ 1,
  data = d_se3,
  family = binomial
)
```

```
)  
  
anova(mod_nulo, mod, test = "Chisq")
```

Analysis of Deviance Table

Model 1: episodio ~ 1

Model 2: episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	33976	24426			
2	33968	20718	8	3708.2	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Interpretación. Este modelo resume la señal direccional en un contraste más sencillo: sector oriental (ENE–E–ESE) frente al resto. La variable respuesta sigue siendo la ocurrencia de un episodio elevado de SO_2 .

La prueba de razón de verosimilitudes confirma que el conjunto de sector, velocidad, hora y mes mejora significativamente el ajuste respecto al modelo nulo. Esta prueba evalúa utilidad global, pero no demuestra que todas las variables individuales sean igualmente importantes ni que las probabilidades estén perfectamente calibradas.

Residuos de devianza

```
d_se3 <- d_se3 %>%  
  mutate(  
    prob_estimada = fitted(mod),  
    residuo_dev = residuals(mod, type = "deviance")  
  )  
  
plot(  
  d_se3$prob_estimada,  
  d_se3$residuo_dev,  
  pch = 16,  
  cex = 0.4,  
  xlab = "Probabilidad estimada",  
  ylab = "Residuo de devianza",  
  main = "Residuos de devianza vs probabilidad estimada")
```

```
)  
abline(h = 0, lty = 2, col = "red")
```



Interpretación. En una regresión logística con respuesta binaria es esperable observar dos ramas de residuos, asociadas a observaciones con episodio y sin episodio. Los residuos positivos de mayor magnitud representan episodios ocurridos pese a una probabilidad estimada relativamente baja; los negativos más alejados corresponden a horas sin episodio a las que el modelo asignó probabilidades relativamente mayores.

La gráfica no prueba independencia temporal. Esa propiedad debe evaluarse mediante un diagnóstico específico de autocorrelación.

Calibración: Hosmer-Lemeshow

```
hl <- hoslem.test(  
  d_se3$episodio,  
  d_se3$prob_estimada,  
  g = 10  
)  
  
print(hl)
```


Hosmer and Lemeshow goodness of fit (GOF) test

```
data: d_se3$episodio, d_se3$prob_estimada  
X-squared = 64.06, df = 8, p-value = 7.403e-11
```

Interpretación. Hosmer-Lemeshow resulta significativo, por lo que existen desviaciones entre algunas probabilidades estimadas y las frecuencias observadas. Esto no implica automáticamente que el modelo sea inútil, especialmente con decenas de miles de observaciones, pero sí indica que sus probabilidades no deben considerarse perfectamente calibradas.

Discriminación: ROC y AUC

```
roc_in <- roc(  
  d_se3$episodio,  
  d_se3$prob_estimada,  
  quiet = TRUE  
)  
  
plot(  
  roc_in,  
  main = "Curva ROC del modelo logístico"  
)
```



```
cat(
  "\nAUC en muestra:",
  round(as.numeric(auc(roc_in)), 3),
  "\n"
)
```

AUC en muestra: 0.783

Interpretación. El modelo simplificado presenta AUC de aproximadamente 0.783, una capacidad discriminante razonable. El valor es menor que el del modelo de 16 rumbos porque la agrupación ENE-E-ESE frente al resto elimina parte del detalle direccional.

PCA sobre la matriz química de SE3

```
mat_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  select(
    SO2, NO, NO2, NOX, CO, O3, PM10, `PM2.5`,
```



```

    sector_E, WSR, Hora, Mes, episodio
  )

completos <- mat_se3 %>%
  drop_na(S02:`PM2.5`)

cat("Filas SE3:", nrow(mat_se3), "\n")

```

Filas SE3: 33977

```

cat(
  "Casos completos:",
  nrow(completos),
  paste0(
    "(",
    round(100 * nrow(completos) / nrow(mat_se3), 1),
    "%)"
  ),
  "\n"
)

```

Casos completos: 27938 (82.2%)

```

cat(
  "Episodios conservados:",
  sum(completos$episodio),
  "de",
  sum(mat_se3$episodio),
  "\n\n"
)

```

Episodios conservados: 3304 de 3951

```

# Transformación logarítmica y estandarización
X <- completos %>%
  select(S02:`PM2.5`) %>%
  mutate(across(everything(), log1p))

pca <- prcomp(X, scale. = TRUE)

```

```

var_exp <- tibble(
  CP = paste0("PC", 1:8),
  Var_pct = round(
    100 * pca$sdev^2 / sum(pca$sdev^2),
    2
  ),
  Acum_pct = round(
    cumsum(100 * pca$sdev^2 / sum(pca$sdev^2)),
    2
  )
)

print(var_exp)

```

```

# A tibble: 8 x 3
  CP      Var_pct Acum_pct
  <chr>   <dbl>   <dbl>
1 PC1     48.6     48.6
2 PC2     19.4     68.0
3 PC3      9.69    77.7
4 PC4      9.21    86.9
5 PC5      6.36    93.3
6 PC6      3.69    97.0
7 PC7      2.97   100.0
8 PC8      0.05    100

```

```

cargas <- as_tibble(
  pca$rotation[, 1:3],
  rownames = "Variable"
) %>%
  mutate(
    across(
      where(is.numeric),
      ~ round(.x, 3)
    )
  )

print(cargas)

```

```

# A tibble: 8 x 4
  Variable    PC1    PC2    PC3


```

	<chr>	<dbl>	<dbl>	<dbl>
1	S02	0.029	0.604	-0.472
2	NO	-0.452	-0.141	-0.13
3	NO2	-0.437	-0.04	-0.337
4	NOX	-0.481	-0.089	-0.266
5	CO	-0.278	0.091	0.705
6	O3	0.319	0.458	-0.001
7	PM10	-0.351	0.367	0.228
8	PM2.5	-0.265	0.503	0.164

```
cat(
  "\nComponentes con eigenvalor > 1:",
  sum(pca$sdev^2 > 1),
  "\n"
)
```

Componentes con eigenvalor > 1: 2

```
fviz_eig(
  pca,
  addlabels = TRUE,
  barfill = "steelblue",
  main = "Varianza explicada por componente (SE3)"
)
```



Interpretación. De las 33,977 horas de SE3 se conservan 27,938 casos completos (82.2%) y 3,304 de 3,951 episodios (83.6%). La similitud de ambas proporciones indica que la eliminación de casos incompletos no excluye desproporcionadamente los episodios.

PC1 explica 48.6% de la variabilidad y está caracterizado principalmente por NOX, NO, NO2, PM10 y CO. SO_2 tiene una carga prácticamente nula en PC1. PC2 explica 19.4% adicional y SO_2 presenta ahí su carga de mayor magnitud. Los primeros cuatro componentes acumulan 86.9% de la variabilidad.

Hallazgo principal. SO_2 no sigue completamente el principal patrón de covariación química de los demás contaminantes; su contribución se concentra en un componente diferente.

Conglomerados sobre el espacio de componentes

```
scores <- as_tibble(
  pca$x[, 1:4]
)

set.seed(2024)

muestra <- scores[
  sample(nrow(scores), 4000),
```

```

]

sil <- map_dfr(
  2:6,
  function(k) {
    km_sil <- kmeans(
      muestra,
      centers = k,
      nstart = 20
    )

    tibble(
      k = k,
      silueta = round(
        mean(
          silhouette(
            km_sil$cluster,
            dist(muestra)
          )[, 3]
        ),
        3
      )
    )
  }
)

print(sil)

```

```

# A tibble: 5 x 2
      k silueta
  <int>   <dbl>
1     2  0.418
2     3  0.262
3     4  0.264
4     5  0.255
5     6  0.239

```

```

# Se conserva k = 4 por interpretación exploratoria.
# La silueta favorece k = 2, por lo que k = 4 no se presenta
# como la solución geométricamente óptima.
set.seed(2024)

```

```

km <- kmeans(
  scores,
  centers = 4,
  nstart = 25,
  iter.max = 50
)

cat(
  "Iteraciones usadas:",
  km$iter,
  "de 50\n"
)

```

Iteraciones usadas: 5 de 50

```

cat(
  "Varianza explicada por la partición:",
  round(
    100 * km$betweenss / km$totss,
    1
  ),
  "%\n\n"
)

```

Varianza explicada por la partición: 58.3 %

```

perfil <- completos %>%
  mutate(
    grupo = factor(km$cluster)
  ) %>%
  group_by(grupo) %>%
  summarise(
    n = n(),
    pct = round(
      100 * n() / nrow(completos),
      1
    ),
    SO2_med = round(median(SO2), 2),
    NOX_med = round(median(NOX), 2),
    CO_med = round(median(CO), 2),

```

```

PM25_med = round(median(`PM2.5`), 1),
O3_med = round(median(O3), 1),
WSR_med = round(median(WSR), 1),
pct_Este = round(
  100 * mean(sector_E == "Este"),
  1
),
pct_episod = round(
  100 * mean(episodio),
  1
),
.groups = "drop"
) %>%
arrange(desc(SO2_med))

print(perfil, width = Inf)

```

A tibble: 4 x 11

	grupo	n	pct	SO2_med	NOX_med	CO_med	PM25_med	O3_med	WSR_med	pct_Este
	<fct>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	1	4111	14.7	16.2	10.4	1.36	22	43	8.5	50.5
2	2	3352	12	4.4	51.8	1.94	28	5	3.6	6.2
3	3	7823	28	4.2	17.7	1.49	15	17	5.8	25.4
4	4	12652	45.3	4.1	8.1	1.11	9	26	8.5	42.7

	pct_episod
	<dbl>
1	72.2
2	1.4
3	0.9
4	1.7

```

perfil_razon <- perfil %>%
  mutate(
    razon_SO2_NOX = round(
      SO2_med / NOX_med,
      3
    )
  ) %>%
  select(
    grupo,
    SO2_med,

```

```

    NOX_med,
    razon_SO2_NOX,
    pct_Este,
    pct_episod
  )
print(perfil_razon)

```

```

# A tibble: 4 x 6
  grupo SO2_med NOX_med razon_SO2_NOX pct_Este pct_episod
  <fct>   <dbl>   <dbl>         <dbl>   <dbl>     <dbl>
1 1      16.2    10.4          1.56    50.5      72.2
2 2       4.4    51.8          0.085    6.2       1.4
3 3       4.2    17.7          0.237   25.4       0.9
4 4       4.1     8.1          0.506   42.7       1.7

```

Interpretación. La silueta alcanza su mayor valor con $k = 2$, por lo que dos grupos producen la separación geométrica más clara. Se conserva $k = 4$ únicamente como una decisión exploratoria orientada a describir perfiles químicos más detallados; no se afirma que sea el número óptimo de conglomerados.

El grupo con mayor mediana de SO_2 también presenta una elevada proporción de observaciones bajo sector oriental y una elevada proporción de episodios dentro del propio grupo. Esta proporción debe interpretarse como **porcentaje de observaciones del grupo que son episodios**, no como porcentaje de todos los episodios de la base contenidos en ese grupo.

El clustering identifica perfiles estadísticos y no atribuye por sí solo cada grupo a una fuente física.

Comparación anual de niveles típicos y episodios

```

kw <- datos %>%
  group_split(Año) %>%
  map_dfr(
    function(d) {
      t <- kruskal.test(
        SO2 ~ Estacion,
        data = d
      )
    }
  )

```



```

    tibble(
      Año = unique(d$Año),
      chi2 = round(t$statistic, 1),
      gl = t$parameter,
      p = t$p.value
    )
  }
)

print(
  kw %>%
  mutate(
    p_formateado = if_else(
      p < 0.001,
      "<0.001",
      format(round(p, 3), nsmall = 3)
    )
  ) %>%
  select(-p)
)

```

```

# A tibble: 4 x 4
  Año   chi2   gl p_formateado
<dbl> <dbl> <int> <chr>
1  2022  3878.     3 <0.001
2  2023 10338     3 <0.001
3  2024  3799.     3 <0.001
4  2025  1455.     3 <0.001

```

```

h1 <- datos %>%
  filter(
    Estacion %in% c("SE3", "GAR")
  ) %>%
  group_split(Año) %>%
  map_dfr(
    function(d) {

      w <- wilcox.test(
        S02 ~ Estacion,
        data = d,
        conf.int = TRUE,

```

```

    exact = FALSE
  )

  tibble(
    Año = unique(d$Año),
    Med_SE3 = median(
      d$S02[d$Estacion == "SE3"]
    ),
    Med_GAR = median(
      d$S02[d$Estacion == "GAR"]
    ),
    Dif_HL = round(w$estimate, 2),
    IC_inf = round(w$conf.int[1], 2),
    IC_sup = round(w$conf.int[2], 2),
    p = w$p.value
  )
}
)

print(hl)

```

```

# A tibble: 4 x 7
  Año Med_SE3 Med_GAR Dif_HL IC_inf IC_sup      p
  <dbl>   <dbl>   <dbl>   <dbl>   <dbl>   <dbl>   <dbl>
1  2022     4.8     3.4     1.3     1.3     1.4  0
2  2023     3.9     2.4     1.5     1.5     1.5  0
3  2024     4.1      3      1      1      1  0
4  2025     4.7     4.4     0.6     0.5     0.6 5.44e-207

```

```

horas <- datos %>%
  group_by(Año, Estacion) %>%
  summarise(
    horas_episodio = sum(episodio),
    .groups = "drop"
  ) %>%
  pivot_wider(
    names_from = Estacion,
    values_from = horas_episodio
  ) %>%
  mutate(
    Exceso_SE3_vs_GAR = SE3 - GAR
  )

```

```
)

print(horas)

# A tibble: 4 x 6
  Año    SE3    SE2    NE    GAR Exceso_SE3_vs_GAR
  <dbl> <int> <int> <int> <int>          <int>
1  2022  1245   518   278    10           1235
2  2023   689   307   120    20           669
3  2024   845   397   122    10           835
4  2025  1172   619   226     9          1163
```

```
indicador_horas <- horas %>%
  summarise(
    exceso_total = sum(Exceso_SE3_vs_GAR),
    exceso_anual = round(
      mean(Exceso_SE3_vs_GAR)
    ),
    dias_equiv_anual = round(
      mean(Exceso_SE3_vs_GAR) / 24,
      1
    )
  )

print(indicador_horas)
```

```
# A tibble: 1 x 3
  exceso_total exceso_anual dias_equiv_anual
      <int>         <dbl>         <dbl>
1      3902           976           40.6
```

Interpretación. Kruskal-Wallis muestra diferencias globales entre las distribuciones de SO_2 de las cuatro estaciones en todos los años. El estimador de Hodges-Lehmann cuantifica el desplazamiento típico entre SE3 y GAR y muestra que este contraste disminuye hacia 2025.

Sin embargo, las horas por encima del umbral absoluto de 11.1 ppb cuentan una historia diferente: SE3 mantiene una cantidad elevada de episodios aun cuando el desplazamiento típico frente a GAR disminuye.

Las 3,902 horas adicionales de episodio observadas en SE3 respecto a GAR durante 2022–2025 representan una **diferencia observacional entre estaciones**. No deben interpretarse como horas causalmente atribuibles a una fuente ni como horas necesariamente evitables.

Sensibilidad al umbral

```
sens <- map_dfr(  
  c(0.90, 0.95, 0.99),  
  function(q) {  
  
    u <- quantile(  
      datos$S02,  
      q,  
      na.rm = TRUE  
    )  
  
    map_dfr(  
      c("SE3", "SE2", "NE", "GAR"),  
      function(e) {  
  
        d <- datos %>%  
          filter(Estacion == e) %>%  
          mutate(  
            y = as.integer(S02 > u)  
          )  
  
        if (sum(d$y) < 30) {  
          return(  
            tibble(  
              Estacion = e,  
              OR = NA,  
              IC_inf = NA,  
              IC_sup = NA  
            )  
          )  
        }  
  
        m <- glm(  
          y ~  
            sector_E +  
            ns(WSR, 3) +  
            Hora_sin + Hora_cos +  
            Mes_sin + Mes_cos,  
          data = d,  
          family = binomial  
        )  
      }  
    )  
  }  
)
```

```

)

co <- tidy(m) %>%
  filter(
    term == "sector_EEste"
  )

tibble(
  Estacion = e,
  OR = round(exp(co$estimate), 2),
  IC_inf = round(
    exp(co$estimate - 1.96 * co$std.error),
    2
  ),
  IC_sup = round(
    exp(co$estimate + 1.96 * co$std.error),
    2
  )
)
}
) %>%
mutate(
  Percentil = paste0("P", q * 100),
  umbral_ppb = round(u, 1),
  .before = 1
)
}
)

print(sens, n = 12)

```

A tibble: 12 x 6

	Percentil <chr>	umbral_ppb <dbl>	Estacion <chr>	OR <dbl>	IC_inf <dbl>	IC_sup <dbl>
1	P90	7.2	SE3	3.38	3.17	3.6
2	P90	7.2	SE2	1.43	1.33	1.53
3	P90	7.2	NE	1	0.89	1.13
4	P90	7.2	GAR	1.4	1.08	1.83
5	P95	11.1	SE3	3.19	2.96	3.44
6	P95	11.1	SE2	1.58	1.43	1.74
7	P95	11.1	NE	1.01	0.81	1.26
8	P95	11.1	GAR	1.08	0.54	2.16

9	P99	30.6	SE3	2.57	2.25	2.93
10	P99	30.6	SE2	1.75	1.37	2.24
11	P99	30.6	NE	0.86	0.3	2.5
12	P99	30.6	GAR	NA	NA	NA

Interpretación. La asociación del sector oriental en SE3 permanece claramente por encima de uno con P90, P95 y P99, lo que indica que el patrón no depende exclusivamente de haber escogido P95. En SE2 también se conserva una asociación positiva. NE permanece cercana a ausencia de asociación y GAR presenta mayor incertidumbre debido a la baja frecuencia de concentraciones extremas.

Diferencia entre tendencia central y frecuencia de episodios

```
comp <- hl %>%
  select(Año, Dif_HL) %>%
  left_join(
    select(
      horas,
      Año,
      Horas_SE3 = SE3
    ),
    by = "Año"
  )


coef_eje <- max(comp$Horas_SE3) /
  max(comp$Dif_HL)

ggplot(
  comp,
  aes(x = Año)
) +
  geom_col(
    aes(y = Horas_SE3),
    fill = "grey70"
  ) +
  geom_line(
    aes(y = Dif_HL * coef_eje),
    colour = "firebrick",
    linewidth = 1.2
  ) +
```

```

geom_point(
  aes(y = Dif_HL * coef_eje),
  colour = "firebrick",
  size = 3
) +
scale_y_continuous(
  name = "Horas de episodio en SE3",
  sec.axis = sec_axis(
    ~ . / coef_eje,
    name = "Desplazamiento Hodges-Lehmann SE3-GAR (ppb)"
  )
) +
scale_x_continuous(
  breaks = 2022:2025
) +
labs(
  title = "Los niveles típicos y los episodios describen fenómenos distintos",
  subtitle = "SE3, umbral absoluto de episodio: 11.1 ppb",
  x = "Año"
) +
theme_minimal(base_size = 12)

```



Interpretación. La evolución del desplazamiento típico SE3-GAR no reproduce la evolución

de las horas de episodio. Por ello, las medidas de tendencia central deben complementarse con métricas específicas de la parte alta de la distribución.

Contexto geográfico y gradiente espacial

```
geo <- tribble(
  ~Estacion, ~lat, ~lon, ~azimut, ~rumbo, ~dist_km,
  "SE3", 25.5844, -100.0011, 87.3, "E", 5.5,
  "SE2", 25.6461, -100.0956, 113.7, "ESE", 16.4,
  "NE", 25.7455, -100.2552, 119.6, "ESE", 35.7,
  "GAR", 25.7997, -100.5878, 110.1, "ESE", 68.5
)

# Resultados de modelos separados por estación usando el
# MISMO umbral absoluto de 11.1 ppb.
or_p95 <- tibble(
  Estacion = c("SE3", "SE2", "NE", "GAR"),
  OR = c(3.19, 1.58, 1.01, 1.08),
  IC_inf = c(2.96, 1.43, 0.81, 0.54),
  IC_sup = c(3.44, 1.74, 1.26, 2.16)
)

left_join(
  geo,
  or_p95,
  by = "Estacion"
) %>%
  ggplot(
    aes(
      x = dist_km,
      y = OR
    )
  ) +
  geom_hline(
    yintercept = 1,
    linetype = "dashed",
    colour = "grey40"
  ) +
  geom_errorbar(
    aes(
```




```

    ymin = IC_inf,
    ymax = IC_sup
  ),
  width = 1.5
) +
geom_point(
  size = 3,
  colour = "firebrick"
) +
geom_text(
  aes(label = Estacion),
  vjust = -1.2,
  size = 3.5
) +
labs(
  title = "La asociación direccional se atenúa con la distancia",
  subtitle = "Sector oriental (ENE-E-ESE), umbral absoluto de SO2 = 11.1 ppb",
  x = "Distancia al complejo de referencia (km)",
  y = "Razón de momios (IC 95%)"
) +
theme_minimal(base_size = 12)

```

La asociación direccional se atenúa con la distancia

Sector oriental (ENE-E-ESE), umbral absoluto de SO2 = 11.1 ppb



Interpretación. El complejo de referencia se localiza hacia E/ESE desde las cuatro esta-

ciones. El OR es mayor en SE3, menor en SE2 y se aproxima a ausencia de asociación en NE y GAR. El patrón es consistente con una atenuación espacial de la señal direccional, aunque no es estrictamente monótono y no constituye por sí mismo evidencia causal de una fuente específica.

Robustez y generalización del modelo simplificado de SE3

```
d_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  mutate(
    dia = as.Date(fecha)
  )

mod <- glm(
  episodio ~
    sector_E +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_se3,
  family = binomial
)

# Errores estándar robustos agrupados por día
rob <- coeftest(
  mod,
  vcov = vcovCL(
    mod,
    cluster = ~ dia
  )
)

b <- rob[
  "sector_EEste",
  "Estimate"
]

se <- rob[
  "sector_EEste",
  "Std. Error"
```

```
]
cat("=== OR sector oriental en SE3 ===\n")
```

```
=== OR sector oriental en SE3 ===
```

```
cat(
  "Convencional:",
  round(
    exp(coef(mod)["sector_EEste"]),
    2
  ),
  "\n"
)
```

```
Convencional: 3.19
```

```
cat(
  "Robusto agrupado por día:",
  round(exp(b), 2),
  " IC95: [",
  round(exp(b - 1.96 * se), 2),
  ", ",
  round(exp(b + 1.96 * se), 2),
  "]\n\n"
)
```

```
Robusto agrupado por día: 3.19 IC95: [ 2.92 , 3.48 ]
```

```
auc_in <- roc(
  d_se3$episodio,
  fitted(mod),
  quiet = TRUE
)

cat(
  "AUC en muestra:",
  round(
    as.numeric(auc_in$auc),
    3
  )
)
```

```
),  
  "\n"  
)
```

AUC en muestra: 0.783

```
# Validación temporal: 2022-2024 -> 2025  
tr <- filter(  
  d_se3,  
  Año <= 2024  
)  
  
te <- filter(  
  d_se3,  
  Año == 2025  
)  
  
m_tr <- glm(  
  episodio ~  
    sector_E +  
    ns(WSR, 3) +  
    Hora_sin + Hora_cos +  
    Mes_sin + Mes_cos,  
  data = tr,  
  family = binomial  
)  
  
p_te <- predict(  
  m_tr,  
  newdata = te,  
  type = "response"  
)  
  
cat(  
  "AUC fuera de muestra (2025):",  
  round(  
    as.numeric(  
      roc(  
        te$episodio,  
        p_te,  
        quiet = TRUE  
      )$auc  
    )  
  )  
)
```

```

    ),
    3
  ),
  "\n"
)

```

AUC fuera de muestra (2025): 0.764

```

cat(
  "Error Brier:",
  round(
    mean(
      (p_te - te$episodio)^2
    ),
    4
  ),
  "\n"
)

```

Error Brier: 0.1065

```

cat(
  "Tasa base 2025:",
  round(
    mean(te$episodio),
    4
  ),
  "\n\n"
)

```

Tasa base 2025: 0.1371

```

# Matriz de confusión con corte exploratorio = tasa base
corte <- mean(tr$episodio)

tab <- table(
  Predicho = p_te > corte,
  Real = te$episodio
)

print(tab)

```

	Real	
Predicho	0	1
FALSE	5025	337
TRUE	2354	835

```
cat(
  "\nSensibilidad:",
  round(
    tab[2, 2] / sum(tab[, 2]),
    3
  ),
  "| Especificidad:",
  round(
    tab[1, 1] / sum(tab[, 1]),
    3
  ),
  "\n\n"
)
```

Sensibilidad: 0.712 | Especificidad: 0.681

```
# Adecuación para PCA
cat("=== Adecuación de la matriz para PCA ===\n")
```

=== Adecuación de la matriz para PCA ===

```
cat(
  "KMO global:",
  round(KMO(X)$MSA, 3),
  "\n"
)
```

KMO global: 0.623

```
bt <- cortest.bartlett(
  cor(X),
  n = nrow(X)
)
```

```
cat(
  "Bartlett: chi2 =",
  round(bt$chisq, 0),
  " p < 0.001\n"
)
```

Bartlett: chi2 = 213445 p < 0.001

Interpretación. El OR principal de SE3 se mantiene prácticamente igual al utilizar errores estándar robustos agrupados por día. Esto fortalece la robustez de la inferencia ante dependencia intradía, pero **no demuestra ausencia de autocorrelación temporal**.

La validación 2022–2024 frente a 2025 muestra que la capacidad discriminante se conserva razonablemente fuera de muestra. El punto de corte usado para la matriz de confusión es exploratorio y no constituye un umbral de alerta validado.

Para PCA, KMO indica adecuación moderada y Bartlett rechaza claramente una matriz de correlaciones identidad.

CBPF

```
d_oa <- datos %>%
  rename(
    date = fecha,
    ws = WSR,
    wd = WDR
  )

# Percentil exacto que corresponde al umbral absoluto de 11.1 ppb
# dentro de cada estación.
pct_eq <- datos %>%
  group_by(Estacion) %>%
  summarise(
    p = 100 * mean(
      S02 <= umbral_ep,
      na.rm = TRUE
    ),
    .groups = "drop"
  )
```

```
print(
  pct_eq %>%
    mutate(
      p = round(p, 2)
    )
)
```


```
# A tibble: 4 x 2
  Estacion      p
  <fct>      <dbl>
1 SE3        88.4
2 SE2        94.5
3 NE         97.8
4 GAR        99.8
```

```
# CBPF de S02
for (e in c("SE3", "SE2", "NE")) {

  p <- pct_eq$p[
    pct_eq$Estacion == e
  ]

  polarPlot(
    filter(
      d_oa,
      Estacion == e
    ),
    pollutant = "S02",
    statistic = "cpf",
    percentile = p,
    main = paste0(
      "CBPF de S02 en ",
      e,
      " (umbral 11.1 ppb)"
    ),
    key.title = "Probabilidad"
  )
}
```



CBPF de SO₂ en SE3 (umbral 11.1 ppb)



Radial axis shows wind spd.

CPF at the 88.3715454572211th percentile (=11)


CBPF de SO₂ en SE2 (umbral 11.1 ppb)



Radial axis shows wind spd.

CPF at the 94.4614921780987th percentile (=11)

CBPF de SO₂ en NE (umbral 11.1 ppb)




Radial axis shows wind spd.

CPF at the 97.7519963839084th percentile (=11)

```
# Contraste visual de NOX en SE3:  
# se usa el mismo percentil relativo empleado en SO2-SE3.  
polarPlot(  
  filter(  
    d_oa,  
    Estacion == "SE3"  
  ),  
  pollutant = "NOX",  
  statistic = "cpf",  
  percentile = pct_eq$p[  
    pct_eq$Estacion == "SE3"  
  ],  
  main = "CBPF de NOX en SE3 (mismo percentil relativo que SO2)",  
  key.title = "Probabilidad"  
)
```

CBPF de NO_x en SE3 (mismo percentil relativo que SO_2)



Interpretación. La CBPF representa la probabilidad condicional de concentraciones elevadas en función conjunta de dirección y velocidad del viento. En SE3 reproduce una zona de mayor probabilidad asociada al sector oriental. En SE2 la señal es menor y en NE es menos marcada.

GAR se omite porque 11.1 ppb corresponde a una parte extremadamente alta de su distribución y existen muy pocas observaciones por encima de ese nivel para estimar una superficie estable.

El CBPF de NO_x en SE3 utiliza el mismo **percentil relativo** empleado para SO_2 en SE3; no representa el mismo umbral de concentración. Su patrón es diferente al de SO_2 .

Hallazgo principal. La CBPF aporta una verificación visual mediante un procedimiento distinto a la regresión logística y reproduce el patrón direccional general. No demuestra por sí sola la fuente causal.

Guardado de objetos

```
saveRDS(  
  list(  
    datos = datos,  
    pca = pca,
```

```

    km = km,
    completos = completos,
    hl = hl,
    horas = horas,
    sens = sens,
    geo = geo,
    or_sector = or_sector,
    tasa_sector_SE3 = tasa_sector_SE3,
    or_p95 = or_p95
  ),
  "objetos_entrega_final.rds"
)

names(
  readRDS(
    "objetos_entrega_final.rds"
  )
)

```

```

[1] "datos"          "pca"             "km"              "completos"
[5] "hl"             "horas"           "sens"            "geo"
[9] "or_sector"      "tasa_sector_SE3" "or_p95"

```

Interpretación. Este bloque no realiza un análisis estadístico nuevo. Guarda los objetos principales para facilitar la reproducibilidad y reutilización de resultados.

Escenario meteorológico hipotético

Este ejercicio es únicamente ilustrativo. No utiliza un pronóstico meteorológico real y no constituye un sistema de alerta validado.

```

mes_escenario <- 9

pronostico_manana <- tibble(
  Hora = 0:23,
  Mes = rep(
    mes_escenario,
    24
  ),
  WSR = c(

```

```

    rep(3.0, 10),
    rep(6.5, 8),
    rep(3.0, 6)
  ),
  WDR = c(
    rep(180, 10),
    rep(95, 8),
    rep(180, 6)
  )
)

rumbos_ref <- c(
  "N", "NNE", "NE", "ENE", "E", "ESE", "SE", "SSE",
  "S", "SSO", "SO", "OSO", "O", "ONO", "NO", "NNO"
)

pronostico_predictivo <- pronostico_manana %>%
  mutate(
    Hora_sin = sin(2 * pi * Hora / 24),
    Hora_cos = cos(2 * pi * Hora / 24),
    Mes_sin = sin(2 * pi * Mes / 12),
    Mes_cos = cos(2 * pi * Mes / 12),

    sector = rumbos_ref[
      ((floor((WDR + 11.25) / 22.5)) %% 16) + 1
    ],

    sector_E = factor(
      if_else(
        sector %in% c("ENE", "E", "ESE"),
        "Este",
        "Resto"
      ),
      levels = c("Resto", "Este")
    )
  )

tasa_base <- mean(
  d_se3$episodio
)

pronostico_predictivo <- pronostico_predictivo %>%

```

```

mutate(
  prob_episodio = predict(
    mod,
    newdata = pronostico_predictivo,
    type = "response"
  ),

  comparacion_base = if_else(
    prob_episodio > tasa_base,
    "Probabilidad superior a la tasa base",
    "Probabilidad no superior a la tasa base"
  )
)

cat(
  "\n=== ESCENARIO HIPOTÉTICO DE 24 HORAS ===\n"
)

```

=== ESCENARIO HIPOTÉTICO DE 24 HORAS ===

```

pronostico_predictivo %>%
  select(
    Hora,
    Viento_Velocidad = WSR,
    Rumbo = sector,
    Probabilidad = prob_episodio,
    Estado = comparacion_base
  ) %>%
  mutate(
    Probabilidad = paste0(
      round(Probabilidad * 100, 1),
      "%"
    )
  ) %>%
  print(n = 24)

```

A tibble: 24 x 5

	Hora	Viento_Velocidad	Rumbo	Probabilidad	Estado
	<int>	<dbl>	<chr>	<chr>	<chr>
1	0	3	S	1.2%	Probabilidad no superior a la tasa~

2	1	3	S	1%	Probabilidad no superior a la tasa~
3	2	3	S	1%	Probabilidad no superior a la tasa~
4	3	3	S	1%	Probabilidad no superior a la tasa~
5	4	3	S	1.2%	Probabilidad no superior a la tasa~
6	5	3	S	1.6%	Probabilidad no superior a la tasa~
7	6	3	S	2.1%	Probabilidad no superior a la tasa~
8	7	3	S	3%	Probabilidad no superior a la tasa~
9	8	3	S	4.3%	Probabilidad no superior a la tasa~
10	9	3	S	6.2%	Probabilidad no superior a la tasa~
11	10	6.5	E	28.9%	Probabilidad superior a la tasa ba~
12	11	6.5	E	35.4%	Probabilidad superior a la tasa ba~
13	12	6.5	E	40.7%	Probabilidad superior a la tasa ba~
14	13	6.5	E	44.1%	Probabilidad superior a la tasa ba~
15	14	6.5	E	45.1%	Probabilidad superior a la tasa ba~
16	15	6.5	E	43.7%	Probabilidad superior a la tasa ba~
17	16	6.5	E	39.9%	Probabilidad superior a la tasa ba~
18	17	6.5	E	34.2%	Probabilidad superior a la tasa ba~
19	18	3	S	8.1%	Probabilidad no superior a la tasa~
20	19	3	S	5.8%	Probabilidad no superior a la tasa~
21	20	3	S	4%	Probabilidad no superior a la tasa~
22	21	3	S	2.8%	Probabilidad no superior a la tasa~
23	22	3	S	2%	Probabilidad no superior a la tasa~
24	23	3	S	1.5%	Probabilidad no superior a la tasa~

Interpretación. El bloque ilustra cómo el modelo transforma combinaciones hipotéticas de dirección, velocidad, hora y mes en probabilidades estimadas de episodio. Como dirección y velocidad cambian simultáneamente, las diferencias entre periodos no deben atribuirse exclusivamente a la dirección. La comparación con la tasa base tiene un propósito demostrativo y no es un umbral regulatorio ni operativo.

Probabilidades ajustadas por las 16 direcciones en SE3

```

rumbos_modelo <- levels(
  model.frame(mod_se3)$sector
)

base_prob <- d_se3 %>%
  select(
    WSR,
    Hora_sin,

```

```

    Hora_cos,
    Mes_sin,
    Mes_cos
  ) %>%
  drop_na()

beta_16 <- coef(mod_se3)
V_16 <- vcov(mod_se3)

tt_16 <- delete.response(
  terms(mod_se3)
)

prob_direccion <- map_dfr(
  rumbos_modelo,
  function(r) {

    nuevo <- base_prob %>%
      mutate(
        sector = factor(
          r,
          levels = rumbos_modelo
        )
      )

    X_16 <- model.matrix(
      tt_16,
      data = nuevo
    )

    X_16 <- X_16[
      ,
      names(beta_16),
      drop = FALSE
    ]

    eta <- as.vector(
      X_16 %*% beta_16
    )

    p <- plogis(eta)
  }
)

```



```

prob_media <- mean(p)

gradiente <- colMeans(
  sweep(
    X_16,
    1,
    p * (1 - p),
    "*"
  )
)

se_prob <- sqrt(
  as.numeric(
    t(gradiente) %*%
    V_16 %*%
    gradiente
  )
)

tibble(
  Rumbo = r,
  Prob_ajustada = prob_media,
  IC_inf = max(
    0,
    prob_media - 1.96 * se_prob
  ),
  IC_sup = min(
    1,
    prob_media + 1.96 * se_prob
  )
)
}
)

prob_direccion <- prob_direccion %>%
  mutate(
    Prob_pct = round(
      100 * Prob_ajustada,
      2
    ),
    IC_inf_pct = round(
      100 * IC_inf,

```

```

      2
    ),
    IC_sup_pct = round(
      100 * IC_sup,
      2
    )
  )
)

print(
  prob_direccion %>%
    select(
      Rumbo,
      Prob_pct,
      IC_inf_pct,
      IC_sup_pct
    ),
  n = 16
)

```

```

# A tibble: 16 x 4
  Rumbo Prob_pct IC_inf_pct IC_sup_pct
<chr>   <dbl>   <dbl>   <dbl>
1 N       7.69     6.07     9.32
2 NNE     8.09     6.34     9.83
3 NE      8.21     6.83     9.59
4 ENE    13.6     12.2    15.0
5 E      29.4     28.0    30.8
6 ESE    16.6     15.6    17.5
7 SE     10.9     10.2    11.6
8 SSE    11.0     9.96    12.1
9 S       8.59     7.06    10.1
10 SSO     6.18     4.29     8.08
11 SO      6.53     4.36     8.69
12 OSO     4.45     2.62     6.27
13 O       2.04     0.91     3.17
14 ONO     2.15     1.27     3.03
15 NO      0.68     0.35     1.01
16 NNO     1.98     1.35     2.61

```

```


ggplot(
  prob_direccion,
  aes(

```

```

x = factor(
  Rumbo,
  levels = rumbos_modelo
),
y = Prob_pct
)
) +
geom_col() +
geom_errorbar(
  aes(
    ymin = IC_inf_pct,
    ymax = IC_sup_pct
  ),
  width = 0.25
) +
labs(
  title = "Probabilidad ajustada de episodio de SO2 según la dirección del viento",
  subtitle = "SE3 | Ajustada por velocidad del viento, hora y mes",
  x = "Dirección de procedencia del viento",
  y = "Probabilidad ajustada de episodio (%)"
) +
theme_minimal(base_size = 12)

```



Interpretación. Las probabilidades ajustadas muestran un patrón direccional definido en SE3. Para cada rumbo se mantienen las condiciones observadas de velocidad, hora y mes y se modifica únicamente la dirección. Posteriormente se promedian las probabilidades estimadas.

El Este presenta la mayor probabilidad ajustada, 29.4% (IC95%: 28.0%–30.8%), seguido por ESE con 16.6% y ENE con 13.6%. Norte presenta 7.69%. En contraste, varias direcciones occidentales presentan probabilidades considerablemente menores.

Estas probabilidades son estimaciones marginales derivadas del modelo y no corresponden a frecuencias crudas ni a un pronóstico meteorológico futuro.

Probabilidades ajustadas por estación y sector oriental

Esta sección reemplaza la versión anterior del modelo conjunto. La corrección principal consiste en **permitir que la relación de WSR, hora y mes cambie por estación**, en lugar de obligar a que dichos controles tengan exactamente el mismo efecto en SE3, SE2, NE y GAR.

```
d_conjunto <- datos %>%
  select(
    episodio,
    Estacion,
    sector_E,
    WSR,
    Hora_sin,
    Hora_cos,
    Mes_sin,
    Mes_cos
  ) %>%
  drop_na() %>%
  mutate(
    Estacion = factor(
      Estacion,
      levels = c(
        "SE3",
        "SE2",
        "NE",
        "GAR"
      )
    ),
    sector_E = factor(
      sector_E,
```

```

    levels = c(
      "Resto",
      "Este"
    )
  )
)

```

Comprobación de la estructura del modelo conjunto

```

# Modelo con interacción Estación × sector,
# pero controles meteorológicos/temporales comunes.
mod_conjunto_comun <- glm(
  episodio ~
    Estacion * sector_E +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_conjunto,
  family = binomial
)

# Modelo flexible:
# permite que sector, WSR, hora y mes cambien por estación.
mod_conjunto_flexible <- glm(
  episodio ~
    Estacion * (
      sector_E +
      ns(WSR, 3) +
      Hora_sin + Hora_cos +
      Mes_sin + Mes_cos
    ),
  data = d_conjunto,
  family = binomial
)

cat(
  "=== CONTROLES COMUNES VS CONTROLES ESPECÍFICOS POR ESTACIÓN ===\n"
)

```

=== CONTROLES COMUNES VS CONTROLES ESPECÍFICOS POR ESTACIÓN ===

```
prueba_flexibilidad <- anova(
  mod_conjunto_comun,
  mod_conjunto_flexible,
  test = "Chisq"
)

print(prueba_flexibilidad)
```

Analysis of Deviance Table

```
Model 1: episodio ~ Estacion * sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
  Mes_sin + Mes_cos
Model 2: episodio ~ Estacion * (sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
  Mes_sin + Mes_cos)
Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1      132921      40537
2      132900      40105 21    432.54 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
comparacion_flexibilidad <- tibble(
  Modelo = c(
    "Controles comunes",
    "Controles específicos por estación"
  ),
  AIC = c(
    AIC(mod_conjunto_comun),
    AIC(mod_conjunto_flexible)
  ),
  BIC = c(
    BIC(mod_conjunto_comun),
    BIC(mod_conjunto_flexible)
  )
)

print(comparacion_flexibilidad)
```

```
# A tibble: 2 x 3
  Modelo                AIC    BIC
  <chr>          <dbl> <dbl>
1 Controles comunes 40567. 40714.
```

2 Controles específicos por estación 40177. 40530.

Interpretación. El modelo flexible presenta menores AIC y BIC que la versión con controles comunes. Esto indica que es preferible permitir que la relación de la velocidad del viento, la hora y el mes varíe entre estaciones. Por esta razón, las probabilidades espaciales definitivas se calculan a partir de `mod_conjunto_flexible`.

¿La asociación del sector oriental cambia entre estaciones después de permitir controles específicos?

```
# Modelo flexible, pero SIN interacción Estacion × sector_E.  
# Mantiene controles específicos de WSR/hora/mes por estación.  
mod_flexible_sin_interaccion_sector <- glm(  
  episodio ~  
    Estacion * (  
      ns(WSR, 3) +  
      Hora_sin + Hora_cos +  
      Mes_sin + Mes_cos  
    ) +  
    sector_E,  
  data = d_conjunto,  
  family = binomial  
)  
  
cat(  
  "=== PRUEBA DE INTERACCIÓN ESTACIÓN × SECTOR ORIENTAL ===\n"  
)
```

=== PRUEBA DE INTERACCIÓN ESTACIÓN × SECTOR ORIENTAL ===

```
prueba_interaccion_flexible <- anova(  
  mod_flexible_sin_interaccion_sector,  
  mod_conjunto_flexible,  
  test = "Chisq"  
)  
  
print(  
  prueba_interaccion_flexible  
)
```

Analysis of Deviance Table

Model 1: episodio ~ Estacion * (ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos) + sector_E

Model 2: episodio ~ Estacion * (sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos)

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	132903	40301			
2	132900	40105	3	195.77	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
comparacion_interaccion_flexible <- tibble(
  Modelo = c(
    "Sin interacción Estación × sector",
    "Con interacción Estación × sector"
  ),
  AIC = c(
    AIC(
      mod_flexible_sin_interaccion_sector
    ),
    AIC(
      mod_conjunto_flexible
    )
  ),
  BIC = c(
    BIC(
      mod_flexible_sin_interaccion_sector
    ),
    BIC(
      mod_conjunto_flexible
    )
  )
)

print(
  comparacion_interaccion_flexible
)
```

A tibble: 2 x 3

Modelo	AIC	BIC
<chr>	<dbl>	<dbl>

- 1 Sin interacción Estación × sector 40367. 40690.
- 2 Con interacción Estación × sector 40177. 40530.

Interpretación. Esta es la prueba global que debe utilizarse para respaldar la interacción `Estacion × sector_E` en la especificación final. Compara dos modelos que ya permiten controles meteorológicos y temporales específicos por estación; la única diferencia es si el contraste sector oriental–resto puede cambiar entre estaciones.

Si la prueba de razón de verosimilitudes resulta significativa y AIC/BIC favorecen al modelo con interacción, queda justificado estimar un contraste Este–Resto diferente para cada estación.

Probabilidades marginales ajustadas con el modelo flexible

```
# Se utiliza una distribución común de WSR, hora y mes
# para estandarizar la comparación entre estaciones.
base_comun <- d_conjunto %>%
  select(
    WSR,
    Hora_sin,
    Hora_cos,
    Mes_sin,
    Mes_cos
  )

beta_flex <- coef(
  mod_conjunto_flexible
)

V_flex <- vcov(
  mod_conjunto_flexible
)

tt_flex <- delete.response(
  terms(mod_conjunto_flexible)
)

combinaciones <- expand_grid(
  Estacion = c(
    "SE3",
    "SE2",
```

```

    "NE",
    "GAR"
  ),
  sector_E = c(
    "Resto",
    "Este"
  )
)

prob_estacion <- map2_dfr(
  combinaciones$Estacion,
  combinaciones$sector_E,
  function(est, sec) {

    nuevo <- base_comun %>%
      mutate(
        Estacion = factor(
          est,
          levels = c(
            "SE3",
            "SE2",
            "NE",
            "GAR"
          )
        ),
        sector_E = factor(
          sec,
          levels = c(
            "Resto",
            "Este"
          )
        )
      )

    X_flex <- model.matrix(
      tt_flex,
      data = nuevo,
      contrasts.arg = mod_conjunto_flexible$contrasts,
      xlev = mod_conjunto_flexible$xlevels
    )

    X_flex <- X_flex[

```

```

    ,
    names(beta_flex),
    drop = FALSE
  ]

eta <- as.vector(
  X_flex %*% beta_flex
)

p <- plogis(eta)

prob_media <- mean(p)

gradiente <- colMeans(
  sweep(
    X_flex,
    1,
    p * (1 - p),
    "*"
  )
)

se_prob <- sqrt(
  as.numeric(
    t(gradiente) %*%
    V_flex %*%
    gradiente
  )
)

tibble(
  Estacion = est,
  Sector = sec,
  Probabilidad = prob_media,
  IC_inf = max(
    0,
    prob_media - 1.96 * se_prob
  ),
  IC_sup = min(
    1,
    prob_media + 1.96 * se_prob
  )
)

```

```

    )
  }
)

prob_estacion <- prob_estacion %>%
  mutate(
    Estacion = factor(
      Estacion,
      levels = c(
        "SE3",
        "SE2",
        "NE",
        "GAR"
      )
    ),
    Sector = factor(
      Sector,
      levels = c(
        "Resto",
        "Este"
      )
    ),
    Prob_pct = round(
      100 * Probabilidad,
      2
    ),
    IC_inf_pct = round(
      100 * IC_inf,
      2
    ),
    IC_sup_pct = round(
      100 * IC_sup,
      2
    )
  )

print(
  prob_estacion %>%
  select(
    Estacion,
    Sector,
    Prob_pct,

```

```

      IC_inf_pct,
      IC_sup_pct
    ),
    n = 8
  )

```

```

# A tibble: 8 x 5
  Estacion Sector Prob_pct IC_inf_pct IC_sup_pct
  <fct>    <fct>    <dbl>    <dbl>    <dbl>
1 SE3     Resto      7.51      7.17      7.85
2 SE3     Este     18.9      18.2     19.6
3 SE2     Resto      4.56      4.25      4.87
4 SE2     Este      6.86      6.36      7.36
5 NE      Resto      2.09      1.92      2.26
6 NE      Este       2.1       1.7       2.5
7 GAR     Resto      0.17      0.08      0.27
8 GAR     Este       0.19      0.09      0.28

```

```

brecha_estacion <- prob_estacion %>%
  select(
    Estacion,
    Sector,
    Prob_pct
  ) %>%
  pivot_wider(
    names_from = Sector,
    values_from = Prob_pct
  ) %>%
  mutate(
    Diferencia_pp = round(
      Este - Resto,
      2
    )
  )

cat(
  "\n=== DIFERENCIA AJUSTADA: SECTOR ORIENTAL - RESTO ===\n"
)

```

```

=== DIFERENCIA AJUSTADA: SECTOR ORIENTAL - RESTO ===

```

```
print(
  brecha_estacion
)
```

```
# A tibble: 4 x 4
  Estacion Resto  Este Diferencia_pp
  <fct>    <dbl> <dbl>         <dbl>
1 SE3      7.51 18.9          11.4
2 SE2      4.56  6.86           2.3
3 NE       2.09  2.1           0.01
4 GAR      0.17  0.19           0.02
```


```
prob_estacion_plot <- prob_estacion %>%
  mutate(
    Sector_grafica = recode(
      as.character(Sector),
      "Este" = "Sector oriental (ENE-E-ESE)",
      "Resto" = "Resto de direcciones"
    )
  )

ggplot(
  prob_estacion_plot,
  aes(
    x = Estacion,
    y = Prob_pct,
    fill = Sector_grafica
  )
) +
  geom_col(
    position = position_dodge(
      width = 0.8
    ),
    width = 0.7
  ) +
  geom_errorbar(
    aes(
      ymin = IC_inf_pct,
      ymax = IC_sup_pct
    ),
    position = position_dodge(
```

```

width = 0.8
),
width = 0.2
) +
labs(
  title = "Probabilidad ajustada de episodio de SO2 por estación",
  subtitle = "Modelo conjunto flexible | Sector oriental frente al resto",
  x = "Estación",
  y = "Probabilidad ajustada de episodio (%)",
  fill = "Sector"
) +
theme_minimal(base_size = 12)

```



Interpretación. Estas probabilidades se obtienen estandarizando las cuatro estaciones sobre una distribución común de velocidad del viento, hora y mes, pero permitiendo que cada estación tenga su propia relación con dichas condiciones. De esta forma, la comparación espacial no obliga artificialmente a que WSR y los patrones temporales tengan el mismo efecto en todas las estaciones.

Las barras deben interpretarse como probabilidades marginales ajustadas asociadas al sector oriental y al resto de direcciones dentro de cada estación. La diferencia en puntos porcentuales cuantifica la brecha ajustada entre ambos escenarios.

Los intervalos de confianza de esta figura utilizan la matriz de covarianza convencional del modelo. Posteriormente pueden recalcularse con una estructura robusta si el diagnóstico de dependencia temporal indica que es necesario.

Contrastes Este vs Resto por estación con corrección Holm conjunta

```
emm_sector <- emmeans(  
  mod_conjunto_flexible,  
  ~ sector_E | Estacion  
)  
  
contrastes_estacion <- contrast(  
  emm_sector,  
  method = list(  
    "Este vs Resto" = c(-1, 1)  
  )  
)  
  
# Quitar el agrupamiento "by" para tratar los cuatro contrastes  
# como una sola familia de pruebas.  
contrastes_estacion <- update(  
  contrastes_estacion,  
  by = NULL  
)  
  
resultado_contrastes <- summary(  
  contrastes_estacion,  
  type = "response",  
  infer = c(TRUE, TRUE),  
  adjust = "holm"  
)  
  
cat(  
  "=== CONTRASTES ESTE VS RESTO POR ESTACIÓN ===\n"  
)
```

=== CONTRASTES ESTE VS RESTO POR ESTACIÓN ===

```
print(  
  resultado_contrastes  
)
```


contrast	Estacion	odds.ratio	SE	df	asympt.LCL	asympt.UCL	null	z.ratio
Este vs Resto SE3		3.19	0.1220	Inf	2.898	3.51	1	30.232
Este vs Resto SE2		1.58	0.0798	Inf	1.394	1.79	1	9.081
Este vs Resto NE		1.01	0.1130	Inf	0.761	1.33	1	0.059
Este vs Resto GAR		1.07	0.3830	Inf	0.441	2.61	1	0.200

p.value
 <0.0001
 <0.0001
 1.0000
 1.0000

Confidence level used: 0.95

Conf-level adjustment: bonferroni method for 4 estimates

Intervals are back-transformed from the log odds ratio scale

P value adjustment: holm method for 4 tests

Tests are performed on the log odds ratio scale

Interpretación. Estos contrastes comprueban, dentro de cada estación, si los momios de episodio bajo el sector oriental difieren de los correspondientes al resto de direcciones. Los p-values se corrigen conjuntamente mediante Holm para controlar las cuatro comparaciones simultáneas.

Un OR mayor que 1 indica mayores momios bajo el sector oriental; un OR menor que 1 indica menores momios. La significancia individual debe evaluarse con el p-value ajustado y con el intervalo de confianza correspondiente.

Diagnóstico de dependencia temporal de los residuos

```

d_conjunto <- datos %>%
  select(
    fecha,    # <- AGREGAR
    episodio,
    Estacion,
    sector_E,
    WSR,
    Hora_sin,
    Hora_cos,
    Mes_sin,
    Mes_cos
  ) %>%
  drop_na() %>%

```

```

mutate(
  Estacion = factor(
    Estacion,
    levels = c("SE3", "SE2", "NE", "GAR")
  ),
  sector_E = factor(
    sector_E,
    levels = c("Resto", "Este")
  )
)

```

Diagnóstico de dependencia temporal de los residuos

```

# =====
# DIAGNÓSTICO DE DEPENDENCIA TEMPORAL DE LOS RESIDUOS
# Modelo conjunto flexible
# =====

# 1. Obtener residuos de Pearson del modelo final
res_temporal <- d_conjunto %>%
  mutate(
    residuo_pearson = residuals(
      mod_conjunto_flexible,
      type = "pearson"
    )
  ) %>%
  select(
    fecha,
    Estacion,
    residuo_pearson
  ) %>%
  arrange(
    Estacion,
    fecha
  )

# 2. Verificar que no haya fecha-hora duplicada dentro de una estación
duplicados_tiempo <- res_temporal %>%
  count(
    Estacion,

```

```

    fecha
  ) %>%
  filter(n > 1)

cat(
  "Número de fecha-hora duplicadas por estación:",
  nrow(duplicados_tiempo),
  "\n\n"
)

```

Número de fecha-hora duplicadas por estación: 0

```

# 3. Autocorrelación usando separaciones temporales REALES
# Se estudian las siguientes 48 horas.
rezagos <- 1:48

acf_temporal <- map_dfr(
  levels(d_conjunto$Estacion),
  function(est) {

    d_est <- res_temporal %>%
      filter(Estacion == est)

    map_dfr(
      rezagos,
      function(k) {

        # Residuo observado exactamente k horas antes
        d_lag <- d_est %>%
          transmute(
            fecha = fecha + hours(k),
            residuo_anterior = residuo_pearson
          )

        # Solo se comparan observaciones cuya separación temporal
        # real es exactamente k horas
        pares <- d_est %>%
          select(
            fecha,
            residuo_actual = residuo_pearson
          ) %>%
          inner_join(

```

```

      d_lag,
      by = "fecha"
    )

    n_pares <- nrow(pares)

    r <- if (n_pares > 2) {
      cor(
        pares$residuo_actual,
        pares$residuo_anterior,
        use = "complete.obs"
      )
    } else {
      NA_real_
    }

    tibble(
      Estacion = est,
      Rezago_horas = k,
      N_pares = n_pares,
      Autocorrelacion = r,
      Limite_95 = if_else(
        n_pares > 0,
        1.96 / sqrt(n_pares),
        NA_real_
      )
    )
  }
)
}
)

# 4. Valores principales para interpretación
cat("=== AUTOCORRELACIÓN EN REZAGOS SELECCIONADOS ===\n")

```

=== AUTOCORRELACIÓN EN REZAGOS SELECCIONADOS ===

```

acf_temporal %>%
  filter(
    Rezago_horas %in% c(1, 2, 3, 6, 12, 24, 48)
  ) %>%
  mutate(

```

```

Autocorrelacion = round(
  Autocorrelacion,
  3
),
Fuera_IC95 = abs(Autocorrelacion) > Limite_95
) %>%
select(
  Estacion,
  Rezago_horas,
  N_pares,
  Autocorrelacion,
  Fuera_IC95
) %>%
print(n = Inf)

```

A tibble: 28 x 5

	Estacion	Rezago_horas	N_pares	Autocorrelacion	Fuera_IC95
	<chr>	<int>	<int>	<dbl>	<lgl>
1	SE3	1	33607	0.461	TRUE
2	SE3	2	33468	0.249	TRUE
3	SE3	3	33389	0.139	TRUE
4	SE3	6	33268	0.044	TRUE
5	SE3	12	33142	0.088	TRUE
6	SE3	24	33072	0.164	TRUE
7	SE3	48	32922	0.102	TRUE
8	SE2	1	32755	0.44	TRUE
9	SE2	2	32572	0.231	TRUE
10	SE2	3	32474	0.126	TRUE
11	SE2	6	32321	0.037	TRUE
12	SE2	12	32193	0.054	TRUE
13	SE2	24	32065	0.114	TRUE
14	SE2	48	31879	0.097	TRUE
15	NE	1	32591	0.461	TRUE
16	NE	2	32374	0.21	TRUE
17	NE	3	32293	0.138	TRUE
18	NE	6	32137	0.056	TRUE
19	NE	12	31945	0.04	TRUE
20	NE	24	31871	0.093	TRUE
21	NE	48	31812	0.076	TRUE
22	GAR	1	31558	0.154	TRUE
23	GAR	2	31098	0.062	TRUE
24	GAR	3	30970	0.071	TRUE

25	GAR	6	30784	-0.001	FALSE
26	GAR	12	30687	0.015	TRUE
27	GAR	24	30663	0.006	FALSE
28	GAR	48	30592	0.013	TRUE

```
# 5. Mayor autocorrelación absoluta observada por estación
cat("\n=== MAYOR AUTOCORRELACIÓN ABSOLUTA POR ESTACIÓN ===\n")
```

```
=== MAYOR AUTOCORRELACIÓN ABSOLUTA POR ESTACIÓN ===
```

```
acf_temporal %>%
  group_by(Estacion) %>%
  slice_max(
    order_by = abs(Autocorrelacion),
    n = 1,
    with_ties = FALSE
  ) %>%
  ungroup() %>%
  mutate(
    Autocorrelacion = round(
      Autocorrelacion,
      3
    )
  ) %>%
  select(
    Estacion,
    Rezago_horas,
    Autocorrelacion
  ) %>%
  print()
```

```
# A tibble: 4 x 3
  Estacion Rezago_horas Autocorrelacion
  <chr>      <int>          <dbl>
1 GAR         1          0.154
2 NE          1          0.461
3 SE2         1          0.44
4 SE3         1          0.461
```

```

# 6. Gráfica
ggplot(
  acf_temporal,
  aes(
    x = Rezago_horas,
    y = Autocorrelacion
  )
) +
  geom_ribbon(
    aes(
      ymin = -Limite_95,
      ymax = Limite_95
    ),
    alpha = 0.15
  ) +
  geom_hline(
    yintercept = 0,
    linetype = "dashed"
  ) +
  geom_segment(
    aes(
      xend = Rezago_horas,
      y = 0,
      yend = Autocorrelacion
    )
  ) +
  facet_wrap(
    ~ Estacion,
    ncol = 2
  ) +
  scale_x_continuous(
    breaks = seq(0, 48, 6)
  ) +
  labs(
    title = "Dependencia temporal de los residuos del modelo conjunto",
    subtitle = "Residuos de Pearson | Rezagos temporales reales de 1 a 48 horas",
    x = "Rezago (horas)",
    y = "Autocorrelación residual"
  ) +
  theme_minimal(base_size = 12)

```

Dependencia temporal de los residuos del modelo conjun
Residuos de Pearson | Rezagos temporales reales de 1 a 48 horas

