

Etapa final - Código (versión compacta)

Alicia Bernádez Omar Arzaga Diego Medrano
Sebastián Alemán Isaac Montaña

Preparación general

```
library(tidyverse)
library(lubridate)
library(ResourceSelection)
library(pROC)
library(splines)
library(broom)
library(sandwich)
library(lmtest)
library(openair)
library(emmeans)
```

```
datos <- read_csv(
  "baseeee_SIMA_limpia_4est_8cont_2022_2025.csv",
  locale = locale(encoding = "UTF-8"),
  show_col_types = FALSE
)

cat("Dimensiones:", nrow(datos), "filas x", ncol(datos), "columnas\n")
```

Dimensiones: 132936 filas x 21 columnas

```
cat("Columnas:", paste(names(datos), collapse = ", "), "\n\n")
```

Columnas: Fecha y hora, Estacion, Municipio, Año, CO, NO, NO2, NOX, O3, PM10, PM2.5, SO2, WD

```

# Fecha y estación
datos <- datos %>%
  mutate(
    fecha = ymd_hms(`Fecha y hora`),
    Estacion = factor(
      Estacion,
      levels = c("SE3", "SE2", "NE", "GAR")
    )
  )

# Clasificación circular del viento en 16 rumbos
rumbos <- c(
  "N", "NNE", "NE", "ENE", "E", "ESE", "SE", "SSE",
  "S", "SSO", "SO", "OSO", "O", "ONO", "NO", "NNO"
)

datos <- datos %>%
  mutate(
    sector = rumbos[((floor((WDR + 11.25) / 22.5)) %% 16) + 1],
    sector = factor(sector, levels = rumbos)
  )

# Umbral ABSOLUTO común a las cuatro estaciones:
# P95 global de SO2.
umbral_ep <- quantile(datos$SO2, 0.95, na.rm = TRUE)

datos <- datos %>%
  mutate(
    episodio = as.integer(SO2 > umbral_ep),

    # Sector oriental utilizado posteriormente
    sector_E = factor(
      if_else(
        sector %in% c("ENE", "E", "ESE"),
        "Este",
        "Resto"
      ),
      levels = c("Resto", "Este")
    ),

    # Variables temporales cíclicas
    Hora_sin = sin(2 * pi * Hora / 24),

```

```

    Hora_cos = cos(2 * pi * Hora / 24),
    Mes_sin = sin(2 * pi * Mes / 12),
    Mes_cos = cos(2 * pi * Mes / 12)
  )

cat(
  "Umbral de episodio (P95 global):",
  round(umbral_ep, 2),
  "ppb\n\n"
)

```

Umbral de episodio (P95 global): 11.1 ppb

```

# Frecuencia y distribución de episodios por estación
resumen_estaciones <- datos %>%
  group_by(Estacion) %>%
  summarise(
    n = n(),
    episodios = sum(episodio, na.rm = TRUE),
    tasa_pct = round(100 * mean(episodio, na.rm = TRUE), 2),
    P50 = median(SO2, na.rm = TRUE),
    P99 = quantile(SO2, 0.99, na.rm = TRUE),
    razon_P99_P50 = round(P99 / P50, 2),
    .groups = "drop"
  )

print(resumen_estaciones)

```

```

# A tibble: 4 x 7
  Estacion      n episodios tasa_pct   P50   P99 razon_P99_P50
  <fct>      <int>      <int>   <dbl> <dbl> <dbl>         <dbl>
1 SE3      33977      3951   11.6   4.4  55.3          12.6
2 SE2      33240      1841    5.54   3.8  27.8           7.32
3 NE       33185       746    2.25   3.8  15.1           3.97
4 GAR      32534       49     0.15   3.3   7.4           2.24

```

```

cat("\nNAs en sector:", sum(is.na(datos$sector)), "\n")

```

NAs en sector: 0

```
table(datos$sector) %>% sort(decreasing = TRUE) %>% head(5)
```

```

ESE      SE      E      SSE      NE
23655 19894 19633 12246  7951

```

Interpretación. En este bloque se prepara la base utilizada en los análisis posteriores. Se cargan 132,936 registros con información de contaminantes, meteorología, estación y tiempo para 2022–2025. La dirección del viento se transforma en 16 sectores de 22.5°, respetando su naturaleza circular.

Para identificar episodios elevados de SO_2 se utiliza un único umbral absoluto de 11.1 ppb, correspondiente al percentil 95 global de las cuatro estaciones. El uso de un mismo umbral permite comparar directamente la frecuencia de episodios entre estaciones sin obligar a que cada estación tenga, por construcción, el mismo 5% de observaciones extremas.

Con este criterio, SE3 presenta la mayor frecuencia de episodios, seguida por SE2, NE y GAR. La relación P99/P50 también es mayor en SE3, lo que muestra que las diferencias entre estaciones son especialmente importantes en la parte alta de la distribución.

Regresión logística direccional en SE3

```

# Tasa cruda de episodios por rumbo
tasa_sector_SE3 <- datos %>%
  filter(Estacion == "SE3") %>%
  group_by(sector) %>%
  summarise(
    n = n(),
    episodios = sum(episodio),
    tasa_pct = round(100 * mean(episodio), 2),
    .groups = "drop"
  ) %>%
  arrange(desc(tasa_pct))

print(tasa_sector_SE3, n = 16)

```

```

# A tibble: 16 x 4
  sector      n episodios tasa_pct
  <fct>  <int>      <int>    <dbl>

```

1	E	3906	930	23.8
2	ESE	6002	1013	16.9
3	SE	5562	836	15.0
4	SSE	2536	351	13.8
5	ENE	2217	277	12.5
6	S	1070	106	9.91
7	NE	1595	116	7.27
8	SSO	547	37	6.76
9	NNE	1072	71	6.62
10	N	1161	75	6.46
11	SO	531	31	5.84
12	OSO	647	21	3.25
13	NNO	1842	37	2.01
14	ONO	1714	22	1.28
15	O	990	12	1.21
16	NO	2585	16	0.62

```
# Preparación de SE3
d_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  mutate(
    sector = relevel(sector, ref = "N")
  )

# Modelo logístico de 16 rumbos
mod_se3 <- glm(
  episodio ~
    sector +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_se3,
  family = binomial
)

# Razones de momios por rumbo
or_sector <- tidy(mod_se3) %>%
  filter(str_detect(term, "^sector")) %>%
  mutate(
    Rumbo = str_remove(term, "^sector"),
    OR = round(exp(estimate), 2),
    IC_inf = round(exp(estimate - 1.96 * std.error), 2),
```

```

    IC_sup = round(exp(estimate + 1.96 * std.error), 2),
    p = signif(p.value, 3)
  ) %>%
  select(Rumbo, OR, IC_inf, IC_sup, p) %>%
  arrange(desc(OR))

print(or_sector, n = 15)

```

```

# A tibble: 15 x 5
  Rumbo    OR IC_inf IC_sup      p
  <chr> <dbl> <dbl> <dbl>   <dbl>
1 E      6.12  4.73  7.92 3.97e-43
2 ESE    2.58  2      3.33 4.38e-13
3 ENE    1.98  1.51  2.62 1.20e- 6
4 SSE    1.53  1.17  2.01 1.93e- 3
5 SE     1.51  1.17  1.96 1.55e- 3
6 S      1.14  0.83  1.56 4.3 e- 1
7 NE     1.08  0.79  1.47 6.34e- 1
8 NNE    1.06  0.75  1.5  7.43e- 1
9 SO     0.83  0.53  1.29 4.09e- 1
10 SSO   0.78  0.51  1.19 2.46e- 1
11 OSO   0.54  0.33  0.9  1.75e- 2
12 ONO   0.25  0.15  0.41 2.94e- 8
13 O     0.24  0.13  0.44 6.20e- 6
14 NNO   0.23  0.15  0.35 2.35e-12
15 NO    0.08  0.04  0.13 1.19e-19

```

```
cat("\nDevianza nula:", round(mod_se3$null.deviance, 1), "\n")
```

Devianza nula: 24426.5

```
cat("Devianza residual:", round(mod_se3$deviance, 1), "\n")
```

Devianza residual: 19809.3

```

cat(
  "Pseudo-R2 McFadden:",
  round(1 - mod_se3$deviance / mod_se3$null.deviance, 3),
  "\n"
)

```

Pseudo- R^2 McFadden: 0.189

```
cat("AIC:", round(AIC(mod_se3), 1), "\n")
```

AIC: 19855.3

Pregunta que responde. ¿Cómo cambia la ocurrencia de episodios elevados de SO_2 en SE3 según la dirección del viento, controlando simultáneamente por velocidad del viento, hora del día y mes?

Interpretación. Las tasas crudas muestran un patrón direccional marcado: el Este presenta la mayor proporción de episodios, seguido por ESE y SE, mientras que varias direcciones occidentales presentan tasas considerablemente menores.

En la regresión logística se utiliza Norte como referencia. La velocidad del viento se incorpora mediante un spline natural de tres grados de libertad y la hora y el mes mediante términos seno/coseno. El resultado principal es el rumbo Este, con OR = 6.12 (IC95%: 4.73–7.92), lo que significa que, manteniendo comparables WSR, hora y mes, los momios de registrar un episodio son aproximadamente 6.1 veces los correspondientes al viento del Norte.

Un OR de 6.12 no significa que la concentración de SO_2 sea 6.12 veces mayor ni que la probabilidad aumente exactamente 6.12 veces. El OR compara momios.

Las direcciones ESE y ENE también presentan asociaciones superiores a la referencia, mientras que varias direcciones occidentales presentan asociaciones considerablemente menores. En conjunto, se observa una estructura direccional coherente: la asociación con episodios de SO_2 es mayor en el sector oriental y menor hacia el sector occidental.

La reducción de devianza respecto al modelo nulo indica que la incorporación de dirección, velocidad y controles temporales aporta información. El pseudo- R^2 de McFadden se interpreta como una medida relativa de mejora frente al modelo nulo, no como un R^2 lineal.

Hallazgo principal. Después de controlar por velocidad del viento, hora y mes, el sector oriental conserva la asociación más fuerte con los episodios elevados de SO_2 en SE3. Este resultado muestra asociación estadística y no identifica por sí solo una fuente causal específica.

Validación del modelo logístico de 16 rumbos

```
mod_nulo_se3 <- glm(  
  episodio ~ 1,  
  data = d_se3,  
  family = binomial
```

```
)

lrt_se3 <- anova(
  mod_nulo_se3,
  mod_se3,
  test = "Chisq"
)

print(lrt_se3)
```

Analysis of Deviance Table

Model 1: episodio ~ 1

Model 2: episodio ~ sector + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	33976	24426			
2	33954	19809	22	4617.2	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
roc_se3 <- roc(
  d_se3$episodio,
  fitted(mod_se3),
  quiet = TRUE
)

cat(
  "\nAUC modelo 16 rumbos:",
  round(as.numeric(auc(roc_se3)), 4),
  "\n"
)
```

AUC modelo 16 rumbos: 0.8112

```
hl_se3 <- hoslem.test(
  d_se3$episodio,
  fitted(mod_se3),
  g = 10
```



```
)
```

```
print(hl_se3)
```

Hosmer and Lemeshow goodness of fit (GOF) test

```
data: d_se3$episodio, fitted(mod_se3)
X-squared = 56.531, df = 8, p-value = 2.223e-09
```

Interpretación. La prueba de razón de verosimilitudes muestra que el modelo completo mejora significativamente respecto a un modelo con solo intercepto. El AUC de aproximadamente 0.811 indica buena capacidad para discriminar horas con y sin episodio.

Hosmer-Lemeshow resulta significativo, lo que señala desviaciones de calibración. Debido al tamaño de muestra, la prueba es muy sensible a diferencias pequeñas; por ello debe interpretarse junto con las demás verificaciones. El modelo se utiliza principalmente para estudiar asociaciones direccionales y no como sistema operativo de alerta.

Sensibilidad al umbral

```
sens <- map_dfr(
  c(0.90, 0.95, 0.99),
  function(q) {

    u <- quantile(
      datos$S02,
      q,
      na.rm = TRUE
    )

    map_dfr(
      c("SE3", "SE2", "NE", "GAR"),
      function(e) {

        d <- datos %>%
          filter(Estacion == e) %>%
          mutate(
            y = as.integer(S02 > u)
          )
      }
    )
  }
)
```

```

    )

    if (sum(d$y) < 30) {
      return(
        tibble(
          Estacion = e,
          OR = NA,
          IC_inf = NA,
          IC_sup = NA
        )
      )
    }

    m <- glm(
      y ~
        sector_E +
        ns(WSR, 3) +
        Hora_sin + Hora_cos +
        Mes_sin + Mes_cos,
      data = d,
      family = binomial
    )

    co <- tidy(m) %>%
      filter(
        term == "sector_EEste"
      )

    tibble(
      Estacion = e,
      OR = round(exp(co$estimate), 2),
      IC_inf = round(
        exp(co$estimate - 1.96 * co$std.error),
        2
      ),
      IC_sup = round(
        exp(co$estimate + 1.96 * co$std.error),
        2
      )
    )
  }
) %>%

```

```

    mutate(
      Percentil = paste0("P", q * 100),
      umbral_ppb = round(u, 1),
      .before = 1
    )
  }
)

print(sens, n = 12)

```

```

# A tibble: 12 x 6
  Percentil umbral_ppb Estacion    OR IC_inf IC_sup
  <chr>      <dbl> <chr>    <dbl> <dbl> <dbl>
1 P90        7.2 SE3      3.38  3.17  3.6
2 P90        7.2 SE2      1.43  1.33  1.53
3 P90        7.2 NE       1      0.89  1.13
4 P90        7.2 GAR      1.4    1.08  1.83
5 P95       11.1 SE3      3.19  2.96  3.44
6 P95       11.1 SE2      1.58  1.43  1.74
7 P95       11.1 NE       1.01  0.81  1.26
8 P95       11.1 GAR      1.08  0.54  2.16
9 P99       30.6 SE3      2.57  2.25  2.93
10 P99       30.6 SE2      1.75  1.37  2.24
11 P99       30.6 NE       0.86  0.3   2.5
12 P99       30.6 GAR      NA     NA    NA

```

Interpretación. La asociación del sector oriental en SE3 permanece claramente por encima de uno con P90, P95 y P99, lo que indica que el patrón no depende exclusivamente de haber escogido P95. En SE2 también se conserva una asociación positiva. NE permanece cercana a ausencia de asociación y GAR presenta mayor incertidumbre debido a la baja frecuencia de concentraciones extremas.

Contexto geográfico y gradiente espacial

```

geo <- tribble(
  ~Estacion, ~lat, ~lon, ~azimut, ~rumbo, ~dist_km,
  "SE3", 25.5844, -100.0011, 87.3, "E", 5.5,
  "SE2", 25.6461, -100.0956, 113.7, "ESE", 16.4,
  "NE", 25.7455, -100.2552, 119.6, "ESE", 35.7,

```

```

"GAR", 25.7997, -100.5878, 110.1, "ESE", 68.5
)

# Resultados de modelos separados por estación usando el
# MISMO umbral absoluto de 11.1 ppb.
or_p95 <- tibble(
  Estacion = c("SE3", "SE2", "NE", "GAR"),
  OR = c(3.19, 1.58, 1.01, 1.08),
  IC_inf = c(2.96, 1.43, 0.81, 0.54),
  IC_sup = c(3.44, 1.74, 1.26, 2.16)
)


left_join(
  geo,
  or_p95,
  by = "Estacion"
) %>%
  ggplot(
    aes(
      x = dist_km,
      y = OR
    )
  ) +
  geom_hline(
    yintercept = 1,
    linetype = "dashed",
    colour = "grey40"
  ) +
  geom_errorbar(
    aes(
      ymin = IC_inf,
      ymax = IC_sup
    ),
    width = 1.5
  ) +
  geom_point(
    size = 3,
    colour = "firebrick"
  ) +
  geom_text(
    aes(label = Estacion),
    vjust = -1.2,

```

```

    size = 3.5
  ) +
  labs(
    title = "La asociación direccional se atenúa con la distancia",
    subtitle = "Sector oriental (ENE-E-ESE), umbral absoluto de SO2 = 11.1 ppb",
    x = "Distancia al complejo de referencia (km)",
    y = "Razón de momios (IC 95%)"
  ) +
  theme_minimal(base_size = 12)

```



Interpretación. El complejo de referencia se localiza hacia E/ESE desde las cuatro estaciones. El OR es mayor en SE3, menor en SE2 y se aproxima a ausencia de asociación en NE y GAR. El patrón es consistente con una atenuación espacial de la señal direccional, aunque no es estrictamente monotónico y no constituye por sí mismo evidencia causal de una fuente específica.

CBPF

```

d_oa <- datos %>%
  rename(

```

```

    date = fecha,
    ws = WSR,
    wd = WDR
  )

# Percentil exacto que corresponde al umbral absoluto de 11.1 ppb
# dentro de cada estación.
pct_eq <- datos %>%
  group_by(Estacion) %>%
  summarise(
    p = 100 * mean(
      SO2 <= umbral_ep,
      na.rm = TRUE
    ),
    .groups = "drop"
  )

print(
  pct_eq %>%
  mutate(
    p = round(p, 2)
  )
)

```

A tibble: 4 x 2

	Estacion	p
	<fct>	<dbl>
1	SE3	88.4
2	SE2	94.5
3	NE	97.8
4	GAR	99.8

CBPF de SO2

```

for (e in c("SE3", "SE2", "NE")) {

  p <- pct_eq$p[
    pct_eq$Estacion == e
  ]

  polarPlot(
    filter(
      d_oa,


```

```

    Estacion == e
  ),
  pollutant = "SO2",
  statistic = "cpf",
  percentile = p,
  main = paste0(
    "CBPF de SO2 en ",
    e,
    " (umbral 11.1 ppb)"
  ),
  key.title = "Probabilidad"
)
}

```


CBPF de SO₂ en SE3 (umbral 11.1 ppb)



Radial axis shows wind spd.

CPF at the 88.3715454572211th percentile (=11)


CBPF de SO₂ en SE2 (umbral 11.1 ppb)



Radial axis shows wind spd.

CPF at the 94.4614921780987th percentile (=11)

CBPF de SO₂ en NE (umbral 11.1 ppb)



Radial axis shows wind spd.

CPF at the 97.7519963839084th percentile (=11)

```
# Contraste visual de NOX en SE3:  
# se usa el mismo percentil relativo empleado en SO2-SE3.  
polarPlot(  
  filter(  

```




```

    d_oa,
    Estacion == "SE3"
),
pollutant = "NOX",
statistic = "cpf",
percentile = pct_eq$p[
    pct_eq$Estacion == "SE3"
],
main = "CBPF de NOX en SE3 (mismo percentil relativo que SO2)",
key.title = "Probabilidad"
)

```

:BPF de NO_x en SE3 (mismo percentil relativo que SO₂)



Interpretación. La CBPF representa la probabilidad condicional de concentraciones elevadas en función conjunta de dirección y velocidad del viento. En SE3 reproduce una zona de mayor probabilidad asociada al sector oriental. En SE2 la señal es menor y en NE es menos marcada.

GAR se omite porque 11.1 ppb corresponde a una parte extremadamente alta de su distribución y existen muy pocas observaciones por encima de ese nivel para estimar una superficie estable.

El CBPF de NOX en SE3 utiliza el mismo **percentil relativo** empleado para SO₂ en SE3; no representa el mismo umbral de concentración. Su patrón es diferente al de SO₂.

Hallazgo principal. La CBPF aporta una verificación visual mediante un procedimiento distinto a la regresión logística y reproduce el patrón direccional general. No demuestra por sí sola la fuente causal.

Probabilidades ajustadas por las 16 direcciones en SE3

```
rumbos_modelo <- levels(
  model.frame(mod_se3)$sector
)

base_prob <- d_se3 %>%
  select(
    WSR,
    Hora_sin,
    Hora_cos,
    Mes_sin,
    Mes_cos
  ) %>%
  drop_na()

beta_16 <- coef(mod_se3)
V_16 <- vcov(mod_se3)

tt_16 <- delete.response(
  terms(mod_se3)
)

prob_direccion <- map_dfr(
  rumbos_modelo,
  function(r) {

    nuevo <- base_prob %>%
      mutate(
        sector = factor(
          r,
          levels = rumbos_modelo
        )
      )

    X_16 <- model.matrix(
```

```

    tt_16,
    data = nuevo
  )

X_16 <- X_16[
  ,
  names(beta_16),
  drop = FALSE
]

eta <- as.vector(
  X_16 %*% beta_16
)

p <- plogis(eta)

prob_media <- mean(p)

gradiente <- colMeans(
  sweep(
    X_16,
    1,
    p * (1 - p),
    "*"
  )
)

se_prob <- sqrt(
  as.numeric(
    t(gradiente) %*%
    V_16 %*%
    gradiente
  )
)

tibble(
  Rumbo = r,
  Prob_ajustada = prob_media,
  IC_inf = max(
    0,
    prob_media - 1.96 * se_prob
  ),

```

```

        IC_sup = min(
          1,
          prob_media + 1.96 * se_prob
        )
      )
    }
  )

prob_direccion <- prob_direccion %>%
  mutate(
    Prob_pct = round(
      100 * Prob_ajustada,
      2
    ),
    IC_inf_pct = round(
      100 * IC_inf,
      2
    ),
    IC_sup_pct = round(
      100 * IC_sup,
      2
    )
  )

print(
  prob_direccion %>%
    select(
      Rumbo,
      Prob_pct,
      IC_inf_pct,
      IC_sup_pct
    ),
  n = 16
)

```


```

# A tibble: 16 x 4
  Rumbo Prob_pct IC_inf_pct IC_sup_pct
  <chr>   <dbl>   <dbl>   <dbl>
1 N       7.69     6.07     9.32
2 NNE     8.09     6.34     9.83
3 NE      8.21     6.83     9.59
4 ENE    13.6     12.2    15.0

```

5	E	29.4	28.0	30.8
6	ESE	16.6	15.6	17.5
7	SE	10.9	10.2	11.6
8	SSE	11.0	9.96	12.1
9	S	8.59	7.06	10.1
10	SSO	6.18	4.29	8.08
11	SO	6.53	4.36	8.69
12	OSO	4.45	2.62	6.27
13	O	2.04	0.91	3.17
14	ONO	2.15	1.27	3.03
15	NO	0.68	0.35	1.01
16	NNO	1.98	1.35	2.61

```
ggplot(
  prob_direccion,
  aes(
    x = factor(
      Rumbo,
      levels = rumbos_modelo
    ),
    y = Prob_pct
  )
) +
  geom_col() +
  geom_errorbar(
    aes(
      ymin = IC_inf_pct,
      ymax = IC_sup_pct
    ),
    width = 0.25
  ) +
  labs(
    title = "Probabilidad ajustada de episodio de SO2 según la dirección del viento",
    subtitle = "SE3 | Ajustada por velocidad del viento, hora y mes",
    x = "Dirección de procedencia del viento",
    y = "Probabilidad ajustada de episodio (%)"
  ) +
  theme_minimal(base_size = 12)
```



Interpretación. Las probabilidades ajustadas muestran un patrón direccional definido en SE3. Para cada rumbo se mantienen las condiciones observadas de velocidad, hora y mes y se modifica únicamente la dirección. Posteriormente se promedian las probabilidades estimadas.

El Este presenta la mayor probabilidad ajustada, 29.4% (IC95%: 28.0%–30.8%), seguido por ESE con 16.6% y ENE con 13.6%. Norte presenta 7.69%. En contraste, varias direcciones occidentales presentan probabilidades considerablemente menores.

Estas probabilidades son estimaciones marginales derivadas del modelo y no corresponden a frecuencias crudas ni a un pronóstico meteorológico futuro.

Probabilidades ajustadas por estación y sector oriental

Esta sección reemplaza la versión anterior del modelo conjunto. La corrección principal consiste en **permitir que la relación de WSR, hora y mes cambie por estación**, en lugar de obligar a que dichos controles tengan exactamente el mismo efecto en SE3, SE2, NE y GAR.

```
d_conjunto <- datos %>%
  select(
    fecha,
    episodio,
    Estacion,
```

```

    sector_E,
    WSR,
    Hora_sin,
    Hora_cos,
    Mes_sin,
    Mes_cos
  ) %>%
  drop_na() %>%
  mutate(
    Estacion = factor(
      Estacion,
      levels = c(
        "SE3",
        "SE2",
        "NE",
        "GAR"
      )
    ),
    sector_E = factor(
      sector_E,
      levels = c(
        "Resto",
        "Este"
      )
    )
  )
)

```

Comprobación de la estructura del modelo conjunto

```

# Modelo con interacción Estación × sector,
# pero controles meteorológicos/temporales comunes.
mod_conjunto_comun <- glm(
  episodio ~
    Estacion * sector_E +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_conjunto,
  family = binomial
)

```

```
# Modelo flexible:
# permite que sector, WSR, hora y mes cambien por estación.
mod_conjunto_flexible <- glm(
  episodio ~
    Estacion * (
      sector_E +
      ns(WSR, 3) +
      Hora_sin + Hora_cos +
      Mes_sin + Mes_cos
    ),
  data = d_conjunto,
  family = binomial
)

cat(
  "=== CONTROLES COMUNES VS CONTROLES ESPECÍFICOS POR ESTACIÓN ===\n"
)
```

=== CONTROLES COMUNES VS CONTROLES ESPECÍFICOS POR ESTACIÓN ===

```
prueba_flexibilidad <- anova(
  mod_conjunto_comun,
  mod_conjunto_flexible,
  test = "Chisq"
)

print(prueba_flexibilidad)
```

Analysis of Deviance Table

```
Model 1: episodio ~ Estacion * sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
  Mes_sin + Mes_cos
Model 2: episodio ~ Estacion * (sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
  Mes_sin + Mes_cos)
Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1      132921      40537
2      132900      40105 21    432.54 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



```

comparacion_flexibilidad <- tibble(
  Modelo = c(
    "Controles comunes",
    "Controles específicos por estación"
  ),
  AIC = c(
    AIC(mod_conjunto_comun),
    AIC(mod_conjunto_flexible)
  ),
  BIC = c(
    BIC(mod_conjunto_comun),
    BIC(mod_conjunto_flexible)
  )
)

print(comparacion_flexibilidad)

```

```

# A tibble: 2 x 3
  Modelo                                AIC    BIC
  <chr>                                <dbl> <dbl>
1 Controles comunes                    40567. 40714.
2 Controles específicos por estación 40177. 40530.

```

Interpretación. El modelo flexible presenta menores AIC y BIC que la versión con controles comunes. Esto indica que es preferible permitir que la relación de la velocidad del viento, la hora y el mes varíe entre estaciones. Por esta razón, las probabilidades espaciales definitivas se calculan a partir de `mod_conjunto_flexible`.

¿La asociación del sector oriental cambia entre estaciones después de permitir controles específicos?

```

# Modelo flexible, pero SIN interacción Estacion × sector_E.
# Mantiene controles específicos de WSR/hora/mes por estación.
mod_flexible_sin_interaccion_sector <- glm(
  episodio ~
    Estacion * (
      ns(WSR, 3) +
      Hora_sin + Hora_cos +
      Mes_sin + Mes_cos
    )
)

```

```

    ) +
    sector_E,
    data = d_conjunto,
    family = binomial
  )

cat(
  "=== PRUEBA DE INTERACCIÓN ESTACIÓN × SECTOR ORIENTAL ===\n"
)

```

=== PRUEBA DE INTERACCIÓN ESTACIÓN × SECTOR ORIENTAL ===

```

prueba_interaccion_flexible <- anova(
  mod_flexible_sin_interaccion_sector,
  mod_conjunto_flexible,
  test = "Chisq"
)

print(
  prueba_interaccion_flexible
)

```

Analysis of Deviance Table

Model 1: episodio ~ Estacion * (ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos) + sector_E

Model 2: episodio ~ Estacion * (sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos)

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	132903	40301			
2	132900	40105	3	195.77	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

comparacion_interaccion_flexible <- tibble(
  Modelo = c(
    "Sin interacción Estación × sector",
    "Con interacción Estación × sector"
  ),
  AIC = c(
    AIC(

```

```

      mod_flexible_sin_interaccion_sector
    ),
    AIC(
      mod_conjunto_flexible
    )
  ),
  BIC = c(
    BIC(
      mod_flexible_sin_interaccion_sector
    ),
    BIC(
      mod_conjunto_flexible
    )
  )
)

print(
  comparacion_interaccion_flexible
)

```

```

# A tibble: 2 x 3
  Modelo                                AIC    BIC
  <chr>                                <dbl> <dbl>
1 Sin interacción Estación × sector 40367. 40690.
2 Con interacción Estación × sector 40177. 40530.

```

Interpretación. Esta es la prueba global que debe utilizarse para respaldar la interacción `Estacion × sector_E` en la especificación final. Compara dos modelos que ya permiten controles meteorológicos y temporales específicos por estación; la única diferencia es si el contraste sector oriental–resto puede cambiar entre estaciones.

Si la prueba de razón de verosimilitudes resulta significativa y AIC/BIC favorecen al modelo con interacción, queda justificado estimar un contraste Este–Resto diferente para cada estación.

Probabilidades marginales ajustadas con el modelo flexible

```

# Se utiliza una distribución común de WSR, hora y mes
# para estandarizar la comparación entre estaciones.
base_comun <- d_conjunto %>%

```

```

select(
  WSR,
  Hora_sin,
  Hora_cos,
  Mes_sin,
  Mes_cos
)

beta_flex <- coef(
  mod_conjunto_flexible
)

V_flex <- vcov(
  mod_conjunto_flexible
)

tt_flex <- delete.response(
  terms(mod_conjunto_flexible)
)

combinaciones <- expand_grid(
  Estacion = c(
    "SE3",
    "SE2",
    "NE",
    "GAR"
  ),
  sector_E = c(
    "Resto",
    "Este"
  )
)

prob_estacion <- map2_dfr(
  combinaciones$Estacion,
  combinaciones$sector_E,
  function(est, sec) {

    nuevo <- base_comun %>%
      mutate(
        Estacion = factor(
          est,

```

```

        levels = c(
            "SE3",
            "SE2",
            "NE",
            "GAR"
        )
    ),
    sector_E = factor(
        sec,
        levels = c(
            "Resto",
            "Este"
        )
    )
)

X_flex <- model.matrix(
    tt_flex,
    data = nuevo,
    contrasts.arg = mod_conjunto_flexible$contrasts,
    xlev = mod_conjunto_flexible$xlevels
)

X_flex <- X_flex[
    ,
    names(beta_flex),
    drop = FALSE
]

eta <- as.vector(
    X_flex %*% beta_flex
)

p <- plogis(eta)

prob_media <- mean(p)

gradiente <- colMeans(
    sweep(
        X_flex,
        1,
        p * (1 - p),

```

```

      "*"
    )
  )

  se_prob <- sqrt(
    as.numeric(
      t(gradiente) %*%
      V_flex %*%
      gradiente
    )
  )

  tibble(
    Estacion = est,
    Sector = sec,
    Probabilidad = prob_media,
    IC_inf = max(
      0,
      prob_media - 1.96 * se_prob
    ),
    IC_sup = min(
      1,
      prob_media + 1.96 * se_prob
    )
  )
}
)

prob_estacion <- prob_estacion %>%
  mutate(
    Estacion = factor(
      Estacion,
      levels = c(
        "SE3",
        "SE2",
        "NE",
        "GAR"
      )
    ),
    Sector = factor(
      Sector,
      levels = c(

```

```

        "Resto",
        "Este"
    )
),
Prob_pct = round(
    100 * Probabilidad,
    2
),
IC_inf_pct = round(
    100 * IC_inf,
    2
),
IC_sup_pct = round(
    100 * IC_sup,
    2
)
)

print(
  prob_estacion %>%
  select(
    Estacion,
    Sector,
    Prob_pct,
    IC_inf_pct,
    IC_sup_pct
  ),
  n = 8
)

```

A tibble: 8 x 5

	Estacion	Sector	Prob_pct	IC_inf_pct	IC_sup_pct
	<fct>	<fct>	<dbl>	<dbl>	<dbl>
1	SE3	Resto	7.51	7.17	7.85
2	SE3	Este	18.9	18.2	19.6
3	SE2	Resto	4.56	4.25	4.87
4	SE2	Este	6.86	6.36	7.36
5	NE	Resto	2.09	1.92	2.26
6	NE	Este	2.1	1.7	2.5
7	GAR	Resto	0.17	0.08	0.27
8	GAR	Este	0.19	0.09	0.28

```

brecha_estacion <- prob_estacion %>%
  select(
    Estacion,
    Sector,
    Prob_pct
  ) %>%
  pivot_wider(
    names_from = Sector,
    values_from = Prob_pct
  ) %>%
  mutate(
    Diferencia_pp = round(
      Este - Resto,
      2
    )
  )

cat(
  "\n=== DIFERENCIA AJUSTADA: SECTOR ORIENTAL - RESTO ===\n"
)

```

=== DIFERENCIA AJUSTADA: SECTOR ORIENTAL - RESTO ===

```

print(
  brecha_estacion
)

```

```

# A tibble: 4 x 4
  Estacion Resto Este Diferencia_pp
  <fct>     <dbl> <dbl>         <dbl>
1 SE3      7.51 18.9          11.4
2 SE2      4.56  6.86          2.3
3 NE       2.09  2.1           0.01
4 GAR      0.17  0.19          0.02

```

```

prob_estacion_plot <- prob_estacion %>%
  mutate(
    Sector_grafica = recode(
      as.character(Sector),
      "Este" = "Sector oriental (ENE-E-ESE)",

```




```

    "Resto" = "Resto de direcciones"
  )
)

ggplot(
  prob_estacion_plot,
  aes(
    x = Estacion,
    y = Prob_pct,
    fill = Sector_grafica
  )
) +
  geom_col(
    position = position_dodge(
      width = 0.8
    ),
    width = 0.7
  ) +
  geom_errorbar(
    aes(
      ymin = IC_inf_pct,
      ymax = IC_sup_pct
    ),
    position = position_dodge(
      width = 0.8
    ),
    width = 0.2
  ) +
  labs(
    title = "Probabilidad ajustada de episodio de SO2 por estación",
    subtitle = "Modelo conjunto flexible | Sector oriental frente al resto",
    x = "Estación",
    y = "Probabilidad ajustada de episodio (%)",
    fill = "Sector"
  ) +
  theme_minimal(base_size = 12)

```



Interpretación. Estas probabilidades se obtienen estandarizando las cuatro estaciones sobre una distribución común de velocidad del viento, hora y mes, pero permitiendo que cada estación tenga su propia relación con dichas condiciones. De esta forma, la comparación espacial no obliga artificialmente a que WSR y los patrones temporales tengan el mismo efecto en todas las estaciones.

Las barras deben interpretarse como probabilidades marginales ajustadas asociadas al sector oriental y al resto de direcciones dentro de cada estación. La diferencia en puntos porcentuales cuantifica la brecha ajustada entre ambos escenarios.

Los intervalos de confianza de esta figura utilizan la matriz de covarianza convencional del modelo. Posteriormente pueden recalcularse con una estructura robusta si el diagnóstico de dependencia temporal indica que es necesario.

Contrastes Este vs Resto por estación con corrección Holm conjunta

```
emm_sector <- emmeans(
  mod_conjunto_flexible,
  ~ sector_E | Estacion
)

contrastes_estacion <- contrast(
```

```

emm_sector,
method = list(
  "Este vs Resto" = c(-1, 1)
)
)

# Quitar el agrupamiento "by" para tratar los cuatro contrastes
# como una sola familia de pruebas.
contrastes_estacion <- update(
  contrastes_estacion,
  by = NULL
)

resultado_contrastes <- summary(
  contrastes_estacion,
  type = "response",
  infer = c(TRUE, TRUE),
  adjust = "holm"
)

cat(
  "=== CONTRASTES ESTE VS RESTO POR ESTACIÓN ===\n"
)

```

=== CONTRASTES ESTE VS RESTO POR ESTACIÓN ===

```

print(
  resultado_contrastes
)

```

contrast	Estacion	odds.ratio	SE	df	asympt.LCL	asympt.UCL	null	z.ratio
Este vs Resto	SE3	3.19	0.1220	Inf	2.898	3.51	1	30.232
Este vs Resto	SE2	1.58	0.0798	Inf	1.394	1.79	1	9.081
Este vs Resto	NE	1.01	0.1130	Inf	0.761	1.33	1	0.059
Este vs Resto	GAR	1.07	0.3830	Inf	0.441	2.61	1	0.200
p.value								
<0.0001								
<0.0001								
1.0000								
1.0000								

Confidence level used: 0.95

Conf-level adjustment: bonferroni method for 4 estimates

Intervals are back-transformed from the log odds ratio scale

P value adjustment: holm method for 4 tests

Tests are performed on the log odds ratio scale

Interpretación. Estos contrastes comprueban, dentro de cada estación, si los momios de episodio bajo el sector oriental difieren de los correspondientes al resto de direcciones. Los p-values se corrigen conjuntamente mediante Holm para controlar las cuatro comparaciones simultáneas.

Un OR mayor que 1 indica mayores momios bajo el sector oriental; un OR menor que 1 indica menores momios. La significancia individual debe evaluarse con el p-value ajustado y con el intervalo de confianza correspondiente.

Diagnóstico de dependencia temporal de los residuos

Pregunta que responde. ¿Los errores del modelo conjunto flexible siguen mostrando una estructura temporal, es decir, las horas cercanas tienden a presentar residuos parecidos aun después de considerar estación, sector oriental, velocidad del viento, hora y mes?

```
# =====  
# DIAGNÓSTICO DE DEPENDENCIA TEMPORAL DE LOS RESIDUOS  
# Modelo conjunto flexible  
# =====  
  
# 1. Obtener residuos de Pearson del modelo conjunto flexible  
res_temporal <- d_conjunto %>%  
  mutate(  
    residuo_pearson = residuals(  
      mod_conjunto_flexible,  
      type = "pearson"  
    )  
  ) %>%  
  select(  
    fecha,  
    Estacion,  
    residuo_pearson  
  ) %>%  
  arrange(  
    Estacion,
```

```

    fecha
  )

# 2. Verificar que no haya fecha-hora duplicada dentro de una estación
duplicados_tiempo <- res_temporal %>%
  count(
    Estacion,
    fecha
  ) %>%
  filter(n > 1)

cat(
  "Número de fecha-hora duplicadas por estación:",
  nrow(duplicados_tiempo),
  "\n\n"
)

```

Número de fecha-hora duplicadas por estación: 0

```

# 3. Autocorrelación usando separaciones temporales REALES
# Se estudian las siguientes 48 horas.
rezagos <- 1:48

acf_temporal <- map_dfr(
  levels(d_conjunto$Estacion),
  function(est) {
    d_est <- res_temporal %>%
      filter(Estacion == est)

    map_dfr(
      rezagos,
      function(k) {

        # Residuo observado exactamente k horas antes
        d_lag <- d_est %>%
          transmute(
            fecha = fecha + hours(k),
            residuo_anterior = residuo_pearson
          )

        # Solo se comparan observaciones cuya separación temporal
        # real es exactamente k horas.
      }
    )
  }
)

```

```

    pares <- d_est %>%
      select(
        fecha,
        residuo_actual = residuo_pearson
      ) %>%
      inner_join(
        d_lag,
        by = "fecha"
      )

    n_pares <- nrow(pares)

    r <- if (n_pares > 2) {
      cor(
        pares$residuo_actual,
        pares$residuo_anterior,
        use = "complete.obs"
      )
    } else {
      NA_real_
    }

    tibble(
      Estacion = est,
      Rezago_horas = k,
      N_pares = n_pares,
      Autocorrelacion = r,
      Limite_95 = if_else(
        n_pares > 0,
        1.96 / sqrt(n_pares),
        NA_real_
      )
    )
  }
)
}
)

# 4. Valores principales para interpretación
cat("=== AUTOCORRELACIÓN EN REZAGOS SELECCIONADOS ===\n")

```

=== AUTOCORRELACIÓN EN REZAGOS SELECCIONADOS ===

```

acf_temporal %>%
  filter(
    Rezago_horas %in% c(1, 2, 3, 6, 12, 24, 48)
  ) %>%
  mutate(
    Autocorrelacion = round(
      Autocorrelacion,
      3
    ),
    Fuera_IC95 = abs(Autocorrelacion) > Limite_95
  ) %>%
  select(
    Estacion,
    Rezago_horas,
    N_pares,
    Autocorrelacion,
    Fuera_IC95
  ) %>%
  print(n = Inf)

```

A tibble: 28 x 5

	Estacion	Rezago_horas	N_pares	Autocorrelacion	Fuera_IC95
	<chr>	<int>	<int>	<dbl>	<lgl>
1	SE3	1	33607	0.461	TRUE
2	SE3	2	33468	0.249	TRUE
3	SE3	3	33389	0.139	TRUE
4	SE3	6	33268	0.044	TRUE
5	SE3	12	33142	0.088	TRUE
6	SE3	24	33072	0.164	TRUE
7	SE3	48	32922	0.102	TRUE
8	SE2	1	32755	0.44	TRUE
9	SE2	2	32572	0.231	TRUE
10	SE2	3	32474	0.126	TRUE
11	SE2	6	32321	0.037	TRUE
12	SE2	12	32193	0.054	TRUE
13	SE2	24	32065	0.114	TRUE
14	SE2	48	31879	0.097	TRUE
15	NE	1	32591	0.461	TRUE
16	NE	2	32374	0.21	TRUE
17	NE	3	32293	0.138	TRUE
18	NE	6	32137	0.056	TRUE
19	NE	12	31945	0.04	TRUE

20	NE	24	31871	0.093	TRUE
21	NE	48	31812	0.076	TRUE
22	GAR	1	31558	0.154	TRUE
23	GAR	2	31098	0.062	TRUE
24	GAR	3	30970	0.071	TRUE
25	GAR	6	30784	-0.001	FALSE
26	GAR	12	30687	0.015	TRUE
27	GAR	24	30663	0.006	FALSE
28	GAR	48	30592	0.013	TRUE

```
# 5. Mayor autocorrelación absoluta observada por estación
cat("\n=== MAYOR AUTOCORRELACIÓN ABSOLUTA POR ESTACIÓN ===\n")
```

```
=== MAYOR AUTOCORRELACIÓN ABSOLUTA POR ESTACIÓN ===
```

```
acf_temporal %>%
  group_by(Estacion) %>%
  slice_max(
    order_by = abs(Autocorrelacion),
    n = 1,
    with_ties = FALSE
  ) %>%
  ungroup() %>%
  mutate(
    Autocorrelacion = round(
      Autocorrelacion,
      3
    )
  ) %>%
  select(
    Estacion,
    Rezago_horas,
    Autocorrelacion
  ) %>%
  print()
```


```
# A tibble: 4 x 3
  Estacion Rezago_horas Autocorrelacion
  <chr>      <int>          <dbl>
1 GAR             1          0.154
```


2 NE	1	0.461
3 SE2	1	0.44
4 SE3	1	0.461

```
# 6. Gráfica
ggplot(
  acf_temporal,
  aes(
    x = Rezago_horas,
    y = Autocorrelacion
  )
) +
  geom_ribbon(
    aes(
      ymin = -Limite_95,
      ymax = Limite_95
    ),
    alpha = 0.15
  ) +
  geom_hline(
    yintercept = 0,
    linetype = "dashed"
  ) +
  geom_segment(
    aes(
      xend = Rezago_horas,
      y = 0,
      yend = Autocorrelacion
    )
  ) +
  facet_wrap(
    ~ Estacion,
    ncol = 2
  ) +
  scale_x_continuous(
    breaks = seq(0, 48, 6)
  ) +
  labs(
    title = "Dependencia temporal de los residuos del modelo conjunto",
    subtitle = "Residuos de Pearson | Rezagos temporales reales de 1 a 48 horas",
    x = "Rezago (horas)",
    y = "Autocorrelación residual"
  )
```

```
) +  
theme_minimal(base_size = 12)
```

Dependencia temporal de los residuos del modelo conjun Residuos de Pearson | Rezagos temporales reales de 1 a 48 horas



Interpretación. El diagnóstico muestra que los residuos de horas cercanas no son completamente independientes. En el render previo, la mayor dependencia se observó a una hora de rezago en SE3, SE2 y NE, mientras que GAR presentó una dependencia menor. Esto indica que parte de la estructura temporal de los episodios no queda explicada por el modelo conjunto actual.

Este resultado no invalida las asociaciones estimadas. Sí justifica dos decisiones posteriores: respetar el orden temporal al evaluar generalización y utilizar errores estándar robustos para la inferencia cuando sea necesario. La dependencia temporal tampoco implica que un error en una hora obligatoriamente se repita en la siguiente; únicamente indica una tendencia de los errores cercanos a estar relacionados.

Modelo meteorológico ampliado en SE3

Objetivo y preparación

Pregunta central. Después de considerar velocidad del viento, temperatura, humedad, presión, radiación, lluvia, hora y mes, ¿la dirección del viento sigue aportando información importante para explicar la ocurrencia de episodios elevados de SO_2 en SE3?

La dirección del viento se mantiene como variable central del estudio. Las demás variables meteorológicas se incorporan como controles para comprobar si el patrón direccional, particularmente el sector oriental, persiste bajo condiciones meteorológicas comparables.

La selección del modelo se realiza exclusivamente con 2022–2024. El año 2025 se conserva fuera del proceso de selección para evaluar generalización temporal.

```
# Base completa de SE3 para el modelo meteorológico ampliado.
# Las variables continuas se conservan en sus unidades originales.
d_met_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  select(
    fecha,
    Año,
    episodio,
    sector,
    WSR,
    TOUT,
    RH,
    PRS,
    SR,
    RAINF,
    Hora_sin,
    Hora_cos,
    Mes_sin,
    Mes_cos
  ) %>%
  drop_na() %>%
  mutate(
    sector = factor(
      sector,
      levels = rumbos
    ),
    sector = relevel(
      sector,
      ref = "N"
    ),
    dia = as.Date(fecha)
  )

# Separación temporal: selección y entrenamiento en 2022–2024;
# evaluación fuera de muestra en 2025.
d_met_tr <- d_met_se3 %>%
```

```

filter(Año <= 2024)

d_met_te <- d_met_se3 %>%
  filter(Año == 2025)

cat("=== BASE DEL MODELO METEOROLÓGICO AMPLIADO ===\n")

```

=== BASE DEL MODELO METEOROLÓGICO AMPLIADO ===

```
cat("SE3 total:", nrow(d_met_se3), "horas\n")
```

SE3 total: 33977 horas

```
cat("Entrenamiento 2022-2024:", nrow(d_met_tr), "horas\n")
```

Entrenamiento 2022-2024: 25426 horas

```
cat("Prueba 2025:", nrow(d_met_te), "horas\n")
```

Prueba 2025: 8551 horas

```
cat("Tasa de episodio entrenamiento:", round(mean(d_met_tr$episodio), 4), "\n")
```

Tasa de episodio entrenamiento: 0.1093

```
cat("Tasa de episodio prueba:", round(mean(d_met_te$episodio), 4), "\n\n")
```

Tasa de episodio prueba: 0.1371

```

# RAINF tiene una distribución muy concentrada en cero.
# log1p(RAINF) conserva la cantidad de precipitación y reduce su asimetría.
# Para el resto de variables meteorológicas continuas se permiten
# relaciones no lineales mediante splines naturales de 3 g.l.
formula_met_completa <- episodio ~
  sector +
  ns(WSR, 3) +
  ns(TOUT, 3) +

```

```

ns(RH, 3) +
ns(PRS, 3) +
ns(SR, 3) +
log1p(RAINF) +
Hora_sin + Hora_cos +
Mes_sin + Mes_cos

mod_met_completo_tr <- glm(
  formula_met_completa,
  data = d_met_tr,
  family = binomial
)

cat("Modelo meteorológico completo ajustado en 2022-2024.\n")

```

Modelo meteorológico completo ajustado en 2022-2024.

```
cat("AIC:", round(AIC(mod_met_completo_tr), 1), "\n")
```

AIC: 13525.3

```
cat("BIC:", round(BIC(mod_met_completo_tr), 1), "\n")
```

BIC: 13818.5

Interpretación. El modelo completo parte de todas las variables meteorológicas disponibles. La dirección se representa mediante los 16 rumbos ya utilizados en el análisis principal. WSR, TOUT, RH, PRS y SR se modelan con splines naturales para no imponer que su relación con la probabilidad de episodio sea estrictamente lineal. RAINF se incorpora como $\log_{1p}(\text{RAINF})$ debido a su concentración de valores cercanos a cero.

La hora y el mes se conservan como controles cíclicos porque ya forman parte de la estructura temporal utilizada en los modelos anteriores.

Selección de variables meteorológicas con AIC y BIC

La dirección, la hora y el mes se mantienen obligatoriamente porque forman parte del diseño principal. AIC y BIC se utilizan para decidir cuáles de los demás bloques meteorológicos aportan suficiente información para permanecer en el modelo.

Cada spline se trata como un bloque completo; por lo tanto, la selección no elimina columnas individuales de una misma transformación.

```
# Modelo mínimo permitido durante la selección.
# Dirección y controles temporales no se eliminan.
formula_met_minima <- episodio ~
  sector +
  Hora_sin + Hora_cos +
  Mes_sin + Mes_cos

# Selección backward según AIC
mod_met_aic_tr <- step(
  mod_met_completo_tr,
  scope = list(
    lower = formula_met_minima,
    upper = formula_met_completa
  ),
  direction = "backward",
  k = 2,
  trace = 0
)

# Selección backward según BIC.
# BIC penaliza con mayor fuerza la complejidad.
mod_met_bic_tr <- step(
  mod_met_completo_tr,
  scope = list(
    lower = formula_met_minima,
    upper = formula_met_completa
  ),
  direction = "backward",
  k = log(nobs(mod_met_completo_tr)),
  trace = 0
)

comparacion_seleccion <- tibble(
  Modelo = c(
    "Completo",
    "Seleccionado por AIC",
    "Seleccionado por BIC"
  ),
  AIC = c(
    AIC(mod_met_completo_tr),
```

```

      AIC(mod_met_aic_tr),
      AIC(mod_met_bic_tr)
    ),
    BIC = c(
      BIC(mod_met_completo_tr),
      BIC(mod_met_aic_tr),
      BIC(mod_met_bic_tr)
    ),
    Parametros = c(
      length(coef(mod_met_completo_tr)),
      length(coef(mod_met_aic_tr)),
      length(coef(mod_met_bic_tr))
    )
  ) %>%
  mutate(
    AIC = round(AIC, 1),
    BIC = round(BIC, 1)
  )

print(comparacion_seleccion)

```

```

# A tibble: 3 x 4
  Modelo          AIC    BIC Parametros
  <chr>         <dbl> <dbl>      <int>
1 Completo      13525. 13818.         36
2 Seleccionado por AIC 13524. 13809         35
3 Seleccionado por BIC 13524. 13809         35

```

```

# Tabla sencilla de qué variables meteorológicas fueron conservadas.
terminos_aic <- attr(
  terms(mod_met_aic_tr),
  "term.labels"
)

terminos_bic <- attr(
  terms(mod_met_bic_tr),
  "term.labels"
)

esta_retenida <- function(terminos, variable) {
  any(str_detect(

```

```

      terminos,
      fixed(variable)
    ))
  }

tabla_retencion <- tibble(
  Variable = c(
    "WSR",
    "TOUT",
    "RH",
    "PRS",
    "SR",
    "RAINF"
  ),
  AIC = map_lgl(
    Variable,
    ~ esta_retenida(terminos_aic, .x)
  ),
  BIC = map_lgl(
    Variable,
    ~ esta_retenida(terminos_bic, .x)
  )
)

cat("\n=== VARIABLES METEOROLÓGICAS RETENIDAS ===\n")

```

=== VARIABLES METEOROLÓGICAS RETENIDAS ===

```
print(tabla_retencion)
```

```

# A tibble: 6 x 3
  Variable AIC   BIC
  <chr>    <lgl> <lgl>
1 WSR      TRUE  TRUE
2 TOUT     TRUE  TRUE
3 RH       TRUE  TRUE
4 PRS      TRUE  TRUE
5 SR       TRUE  TRUE
6 RAINF    FALSE FALSE

```



```
cat("\n=== FÓRMULA SELECCIONADA POR AIC ===\n")
```

```
=== FÓRMULA SELECCIONADA POR AIC ===
```

```
print(formula(mod_met_aic_tr))
```

```
episodio ~ sector + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) + ns(PRS,  
  3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos
```

```
cat("\n=== FÓRMULA SELECCIONADA POR BIC ===\n")
```

```
=== FÓRMULA SELECCIONADA POR BIC ===
```

```
print(formula(mod_met_bic_tr))
```

```
episodio ~ sector + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) + ns(PRS,  
  3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos
```

Interpretación. AIC y BIC no se interpretan como pruebas causales. Se utilizan para balancear ajuste y complejidad: un valor menor es preferible dentro de modelos ajustados sobre la misma muestra. BIC aplica una penalización mayor y por ello suele producir una especificación más parsimoniosa.

Para el análisis principal se adopta la especificación seleccionada por BIC. La selección AIC se conserva como análisis de sensibilidad: si ambos criterios retienen variables similares, aumenta la estabilidad de la elección; si difieren, la diferencia debe reportarse en lugar de ocultarse.

¿La dirección sigue aportando información después de controlar toda la meteorología seleccionada?

```
# El modelo BIC es la especificación principal.  
mod_met_final_tr <- mod_met_bic_tr  
  
# Mismo modelo, pero eliminando la dirección.  
# Todas las demás variables permanecen idénticas.
```

```
mod_met_sin_direccion_tr <- update(
  mod_met_final_tr,
  . ~ . - sector
)

cat("=== APORTE GLOBAL DE LA DIRECCIÓN DEL VIENTO ===\n")
```

=== APORTE GLOBAL DE LA DIRECCIÓN DEL VIENTO ===

```
prueba_direccion_tr <- anova(
  mod_met_sin_direccion_tr,
  mod_met_final_tr,
  test = "Chisq"
)

print(prueba_direccion_tr)
```

Analysis of Deviance Table

Model 1: episodio ~ ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) + ns(PRS, 3) +
ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos

Model 2: episodio ~ sector + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) + ns(PRS,
3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	25406	14647			
2	25391	13454	15	1192.7	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
comparacion_direccion <- tibble(
  Modelo = c(
    "Sin dirección",
    "Con dirección"
  ),
  AIC = c(
    AIC(mod_met_sin_direccion_tr),
    AIC(mod_met_final_tr)
  ),
  BIC = c(
    BIC(mod_met_sin_direccion_tr),
```

```

      BIC(mod_met_final_tr)
    )
  ) %>%
  mutate(
    AIC = round(AIC, 1),
    BIC = round(BIC, 1)
  )

print(comparacion_direccion)

```

```

# A tibble: 2 x 3
  Modelo      AIC    BIC
  <chr>      <dbl> <dbl>
1 Sin dirección 14687. 14850.
2 Con dirección 13524. 13809

```

```

# Una vez elegida la estructura usando únicamente 2022-2024,
# se reajusta la MISMA fórmula con todo 2022-2025 para obtener
# estimaciones finales descriptivas del periodo completo.
formula_met_final <- formula(mod_met_final_tr)

mod_met_final <- glm(
  formula_met_final,
  data = d_met_se3,
  family = binomial
)

mod_met_sin_direccion <- update(
  mod_met_final,
  . ~ . - sector
)

# Inferencia robusta agrupada por día para reducir el impacto
# de la dependencia temporal intradía sobre los errores estándar.
V_met_rob <- vcovCL(
  mod_met_final,
  cluster = d_met_se3$día
)

rob_met <- coeftest(
  mod_met_final,

```

```

vcov. = V_met_rob
)

# Convertir explícitamente la salida de coeftest a un tibble limpio.
# Esto evita un conflicto entre la clase "coeftest" y vctrs/dplyr
# que puede producir errores internos al usar as.data.frame().
rob_tab <- tibble(
  term = rownames(rob_met),
  estimate = as.numeric(rob_met[, "Estimate"]),
  std_error = as.numeric(rob_met[, "Std. Error"]),
  p_value = as.numeric(rob_met[, "Pr(>|z|)"])
)

rob_dir <- rob_tab %>%
  filter(str_detect(term, "^sector")) %>%
  transmute(
    Rumbo = str_remove(term, "^sector"),
    OR_robusto = exp(estimate),
    IC_inf = exp(estimate - 1.96 * std_error),
    IC_sup = exp(estimate + 1.96 * std_error),
    p = p_value,
    p_Holm = p.adjust(p_value, method = "holm")
  ) %>%
  mutate(
    across(
      c(OR_robusto, IC_inf, IC_sup),
      ~ round(.x, 2)
    ),
    p = signif(p, 3),
    p_Holm = signif(p_Holm, 3)
  ) %>%
  arrange(desc(OR_robusto))

cat("\n=== OR POR RUMBO CON ERRORES ROBUSTOS AGRUPADOS POR DÍA ===\n")

```

=== OR POR RUMBO CON ERRORES ROBUSTOS AGRUPADOS POR DÍA ===

```
print(rob_dir, n = 15)
```

A tibble: 15 x 6

	Rumbo	OR_robusto	IC_inf	IC_sup	p	p_Holm
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	E	6.47	4.78	8.76	1.01e-33	1.52e-32
2	ESE	2.65	1.96	3.58	2.44e-10	3.17e-9
3	ENE	2.07	1.5	2.87	1.02e-5	1.02e-4
4	SSE	1.44	1.04	1.98	2.82e-2	1.97e-1
5	SE	1.42	1.05	1.93	2.26e-2	1.81e-1
6	NE	1.14	0.81	1.61	4.56e-1	1 e+0
7	NNE	1.09	0.75	1.59	6.48e-1	1 e+0
8	S	1.08	0.75	1.56	6.84e-1	1 e+0
9	SO	0.88	0.53	1.44	5.99e-1	1 e+0
10	SSO	0.72	0.46	1.14	1.65e-1	8.24e-1
11	OSO	0.63	0.36	1.1	1.04e-1	6.25e-1
12	O	0.29	0.15	0.54	1.23e-4	1.11e-3
13	ONO	0.29	0.18	0.49	2.84e-6	3.12e-5
14	NNO	0.23	0.15	0.37	3.37e-10	4.04e-9
15	NO	0.09	0.05	0.17	7.78e-15	1.09e-13

```
# Aporte de cada término retenido en la especificación final.
cat("\n=== PRUEBA DE ELIMINACIÓN DE TÉRMINOS DEL MODELO FINAL ===\n")
```

=== PRUEBA DE ELIMINACIÓN DE TÉRMINOS DEL MODELO FINAL ===

```
print(
  drop1(
    mod_met_final,
    test = "Chisq"
  )
)
```

Single term deletions

```
Model:
episodio ~ sector + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) + ns(PRS,
  3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos
      Df Deviance   AIC    LRT Pr(>Chi)
<none>          19146 19216
sector      15    20831 20871 1684.94 < 2.2e-16 ***
ns(WSR, 3)   3    19176 19240  29.29 1.945e-06 ***
ns(TOUT, 3)  3    19227 19291  80.36 < 2.2e-16 ***
```

```

ns(RH, 3)      3      19293 19357   146.66 < 2.2e-16 ***
ns(PRS, 3)     3      19167 19231    21.13 9.878e-05 ***
ns(SR, 3)      3      19265 19329   118.63 < 2.2e-16 ***
Hora_sin      1      19175 19243    29.01 7.216e-08 ***
Hora_cos      1      19407 19475   261.05 < 2.2e-16 ***
Mes_sin       1      19167 19235    20.96 4.686e-06 ***
Mes_cos       1      19169 19237    22.60 1.998e-06 ***

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Interpretación. La comparación Sin dirección frente a Con dirección es la prueba principal de esta extensión. Ambos modelos contienen exactamente los mismos controles meteorológicos y temporales; la única diferencia es la información direccional. Si el modelo con dirección presenta menor AIC/BIC y la razón de verosimilitudes es significativa, la dirección aporta información adicional sobre la ocurrencia de episodios aun después de controlar por las demás condiciones meteorológicas seleccionadas.

Los OR robustos permiten revisar cuáles rumbos presentan asociaciones mayores o menores frente a Norte sin depender únicamente de errores estándar convencionales. La corrección Holm se utiliza para no interpretar quince comparaciones de rumbo como si fueran pruebas independientes sin ajuste.

`drop1()` complementa la selección mostrando cuánto se deteriora el modelo al retirar, uno por uno, los términos que permanecieron en la especificación final.

Generalización temporal: 2022–2024 frente a 2025

```

# Modelo de referencia anterior, ajustado sobre EXACTAMENTE la misma
# muestra de entrenamiento que el modelo meteorológico ampliado.
mod_base_16_tr <- glm(
  episodio ~
    sector +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_met_tr,
  family = binomial
)

# Probabilidades de 2025
p_base_2025 <- predict(

```

```

    mod_base_16_tr,
    newdata = d_met_te,
    type = "response"
  )

p_met_2025 <- predict(
  mod_met_final_tr,
  newdata = d_met_te,
  type = "response"
)

# Métricas fuera de muestra
auc_base_2025 <- as.numeric(
  auc(
    roc(
      d_met_te$episodio,
      p_base_2025,
      quiet = TRUE
    )
  )
)

auc_met_2025 <- as.numeric(
  auc(
    roc(
      d_met_te$episodio,
      p_met_2025,
      quiet = TRUE
    )
  )
)

brier_base_2025 <- mean(
  (p_base_2025 - d_met_te$episodio)^2
)

brier_met_2025 <- mean(
  (p_met_2025 - d_met_te$episodio)^2
)

validacion_2025 <- tibble(
  Modelo = c(

```

```

    "Dirección + WSR + tiempo",
    "Meteorología ampliada seleccionada"
  ),
  AUC_2025 = c(
    auc_base_2025,
    auc_met_2025
  ),
  Brier_2025 = c(
    brier_base_2025,
    brier_met_2025
  )
) %>%
mutate(
  AUC_2025 = round(AUC_2025, 3),
  Brier_2025 = round(Brier_2025, 4)
)

cat("=== VALIDACIÓN TEMPORAL EN 2025 ===\n")

```

```

=== VALIDACIÓN TEMPORAL EN 2025 ===

```

```

print(validacion_2025)

```

```

# A tibble: 2 x 3
  Modelo                                AUC_2025 Brier_2025
  <chr>                                <dbl>     <dbl>
1 Dirección + WSR + tiempo            0.789     0.104
2 Meteorología ampliada seleccionada    0.794     0.106

```

```

# Calibración descriptiva por deciles en 2025.
calibracion_2025 <- d_met_te %>%
  mutate(
    prob_met = p_met_2025,
    decil = ntile(prob_met, 10)
  ) %>%
  group_by(decil) %>%
  summarise(
    n = n(),
    Prob_media = mean(prob_met),
    Frecuencia_observada = mean(episodio),
    .groups = "drop"
  )

```



```

)

print(
  calibracion_2025 %>%
    mutate(
      Prob_media = round(100 * Prob_media, 2),
      Frecuencia_observada = round(100 * Frecuencia_observada, 2)
    )
)

```

```

# A tibble: 10 x 4
  decil      n Prob_media Frecuencia_observada
  <int> <int>      <dbl>          <dbl>
1     1    856      0.19            0.93
2     2    855      0.61            1.29
3     3    855      1.25            3.27
4     4    855      2.16            5.26
5     5    855      3.44            6.55
6     6    855      5.18           10.9
7     7    855      7.42           16.5
8     8    855     10.9           22.1
9     9    855     18.2           30.9
10    10    855     35.5           39.4


```

```

ggplot(
  calibracion_2025,
  aes(
    x = 100 * Prob_media,
    y = 100 * Frecuencia_observada
  )
) +
  geom_abline(
    intercept = 0,
    slope = 1,
    linetype = "dashed"
  ) +
  geom_point(size = 3) +
  geom_line() +
  labs(
    title = "Calibración fuera de muestra del modelo meteorológico",
    subtitle = "SE3 | Año de prueba: 2025",

```

```
x = "Probabilidad media estimada (%)",
y = "Frecuencia observada de episodio (%)"
) +
theme_minimal(base_size = 12)
```



Interpretación. Esta validación no mezcla horas aleatoriamente: el modelo se selecciona y ajusta con 2022–2024 y se evalúa en un periodo posterior completo, 2025. Esto es especialmente importante porque el diagnóstico temporal mostró dependencia entre horas cercanas.

El AUC evalúa discriminación y el Brier evalúa la precisión de las probabilidades. Para AUC, valores mayores indican mejor separación entre horas con y sin episodio; para Brier, valores menores son mejores. La comparación con el modelo previo permite comprobar si incorporar meteorología adicional realmente mejora la generalización y no solo el ajuste dentro de muestra.

La gráfica de calibración compara probabilidades medias estimadas con frecuencias realmente observadas en 2025. Una mayor cercanía a la diagonal indica mejor correspondencia entre probabilidad y frecuencia.

Probabilidad ajustada por los 16 rumbos después de controlar la meteorología

```

beta_met <- coef(mod_met_final)
V_met <- V_met_rob

tt_met <- delete.response(
  terms(mod_met_final)
)

rumbos_met <- levels(d_met_se3$sector)

prob_direccion_met <- map_dfr(
  rumbos_met,
  function(r) {

    # Estandarización marginal:
    # se fija únicamente la dirección y se conserva la distribución
    # observada de las demás condiciones meteorológicas y temporales.
    nuevo <- d_met_se3 %>%
      mutate(
        sector = factor(
          r,
          levels = rumbos_met
        )
      )

    X_met <- model.matrix(
      tt_met,
      data = nuevo,
      contrasts.arg = mod_met_final$contrasts,
      xlev = mod_met_final$xlevels
    )

    X_met <- X_met[
      ,
      names(beta_met),
      drop = FALSE
    ]

    eta <- as.vector(
      X_met %*% beta_met
    )
  }
)

```

```

p <- plogis(eta)
prob_media <- mean(p)

# Delta method usando la covarianza robusta agrupada por día.
gradiente <- colMeans(
  sweep(
    X_met,
    1,
    p * (1 - p),
    "*"
  )
)

se_prob <- sqrt(
  as.numeric(
    t(gradiente) %*%
    V_met %*%
    gradiente
  )
)

tibble(
  Rumbo = r,
  Prob_ajustada = prob_media,
  IC_inf = max(
    0,
    prob_media - 1.96 * se_prob
  ),
  IC_sup = min(
    1,
    prob_media + 1.96 * se_prob
  )
)
}
)

prob_direccion_met <- prob_direccion_met %>%
  mutate(
    Prob_pct = 100 * Prob_ajustada,
    IC_inf_pct = 100 * IC_inf,
    IC_sup_pct = 100 * IC_sup
  )

```

```
cat("=== PROBABILIDAD AJUSTADA POR RUMBO CON METEOROLOGÍA AMPLIADA ===\n")
```

```
=== PROBABILIDAD AJUSTADA POR RUMBO CON METEOROLOGÍA AMPLIADA ===
```

```
print(
  prob_direccion_met %>%
    transmute(
      Rumbo,
      Prob_pct = round(Prob_pct, 2),
      IC_inf_pct = round(IC_inf_pct, 2),
      IC_sup_pct = round(IC_sup_pct, 2)
    ),
  n = 16
)
```

```
# A tibble: 16 x 4
  Rumbo Prob_pct IC_inf_pct IC_sup_pct
  <chr>   <dbl>   <dbl>   <dbl>
1 N       7.64     5.77     9.52
2 NNE     8.23     6.2      10.3
3 NE      8.53     7.02     10.0
4 ENE    13.7     12.0     15.3
5 E      28.6     26.8     30.4
6 ESE    16.3     15.1     17.5
7 SE     10.2     9.35     11.1
8 SSE    10.3     9.11     11.5
9 S       8.15     6.61     9.69
10 SSO    5.79     4.01     7.56
11 SO     6.83     4.47     9.18
12 OSO    5.14     2.92     7.37
13 O      2.49     1.13     3.86
14 ONO    2.53     1.47     3.59
15 NO     0.85     0.39     1.31
16 NNO    2.05     1.3      2.8
```

```
# Comparación compacta con el modelo direccional anterior.
comparacion_prob_direccion <- prob_direccion %>%
  select(
    Rumbo,
    Prob_anterior_pct = Prob_pct
```

```

) %>%
left_join(
  prob_direccion_met %>%
    transmute(
      Rumbo,
      Prob_meteo_pct = round(Prob_pct, 2)
    ),
  by = "Rumbo"
) %>%
mutate(
  Cambio_pp = round(
    Prob_meteo_pct - Prob_anterior_pct,
    2
  )
)

cat("\n=== CAMBIO RESPECTO AL MODELO AJUSTADO SOLO POR WSR, HORA Y MES ===\n")

```

=== CAMBIO RESPECTO AL MODELO AJUSTADO SOLO POR WSR, HORA Y MES ===

```
print(comparacion_prob_direccion, n = 16)
```


A tibble: 16 x 4

	Rumbo	Prob_anterior_pct	Prob_meteo_pct	Cambio_pp
	<chr>	<dbl>	<dbl>	<dbl>
1	N	7.69	7.64	-0.05
2	NNE	8.09	8.23	0.14
3	NE	8.21	8.53	0.32
4	ENE	13.6	13.7	0.09
5	E	29.4	28.6	-0.76
6	ESE	16.6	16.3	-0.28
7	SE	10.9	10.2	-0.7
8	SSE	11.0	10.3	-0.76
9	S	8.59	8.15	-0.44
10	SSO	6.18	5.79	-0.39
11	SO	6.53	6.83	0.3
12	OSO	4.45	5.14	0.69
13	O	2.04	2.49	0.45
14	ONO	2.15	2.53	0.38
15	NO	0.68	0.85	0.17
16	NNO	1.98	2.05	0.07

```

ggplot(
  prob_direccion_met,
  aes(
    x = factor(
      Rumbo,
      levels = rumbos_met
    ),
    y = Prob_pct
  )
) +
  geom_col() +
  geom_errorbar(
    aes(
      ymin = IC_inf_pct,
      ymax = IC_sup_pct
    ),
    width = 0.25
  ) +
  labs(
    title = "Probabilidad ajustada de episodio de SO2 según la dirección del viento",
    subtitle = "SE3 | Ajustada por la meteorología seleccionada y con IC robustos",
    x = "Dirección de procedencia del viento",
    y = "Probabilidad ajustada de episodio (%)"
  ) +
  theme_minimal(base_size = 12)

```



Interpretación. Esta figura responde directamente a la pregunta principal del análisis ampliado. Para cada rumbo se fija la dirección y se conservan las condiciones observadas de las demás variables del modelo; después se promedian las probabilidades estimadas. Por ello, las diferencias direccionales ya no pueden explicarse únicamente por diferencias en velocidad, temperatura, humedad, presión, radiación, lluvia, hora o mes que hayan sido retenidas por la selección.

La comparación con `prob_direccion` permite revisar si el patrón oriental observado en el modelo original se conserva, disminuye o cambia después del ajuste meteorológico ampliado. Si E, ENE y ESE continúan entre los rumbos de mayor probabilidad, el hallazgo direccional se vuelve más robusto frente a confusión meteorológica.

Estas probabilidades siguen siendo asociaciones ajustadas; no identifican por sí solas una fuente causal específica.

Misma dirección del viento bajo diferentes condiciones meteorológicas

En esta sección se fija la dirección en **Este** y se modifica una condición meteorológica a la vez dentro de un rango observado. Las demás condiciones permanecen con su distribución real y las probabilidades se promedian. Esto permite responder, por ejemplo, cómo cambia la probabilidad ajustada de episodio con viento del Este a diferentes velocidades o niveles de humedad.

No se incluyen interacciones Dirección $\times$ Meteorología en esta etapa. Por lo tanto, estas curvas describen probabilidades bajo distintos escenarios con dirección Este, pero no prueban que una variable meteorológica modifique específicamente el efecto causal de esa dirección.

```
variables_meteo <- c(
  "WSR",
  "TOUT",
  "RH",
  "PRS",
  "SR",
  "RAINF"
)

etiquetas_meteo <- c(
  WSR = "Velocidad del viento (WSR)",
  TOUT = "Temperatura (TOUT)",
  RH = "Humedad relativa (RH)",
  PRS = "Presión (PRS)",
  SR = "Radiación solar (SR)",
  RAINF = "Precipitación (RAINF)"
)

# Determinar si cada variable quedó en la especificación BIC final.
terminos_finales_met <- attr(
  terms(mod_met_final),
  "term.labels"
)

retenida_final <- function(variable) {
  any(
    str_detect(
      terminos_finales_met,
      fixed(variable)
    )
  )
}

# Crear rangos realistas de evaluación.
# Para lluvia se usa 0 y cuantiles de las observaciones positivas,
# ya que la gran mayoría de las horas tiene RAINF = 0.
crear_grid_meteo <- function(variable) {
  x <- d_met_se3[[variable]]
```

```

if (variable == "RAINF") {
  positivos <- x[x > 0]

  if (length(positivos) == 0) {
    return(0)
  }

  return(
    sort(
      unique(
        c(
          0,
          as.numeric(
            quantile(
              positivos,
              probs = c(
                0.25,
                0.50,
                0.75,
                0.90,
                0.95
              ),
              na.rm = TRUE
            )
          )
        )
      )
    )
  )
}

seq(
  as.numeric(
    quantile(
      x,
      0.05,
      na.rm = TRUE
    )
  ),
  as.numeric(
    quantile(
      x,

```

```

    0.95,
    na.rm = TRUE
  )
),
length.out = 21
)
}

curvas_meteo_este <- map_dfr(
  variables_meteo,
  function(variable) {

    valores <- crear_grid_meteo(variable)

    map_dfr(
      valores,
      function(valor) {

        nuevo <- d_met_se3 %>%
          mutate(
            sector = factor(
              "E",
              levels = rumbos_met
            )
          )

        nuevo[[variable]] <- valor

        p <- predict(
          mod_met_final,
          newdata = nuevo,
          type = "response"
        )

        tibble(
          Variable = variable,
          Valor = valor,
          Probabilidad = mean(p),
          Retenida_BIC = retenida_final(variable)
        )
      }
    )
  }
)

```

```

    }
  ) %>%
  mutate(
    Etiqueta = recode(
      Variable,
      !!!etiquetas_meteo
    )
  )

cat("=== ESTADO DE CADA VARIABLE EN EL MODELO BIC ===\n")

```

=== ESTADO DE CADA VARIABLE EN EL MODELO BIC ===

```

curvas_meteo_este %>%
  distinct(
    Variable,
    Retenida_BIC
  ) %>%
  print()

```

```

# A tibble: 6 x 2
  Variable Retenida_BIC
  <chr>    <lgl>
1 WSR      TRUE
2 TOUT     TRUE
3 RH       TRUE
4 PRS      TRUE
5 SR       TRUE
6 RAINF    FALSE

```

```

# Resumen de valores bajo, intermedio y alto dentro del rango evaluado.
resumen_escenarios_este <- curvas_meteo_este %>%
  group_by(
    Variable,
    Etiqueta,
    Retenida_BIC
  ) %>%
  arrange(Valor, .by_group = TRUE) %>%
  summarise(
    Valor_bajo = first(Valor),
    Prob_baja_pct = 100 * first(Probabilidad),

```

```

    Valor_intermedio = Valor[ceiling(n() / 2)],
    Prob_intermedia_pct = 100 * Probabilidad[ceiling(n() / 2)],
    Valor_alto = last(Valor),
    Prob_alta_pct = 100 * last(Probabilidad),
    Cambio_pp = 100 * (last(Probabilidad) - first(Probabilidad)),
    .groups = "drop"
  ) %>%
  mutate(
    across(
      c(
        Valor_bajo,
        Prob_baja_pct,
        Valor_intermedio,
        Prob_intermedia_pct,
        Valor_alto,
        Prob_alta_pct,
        Cambio_pp
      ),
      ~ round(.x, 2)
    )
  )

cat("\n=== ESCENARIOS CON DIRECCIÓN FIJA EN ESTE ===\n")

```

=== ESCENARIOS CON DIRECCIÓN FIJA EN ESTE ===

```
print(resumen_escenarios_este, n = Inf)
```

A tibble: 6 x 10


	Variable	Etiqueta	Retenida_BIC	Valor_bajo	Prob_baja_pct	Valor_intermedio
	<chr>	<chr>	<lgl>	<dbl>	<dbl>	<dbl>
1	PRS	Presión (PRS)	TRUE	721.	25.8	729.
2	RAINF	Precipitación~	FALSE	0	28.6	0.02
3	RH	Humedad relat~	TRUE	23	33.5	56
4	SR	Radiación sol~	TRUE	0	27.6	0.32
5	TOUT	Temperatura (~	TRUE	10.3	20.8	22.9
6	WSR	Velocidad del~	TRUE	1.8	26.7	8.7

i 4 more variables: Prob_intermedia_pct <dbl>, Valor_alto <dbl>,

Prob_alta_pct <dbl>, Cambio_pp <dbl>

```
ggplot(
  curvas_meteo_este,
  aes(
    x = Valor,
    y = 100 * Probabilidad
  )
) +
  geom_line(linewidth = 0.9) +
  geom_point(size = 1.5) +
  facet_wrap(
    ~ Etiqueta,
    scales = "free_x"
  ) +
  labs(
    title = "Probabilidad de episodio con viento del Este bajo distintas condiciones",
    subtitle = "SE3 | Una variable cambia a la vez; las demás conservan su distribución obser",
    x = "Valor de la condición meteorológica",
    y = "Probabilidad ajustada de episodio (%)"
  ) +
  theme_minimal(base_size = 11)
```

Probabilidad de episodio con viento del Este bajo distintas condiciones
SE3 | Una variable cambia a la vez; las demás conservan su distribución o



Interpretación. Las curvas permiten pasar de una conclusión general sobre dirección a una descripción meteorológica más detallada. Cada panel responde cómo cambia la probabilidad

promedio estimada de episodio cuando el viento se fija en Este y una condición meteorológica recorre valores observados realistas.

Una variable que haya sido excluida por BIC producirá una curva plana en el modelo final, porque ya no forma parte de la ecuación. Para las variables retenidas, la forma de la curva muestra si la probabilidad aumenta, disminuye o presenta una relación no lineal dentro del rango observado.

Estas curvas no deben interpretarse como efectos causales aislados. Son probabilidades ajustadas derivadas del modelo estadístico.

¿La meteorología adicional reduce la dependencia temporal residual?

Para comparar de manera justa, se reajusta el modelo direccional anterior y el modelo meteorológico final sobre la misma base de SE3. La autocorrelación se calcula únicamente entre pares de observaciones separados exactamente por el número de horas indicado.

```
# Modelo base de 16 rumbos en la misma muestra completa.
mod_base_16_misma_muestra <- glm(
  episodio ~
    sector +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_met_se3,
  family = binomial
)

acf_residuo_real <- function(modelo, datos_modelo, etiqueta, rezagos = 1:48) {

  resid_base <- datos_modelo %>%
    transmute(
      fecha,
      residuo = residuals(
        modelo,
        type = "pearson"
      )
    ) %>%
    arrange(fecha)

  map_dfr(
    rezagos,
    function(k) {
```

```

anterior <- resid_base %>%
  transmute(
    fecha = fecha + hours(k),
    residuo_anterior = residuo
  )

pares <- resid_base %>%
  transmute(
    fecha,
    residuo_actual = residuo
  ) %>%
  inner_join(
    anterior,
    by = "fecha"
  )

n_pares <- nrow(pares)

tibble(
  Modelo = etiqueta,
  Rezago_horas = k,
  N_pares = n_pares,
  Autocorrelacion = if (n_pares > 2) {
    cor(
      pares$residuo_actual,
      pares$residuo_anterior,
      use = "complete.obs"
    )
  } else {
    NA_real_
  },
  Limite_95 = if_else(
    n_pares > 0,
    1.96 / sqrt(n_pares),
    NA_real_
  )
)
}
)
}

acf_comparacion_met <- bind_rows(

```



```

acf_residuo_real(
  mod_base_16_misma_muestra,
  d_met_se3,
  "Base: dirección + WSR + tiempo"
),
acf_residuo_real(
  mod_met_final,
  d_met_se3,
  "Meteorología ampliada"
)
)

cat("=== AUTOCORRELACIÓN RESIDUAL ANTES Y DESPUÉS ===\n")

```

=== AUTOCORRELACIÓN RESIDUAL ANTES Y DESPUÉS ===

```

acf_comparacion_met %>%
  filter(
    Rezago_horas %in% c(1, 2, 3, 6, 12, 24, 48)
  ) %>%
  mutate(
    Autocorrelacion = round(
      Autocorrelacion,
      3
    )
  ) %>%
  select(
    Modelo,
    Rezago_horas,
    N_pares,
    Autocorrelacion
  ) %>%
  print(n = Inf)

```

A tibble: 14 x 4

	Modelo	Rezago_horas	N_pares	Autocorrelacion
	<chr>	<int>	<int>	<dbl>
1	Base: dirección + WSR + tiempo	1	33607	0.407
2	Base: dirección + WSR + tiempo	2	33468	0.214
3	Base: dirección + WSR + tiempo	3	33389	0.118
4	Base: dirección + WSR + tiempo	6	33268	0.037

5 Base: dirección + WSR + tiempo	12	33142	0.073
6 Base: dirección + WSR + tiempo	24	33072	0.134
7 Base: dirección + WSR + tiempo	48	32922	0.081
8 Meteorología ampliada	1	33607	0.422
9 Meteorología ampliada	2	33468	0.211
10 Meteorología ampliada	3	33389	0.12
11 Meteorología ampliada	6	33268	0.045
12 Meteorología ampliada	12	33142	0.053
13 Meteorología ampliada	24	33072	0.109
14 Meteorología ampliada	48	32922	0.056

```
# Cambio específico en lag 1, donde el diagnóstico previo mostró
# la dependencia de mayor magnitud.
comparacion_lag1 <- acf_comparacion_met %>%
  filter(Rezago_horas == 1) %>%
  select(
    Modelo,
    Autocorrelacion
  ) %>%
  mutate(
    Autocorrelacion = round(
      Autocorrelacion,
      3
    )
  )

cat("\n=== COMPARACIÓN EN REZAGO DE 1 HORA ===\n")
```

=== COMPARACIÓN EN REZAGO DE 1 HORA ===

```
print(comparacion_lag1)
```


```
# A tibble: 2 x 2
  Modelo                               Autocorrelacion
  <chr>                                <dbl>
1 Base: dirección + WSR + tiempo      0.407
2 Meteorología ampliada               0.422
```

```

ggplot(
  acf_comparacion_met,
  aes(
    x = Rezago_horas,
    y = Autocorrelacion,
    linetype = Modelo
  )
) +
  geom_hline(
    yintercept = 0,
    linetype = "dashed"
  ) +
  geom_line(linewidth = 0.9) +
  geom_point(size = 1.1) +
  scale_x_continuous(
    breaks = seq(0, 48, 6)
  ) +
  labs(
    title = "Dependencia temporal residual antes y después del ajuste meteorológico",
    subtitle = "SE3 | Residuos de Pearson y rezagos temporales reales",
    x = "Rezago (horas)",
    y = "Autocorrelación residual",
    linetype = "Modelo"
  ) +
  theme_minimal(base_size = 12)

```

Dependencia temporal residual antes y después del ajuste SE3 | Residuos de Pearson y rezagos temporales reales



Interpretación. Esta comparación permite comprobar si temperatura, humedad, presión, radiación y precipitación explican parte de la dependencia temporal que permanecía en los residuos. Una reducción de la autocorrelación, especialmente en el rezago de una hora, indicaría que el modelo meteorológico ampliado captura estructura que antes quedaba sin explicar.

Si todavía permanece autocorrelación residual, no se interpreta como fracaso del modelo. Significa que existe persistencia temporal adicional que una regresión logística puramente meteorológica no representa por completo. Por esta razón, las inferencias finales sobre los rumbos se acompañan con errores estándar robustos agrupados por día y las probabilidades consecutivas no se describen como observaciones completamente independientes.

Síntesis del modelo meteorológico ampliado

El análisis ampliado está diseñado para responder una sola pregunta central: **si la dirección del viento conserva una asociación con los episodios elevados de SO_2 después de considerar el resto de la meteorología disponible.**

La secuencia metodológica es:

1. partir de todas las variables meteorológicas disponibles en SE3;
2. seleccionar una especificación parsimoniosa con AIC y BIC usando únicamente 2022–2024;
3. comparar formalmente el modelo con y sin dirección del viento;

4. validar generalización en 2025;
5. recalcular probabilidades ajustadas por los 16 rumbos con inferencia robusta;
6. estudiar la misma dirección del viento bajo distintos valores meteorológicos;
7. comprobar si la meteorología adicional reduce la dependencia temporal de los residuos.

El análisis sigue siendo observacional. Una asociación persistente con el sector oriental es compatible con la hipótesis espacial planteada en el proyecto, pero no identifica de forma causal una fuente específica sin evidencia adicional.

Guardado final de modelos ampliados

```
saveRDS(  
  list(  
    datos = datos,  
    mod_se3 = mod_se3,  
    mod_conjunto_flexible = mod_conjunto_flexible,  
    acf_temporal = acf_temporal,  
    mod_met_completo_tr = mod_met_completo_tr,  
    mod_met_aic_tr = mod_met_aic_tr,  
    mod_met_bic_tr = mod_met_bic_tr,  
    mod_met_final = mod_met_final,  
    rob_dir = rob_dir,  
    validacion_2025 = validacion_2025,  
    calibracion_2025 = calibracion_2025,  
    prob_direccion_met = prob_direccion_met,  
    curvas_meteo_este = curvas_meteo_este,  
    acf_comparacion_met = acf_comparacion_met  
  ),  
  "objetos_entrega_final_modelo_meteorologico.rds"  
)  
  
cat(  
  "Objetos del modelo meteorológico ampliado guardados correctamente.\n"  
)
```

Objetos del modelo meteorológico ampliado guardados correctamente.