

Código del Proyecto

Alicia Bernádez A01562634 Omar Arzaga A01569294
Diego Medrano A01254882 Sebastián Alemán A00841034
Isaac Montaña A00841681

```
library(readxl)
library(dplyr)
```

Adjuntando el paquete: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
library(purrr)
library(stringr)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v forcats   1.0.1      v readr      2.2.0
v ggplot2   4.0.3      v tibble     3.3.1
v lubridate 1.9.5      v tidyr      1.3.2
```

```
-- Conflicts ----- tidyverse_conflicts() --
```

```
x dplyr::filter() masks stats::filter()
```

```
x dplyr::lag()     masks stats::lag()
```

```
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(lubridate)
library(VIM)
```

Cargando paquete requerido: colorspace
Cargando paquete requerido: grid
VIM is ready to use.

Suggestions and bug-reports can be submitted at: <https://github.com/statistikat/VIM/issues>

Adjuntando el paquete: 'VIM'

The following object is masked from 'package:datasets':

sleep

```
# Catálogo de estaciones.
# la hoja de García se llama "NO2" en los archivos de SIMA, igual que
# el contaminante. La reetiquetamos como "GAR" para evitar la colisión.
catalogo <- tribble(
  ~hoja, ~est, ~mun,
  "SE3", "SE3", "Cadereyta",
  "SE2", "SE2", "Juárez",
  "NE", "NE", "San Nicolás",
  "NO2", "GAR", "García"
)

contaminantes <- c("CO", "NO", "NO2", "NOX", "O3", "PM10", "PM2.5", "SO2")
meteorologicas <- c("WDR", "WSR", "TOUT", "RH", "PRS", "SR", "RAINF")

# Función para leer únicamente las estaciones y variables de interés
leer_estacion <- function(archivo, anio, hoja, est, mun) {
  x <- read_excel(archivo, sheet = hoja)
  if ("date" %in% names(x)) x <- rename(x, `Fecha y hora` = date)
  x %>%
    mutate(Estacion = est, Municipio = mun, Año = anio) %>%
    select(`Fecha y hora`,
           all_of(contaminantes),
           all_of(meteorologicas),
           Estacion, Municipio, Año)
}
```

```

leer_base <- function(archivo, anio) {
  pmap_dfr(catalogo, function(hoja, est, mun)
    leer_estacion(archivo, anio, hoja, est, mun))
}

# Leer las bases de cada año
datos22 <- leer_base("BD 2022.xlsx", 2022)
datos23 <- leer_base("BD 2023.xlsx", 2023)
datos24 <- leer_base("BD 2024.xlsx", 2024)
datos25 <- leer_base("BD 2025.xlsx", 2025)

# Unir todos los años en una sola base
datos <- bind_rows(
  datos22,
  datos23,
  datos24,
  datos25
)

# Revisar la base final
dim(datos)

```

```
[1] 140236      19
```

```
head(datos)
```

```

# A tibble: 6 x 19
  `Fecha y hora`      CO      NO      NO2      NOX      O3  PM10 PM2.5  SO2  WDR
  <dtm>             <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 2022-01-01 00:00:00  1.61   5.3  21.8  27.1    17   138    83   3.9    90
2 2022-01-01 01:00:00  2.15  23.7  26.1  49.6     7   145   122   4.5   353
3 2022-01-01 02:00:00  1.38   6.9  15    21.7    14   324   153   4.7   329
4 2022-01-01 03:00:00  2.38  14.5  22.9  37.3     5   110    NA   4.1   282
5 2022-01-01 04:00:00  2.83  17.8  24.3  42      4   246   192   3.6   292
6 2022-01-01 05:00:00  2.13   9.8  24.3  33.9     6   283   174   3.4   304
# i 9 more variables: WSR <dbl>, TOUT <dbl>, RH <dbl>, PRS <dbl>, SR <dbl>,
#   RAINF <dbl>, Estacion <chr>, Municipio <chr>, Año <dbl>

```

```
table(datos$Año)
```

```
2022 2023 2024 2025  
35040 35033 35130 35033
```

```
table(datos$Estacion, datos$Año)
```

```
2022 2023 2024 2025  
GAR 8760 8759 8782 8758  
NE 8760 8758 8784 8758  
SE2 8760 8758 8782 8759  
SE3 8760 8758 8782 8758
```

```
names(datos22)
```

```
[1] "Fecha y hora" "CO" "NO" "NO2" "NOX"  
[6] "03" "PM10" "PM2.5" "SO2" "WDR"  
[11] "WSR" "TOUT" "RH" "PRS" "SR"  
[16] "RAINF" "Estacion" "Municipio" "Año"
```

```
names(datos23)
```

```
[1] "Fecha y hora" "CO" "NO" "NO2" "NOX"  
[6] "03" "PM10" "PM2.5" "SO2" "WDR"  
[11] "WSR" "TOUT" "RH" "PRS" "SR"  
[16] "RAINF" "Estacion" "Municipio" "Año"
```

```
names(datos24)
```

```
[1] "Fecha y hora" "CO" "NO" "NO2" "NOX"  
[6] "03" "PM10" "PM2.5" "SO2" "WDR"  
[11] "WSR" "TOUT" "RH" "PRS" "SR"  
[16] "RAINF" "Estacion" "Municipio" "Año"
```

```
names(datos25)
```

```
[1] "Fecha y hora" "CO"          "NO"          "NO2"          "NOX"
[6] "O3"           "PM10"        "PM2.5"       "SO2"          "WDR"
[11] "WSR"          "TOUT"        "RH"          "PRS"          "SR"
[16] "RAINF"        "Estacion"    "Municipio"   "Año"
```

```
# Ver a grandes rasgos el tibble
head(datos)
```

```
# A tibble: 6 x 19
  `Fecha y hora`      CO      NO      NO2      NOX      O3      PM10      PM2.5      SO2      WDR
  <dtm>            <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 2022-01-01 00:00:00  1.61   5.3  21.8  27.1    17   138    83   3.9    90
2 2022-01-01 01:00:00  2.15  23.7  26.1  49.6     7   145   122   4.5   353
3 2022-01-01 02:00:00  1.38   6.9  15    21.7    14   324   153   4.7   329
4 2022-01-01 03:00:00  2.38  14.5  22.9  37.3     5   110    NA   4.1   282
5 2022-01-01 04:00:00  2.83  17.8  24.3  42      4   246   192   3.6   292
6 2022-01-01 05:00:00  2.13   9.8  24.3  33.9     6   283   174   3.4   304
# i 9 more variables: WSR <dbl>, TOUT <dbl>, RH <dbl>, PRS <dbl>, SR <dbl>,
#   RAINF <dbl>, Estacion <chr>, Municipio <chr>, Año <dbl>
```

```
# Ver las dimensiones y tipos de datos
print(dim(datos))
```

```
[1] 140236      19
```

```
str(datos)
```

```
tibble [140,236 x 19] (S3: tbl_df/tbl/data.frame)
 $ Fecha y hora: POSIXct[1:140236], format: "2022-01-01 00:00:00" "2022-01-
01 01:00:00" ...
 $ CO          : num [1:140236] 1.61 2.15 1.38 2.38 2.83 2.13 2.54 2.25 1.82 1.52 ...
 $ NO          : num [1:140236] 5.3 23.7 6.9 14.5 17.8 9.8 18.7 20 9.7 6.2 ...
 $ NO2         : num [1:140236] 21.8 26.1 15 22.9 24.3 24.3 24.1 22.3 17.8 15.9 ...
 $ NOX         : num [1:140236] 27.1 49.6 21.7 37.3 42 33.9 42.7 42.2 27.3 21.9 ...
 $ O3          : num [1:140236] 17 7 14 5 4 6 4 3 4 9 ...
 $ PM10        : num [1:140236] 138 145 324 110 246 283 172 214 197 159 ...
 $ PM2.5       : num [1:140236] 83 122 153 NA 192 174 134 132 107 86 ...
```

```

$ SO2      : num [1:140236] 3.9 4.5 4.7 4.1 3.6 3.4 3.3 3.3 NA 3.7 ...
$ WDR      : num [1:140236] 90 353 329 282 292 304 261 266 277 280 ...
$ WSR      : num [1:140236] 2.1 2 5 4.4 6 5.6 5.3 3.6 4.6 3.9 ...
$ TOUT     : num [1:140236] 22.3 20.8 19.2 17.6 17.1 ...
$ RH       : num [1:140236] 66 72 77 81 83 81 82 83 81 74 ...
$ PRS      : num [1:140236] 724 724 724 724 724 ...
$ SR       : num [1:140236] 0 0.001 0.001 0.001 0.001 0.001 0.001 0.001 0.011 0.039 ...
$ RAINF    : num [1:140236] 0 0 0 0 0 0 0 0 0 0 ...
$ Estacion : chr [1:140236] "SE3" "SE3" "SE3" "SE3" ...
$ Municipio : chr [1:140236] "Cadereyta" "Cadereyta" "Cadereyta" "Cadereyta" ...
$ Año      : num [1:140236] 2022 2022 2022 2022 2022 ...

```

```

# Ver cantidad de datos faltantes
colSums(is.na(datos))

```

Fecha y hora	CO	NO	NO2	NOX	O3
0	9838	7906	6840	6561	6449
PM10	PM2.5	SO2	WDR	WSR	TOUT
3736	15005	6121	2803	3147	13920
RH	PRS	SR	RAINF	Estacion	Municipio
6081	3077	11429	1679	0	0
Año					
0					

```

# Ver si hay datos atípicos o sesgos
summary(datos)

```

Fecha y hora		CO		NO			
Min.	:2022-01-01 00:00:00	Min.	: 0.000	Min.	: 0.50		
1st Qu.	:2023-01-01 04:00:00	1st Qu.	: 0.830	1st Qu.	: 3.00		
Median	:2024-01-01 11:00:00	Median	: 1.290	Median	: 4.40		
Mean	:2024-01-01 11:00:59	Mean	: 1.418	Mean	: 10.09		
3rd Qu.	:2024-12-31 17:00:00	3rd Qu.	: 1.770	3rd Qu.	: 8.20		
Max.	:2025-12-31 23:00:00	Max.	:15.300	Max.	:400.30		
		NAs	:9838	NAs	:7906		
		NO2		NOX			
		O3		PM10			
Min.	: 0.00	Min.	: 0.70	Min.	: 1.00	Min.	: 2.00
1st Qu.	: 5.50	1st Qu.	: 8.90	1st Qu.	: 14.00	1st Qu.	: 36.53
Median	: 9.10	Median	: 14.00	Median	: 24.00	Median	: 52.00
Mean	: 12.07	Mean	: 22.02	Mean	: 27.86	Mean	: 63.18
3rd Qu.	: 15.70	3rd Qu.	: 24.40	3rd Qu.	: 37.00	3rd Qu.	: 76.00

Max. :102.60	Max. :458.40	Max. :183.00	Max. :1000.00
NAs :6840	NAs :6561	NAs :6449	NAs :3736
PM2.5	SO2	WDR	WSR
Min. : 0.00	Min. : 0.50	Min. : 1.0	Min. : 0.100
1st Qu.: 10.52	1st Qu.: 2.90	1st Qu.: 91.0	1st Qu.: 4.400
Median : 17.00	Median : 3.80	Median :122.0	Median : 7.400
Mean : 21.11	Mean : 5.03	Mean :145.4	Mean : 8.055
3rd Qu.: 27.00	3rd Qu.: 4.90	3rd Qu.:168.0	3rd Qu.:11.100
Max. :999.00	Max. :404.70	Max. :360.0	Max. :30.500
NAs :15005	NAs :6121	NAs :2803	NAs :3147
TOUT	RH	PRS	SR
Min. : -9999.00	Min. : -9999.00	Min. :680.3	Min. : -0.0120
1st Qu.: 18.60	1st Qu.: 43.00	1st Qu.:709.6	1st Qu.: 0.0000
Median : 24.15	Median : 61.00	Median :721.1	Median : 0.0020
Mean : 23.34	Mean : 58.85	Mean :718.1	Mean : 0.1279
3rd Qu.: 28.66	3rd Qu.: 77.00	3rd Qu.:725.1	3rd Qu.: 0.2250
Max. : 785.00	Max. : 725.00	Max. :750.0	Max. : 3.3630
NAs :13920	NAs :6081	NAs :3077	NAs :11429
RAINF	Estacion	Municipio	Año
Min. : 0.000000	Length :140236	Length :140236	Min. :2022
1st Qu.: 0.000000	N.unique : 4	N.unique : 4	1st Qu.:2023
Median : 0.000000	N.blank : 0	N.blank : 0	Median :2024
Mean : 0.001608	Min.nchar: 2	Min.nchar: 6	Mean :2024
3rd Qu.: 0.000000	Max.nchar: 3	Max.nchar: 11	3rd Qu.:2024
Max. :17.990000			Max. :2025
NAs :1679			

Si el dato se sale del rango proporcionado por SIMA, esa celda se vuelve valor nulo

```
rangos <- tribble(
```

```
  ~Año, ~variable, ~lim_min, ~lim_max,
  2022, "PM10", 0, 999, 2022, "PM2.5", 0, 450, 2022, "O3", 0, 160,
  2022, "NO", 0, 400, 2022, "NO2", 0, 175, 2022, "NOX", 0, 420,
  2022, "SO2", 0, 200, 2022, "CO", 0, 8, 2022, "RH", 0, 100,
  2022, "WSR", 0, 35, 2022, "TOUT", -5, 45, 2022, "SR", 0, 1.25,
  2022, "PRS", 700, 740, 2022, "WDR", 0, 360, 2022, "RAINF", 0, 25,

  2023, "PM10", 0, 900, 2023, "PM2.5", 0, 800, 2023, "O3", 0, 175,
  2023, "NO", 0, 500, 2023, "NO2", 0, 175, 2023, "NOX", 0, 500,
  2023, "SO2", 0, 250, 2023, "CO", 0, 14, 2023, "RH", 0, 100,
  2023, "WSR", 0, 40, 2023, "TOUT", 0, 45, 2023, "SR", 0, 1,
  2023, "PRS", 690, 740, 2023, "WDR", 0, 360, 2023, "RAINF", 0, 70,
```

```

2024, "PM10", 0, 999, 2024, "PM2.5", 0, 999, 2024, "O3", 0, 180,
2024, "NO", 0, 400, 2024, "NO2", 0, 130, 2024, "NOX", 0, 500,
2024, "SO2", 0, 150, 2024, "CO", 0, 18, 2024, "RH", 0, 100,
2024, "WSR", 0, 38, 2024, "TOUT", -4, 45.5, 2024, "SR", 0, 1.26,
2024, "PRS", 687.5, 740, 2024, "WDR", 0, 360, 2024, "RAINF", 0, 50,

2025, "PM10", 0, 820, 2025, "PM2.5", 0, 350, 2025, "O3", 0, 185,
2025, "NO", 0, 350, 2025, "NO2", 0, 175, 2025, "NOX", 0, 400,
2025, "SO2", 0, 405, 2025, "CO", 0, 10, 2025, "RH", 0, 100,
2025, "WSR", 0, 40, 2025, "TOUT", -4.5, 45, 2025, "SR", 0, 1.2,
2025, "PRS", 688, 740, 2025, "WDR", 0, 360, 2025, "RAINF", 0, 25
)

datosF <- datos %>%
  pivot_longer(cols = all_of(c(contaminantes, meteorologicas)),
               names_to = "variable", values_to = "valor") %>%
  left_join(rangos, by = c("Año", "variable")) %>%
  mutate(valor = if_else(!is.na(valor) & (valor < lim_min | valor > lim_max),
                        NA_real_, valor)) %>%
  select(-lim_min, -lim_max) %>%
  pivot_wider(names_from = variable, values_from = valor)

# Ver cantidad de valores fuera de rango convertidos a NA
# Se restringe a las 15 variables numéricas y se comparan por nombre:
vars <- c(contaminantes, meteorologicas)

valores_corregidos <- colSums(is.na(datosF[vars])) - colSums(is.na(datos[vars]))

sort(valores_corregidos, decreasing = TRUE)

```

PRS	SR	TOUT	RH	PM10	CO	NO	O3	SO2	NO2	NOX	PM2.5	WDR
4496	58	20	12	2	1	1	1	1	0	0	0	0
WSR	RAINF											
0	0											

Table 1: Resultado de la eliminación de registros duplicados

Indicador	Cantidad
Registros antes de eliminar duplicados	140236
Registros después de eliminar duplicados	140236
Duplicados eliminados	0

Indicador	Cantidad
-----------	----------

```
# Ver cantidad y porcentaje de datos faltantes después de la limpieza
colSums(is.na(datosF))
```

Fecha y hora	Estacion	Municipio	Año	CO	NO
0	0	0	0	9839	7907
NO2	NOX	03	PM10	PM2.5	S02
6840	6561	6450	3738	15005	6122
WDR	WSR	TOUT	RH	PRS	SR
2803	3147	13940	6093	7573	11487
RAINF					
1679					

```
round(colMeans(is.na(datosF)) * 100, 2)
```

Fecha y hora	Estacion	Municipio	Año	CO	NO
0.00	0.00	0.00	0.00	7.02	5.64
NO2	NOX	03	PM10	PM2.5	S02
4.88	4.68	4.60	2.67	10.70	4.37
WDR	WSR	TOUT	RH	PRS	SR
2.00	2.24	9.94	4.34	5.40	8.19
RAINF					
1.20					

Imputación de datos

```
# Preparación e imputación de datos mediante KNN

# Conservar únicamente registros completos en las variables principales
datos_imputados <- datosF %>%
  filter(
    !is.na(S02),
    !is.na(WDR),
    !is.na(WSR)
  ) %>%
  mutate(
    # Variables temporales
    Mes = month(`Fecha y hora`),
```

```

Hora = hour(`Fecha y hora`),

# Transformar dirección del viento para respetar
# su naturaleza circular
WDR_sin = sin(WDR * pi / 180),
WDR_cos = cos(WDR * pi / 180),

# Transformaciones circulares de hora y mes
Hora_sin = sin(2 * pi * Hora / 24),
Hora_cos = cos(2 * pi * Hora / 24),
Mes_sin = sin(2 * pi * Mes / 12),
Mes_cos = cos(2 * pi * Mes / 12)
)

# Imputar únicamente las variables meteorológicas secundarias
# utilizando KNN dentro de cada estación
datos_imputados <- datos_imputados %>%
  group_split(Estacion, .keep = TRUE) %>%
  map_dfr(~ VIM::kNN(
    .x,

    # Variables que se van a imputar
    variable = c("TOUT", "RH", "PRS", "SR"),

    # Variables utilizadas para buscar observaciones similares
    dist_var = c(
      "WSR",
      "WDR_sin", "WDR_cos",
      "Año",
      "Hora_sin", "Hora_cos",
      "Mes_sin", "Mes_cos",
      "TOUT", "RH", "PRS", "SR"
    ),

    k = 5,
    imp_var = FALSE,
    useImputedDist = FALSE,
    methodStand = "iqr"
  )) %>%
  arrange(Estacion, `Fecha y hora`) %>%

```

```
# Eliminar solamente las variables auxiliares
select(
  -WDR_sin, -WDR_cos,
  -Hora_sin, -Hora_cos,
  -Mes_sin, -Mes_cos
)

# Revisar datos faltantes después de la preparación
colSums(is.na(datos_imputados))
```

Fecha y hora	Estacion	Municipio	Año	CO	NO
0	0	0	0	6658	4704
NO2	NOX	03	PM10	PM2.5	S02
3709	3431	3526	1604	12556	0
WDR	WSR	TOUT	RH	PRS	SR
0	0	0	0	0	0
RAINF	Mes	Hora			
4	0	0			

```
datos_imputados <- datos_imputados %>%
  filter(!is.na(RAINF))

# Verificar que ya no existan datos faltantes
colSums(is.na(datos_imputados))
```

Fecha y hora	Estacion	Municipio	Año	CO	NO
0	0	0	0	6658	4704
NO2	NOX	03	PM10	PM2.5	S02
3709	3431	3526	1604	12556	0
WDR	WSR	TOUT	RH	PRS	SR
0	0	0	0	0	0
RAINF	Mes	Hora			
0	0	0			

```
# Documenta el desbalance del panel (GAR arranca con menos datos en 2022)
table(datos_imputados$Estacion, datos_imputados$Año)
```

2022 2023 2024 2025

```

GAR 7146 8450 8514 8424
NE 8254 8472 8622 7837
SE2 8120 8228 8388 8504
SE3 8486 8325 8615 8551

```

Datos no imputados

```

# Cantidad y porcentaje de registros excluidos
# por datos faltantes en S02, WDR o WSR
registros_iniciales <- nrow(datosF)
registros_finales <- nrow(datos_imputados)

registros_excluidos <- registros_iniciales - registros_finales

porcentaje_excluido <- round(
  registros_excluidos / registros_iniciales * 100,
  2
)

registros_excluidos

```

```
[1] 7300
```

```
porcentaje_excluido
```

```
[1] 5.21
```

Transformación y estandarización de los datos

```

datos_transformados <- datos_imputados %>%
  mutate(
    # Transformación circular de la dirección del viento
    WDR_sin = sin(2 * pi * WDR / 360),
    WDR_cos = cos(2 * pi * WDR / 360),

    # Transformación logarítmica de S02
    S02_log = log1p(S02),

    # Variables estandarizadas
    S02_z = as.numeric(scale(S02_log)),

```

```

    RH_z    = as.numeric(scale(RH)),
    WSR_z    = as.numeric(scale(WSR)),
    TOUT_z   = as.numeric(scale(TOUT)),
    SR_z     = as.numeric(scale(SR)),
    PRS_z    = as.numeric(scale(PRS)),
    RAINF_z  = as.numeric(scale(RAINF)),
    CO_log    = log1p(CO),
    NO_log    = log1p(NO),
    NO2_log   = log1p(NO2),
    NOX_log   = log1p(NOX),
    O3_log    = log1p(O3),
    PM10_log  = log1p(PM10),
    PM25_log  = log1p(`PM2.5`)
  )
names(datos_transformados)

```

```

[1] "Fecha y hora" "Estacion"      "Municipio"     "Año"           "CO"
[6] "NO"           "NO2"           "NOX"           "O3"           "PM10"
[11] "PM2.5"       "SO2"           "WDR"           "WSR"           "TOUT"
[16] "RH"          "PRS"           "SR"            "RAINF"         "Mes"
[21] "Hora"        "WDR_sin"       "WDR_cos"       "SO2_log"       "SO2_z"
[26] "RH_z"        "WSR_z"         "TOUT_z"        "SR_z"          "PRS_z"
[31] "RAINF_z"     "CO_log"        "NO_log"        "NO2_log"       "NOX_log"
[36] "O3_log"      "PM10_log"      "PM25_log"

```

```

summary(
  datos_transformados %>%
    select(
      SO2, SO2_log, SO2_z,
      WDR, WDR_sin, WDR_cos,
      WSR, WSR_z
    )
)

```

SO2		SO2_log		SO2_z		WDR	
Min.	: 0.500	Min.	: 0.4055	Min.	: -2.7312	Min.	: 1.0
1st Qu.:	2.900	1st Qu.:	1.3610	1st Qu.:	-0.6202	1st Qu.:	92.0
Median :	3.800	Median :	1.5686	Median :	-0.1614	Median :	122.0
Mean :	5.035	Mean :	1.6417	Mean :	0.0000	Mean :	145.4
3rd Qu.:	4.900	3rd Qu.:	1.7750	3rd Qu.:	0.2944	3rd Qu.:	168.0

Max. :404.700	Max. :6.0056	Max. : 9.6414	Max. :360.0
WDR_sin	WDR_cos	WSR	WSR_z
Min. :-1.0000	Min. :-1.0000	Min. : 0.100	Min. :-1.6833
1st Qu.: 0.1219	1st Qu.: -0.6561	1st Qu.: 4.300	1st Qu.: -0.7894
Median : 0.6947	Median : -0.1908	Median : 7.300	Median : -0.1508
Mean : 0.4264	Mean : -0.0898	Mean : 8.009	Mean : 0.0000
3rd Qu.: 0.9397	3rd Qu.: 0.4848	3rd Qu.: 11.100	3rd Qu.: 0.6579
Max. : 1.0000	Max. : 1.0000	Max. : 30.500	Max. : 4.7870