

Etapas 1. Conociendo el negocio

Alicia Bernádez, Omar Arzaga, Diego Medrano, Sebastián Alemán, Isaac Montaña

Parte 1: Conociendo el negocio

La calidad del aire es un aspecto fundamental para el bienestar de la población y el medio ambiente. De manera general, se refiere a la condición del aire que se respira en función de la presencia y concentración de distintos contaminantes, tanto partículas como gases. Cuando estos contaminantes se encuentran en concentraciones elevadas pueden representar un riesgo para la salud humana y afectar también a los ecosistemas. Por esta razón, conocer y monitorear la calidad del aire permite identificar condiciones de riesgo y generar información que ayude a establecer acciones para reducir la exposición de la población a la contaminación atmosférica (HOLCIM, s.f.).

Importancia del análisis de la calidad del aire

El análisis de la calidad del aire es importante para la ciudadanía debido a que permite conocer el nivel de exposición de la población a contaminantes que pueden causar efectos adversos sobre la salud. La Organización Mundial de la Salud estima que la contaminación del aire exterior ocasionó aproximadamente 4.2 millones de muertes prematuras durante 2019 y la relaciona principalmente con enfermedades cardiovasculares, accidentes cerebrovasculares, enfermedades respiratorias y cáncer de pulmón (OMS, 2024). Asimismo, el National Institute of Environmental Health Sciences señala que la contaminación atmosférica puede afectar el desarrollo y funcionamiento pulmonar, contribuir al asma y a la enfermedad pulmonar obstructiva crónica, además de afectar al sistema cardiovascular (NIEHS, s.f.).

Contar con información actualizada sobre la calidad del aire permite también que la ciudadanía tome medidas para disminuir su exposición durante episodios de contaminación elevada. Además, esta información puede ser utilizada por las autoridades para diseñar estrategias relacionadas con transporte industria, energía, desarrollo urbano y otras fuentes importantes de emisiones. La OMS señala que muchas fuentes de contaminación atmosférica no pueden ser controladas directamente por los individuos, por lo que requieren acciones coordinadas de política pública (OMS, 2024).

Contaminantes y aspectos considerados para evaluar la calidad del aire

El análisis de la calidad del aire considera principalmente la concentración de contaminantes atmosféricos, su tiempo de exposición, su comportamiento en diferentes lugares y momentos y las condiciones ambientales que pueden influir en su dispersión. Entre los contaminantes de mayor importancia para la salud se encuentran las partículas suspendidas (PM_{10} , $PM_{2.5}$), el ozono (O_3), el dióxido de nitrógeno (NO_2), el dióxido de azufre (SO_2) y el monóxido de carbono (CO), los cuales también están incluidos en las Directrices Mundiales sobre la Calidad del Aire de la OMS.

El material particulado representa uno de los contaminantes de mayor interés para la salud. Las partículas PM_{10} presentan un diámetro aerodinámico menor o igual a 10 micrómetros, mientras que las $PM_{2.5}$ son menores o iguales a 2.5 micrómetros. Debido a su menor tamaño, las partículas finas pueden penetrar profundamente en los pulmones e incluso ingresar al torrente sanguíneo, por lo que se han relacionado con efectos cardiovasculares, cerebrovasculares y respiratorios. La evidencia de sus efectos sobre la salud es especialmente amplia y la exposición tanto a corto como a largo plazo se ha asociado con incrementos en morbilidad y mortalidad (OMS, 2024).

A nivel internacional no existe una sola clasificación universal de la calidad del aire; sin embargo, la OMS establece valores guía y objetivos intermedios para los principales contaminantes como referencia para la protección de la salud. En México, estos valores se complementan con el Índice Aire y Salud, que comunica las condiciones de contaminación mediante cinco categorías: buena, aceptable, mala, muy mala y extremadamente mala, relacionadas respectivamente con niveles de riesgo desde bajo a extremadamente alto.

Medición de la calidad del aire y variables relacionadas

La calidad del aire se evalúa de manera cuantitativa mediante la medición de las concentraciones de los contaminantes presentes en la atmósfera. Para ello se utilizan redes de monitoreo equipadas con instrumentos diseñados para detectar contaminantes específicos. Algunos equipos, por ejemplo, utilizan métodos ópticos para determinar la cantidad de partículas presentes en un volumen de aire, mientras que las mediciones terrestres también pueden complementarse con información obtenida mediante satélites. Este tipo de monitoreo permite conocer cómo varía la contaminación a través del tiempo y entre distintas zonas, además de identificar episodios en los que las concentraciones pueden representar un riesgo para la población (PNUMA, 2022).

En México, el Sistema Nacional de Información de la Calidad del Aire (SINAICA), administrado por el Instituto Nacional de Ecología y Cambio Climático (INECC), integra información proveniente de los diferentes sistemas de monitoreo del país. A partir de los datos validados de las estaciones es posible evaluar el cumplimiento de las Normas Oficiales Mexicanas, analizar estadísticas descriptivas y estudiar el comportamiento temporal de los contaminantes. Entre la información disponible se encuentran concentraciones horarias, promedios móviles de ocho

horas, promedios de 24 horas y otros indicadores utilizados dependiendo del contaminante que se quiera evaluar (INECC, s.f.).

Para interpretar correctamente estas mediciones es necesario considerar tanto la unidad de concentración como el periodo de exposición. Las concentraciones de las partículas suelen expresarse en microgramos por metro cúbico, mientras que algunos contaminantes gaseosos pueden expresarse en partes por millón (ppm), partes por billón (ppb) o mediante unidad de masa por volumen. Además, una medición horaria no representa lo mismo que una concentración promedio de ocho o 24 horas. Por ejemplo, la normatividad mexicana define una concentración horaria como el promedio de los registros obtenidos durante 60 minutos y un promedio móvil de ocho horas como el promedio correspondiente a ocho horas continuas (DOF, s.f.)

También es importante distinguir entre la concentración de un contaminante y un índice de calidad del aire. La primera representa directamente la cantidad medida del contaminante, mientras que un índice transforma esta información en categorías más fáciles de comunicar a la población. Por ejemplo, Estados Unidos utiliza el Air Quality Index, mientras que en México se usa el Índice Aire y Salud. El objetivo de estos índices es facilitar la interpretación del nivel de contaminación y del riesgo que representa para la salud, pero no sustituyen las mediciones originales utilizadas para su cálculo (WHO, 2021; SEMARNAT, 2023).

El comportamiento de los contaminantes tampoco depende únicamente de la cantidad de emisiones producidas. Variables meteorológicas como la temperatura, humedad relativa, velocidad y dirección del viento, presión atmosférica, precipitación y radiación solar pueden modificar su transporte, dispersión y acumulación. Estas variables no pueden controlarse directamente, pero conocerlas permite identificar las condiciones bajo las cuales pueden presentarse mayores concentraciones. En cambio, la mejora de la calidad del aire depende principalmente de reducir las emisiones generadas por actividades como el transporte, los procesos industriales, la generación de energía y otras fuentes antropogénicas. Por ello, analizar simultáneamente contaminantes, fuentes de emisión y condiciones meteorológicas permite obtener una visión más completa del comportamiento de la calidad del aire.

Normas y lineamientos para la protección de la salud

A nivel internacional, una de las principales referencias son las Directrices Mundiales sobre la Calidad del Aire de la Organización Mundial de la Salud, actualizadas en 2021. Estas directrices establecen niveles recomendados y metas intermedias para seis contaminantes considerados especialmente importantes para la salud: $PM_{2.5}$, PM_{10} , O_3 , NO_2 , SO_2 y CO . Los valores recomendados se establecen a partir de la evidencia científica disponible sobre los efectos de la exposición a estos contaminantes y consideran diferentes periodos de exposición dependiendo de cada sustancia (OMS, 2021).

Sin embargo, es importante señalar que las directrices de la OMS no son normas legalmente obligatorias. Su función es proporcionar una referencia internacional basada en criterios de salud para que los distintos gobiernos puedan desarrollar o actualizar sus propias normas de

calidad del aire. La OMS reconoce que adoptar estos valores puede variar entre países debido a sus condiciones ambientales, sociales, económicas y técnicas. Por lo tanto, un país puede establecer límites legales distintos a los valores guía recomendados internacionalmente.

En México, los límites de concentración utilizados para proteger la salud de la población se establecen mediante Normas Oficiales Mexicanas. Para los principales contaminantes se encuentran la NOM-020-SSA1-2021, correspondiente al ozono; la NOM-021-SSA1-2021 para el monóxido de carbono; la NOM-022-SSA1-2019 para el dióxido de azufre; la NOM-023-SSA1-2021 para el dióxido de nitrógeno y la NOM-025-SSA1-2021 correspondiente a las partículas suspendidas. Estas normas establecen valores máximos permisibles y criterios específicos para determinar si las concentraciones registradas representan condiciones adecuadas para la protección de la salud (DOF, 2019; DOF, 2021).

A estas normas se suma la NOM-172-SEMARNAT-2023, cuyo objetivo es establecer los lineamientos para obtener y comunicar el Índice de Calidad del Aire y Riesgos a la Salud. A través de este índice, las concentraciones registradas pueden comunicarse mediante categorías como buena, aceptable, mala, muy mala y extremadamente mala, acompañadas de diferentes niveles de riesgo y recomendaciones a la población. De esta forma, la normatividad no solamente permite evaluar las concentraciones, sino también traducir los resultados del monitoreo a información que pueda ser utilizada por la ciudadanía (SEMARNAT, 2023).

Una de las principales problemáticas relacionadas con la regulación de la calidad del aire es que los valores establecidos por las normas nacionales y las recomendaciones internacionales no siempre coinciden. Las directrices de la OMS están diseñadas como niveles de referencia orientados a disminuir los efectos sobre la salud, mientras que cada país determina los valores que serán legalmente obligatorios (OMS, 2021). Incluso las propias normas mexicanas han sido actualizadas conforme ha aparecido nueva evidencia científica; por ejemplo, la actualización de la norma para el monóxido de carbono señala que el límite de la norma anterior era superior a referencias internacionales y que esta diferencia fue una de las razones para modificarla (DOF, 2021).

Por esta razón, cumplir con una norma Oficial Mexicana no debe interpretarse automáticamente como la ausencia total de riesgo para la salud. La OMS señala que sus recomendaciones se basan en la evidencia disponible sobre los efectos observados incluso a concentraciones relativamente bajas, mientras que las normas nacionales constituyen los criterios obligatorios aplicables dentro del país (OMS, 2021). Esto hace necesario especificar siempre qué referencia se utiliza, qué unidad se está analizando y durante qué periodo se promedió la concentración, especialmente cuando se pretende comparar resultados (INECC, s.f.).

Dificultades en la medición de la calidad del aire

A pesar de la importancia del monitoreo, medir la calidad del aire presenta diferentes dificultades. Una de ellas es la disponibilidad de infraestructura suficiente para representar adecuadamente una región. Las estaciones de monitoreo proporcionan información de los lugares en los que

están instalados, por lo que una red con pocas estaciones puede no representar completamente las diferencias que existen entre zonas industriales, residenciales, comerciales o cercanas a vialidades. El Programa de las Naciones Unidas para el Medio Ambiente también señala que la cobertura del monitoreo sigue siendo limitada en distintas regiones del mundo y que mejorar la infraestructura y el acceso a sistemas de vigilancia continúa siendo un reto importante (PNUMA, 2022).

Otra dificultad corresponde a la calidad y disponibilidad de los registros. Los equipos pueden requerir calibración y mantenimiento, y durante su operación puede producirse interrupciones o datos que posteriormente deban ser revisados. Por esta razón, los datos obtenidos directamente de una estación no necesariamente pueden utilizarse de manera inmediata en un análisis. SINAICA distingue entre datos crudos y datos validados, y para sus indicadores utiliza información que previamente ha sido revisada por los responsables de los sistemas de monitoreo (INECC, s.f.).

Además, las concentraciones pueden presentar una gran variabilidad espacial y temporal debido a cambios en las emisiones y en las condiciones meteorológicas. Una concentración registrada en determinada estación y hora puede ser diferente a la observada en otra parte de la ciudad, por lo que la ubicación del equipo, el periodo analizado y las características del entorno deben considerarse al interpretar los resultados. Por ello, el análisis de calidad del aire requiere no solamente disponer de mediciones, sino también verificar que exista una cantidad suficiente de datos válidos y considerar las condiciones bajo las cuales fueron obtenidos (OMS, 2021).

Estas dificultades son especialmente importantes para el presente proyecto, ya que antes de estudiar relaciones entre variables será necesario evaluar la calidad de los datos proporcionados por las estaciones. La presencia de observaciones faltantes, valores atípicos, diferencias entre periodos de medición o estaciones con información incompleta puede afectar los resultados estadísticos. Por esta razón, la revisión, depuración y preparación de los datos constituye una etapa fundamental antes de realizar cualquier análisis posterior.

Sistema Integral de Monitoreo Ambiental de Nuevo León

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA) es la red utilizada por el gobierno del estado para dar seguimiento a las condiciones atmosféricas y de calidad del aire. La secretaría del medio ambiente es el organismo responsable de la información generada por esta red, la cual monitorea diferentes contaminantes y parámetros meteorológicos y permite conocer las condiciones existentes en distintas zonas del Área Metropolitana de Monterrey (Gobierno de Nuevo León, s.f.).

Uno de los principales objetivos de SIMA es evaluar la calidad del aire mediante el monitoreo de las concentraciones de contaminantes a las que se encuentra expuesta la población. Además, el sistema permite informar a la ciudadanía cuando se presentan condiciones adversas y episodios de contaminación elevada. La Secretaría del Medio Ambiente utiliza esta información para

comunicar tanto las condiciones meteorológicas como el estado de la calidad del aire en la Zona metropolitana de Monterrey (Gobierno de Nuevo León, s.f.).

Actualmente, la información generada por SIMA puede consultarse mediante su plataforma de calidad del aire, donde se presentan el Índice Aire y Salud, mapas, reportes y otros productos relacionados con el monitoreo ambiental. Estas herramientas permiten que la población conozca el estado del aire que respira y las recomendaciones correspondientes al nivel de riesgo registrado. Al mismo tiempo, los registros históricos producidos por las estaciones constituyen una fuente de datos que puede utilizarse para realizar análisis estadísticos sobre la evolución y las relaciones entre los contaminantes y las condiciones ambientales de la región (SIMA, s.f.).

La información generada por SIMA resulta especialmente relevante para este proyecto debido a que permite estudiar simultáneamente diferentes contaminantes y variables meteorológicas dentro de una misma zona urbana. A partir de estos registros será posible delimitar una problemática específica de investigación y posteriormente analizar las relaciones existentes entre las variables seleccionadas, tomando en cuenta tanto la calidad y disponibilidad de los datos como el contexto ambiental de la zona metropolitana de Monterrey (SIMA, s.f.).

Objetivo de trabajo

Se busca analizar cómo la presencia de áreas verdes y la forma de urbanización influyen en la calidad del aire local. Esto implica cuantificar el efecto de la cobertura vegetal y la densidad/forma urbana sobre los niveles de contaminantes como NO_2/NO_x , PM_{10} , $PM_{2.5}$, SO_2 , O_3 y CO . Para ello, se integrarán datos del Sistema Integral de Monitoreo Ambiental (SIMA), métricas de vegetación y datos meteorológicos con el fin de estimar los efectos locales. El resultado esperado incluye la producción de mapas e indicadores que prioricen la infraestructura verde y la planificación urbana para reducir la exposición a contaminantes y mitigar episodios críticos de contaminación.

Antecedentes relacionados con el objetivo del trabajo

La infraestructura verde y áreas verdes se han asociado con mejoras en calidad del aire al reducir la concentración de contaminantes y mejorar la salud ambiental (Oliveira et al., 2025; Akaraci et al., 2022). Esto debido a su capacidad para mitigar concentraciones de PM , con estudios que demuestran una capacidad para reducir $PM_{2.5}$ en un 15-20% en su entorno inmediato (Oliveira et al., 2025). De igual manera, las zonas verdes también se asocian a mitigar islas de calor urbanas (Oliveira et al., 2025).

Como parte de la revisión de literatura relacionada con el objetivo del proyecto, se identificó un estudio realizado en el área metropolitana de São Paulo que analiza la relación entre las áreas verdes urbanas, grado de urbanización y la concentración de contaminantes atmosféricos. Este estudio es de relevancia para el desarrollo del proyecto, ya que se integran variables de vegetación y urbanización, con datos de monitoreo ambiental.

Resumen de la metodología

El estudio utilizó una combinación de datos de teledetección, mediciones de la calidad del aire y técnicas estadísticas avanzadas para analizar la relación entre las áreas verdes urbanas y la contaminación del aire en el Área Metropolitana de São Paulo. Los aspectos clave incluyen:

- Análisis de las concentraciones de PM_{10} y $PM_{2.5}$ de 27 estaciones de monitoreo en toda la zona metropolitana de São Paulo
- Cálculo del Índice de Vegetación de Diferencia Normalizada (NDVI) y del Índice de Áreas Construidas de Diferencia Normalizada (NDBI) para evaluar las áreas verdes y la urbanización
- Aplicación del algoritmo de agrupamiento K-means para identificar patrones regionales y similitudes en la calidad del aire, la urbanización y las características de la vegetación
- Utilización del análisis de pendiente de Sen para detectar tendencias temporales en $PM_{2.5}$, PM_{10} , NDVI y NDBI

Métricas y resultados

El análisis reveló una disminución general en las concentraciones de $PM_{2.5}$ y PM_{10} entre 2014 y 2023, observándose en regiones con un $NDVI$ más alto niveles de PM hasta un 50% inferiores en comparación con las zonas industriales y de mucho tráfico. El análisis de la pendiente de Sen mostró una disminución en los niveles de contaminantes que coincide con el aumento de áreas verdes y las políticas de plantación de árboles en la zona.

Limitaciones y relaciones

Si bien el estudio destaca el papel de las zonas verdes en la mitigación de la contaminación atmosférica, reconoce que otros factores, como el tráfico, las emisiones industriales y las condiciones meteorológicas, también influyen significativamente en las concentraciones de partículas en suspensión. La distribución desigual de las estaciones de monitoreo, particularmente en la región sur, introduce incertidumbres espaciales en el análisis.

Parte 2: Comprensión y preparación de los datos

```
library(readxl)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(dplyr)
library(googlesheets4)
```

```
library(googlesheets4)
library(purrr)
library(dplyr)

options(
  gargle_oauth_cache = ".secrets"
)

gs4_auth(
  cache = ".secrets",
  email = TRUE,
  scopes = "https://www.googleapis.com/auth/spreadsheets.readonly"
)
```

i The googlesheets4 package is using a cached token for 'a01562634@tec.mx'.

```
#Leer el archivo
url <- "https://docs.google.com/spreadsheets/d/1n40s3KhB_eoNonYgfjjaIDrYEUsLOG4cW1VmVp5TBTA/"

# Obtener nombres de las hojas
hojas <- sheet_names(url)

# Unir las hojas en un solo dataframe
#Importante notar que las 15 hojas fueron incluidas en una sola, por lo que se tuvo que agregar
datos25 <- map_dfr(hojas, function(hoja) {
  df <- read_sheet(url, sheet = hoja)
  df$Estacion <- hoja
})
```



```
    return(df)
})
```

v Reading from "BD 2025".

v Range ''CE''.

v Reading from "BD 2025".

v Range ''NE''.

v Reading from "BD 2025".

v Range ''NE2''.

v Reading from "BD 2025".

v Range ''NE3''.

v Reading from "BD 2025".

v Range ''NO''.

v Reading from "BD 2025".

v Range ''NO2''.

v Reading from "BD 2025".

v Range ''NO3''.

v Reading from "BD 2025".

v Range ''NTE''.

v Reading from "BD 2025".

```

v Range 'NTE2'.

v Reading from "BD 2025".

v Range 'SE'.

v Reading from "BD 2025".

v Range 'SE2'.

v Reading from "BD 2025".

v Range 'SE3'.

v Reading from "BD 2025".

v Range 'S0'.

v Reading from "BD 2025".

v Range 'S02'.

v Reading from "BD 2025".

v Range 'SUR'.

```

```

#Ver a grandes rasgos el tibble
head(datos25)

```

```

# A tibble: 6 x 17
  date                CO      NO      NO2      NOX      O3      PM10      PM2.5      PRS      RAINF
  <dtm>              <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 2025-01-01 00:00:00 2.42   5.9  13.1  26.6   24    84    NA      NA      NA
2 2025-01-01 01:00:00 2.12   3    7.1  10.3   42    81   75.5   714.    0
3 2025-01-01 02:00:00 2.11   2.8   6.2   9.3   41    63   35.3   714.    0
4 2025-01-01 03:00:00 2.1    2.6   5.6   8.5   41    46   26.9   714.    0
5 2025-01-01 04:00:00 2.11   2.6   5.7   8.5   39    39   21.7   714.    0
6 2025-01-01 05:00:00 2.18   2.6  12.5  15.3   29    35   20.4   714     0
# i 7 more variables: RH <dbl>, S02 <dbl>, SR <dbl>, TOUT <dbl>, WSR <dbl>,
#   WDR <dbl>, Estacion <chr>

```

```
#Ver las dimensiones y tipos de datos
print(dim(datos25))
```

```
[1] 131378      17
```

```
str(datos25)
```

```
tibble [131,378 x 17] (S3: tbl_df/tbl/data.frame)
 $ date      : POSIXct[1:131378], format: "2025-01-01 00:00:00" "2025-01-
01 01:00:00" ...
 $ CO        : num [1:131378] 2.42 2.12 2.11 2.1 2.11 2.18 2.18 2.14 2.16 2.16 ...
 $ NO        : num [1:131378] 5.9 3 2.8 2.6 2.6 2.6 3 2.5 3 4.4 ...
 $ NO2       : num [1:131378] 13.1 7.1 6.2 5.6 5.7 12.5 14 9.1 19.8 17.4 ...
 $ NOX       : num [1:131378] 26.6 10.3 9.3 8.5 8.5 15.3 17.2 11.8 23 22.1 ...
 $ O3        : num [1:131378] 24 42 41 41 39 29 28 32 18 22 ...
 $ PM10      : num [1:131378] 84 81 63 46 39 35 50 54 52 56 ...
 $ PM2.5     : num [1:131378] NA 75.5 35.3 26.9 21.7 ...
 $ PRS       : num [1:131378] NA 714 714 714 714 ...
 $ RAINF     : num [1:131378] NA 0 0 0 0 0 0 0 0 0 ...
 $ RH        : num [1:131378] NA 56 63 67 71 77 84 83 82 76 ...
 $ SO2       : num [1:131378] 5.4 5 4.7 4.5 4.6 4.6 4.9 5.5 5.7 6.3 ...
 $ SR        : num [1:131378] NA 0 0 0 0 0 0 0 0.007 0.067 ...
 $ TOUT      : num [1:131378] 17.9 17 16.2 15.9 15.4 ...
 $ WSR       : num [1:131378] 12.2 8 7.9 8.2 7.1 6.9 5.6 3.5 1.8 2.1 ...
 $ WDR       : num [1:131378] NA 69 114 108 89 47 53 26 299 187 ...
 $ Estacion: chr [1:131378] "CE" "CE" "CE" "CE" ...
```

```
#Ver cantidad de datos faltantes
colSums(is.na(datos25))
```

	date	CO	NO	NO2	NOX	O3	PM10	PM2.5
	0	17784	19500	17398	17598	8655	6351	44797
	PRS	RAINF	RH	SO2	SR	TOUT	WSR	WDR
	7025	5955	23813	12477	6107	15548	4690	4304
Estacion	0							

```
#Ver si hay datos atípicos o sesgos
summary(datos25)
```

date		CO	NO
Min. : 2025-01-01 00:00:00		Min. : 0.050	Min. : 0.50
1st Qu.: 2025-04-02 06:00:00		1st Qu.: 0.550	1st Qu.: 2.70
Median : 2025-07-02 12:00:00		Median : 0.830	Median : 4.30
Mean : 2025-07-02 11:38:15		Mean : 1.021	Mean : 11.92
3rd Qu.: 2025-10-01 17:00:00		3rd Qu.: 1.240	3rd Qu.: 9.40
Max. : 2025-12-31 23:00:00		Max. : 9.790	Max. : 495.80
		NAs : 17784	NAs : 19500

NO2	NOX	O3	PM10
Min. : 0.00	Min. : -9999.00	Min. : 0.50	Min. : 2.00
1st Qu.: 6.00	1st Qu.: 9.20	1st Qu.: 13.00	1st Qu.: 27.00
Median : 10.90	Median : 15.50	Median : 25.00	Median : 40.00
Mean : 13.91	Mean : 25.21	Mean : 28.93	Mean : 49.06
3rd Qu.: 18.70	3rd Qu.: 28.80	3rd Qu.: 40.00	3rd Qu.: 59.00
Max. : 165.10	Max. : 702.20	Max. : 184.00	Max. : 811.00
NAs : 17398	NAs : 17598	NAs : 8655	NAs : 6351

PM2.5	PRS	RAINF	RH
Min. : 0.00	Min. : 0.0	Min. : -9999.0000	Min. : -9999.00
1st Qu.: 9.00	1st Qu.: 710.6	1st Qu.: 0.0000	1st Qu.: 40.00
Median : 16.00	Median : 714.7	Median : 0.0000	Median : 58.00
Mean : 18.78	Mean : 715.7	Mean : 0.0053	Mean : 55.48
3rd Qu.: 25.00	3rd Qu.: 721.7	3rd Qu.: 0.0000	3rd Qu.: 74.00
Max. : 340.25	Max. : 750.0	Max. : 360.0000	Max. : 725.00
NAs : 44797	NAs : 7025	NAs : 5955	NAs : 23813

SO2	SR	TOUT	WSR
Min. : 0.500	Min. : -0.003	Min. : -4.10	Min. : -9999.000
1st Qu.: 3.000	1st Qu.: 0.000	1st Qu.: 19.85	1st Qu.: 4.700
Median : 4.100	Median : 0.001	Median : 24.61	Median : 7.600
Mean : 4.867	Mean : 0.138	Mean : 23.76	Mean : 8.044
3rd Qu.: 5.300	3rd Qu.: 0.206	3rd Qu.: 28.75	3rd Qu.: 11.000
Max. : 404.700	Max. : 604.000	Max. : 43.63	Max. : 337.000
NAs : 12477	NAs : 6107	NAs : 15548	NAs : 4690

WDR	Estacion
Min. : -9999.0	Length : 131378
1st Qu.: 80.0	N.unique : 15
Median : 122.0	N.blank : 0
Mean : 147.4	Min.nchar: 2
3rd Qu.: 206.0	Max.nchar: 4
Max. : 360.0	
NAs : 4304	

Podemos notar que hay una gran cantidad de datos faltantes. Especialmente en la columna de PM2.5 donde hubo 44797 valores faltantes. Otras variables con gran cantidad de datos

faltantes son RH, NO y CO. Podemos notar que hay una gran cantidad de datos faltantes. Especialmente en la columna de $PM_{2.5}$ donde hubo 44797 valores faltantes. Otras variables con gran cantidad de datos faltantes son *RH*, *NO* y *CO*.

Podemos notar que hay una gran cantidad de datos faltantes. Especialmente en la columna de $PM_{2.5}$ donde hubo 44797 valores faltantes. Otras variables con gran cantidad de datos faltantes son *RH*, *NO* y *CO*.

Revisando los valores máximos y mínimos de las variables podemos notar como en varias de ellas (WDR, WSR, RAINF, etc) tienen un mínimo de -9999 y en otras como RH el máximo es de 725 cuando es una medida que va desde 0 hasta 100.

```
#Si el dato se sale del rango proporcionado por SIMA, esa celda se vuelve valor nulo
datos25F <- datos25 %>%
  mutate(
    PM10    = ifelse(PM10 < 0 | PM10 > 820, NA, PM10),
    `PM2.5` = ifelse(`PM2.5` < 0 | `PM2.5` > 350, NA, `PM2.5`),
    O3      = ifelse(O3 < 0 | O3 > 185, NA, O3),
    NO      = ifelse(NO < 0 | NO > 350, NA, NO),
    NO2     = ifelse(NO2 < 0 | NO2 > 175, NA, NO2),
    NOX     = ifelse(NOX < 0 | NOX > 400, NA, NOX),
    SO2     = ifelse(SO2 < 0 | SO2 > 405, NA, SO2),
    CO      = ifelse(CO < 0 | CO > 10, NA, CO),
    RH      = ifelse(RH < 0 | RH > 100, NA, RH),
    WSR     = ifelse(WSR < 0 | WSR > 40, NA, WSR),
    TOUT    = ifelse(TOUT < -4.5 | TOUT > 45, NA, TOUT),
    SR      = ifelse(SR < 0 | SR > 1.2, NA, SR),
    PRS     = ifelse(PRS < 688 | PRS > 740, NA, PRS),
    WDR     = ifelse(WDR < 0 | WDR > 360, NA, WDR),
    RAINF   = ifelse(RAINF < 0 | RAINF > 25, NA, RAINF)
  )
```

```
#Eliminar duplicados
datos25F <- distinct(datos25F)

nrow(datos25F)
```

```
[1] 131378
```

No se eliminaron filas, por lo que no había filas duplicadas