

Etapa 1. Conociendo el negocio

Alicia Bernádez Omar Arzaga Diego Medrano
Sebastián Alemán Isaac Montaña

Parte 1: Conociendo el negocio

La calidad del aire es un aspecto fundamental para el bienestar de la población y el medio ambiente, ya que depende de la presencia y concentración de diferentes contaminantes en la atmósfera. Cuando estos alcanzan niveles elevados pueden generar efectos negativos sobre la salud y los ecosistemas. Por ello, su monitoreo permite identificar condiciones de riesgo y generar información útil para reducir la exposición de la población y apoyar la toma de decisiones públicas (HOLCIM, s.f.).

Importancia del análisis de la calidad del aire

El análisis de la calidad del aire es importante para la ciudadanía debido a sus efectos sobre la salud. La Organización Mundial de la Salud estima que la contaminación del aire exterior ocasionó aproximadamente 4.2 millones de muertes prematuras en 2019 y la relaciona con enfermedades cardiovasculares, respiratorias, accidentes cerebrovasculares y cáncer de pulmón (OMS, 2024). Además, contar con información actualizada permite emitir recomendaciones durante episodios de contaminación, industria y desarrollo urbano.

Entre los contaminantes de mayor importancia se encuentran las partículas suspendidas (PM_{10} y $PM_{2.5}$), el ozono (O_3), el dióxido de nitrógeno (NO_2), el dióxido de azufre (SO_2) y el monóxido de carbono (CO). El material particulado es especialmente relevante debido a que las partículas más pequeñas pueden penetrar profundamente en los pulmones e incluso ingresar al torrente sanguíneo, generando efectos cardiovasculares y respiratorios (OMS, 2024). La OMS establece valores guía internacionales para estos contaminantes; mientras que en México el Índice Aire y Salud comunica las condiciones mediante las categorías buena, aceptable, mala, muy mala y extremadamente mala.

Medición de la calidad del aire y variables relacionadas

La calidad del aire se evalúa mediante redes de monitoreo que registran las concentraciones de contaminantes atmosféricos. Estas mediciones permiten analizar su comportamiento temporal y espacial, además de detectar episodios que puedan representar un riesgo para la población (PNUMA, 2022). En México, el Sistema Nacional de Información de la Calidad del Aire (SINAICA), administrado por el INEEC, integra y valida información proveniente de distintos sistemas de monitoreo del país (INECC, s.f.).

Para interpretar los resultados es necesario considerar tanto la unidad de concentración como el periodo de exposición. Las partículas suelen expresarse en microgramos por metro cúbico, mientras que algunos gases se reportan en partes por millón o partes por billón. También pueden analizarse concentraciones horarias, promedios de 8 horas, 24 horas o anuales. Además de las emisiones, variables meteorológicas como temperatura, humedad, velocidad y dirección del viento, presión, precipitación y radiación solar influyen en la dispersión, transporte y acumulación de los contaminantes.

Normas y lineamientos para la protección de la salud

A nivel internacional, las Directrices Mundiales sobre la Calidad del Aire de la OMS establecen valores recomendados para $PM_{2.5}$, PM_{10} , O_3 , NO_2 , SO_2 y CO . Estas directrices se basan en evidencia científica sobre sus efectos en la salud, pero no son legalmente obligatorias; funcionan como referencia para que cada país desarrolle sus propias regulaciones (OMS, 2021).

En México, los límites para la protección de la salud se establecen mediante Normas Oficiales Mexicanas. Para los principales contaminantes se encuentran la NOM-020-SSA1-2021, correspondiente al ozono; la NOM-021-SSA1-2021 para el monóxido de carbono; la NOM-022-SSA1-2019 para el dióxido de azufre; la NOM-023-SSA1-2021 para el dióxido de nitrógeno y la NOM-025-SSA1-2021 correspondiente a las partículas suspendidas (DOF, 2019; DOF, 2021). Asimismo, la NOM-172-SEMARNAT establece los lineamientos para comunicar el Índice de Calidad del Aire y Riesgos a la Salud (SEMARNAT, 2023). Una problemática importante es que los límites establecidos en las normas nacionales no siempre coinciden con las recomendaciones de la OMS, por lo que cumplir con una norma nacional no implica necesariamente la ausencia total de riesgo para la salud.

Dificultades en la medición de la calidad del aire

El monitoreo de la calidad del aire presenta dificultades relacionadas con la cobertura de las estaciones, la disponibilidad y calidad de los registros y la variabilidad espacial y temporal de los contaminantes. Los equipos requieren mantenimiento y calibración, pueden presentarse datos faltantes y una estación representa principalmente las condiciones de su entorno inmediato. Por ello, antes de realizar análisis estadísticos es necesario validar, depurar y evaluar la disponibilidad de los datos (INECC, s.f. ; PNUMA, 2022).

Sistema Integral de Monitoreo Ambiental de Nuevo León

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA), administrado por la Secretaría de Medio Ambiente del Estado, monitorea contaminantes atmosféricos y variables meteorológicas en diferentes zonas del Área Metropolitana de Monterrey. Además de informar a la ciudadanía mediante el Índice Aire y Salud, sus registros históricos permiten estudiar el comportamiento y las relaciones entre contaminantes y condiciones ambientales (Gobierno de Nuevo León, s.f.).

La información generada por SIMA constituye la principal fuente de datos para este proyecto y permitirá analizar una problemática específica relacionada con el comportamiento del SO_2 y su posible relación con condiciones meteorológicas y fuentes industriales de la región.

Objetivo general del trabajo

Analizar y caracterizar la relación entre las concentraciones de dióxido de azufre (SO_2) y las condiciones meteorológicas registradas en la estación SE3 (Cadereyta), SE2 (Juárez) y NE (San Nicolás) durante el periodo 2022-2025, con el propósito de identificar patrones direccionales asociados con episodios de concentraciones elevadas y evaluar su posible relación con fuentes industriales localizadas en la región.

Pregunta guía:

¿Existe un patrón direccional y meteorológico en las concentraciones de dióxido de azufre (SO_2) registradas en la estación SE2, SE3 y NE durante el periodo 2022-2025 que sea consistente con la influencia de una fuente industrial puntual localizada en la zona?

Objetivos específicos:

- Describir el comportamiento temporal de las concentraciones de SO_2 registradas en las estaciones NE, SE2 y SE3 durante 2022-2025, identificando su distribución, variación temporal y los periodos en los que se presentan concentraciones elevadas en cada sitio.
- Analizar la relación entre las concentraciones de SO_2 , la dirección y la velocidad del viento con el fin de identificar los sectores direccionales asociados con una mayor frecuencia de episodios de alta concentración.
- Comparar los patrones direccionales identificados con la ubicación de fuentes industriales relevantes en la Zona Metropolitana de Monterrey, con el propósito de evaluar si las concentraciones elevadas presentan un comportamiento espacial consistente con la influencia de una o múltiples fuentes industriales.

Antecedentes relacionados con el objetivo del trabajo

Diversos estudios han analizado la relación entre las concentraciones de contaminantes atmosféricos, las condiciones meteorológicas y la ubicación de fuentes de emisión de contaminantes con el propósito de determinar el posible origen de episodios de contaminación. Para el presente proyecto resultan especialmente relevantes los trabajos de Uria-Tellaetxe y Carslaw (2014), Clarke et al. (2014) y Xue et al. (2023) ya que presentan metodologías y aplicaciones relacionadas con la identificación de fuentes mediante información de calidad del aire, dirección y velocidad del viento.

Uria-Tellaetxe y Carslaw (2014) desarrollaron la Función de probabilidad bivariada condicional como una extensión de la función de probabilidad condicional. Esta metodología permite relacionar las concentraciones registradas de un contaminante con la dirección y velocidad del viento, de manera que sea posible identificar los sectores y condiciones meteorológicas asociados con concentraciones elevadas. Los autores describen su propuesta como “un nuevo método de modelación de receptor para identificar y caracterizar fuentes de emisión” (Uria-Tellaetxe & Carslaw, 2014). La principal ventaja de incorporar la velocidad del viento es que proporciona información extra sobre las características de dispersión de las fuentes y no únicamente sobre su dirección. Además, los autores comprobaron el funcionamiento de la técnica mediante simulaciones de dispersión e incorporaron el procedimiento al paquete openair de R. Esta metodología resulta relevante para el análisis de las estaciones de Cadereyta, Juárez y San Nicolás, debido a que permite estudiar si los episodios elevados de SO_2 aparecen repetidamente bajo determinadas combinaciones de dirección y velocidad del viento. De esta forma, en lugar de analizar solamente una correlación entre SO_2 y variables meteorológicas, es posible determinar si existe un patrón direccional consistente con la ubicación de una fuente industrial.

Por otra parte, Clarke et al. (2014) aplicaron un enfoque de identificación de fuentes en Ulsan, Corea del Sur, una ciudad caracterizada por una importante actividad industrial. Los autores utilizaron concentraciones horarias de SO_2 , CO , O_3 , NO_2 y PM_{10} registradas durante un año en 13 estaciones automáticas de monitoreo. El análisis consideró las variaciones diarias y estacionales, la distribución espacial de los contaminantes y la dirección del viento. Los resultados mostraron una relación particularmente clara para el dióxido de azufre, pues señalan que “la contaminación por SO_2 en Ulsan se originó principalmente en áreas industriales locales” (Clarke et al., 2014, p. 239). Este estudio constituye un antecedente directo para el proyecto debido a que demuestra que los registros generados diariamente por estaciones automáticas pueden utilizarse no solo para conocer las concentraciones de contaminantes, sino también para estudiar relaciones entre las fuentes y los receptores. Asimismo, los investigadores analizaron de manera individual episodios de concentraciones elevadas, lo cual respalda el interés por estudiar específicamente las horas de mayor SO_2 en Cadereyta, Juárez y San Nicolás y las condiciones de viento presentes durante esos eventos.

Finalmente, Xue et al. (2023) estudiaron episodios recurrentes de contaminación por SO_2 dentro de un parque industrial químico. A partir de las mediciones de una estación identificaron 68 eventos de contaminación y posteriormente realizaron un análisis retrospectivo para determinar su posible fuente. Una característica especialmente importante del trabajo es que los autores

reconocen que “los datos de apoyo disponibles correspondían únicamente a las mediciones de un solo monitor” (Xue et al., 2023). A pesar de esta limitación, combinaron las observaciones con información meteorológica y modelos de dispersión para aumentar la certeza de la localización de las fuentes. Finalmente, asociaron los episodios estudiados con una unidad industrial de craqueo catalítico.

En conjunto, los tres estudios muestran que las concentraciones de SO_2 pueden analizarse junto con la dirección y velocidad del viento para identificar patrones compatibles con fuentes industriales. Uria-Tellaetxe y Carslaw (2014) proporcionan la metodología direccional; Clarke et al. (2014) demuestran su utilidad en una ciudad industrial utilizando datos horarios de estaciones de monitoreo; y Xue et al. (2023) muestran la importancia de estudiar individualmente los episodios elevados de SO_2 y reconstruir sus posibles fuentes. Estos antecedentes sustentan el análisis propuesto para las estaciones previamente mencionadas, donde se busca determinar si las concentraciones elevadas de SO_2 presentan un patrón meteorológico y direccional consistente y si dicho sector coincide espacialmente con fuentes industriales localizadas en la región.

Parte 2: Comprensión y preparación de los datos

```
library(readxl)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(dplyr)
library(googlesheets4)
```

```
library(readxl)
library(dplyr)
library(purrr)
library(stringr)
```

```

# Función para leer todas las hojas de cada archivo
leer_base <- function(archivo, anio) {

  hojas <- excel_sheets(archivo)

  map_dfr(hojas, function(hoja) {

    read_excel(archivo, sheet = hoja) %>%
      mutate(
        Estacion = hoja,
        Año = anio
      )

  })
}

# Leer las bases de cada año
datos22 <- leer_base("BD 2022.xlsx", 2022)
datos23 <- leer_base("BD 2023.xlsx", 2023)
datos24 <- leer_base("BD 2024.xlsx", 2024)
datos25 <- leer_base("BD 2025.xlsx", 2025)

# Unificar el nombre de la columna de fecha de 2025
datos25 <- datos25 %>%
  rename(`Fecha y hora` = date)

# Unir todos los años en una sola base
datos <- bind_rows(
  datos22,
  datos23,
  datos24,
  datos25
)

# Revisar la base final
dim(datos)

```

```
[1] 517872    18
```

```
head(datos)
```

```
# A tibble: 6 x 18
```

```

      `Fecha y hora`      CO      NO      NO2      NOX      O3      PM10      PM2.5      PRS      RAINF
      <dtm>      <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 2022-01-01 00:00:00  2.6    3.5   44.9   48.5    15    134    91    706.    0
2 2022-01-01 01:00:00  2.23   2.9   32.9   36     19    141   113.   705.    0
3 2022-01-01 02:00:00  1.99   2.9   27.6   30.7    21    117   92.5   705.    0
4 2022-01-01 03:00:00  2.03   NA     NA     NA     18    108   69.2   705.    0
5 2022-01-01 04:00:00  1.86   NA     NA     NA     20    106   68.0   705.    0
6 2022-01-01 05:00:00  1.76   NA     NA     NA     20     81   49.6   705.    0
# i 8 more variables: RH <dbl>, SO2 <dbl>, SR <dbl>, TOUT <dbl>, WSR <dbl>,
#   WDR <dbl>, Estacion <chr>, Año <dbl>

```

```
table(datos$Año)
```

```

      2022      2023      2024      2025
123383 131370 131741 131378

```

```
table(datos$Estacion, datos$Año)
```

```

      2022 2023 2024 2025
CE      8760 8758 8784 8759
NE      8760 8758 8784 8758
NE2     8760 8758 8782 8758
NE3     8760 8757 8782 8759
NO      8760 8758 8783 8759
NO2     8760 8759 8782 8758
NO3      743 8759 8784 8759
NTE     8760 8758 8782 8759
NTE2    8760 8758 8782 8758
SE      8760 8758 8784 8759
SE2     8760 8758 8782 8759
SE3     8760 8758 8782 8758
SO      8760 8758 8784 8758
SO2     8760 8758 8782 8758
SUR     8760 8757 8782 8759

```

```
names(datos22)
```

```
[1] "Fecha y hora" "CO"           "NO"           "NO2"          "NOX"
```

```
[6] "O3"          "PM10"          "PM2.5"          "PRS"          "RAINF"
[11] "RH"          "SO2"           "SR"             "TOUT"         "WSR"
[16] "WDR"         "Estacion"      "Año"
```

```
names(datos23)
```

```
[1] "Fecha y hora" "CO"           "NO"           "NO2"          "NOX"
[6] "O3"           "PM10"         "PM2.5"        "PRS"          "RAINF"
[11] "RH"           "SO2"          "SR"           "TOUT"         "WSR"
[16] "WDR"          "Estacion"     "Año"
```

```
names(datos24)
```

```
[1] "Fecha y hora" "CO"           "NO"           "NO2"          "NOX"
[6] "O3"           "PM10"         "PM2.5"        "PRS"          "RAINF"
[11] "RH"           "SO2"          "SR"           "TOUT"         "WSR"
[16] "WDR"          "Estacion"     "Año"
```

```
names(datos25)
```

```
[1] "Fecha y hora" "CO"           "NO"           "NO2"          "NOX"
[6] "O3"           "PM10"         "PM2.5"        "PRS"          "RAINF"
[11] "RH"           "SO2"          "SR"           "TOUT"         "WSR"
[16] "WDR"          "Estacion"     "Año"
```

```
# Ver a grandes rasgos el tibble
head(datos)
```

```
# A tibble: 6 x 18
  `Fecha y hora`      CO      NO      NO2      NOX      O3  PM10 PM2.5    PRS RAINF
  <dtm>          <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 2022-01-01 00:00:00  2.6   3.5  44.9  48.5    15   134   91   706.    0
2 2022-01-01 01:00:00  2.23  2.9  32.9  36     19   141  113.   705.    0
3 2022-01-01 02:00:00  1.99  2.9  27.6  30.7    21   117  92.5   705.    0
4 2022-01-01 03:00:00  2.03  NA    NA    NA     18   108  69.2   705.    0
5 2022-01-01 04:00:00  1.86  NA    NA    NA     20   106  68.0   705.    0
6 2022-01-01 05:00:00  1.76  NA    NA    NA     20    81  49.6   705.    0
# i 8 more variables: RH <dbl>, SO2 <dbl>, SR <dbl>, TOUT <dbl>, WSR <dbl>,
#   WDR <dbl>, Estacion <chr>, Año <dbl>
```



```
# Ver las dimensiones y tipos de datos
print(dim(datos))
```

```
[1] 517872      18
```

```
str(datos)
```

```
tibble [517,872 x 18] (S3: tbl_df/tbl/data.frame)
 $ Fecha y hora: POSIXct[1:517872], format: "2022-01-01 00:00:00" "2022-01-
01 01:00:00" ...
 $ CO          : num [1:517872] 2.6 2.23 1.99 2.03 1.86 1.76 1.55 1.41 1.31 1.39 ...
 $ NO          : num [1:517872] 3.5 2.9 2.9 NA NA NA 2.8 2.9 3 6.6 ...
 $ NO2         : num [1:517872] 44.9 32.9 27.6 NA NA NA 16.4 13.5 13.1 16.5 ...
 $ NOX         : num [1:517872] 48.5 36 30.7 NA NA NA 19.4 16.5 16.3 23.4 ...
 $ O3          : num [1:517872] 15 19 21 18 20 20 22 21 17 13 ...
 $ PM10        : num [1:517872] 134 141 117 108 106 81 71 59 57 52 ...
 $ PM2.5       : num [1:517872] 91 112.6 92.5 69.2 68 ...
 $ PRS         : num [1:517872] 706 705 705 705 705 ...
 $ RAINF       : num [1:517872] 0 0 0 0 0 0 0 0 0 0 ...
 $ RH          : num [1:517872] 46 48 46 46 46 42 37 31 26 27 ...
 $ SO2         : num [1:517872] 5.3 6.1 5.8 6 5.6 5.3 4.9 4.6 4.1 3.9 ...
 $ SR          : num [1:517872] 0 0 0 0 0 0 0 0 0.008 0.038 ...
 $ TOUT        : num [1:517872] 21.4 20.8 20.5 20.1 19.9 ...
 $ WSR         : num [1:517872] 3.4 3.3 5.9 5.1 4.7 4.2 4.3 5.1 5.9 4.2 ...
 $ WDR         : num [1:517872] 267 259 233 220 244 132 235 222 209 97 ...
 $ Estacion    : chr [1:517872] "CE" "CE" "CE" "CE" ...
 $ Año         : num [1:517872] 2022 2022 2022 2022 2022 ...
```

Descripción de las variables

Variable	Descripción	Tipo
date	Fecha y hora del registro	Temporal
SO2	Concentración de dióxido de azufre	Numérica
WDR	Dirección del viento (0°–360°)	Numérica
WSR	Velocidad del viento	Numérica
TOUT	Temperatura exterior	Numérica
RH	Humedad relativa (%)	Numérica
PRS	Presión atmosférica	Numérica
SR	Radiación solar	Numérica

Variable	Descripción	Tipo
RAINF	Precipitación registrada	Numérica
Estacion	Estación de monitoreo de SIMA	Catórica
Año	Año correspondient al registro	Temporal

```
# Ver cantidad de datos faltantes
colSums(is.na(datos))
```

```
Fecha y hora      CO      NO      NO2      NOX      O3
0      39664      37259      32800      32546      26056
PM10      PM2.5      PRS      RAINF      RH      S02
19288      140996      16580      12127      57256      39415
SR      TOUT      WSR      WDR      Estacion      Año
23221      31199      14984      15656      0      0
```

```
# Ver si hay datos atípicos o sesgos
summary(datos)
```

```
Fecha y hora      CO      NO
Min. :2022-01-01 00:00:00 Min. : 0.000 Min. : 0.30
1st Qu.:2023-01-17 21:00:00 1st Qu.: 0.670 1st Qu.: 3.00
Median :2024-01-12 14:00:00 Median : 1.100 Median : 5.00
Mean :2024-01-10 04:30:22 Mean : 1.279 Mean : 11.96
3rd Qu.:2025-01-06 07:00:00 3rd Qu.: 1.720 3rd Qu.: 11.10
Max. :2025-12-31 23:00:00 Max. :37.000 Max. :945.10
NAs :39664 NAs :37259

NO2      NOX      O3      PM10
Min. : 0.00 Min. : -9999.00 Min. : 0.50 Min. : 1.00
1st Qu.: 7.00 1st Qu.: 11.00 1st Qu.: 13.00 1st Qu.: 33.00
Median : 11.90 Median : 17.70 Median : 23.00 Median : 48.00
Mean : 14.99 Mean : 26.67 Mean : 27.43 Mean : 57.97
3rd Qu.: 19.90 3rd Qu.: 30.90 3rd Qu.: 37.00 3rd Qu.: 71.00
Max. :167.80 Max. : 971.80 Max. :184.00 Max. :1001.00
NAs :32800 NAs :32546 NAs :26056 NAs :19288

PM2.5      PRS      RAINF      RH
Min. : 0.00 Min. : 0.0 Min. : -9999.0000 Min. : -9999.00
1st Qu.: 10.00 1st Qu.:710.0 1st Qu.: 0.0000 1st Qu.: 39.00
Median : 16.59 Median :714.5 Median : 0.0000 Median : 58.00
Mean : 20.09 Mean :715.4 Mean : 0.0115 Mean : 55.75
3rd Qu.: 26.00 3rd Qu.:721.6 3rd Qu.: 0.0000 3rd Qu.: 74.00
```

Max.	:999.00	Max.	:750.0	Max.	: 360.0000	Max.	: 725.00
NAs	:140996	NAs	:16580	NAs	:12127	NAs	:57256
SO2		SR		TOUT		WSR	
Min.	: 0.500	Min.	:-9999.0000	Min.	:-9999.00	Min.	:-9999.000
1st Qu.:	2.800	1st Qu.:	0.0000	1st Qu.:	18.73	1st Qu.:	4.700
Median :	3.700	Median :	0.0020	Median :	24.26	Median :	7.600
Mean :	4.563	Mean :	0.1261	Mean :	23.45	Mean :	8.377
3rd Qu.:	5.100	3rd Qu.:	0.2390	3rd Qu.:	28.61	3rd Qu.:	11.300
Max.	:404.700	Max.	: 604.0000	Max.	: 785.00	Max.	: 337.000
NAs	:39415	NAs	:23221	NAs	:31199	NAs	:14984
WDR		Estacion		Año			
Min.	:-9999.0	Length	:517872	Min.	:2022		
1st Qu.:	76.0	N.unique :	15	1st Qu.:	2023		
Median :	117.0	N.blank :	0	Median :	2024		
Mean :	142.3	Min.nchar:	2	Mean :	2024		
3rd Qu.:	195.0	Max.nchar:	4	3rd Qu.:	2025		
Max.	: 360.0			Max.	:2025		
NAs	:15656						

Se puede notar que hay una gran cantidad de datos faltantes. Especialmente en la columna de $PM_{2.5}$ donde hubo 140,996 valores faltantes. Otras variables con gran cantidad de datos faltantes son RH , NO y CO .

Revisando los valores máximos y mínimos de las variables podemos notar como en varias de ellas (WDR, WSR, RAINF, etc) tienen un mínimo de -9999 y en otras como RH el máximo es de 725 cuando es una medida que va desde 0 hasta 100.

```
# Si el dato se sale del rango proporcionado por SIMA, esa celda se vuelve valor nulo
datosF <- datos %>%
  mutate(
    PM10      = ifelse(PM10 < 0 | PM10 > 820, NA, PM10),
    `PM2.5`   = ifelse(`PM2.5` < 0 | `PM2.5` > 350, NA, `PM2.5`),
    O3        = ifelse(O3 < 0 | O3 > 185, NA, O3),
    NO        = ifelse(NO < 0 | NO > 350, NA, NO),
    NO2       = ifelse(NO2 < 0 | NO2 > 175, NA, NO2),
    NOX       = ifelse(NOX < 0 | NOX > 400, NA, NOX),
    SO2       = ifelse(SO2 < 0 | SO2 > 405, NA, SO2),
    CO        = ifelse(CO < 0 | CO > 10, NA, CO),
    RH        = ifelse(RH < 0 | RH > 100, NA, RH),
    WSR       = ifelse(WSR < 0 | WSR > 40, NA, WSR),
    TOUT      = ifelse(TOUT < -4.5 | TOUT > 45, NA, TOUT),
    SR        = ifelse(SR < 0 | SR > 1.2, NA, SR),
```

```

    PRS      = ifelse(PRS < 688 | PRS > 740, NA, PRS),
    WDR      = ifelse(WDR < 0 | WDR > 360, NA, WDR),
    RAINF    = ifelse(RAINF < 0 | RAINF > 25, NA, RAINF)
  )

# Ver cantidad de valores fuera de rango convertidos a NA
valores_corregidos <- colSums(is.na(datosF)) - colSums(is.na(datos))

valores_corregidos

```

Fecha y hora	CO	NO	NO2	NOX	O3
0	34	300	0	237	0
PM10	PM2.5	PRS	RAINF	RH	SO2
12	43	1839	34	291	0
SR	TOUT	WSR	WDR	Estacion	Año
1144	43	482	1	0	0

```

# Guardar cantidad de filas antes de eliminar duplicados
filas_antes <- nrow(datosF)

# Eliminar duplicados
datosF <- distinct(datosF)

# Ver cantidad de filas después de eliminar duplicados
filas_despues <- nrow(datosF)

# Calcular duplicados eliminados
duplicados_eliminados <- filas_antes - filas_despues

filas_antes

```

```
[1] 517872
```

```
filas_despues
```

```
[1] 517872
```

```
duplicados_eliminados
```

```
[1] 0
```

No se eliminaron filas, por lo que no había filas duplicadas

```
# Registros por año
table(datosF$Año)
```

```
2022 2023 2024 2025
123383 131370 131741 131378
```

```
# Registros por estación y año
table(datosF$Estacion, datosF$Año)
```

```
2022 2023 2024 2025
CE 8760 8758 8784 8759
NE 8760 8758 8784 8758
NE2 8760 8758 8782 8758
NE3 8760 8757 8782 8759
NO 8760 8758 8783 8759
NO2 8760 8759 8782 8758
NO3 743 8759 8784 8759
NTE 8760 8758 8782 8759
NTE2 8760 8758 8782 8758
SE 8760 8758 8784 8759
SE2 8760 8758 8782 8759
SE3 8760 8758 8782 8758
SO 8760 8758 8784 8758
SO2 8760 8758 8782 8758
SUR 8760 8757 8782 8759
```

```
# Ver cantidad y porcentaje de datos faltantes después de la limpieza
colSums(is.na(datosF))
```

Fecha y hora	CO	NO	NO2	NOX	O3
0	39698	37559	32800	32783	26056
PM10	PM2.5	PRS	RAINF	RH	S02
19300	141039	18419	12161	57547	39415
SR	TOUT	WSR	WDR	Estacion	Año
24365	31242	15466	15657	0	0

```
round(colMeans(is.na(datosF)) * 100, 2)
```

Fecha y hora	CO	NO	NO2	NOX	O3
0.00	7.67	7.25	6.33	6.33	5.03
PM10	PM2.5	PRS	RAINF	RH	S02
3.73	27.23	3.56	2.35	11.11	7.61
SR	TOUT	WSR	WDR	Estacion	Año
4.70	6.03	2.99	3.02	0.00	0.00

```
# Seleccionar las estaciones de interés de acuerdo con el objetivo
datosE <- datos %>%
  filter(Estacion %in% c("NE", "SE2", "SE3"))

# Revisar la base seleccionada
dim(datosE)
```

```
[1] 105177      18
```

```
table(datosE$Estacion, datosE$Año)
```

	2022	2023	2024	2025
NE	8760	8758	8784	8758
SE2	8760	8758	8782	8759
SE3	8760	8758	8782	8758

Referencias

- Ashbaugh, L. L., Malm, W. C., & Sadeh, W. Z. (1985). A residence time probability analysis of sulfur concentrations at Grand Canyon National Park. *Atmospheric Environment*, 19(8), 1263–1270. [https://doi.org/10.1016/0004-6981\(85\)90256-2](https://doi.org/10.1016/0004-6981(85)90256-2)
- Carslaw, D. C., Beevers, S. D., Ropkins, K., & Bell, M. C. (2006). Detecting and quantifying aircraft and other on-airport contributions to ambient nitrogen oxides in the vicinity of a large international airport. *Atmospheric Environment*, 40(28), 5424–5434. <https://doi.org/10.1016/j.atmosenv.2006.04.062>
- Carslaw, D. C., & Ropkins, K. (2012). Openair—An R package for air quality data analysis. *Environmental Modelling & Software*, 27–28, 52–61. <https://doi.org/10.1016/j.envsoft.2011.09.008>

Clarke, K., Kwon, H.-O., & Choi, S.-D. (2014). Fast and reliable source identification of criteria air pollutants in an industrial city. *Atmospheric Environment*, 95, 239–248. <https://doi.org/10.1016/j.atmosenv.2014.06.040>

Comisión Federal para la Protección contra Riesgos Sanitarios. (s. f.). *Normas Oficiales Mexicanas (NOM) de calidad del aire ambiente*. Gobierno de México. <https://www.gob.mx/cofepris/acciones-y-programas/4-normas-oficiales-mexicanas-nom-de-calidad-del-aire-ambiente>

Gobierno del Estado de Nuevo León. (s. f.). *Índice Aire y Salud: Reporte de la calidad del aire en la Zona Metropolitana de Monterrey*. Sistema Integral de Monitoreo Ambiental. https://aire.nl.gob.mx/icars2020/map_calidad_icars.php

Holcim España. (s. f.). *¿Qué es la calidad del aire? Importancia y medición*. <https://www.holcim.es/que-es-la-calidad-del-aire-importancia-y-medicion>

Instituto Nacional de Ecología y Cambio Climático. (s. f.). *Sistema Nacional de Información de la Calidad del Aire (SINAICA)*. Gobierno de México. <https://sinaica.inecc.gob.mx/scica/>

National Environmental Satellite, Data, and Information Service. (s. f.). *How is air quality measured?* National Oceanic and Atmospheric Administration. <https://www.nesdis.noaa.gov/about/k-12-education/dust-ash-fire-smoke/how-air-quality-measured>

National Institute of Environmental Health Sciences. (s. f.). *La contaminación del aire y su salud*. National Institutes of Health. <https://www.niehs.nih.gov/health/topics/enfermedades/contaminacion>

Organización Mundial de la Salud. (2021). *Directrices mundiales de la OMS sobre la calidad del aire: Partículas en suspensión (PM_{2.5} y PM₁₀), ozono, dióxido de nitrógeno, dióxido de azufre y monóxido de carbono*. <https://www.who.int/es/news-room/questions-and-answers/item/who-global-air-quality-guidelines>

Organización Mundial de la Salud. (2024). *Contaminación del aire ambiente (exterior) y salud*. [https://www.who.int/es/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/es/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health)

Programa de las Naciones Unidas para el Medio Ambiente. (2022). *¿Cómo se mide la calidad del aire?* <https://www.unep.org/es/noticias-y-reportajes/reportajes/como-se-mide-la-calidad-del-aire>

Secretaría de Medio Ambiente y Recursos Naturales. (2023). *Proyecto de Norma Oficial Mexicana PROY-NOM-172-SEMARNAT-2023, Lineamientos para la obtención y comunicación del índice de calidad del aire y riesgos a la salud*. *Diario Oficial de la Federación*. https://www.diaariooficial.gob.mx/normasOficiales/9314/semarnat_1_C/semarnat_1_C.html

Uria-Tellaetxe, I., & Carslaw, D. C. (2014). Conditional bivariate probability function for source identification. *Environmental Modelling & Software*, 59, 1-9. <https://doi.org/10.1016/j.envsoft.2014.05.002>

Xue, Y., Cui, X., Li, K., Yu, Q., & Ma, W. (2023). Statistical source analysis of recurring sulfur dioxide pollution events in a chemical industrial park. *Atmospheric Environment*, 296, 119564. <https://doi.org/10.1016/j.atmosenv.2022.119564>