

Etapa 1. Conociendo el negocio

Alicia Bernádez Omar Arzaga Diego Medrano
Sebastián Alemán Isaac Montaña

Parte 1: Conociendo el negocio

La calidad del aire es un aspecto fundamental para el bienestar de la población y el medio ambiente, ya que depende de la presencia y concentración de diferentes contaminantes en la atmósfera. Cuando estos alcanzan niveles elevados pueden generar efectos negativos sobre la salud y los ecosistemas. Por ello, su monitoreo permite identificar condiciones de riesgo y generar información útil para reducir la exposición de la población y apoyar la toma de decisiones públicas (HOLCIM, s.f.).

Importancia del análisis de la calidad del aire

El análisis de la calidad del aire es importante para la ciudadanía debido a sus efectos sobre la salud. La Organización Mundial de la Salud estima que la contaminación del aire exterior ocasionó aproximadamente 4.2 millones de muertes prematuras en 2019 y la relaciona con enfermedades cardiovasculares, respiratorias, accidentes cerebrovasculares y cáncer de pulmón (OMS, 2024). Además, contar con información actualizada permite emitir recomendaciones durante episodios de contaminación, industria y desarrollo urbano.

Entre los contaminantes de mayor importancia se encuentran las partículas suspendidas (PM_{10} y $PM_{2.5}$), el ozono (O_3), el dióxido de nitrógeno (NO_2), el dióxido de azufre (SO_2) y el monóxido de carbono (CO). El material particulado es especialmente relevante debido a que las partículas más pequeñas pueden penetrar profundamente en los pulmones e incluso ingresar al torrente sanguíneo, generando efectos cardiovasculares y respiratorios (OMS, 2024). La OMS establece valores guía internacionales para estos contaminantes; mientras que en México el Índice Aire y Salud comunica las condiciones mediante las categorías buena, aceptable, mala, muy mala y extremadamente mala.

Medición de la calidad del aire y variables relacionadas

La calidad del aire se evalúa mediante redes de monitoreo que registran las concentraciones de contaminantes atmosféricos. Estas mediciones permiten analizar su comportamiento temporal y espacial, además de detectar episodios que puedan representar un riesgo para la población (PNUMA, 2022). En México, el Sistema Nacional de Información de la Calidad del Aire (SINAICA), administrado por el INEEC, integra y valida información proveniente de distintos sistemas de monitoreo del país (INECC, s.f.).

Para interpretar los resultados es necesario considerar tanto la unidad de concentración como el periodo de exposición. Las partículas suelen expresarse en microgramos por metro cúbico, mientras que algunos gases se reportan en partes por millón o partes por billón. También pueden analizarse concentraciones horarias, promedios de 8 horas, 24 horas o anuales. Además de las emisiones, variables meteorológicas como temperatura, humedad, velocidad y dirección del viento, presión, precipitación y radiación solar influyen en la dispersión, transporte y acumulación de los contaminantes.

Normas y lineamientos para la protección de la salud

A nivel internacional, las Directrices Mundiales sobre la Calidad del Aire de la OMS establecen valores recomendados para $PM_{2.5}$, PM_{10} , O_3 , NO_2 , SO_2 y CO . Estas directrices se basan en evidencia científica sobre sus efectos en la salud, pero no son legalmente obligatorias; funcionan como referencia para que cada país desarrolle sus propias regulaciones (OMS, 2021).

En México, los límites para la protección de la salud se establecen mediante Normas Oficiales Mexicanas. Para los principales contaminantes se encuentran la NOM-020-SSA1-2021, correspondiente al ozono; la NOM-021-SSA1-2021 para el monóxido de carbono; la NOM-022-SSA1-2019 para el dióxido de azufre; la NOM-023-SSA1-2021 para el dióxido de nitrógeno y la NOM-025-SSA1-2021 correspondiente a las partículas suspendidas (DOF, 2019; DOF, 2021). Asimismo, la NOM-172-SEMARNAT establece los lineamientos para comunicar el Índice de Calidad del Aire y Riesgos a la Salud (SEMARNAT, 2023). Una problemática importante es que los límites establecidos en las normas nacionales no siempre coinciden con las recomendaciones de la OMS, por lo que cumplir con una norma nacional no implica necesariamente la ausencia total de riesgo para la salud.

Dificultades en la medición de la calidad del aire

El monitoreo de la calidad del aire presenta dificultades relacionadas con la cobertura de las estaciones, la disponibilidad y calidad de los registros y la variabilidad espacial y temporal de los contaminantes. Los equipos requieren mantenimiento y calibración, pueden presentarse datos faltantes y una estación representa principalmente las condiciones de su entorno inmediato. Por ello, antes de realizar análisis estadísticos es necesario validar, depurar y evaluar la disponibilidad de los datos (INECC, s.f. ; PNUMA, 2022).

Sistema Integral de Monitoreo Ambiental de Nuevo León

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA), administrado por la Secretaría de Medio Ambiente del Estado, monitorea contaminantes atmosféricos y variables meteorológicas en diferentes zonas del Área Metropolitana de Monterrey. Además de informar a la ciudadanía mediante el Índice Aire y Salud, sus registros históricos permiten estudiar el comportamiento y las relaciones entre contaminantes y condiciones ambientales (Gobierno de Nuevo León, s.f.).

La información generada por SIMA constituye la principal fuente de datos para este proyecto y permitirá analizar una problemática específica relacionada con el comportamiento del SO_2 y su posible relación con condiciones meteorológicas y fuentes industriales de la región.

Objetivo general del trabajo

Analizar y caracterizar la relación entre las concentraciones de dióxido de azufre (SO_2) y las condiciones meteorológicas registradas en la estación SE3 (Cadereyta), SE2 (Juárez) y NE (San Nicolás) durante el periodo 2022-2025, con el propósito de identificar patrones direccionales asociados con episodios de concentraciones elevadas y evaluar su posible relación con fuentes industriales localizadas en la región.

Pregunta guía:

¿Existe un patrón direccional y meteorológico en las concentraciones de dióxido de azufre (SO_2) registradas en la estación SE2, SE3 y NE durante el periodo 2022-2025 que sea consistente con la influencia de una fuente industrial puntual localizada en la zona?

Objetivos específicos:

- Describir el comportamiento temporal de las concentraciones de SO_2 registradas en las estaciones NE, SE2 y SE3 durante 2022-2025, identificando su distribución, variación temporal y los periodos en los que se presentan concentraciones elevadas en cada sitio.
- Analizar la relación entre las concentraciones de SO_2 , la dirección y la velocidad del viento con el fin de identificar los sectores direccionales asociados con una mayor frecuencia de episodios de alta concentración.
- Comparar los patrones direccionales identificados con la ubicación de fuentes industriales relevantes en la Zona Metropolitana de Monterrey, con el propósito de evaluar si las concentraciones elevadas presentan un comportamiento espacial consistente con la influencia de una o múltiples fuentes industriales.

Antecedentes relacionados con el objetivo del trabajo

Diversos estudios han analizado la relación entre las concentraciones de contaminantes atmosféricos, las condiciones meteorológicas y la ubicación de fuentes de emisión de contaminantes con el propósito de determinar el posible origen de episodios de contaminación. Para el presente proyecto resultan especialmente relevantes los trabajos de Uria-Tellaetxe y Carslaw (2014), Clarke et al. (2014) y Xue et al. (2023) ya que presentan metodologías y aplicaciones relacionadas con la identificación de fuentes mediante información de calidad del aire, dirección y velocidad del viento.

Uria-Tellaetxe y Carslaw (2014) desarrollaron la Función de probabilidad bivariada condicional como una extensión de la función de probabilidad condicional. Esta metodología permite relacionar las concentraciones registradas de un contaminante con la dirección y velocidad del viento, de manera que sea posible identificar los sectores y condiciones meteorológicas asociados con concentraciones elevadas. Los autores describen su propuesta como “un nuevo método de modelación de receptor para identificar y caracterizar fuentes de emisión” (Uria-Tellaetxe & Carslaw, 2014). La principal ventaja de incorporar la velocidad del viento es que proporciona información extra sobre las características de dispersión de las fuentes y no únicamente sobre su dirección. Además, los autores comprobaron el funcionamiento de la técnica mediante simulaciones de dispersión e incorporaron el procedimiento al paquete *openair* de R. Esta metodología resulta relevante para el análisis de las estaciones de Cadereyta, Juárez y San Nicolás, debido a que permite estudiar si los episodios elevados de SO_2 aparecen repetidamente bajo determinadas combinaciones de dirección y velocidad del viento. De esta forma, en lugar de analizar solamente una correlación entre SO_2 y variables meteorológicas, es posible determinar si existe un patrón direccional consistente con la ubicación de una fuente industrial.

Por otra parte, Clarke et al. (2014) aplicaron un enfoque de identificación de fuentes en Ulsan, Corea del Sur, una ciudad caracterizada por una importante actividad industrial. Los autores utilizaron concentraciones horarias de SO_2 , CO , O_3 , NO_2 y PM_{10} registradas durante un año en 13 estaciones automáticas de monitoreo. El análisis consideró las variaciones diarias y estacionales, la distribución espacial de los contaminantes y la dirección del viento. Los resultados mostraron una relación particularmente clara para el dióxido de azufre, pues señalan que “la contaminación por SO_2 en Ulsan se originó principalmente en áreas industriales locales” (Clarke et al., 2014, p. 239). Este estudio constituye un antecedente directo para el proyecto debido a que demuestra que los registros generados diariamente por estaciones automáticas pueden utilizarse no solo para conocer las concentraciones de contaminantes, sino también para estudiar relaciones entre las fuentes y los receptores. Asimismo, los investigadores analizaron de manera individual episodios de concentraciones elevadas, lo cual respalda el interés por estudiar específicamente las horas de mayor SO_2 en Cadereyta, Juárez y San Nicolás y las condiciones de viento presentes durante esos eventos.

Finalmente, Xue et al. (2023) estudiaron episodios recurrentes de contaminación por SO_2 dentro de un parque industrial químico. A partir de las mediciones de una estación identificaron

68 eventos de contaminación y posteriormente realizaron un análisis retrospectivo para determinar su posible fuente. Una característica especialmente importante del trabajo es que los autores reconocen que “los datos de apoyo disponibles correspondían únicamente a las mediciones de un solo monitor” (Xue et al., 2023). A pesar de esta limitación, combinaron las observaciones con información meteorológica y modelos de dispersión para aumentar la certeza de la localización de las fuentes. Finalmente, asociaron los episodios estudiados con una unidad industrial de craqueo catalítico.

En conjunto, los tres estudios muestran que las concentraciones de SO_2 pueden analizarse junto con la dirección y velocidad del viento para identificar patrones compatibles con fuentes industriales. Uria-Tellaetxe y Carslaw (2014) proporcionan la metodología direccional; Clarke et al. (2014) demuestran su utilidad en una ciudad industrial utilizando datos horarios de estaciones de monitoreo; y Xue et al. (2023) muestran la importancia de estudiar individualmente los episodios elevados de SO_2 y reconstruir sus posibles fuentes. Estos antecedentes sustentan el análisis propuesto para las estaciones previamente mencionadas, donde se busca determinar si las concentraciones elevadas de SO_2 presentan un patrón meteorológico y direccional consistente y si dicho sector coincide espacialmente con fuentes industriales localizadas en la región.

Parte 2: Comprensión y preparación de los datos

Descripción de las variables a utilizar a lo largo del proyecto

A partir de este momento se trabajará con las variables de interés para la limpieza e imputación de datos.

Variable	Descripción	Tipo	Justificación
fecha y hora	Fecha y hora del registro	Temporal	Analizar patrones temporales
SO2	Concentración de dióxido de azufre	Numérica	Variable principal
WDR	Dirección del viento (0°–360°)	Numérica	Identificar dirección de origen
WSR	Velocidad del viento	Numérica	Evaluar dispersión y transporte
TOUT	Temperatura exterior	Numérica	Caracterizar condiciones atmosféricas
RH	Humedad relativa (%)	Numérica	Caracterizar condiciones meteorológicas

Variable	Descripción	Tipo	Justificación
PRS	Presión atmosférica	Numérica	Complementar análisis meteorológico
SR	Radiación solar	Numérica	Analizar variación diurna
RAINF	Precipitación registrada	Numérica	Evaluar efecto de la lluvia
Estacion	Estación de monitoreo de SIMA	Categorica	Comparar ubicaciones
Año	Año correspondiente al registro	Temporal	Comparar periodos

```
library(readxl)
```

Warning: package 'readxl' was built under R version 4.5.2

```
library(dplyr)
```

Warning: package 'dplyr' was built under R version 4.5.2

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
library(purrr)
```

Warning: package 'purrr' was built under R version 4.5.2

```
library(stringr)
library(tidyverse)
```

Warning: package 'ggplot2' was built under R version 4.5.2

Warning: package 'readr' was built under R version 4.5.2

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v forcats   1.0.1      v readr     2.2.0
v ggplot2   4.0.3      v tibble    3.3.1
v lubridate 1.9.5      v tidyr     1.3.2
```

```
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(lubridate)

# Función para leer únicamente las estaciones y variables de interés
leer_base <- function(archivo, anio) {

  hojas <- excel_sheets(archivo)

  # Seleccionar únicamente las estaciones del estudio
  hojas <- hojas[hojas %in% c("NE", "SE2", "SE3")]

  map_dfr(hojas, function(hoja) {

    read_excel(archivo, sheet = hoja) %>%
      mutate(
        Estacion = hoja,
        Año = anio
      ) %>%
      select(
        any_of(c("Fecha y hora", "date")),
        SO2,
        WDR,
        WSR,
        TOUT,
```

```

        RH,
        PRS,
        SR,
        RAINF,
        Estacion,
        Año
    )

  })
}

# Leer las bases de cada año
datos22 <- leer_base("BD 2022.xlsx", 2022)
datos23 <- leer_base("BD 2023.xlsx", 2023)
datos24 <- leer_base("BD 2024.xlsx", 2024)
datos25 <- leer_base("BD 2025.xlsx", 2025)

# Unificar el nombre de la columna de fecha de 2025
datos25 <- datos25 %>%
  rename(`Fecha y hora` = date)

# Unir todos los años en una sola base
datos <- bind_rows(
  datos22,
  datos23,
  datos24,
  datos25
)

# Revisar la base final
dim(datos)

```

```
[1] 105177      11
```

```
head(datos)
```

```

# A tibble: 6 x 11
  `Fecha y hora`      SO2   WDR   WSR  TOUT    RH   PRS    SR RAINF Estacion
  <dtm>          <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <chr>
1 2022-01-01 00:00:00  4.4  327  4.6  22.1   71  712.    0    0 NE
2 2022-01-01 01:00:00  5.1  322   4   21.1   73  712.    0    0 NE

```



```

3 2022-01-01 02:00:00 6 302 3.5 20.4 75 712. 0 0 NE
4 2022-01-01 03:00:00 5.7 288 3.6 19.9 76 712. 0 0 NE
5 2022-01-01 04:00:00 5.1 311 3.8 19.4 76 712. 0 0 NE
6 2022-01-01 05:00:00 5 292 3.4 18.8 77 712. 0 0 NE
# i 1 more variable: Año <dbl>

```

```
table(datos$Año)
```

```

2022 2023 2024 2025
26280 26274 26348 26275

```

```
table(datos$Estacion, datos$Año)
```

```

      2022 2023 2024 2025
NE    8760 8758 8784 8758
SE2   8760 8758 8782 8759
SE3   8760 8758 8782 8758

```

Después de unir las bases correspondientes a los años 2022–2025, se obtuvo un conjunto de datos compuesto por 105177 registros y 11 variables, distribuidos entre 3 estaciones de monitoreo.

```
names(datos22)
```

```

[1] "Fecha y hora" "SO2"      "WDR"      "WSR"      "TOUT"
[6] "RH"           "PRS"      "SR"       "RAINF"    "Estacion"
[11] "Año"

```

```
names(datos23)
```

```

[1] "Fecha y hora" "SO2"      "WDR"      "WSR"      "TOUT"
[6] "RH"           "PRS"      "SR"       "RAINF"    "Estacion"
[11] "Año"

```

```
names(datos24)
```

```

[1] "Fecha y hora" "SO2"          "WDR"          "WSR"          "TOUT"
[6] "RH"           "PRS"          "SR"           "RAINF"        "Estacion"
[11] "Año"

```

```
names(datos25)
```

```

[1] "Fecha y hora" "SO2"          "WDR"          "WSR"          "TOUT"
[6] "RH"           "PRS"          "SR"           "RAINF"        "Estacion"
[11] "Año"

```

```

# Ver a grandes rasgos el tibble
head(datos)

```

```

# A tibble: 6 x 11
  `Fecha y hora`      SO2   WDR   WSR  TOUT    RH   PRS    SR RAINF Estacion
  <dtm>            <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <chr>
1 2022-01-01 00:00:00  4.4  327  4.6  22.1   71  712.    0    0 NE
2 2022-01-01 01:00:00  5.1  322   4   21.1   73  712.    0    0 NE
3 2022-01-01 02:00:00   6   302  3.5  20.4   75  712.    0    0 NE
4 2022-01-01 03:00:00  5.7  288  3.6  19.9   76  712.    0    0 NE
5 2022-01-01 04:00:00  5.1  311  3.8  19.4   76  712.    0    0 NE
6 2022-01-01 05:00:00   5   292  3.4  18.8   77  712.    0    0 NE
# i 1 more variable: Año <dbl>

```

```

# Ver las dimensiones y tipos de datos
print(dim(datos))

```

```
[1] 105177    11
```

```
str(datos)
```

```

tibble [105,177 x 11] (S3: tbl_df/tbl/data.frame)
 $ Fecha y hora: POSIXct[1:105177], format: "2022-01-01 00:00:00" "2022-01-
01 01:00:00" ...
 $ SO2         : num [1:105177] 4.4 5.1 6 5.7 5.1 5 4.8 5.7 4.5 3.3 ...
 $ WDR         : num [1:105177] 327 322 302 288 311 292 240 145 295 295 ...
 $ WSR         : num [1:105177] 4.6 4 3.5 3.6 3.8 3.4 3.7 4.2 13 14.7 ...
 $ TOUT        : num [1:105177] 22.1 21.1 20.4 19.9 19.4 ...
 $ RH          : num [1:105177] 71 73 75 76 76 77 77 68 25 21 ...
 $ PRS         : num [1:105177] 712 712 712 712 712 ...

```

```
$ SR      : num [1:105177] 0 0 0 0 0 0 0 0 0.004 0.07 ...
$ RAINF   : num [1:105177] 0 0 0 0 0 0 0 0 0 0 ...
$ Estacion : chr [1:105177] "NE" "NE" "NE" "NE" ...
$ Año     : num [1:105177] 2022 2022 2022 2022 2022 ...
```

```
# Ver cantidad de datos faltantes
colSums(is.na(datos))
```

Fecha y hora	S02	WDR	WSR	TOUT	RH
0	3633	2287	2625	13408	4456
PRS	SR	RAINF	Estacion	Año	
2079	1095	1172	0	0	

```
# Ver si hay datos atípicos o sesgos
summary(datos)
```

```

Fecha y hora          S02          WDR
Min.   :2022-01-01 00:00:00  Min.   : 0.500  Min.   : 1.0
1st Qu.:2023-01-01 04:00:00  1st Qu.: 3.100  1st Qu.: 89.0
Median :2024-01-01 11:00:00  Median : 4.000  Median :132.0
Mean   :2024-01-01 11:04:35  Mean   : 5.527  Mean   :147.9
3rd Qu.:2024-12-31 17:00:00  3rd Qu.: 5.200  3rd Qu.:174.0
Max.   :2025-12-31 23:00:00  Max.   :404.700 Max.   :360.0
NA's   :                NA's   :3633   NA's   :2287

      WSR      TOUT      RH      PRS
Min.   : 0.100  Min.   : -9999.00  Min.   : -9999.00  Min.   :680.3
1st Qu.: 3.975  1st Qu.:  18.79   1st Qu.:  44.00   1st Qu.:720.0
Median : 6.800  Median :  24.37   Median :  63.00   Median :722.5
Mean   : 7.352  Mean   :  23.52   Mean   :  60.01   Mean   :723.8
3rd Qu.:10.100  3rd Qu.:  28.85   3rd Qu.:  78.00   3rd Qu.:727.9
Max.   :29.700  Max.   :  785.00   Max.   :  725.00   Max.   :750.0
NA's   :2625   NA's   :13408   NA's   :4456     NA's   :2079

      SR      RAINF      Estacion      Año
Min.   : -0.0120  Min.   :0.00000  Length:105177  Min.   :2022
1st Qu.: 0.0000  1st Qu.:0.00000  Class :character  1st Qu.:2023
Median : 0.0060  Median :0.00000  Mode  :character  Median :2024
Mean   : 0.1314  Mean   :0.00097              Mean   :2024
3rd Qu.: 0.2130  3rd Qu.:0.00000              3rd Qu.:2024
Max.   : 0.8810  Max.   :7.37000              Max.   :2025
NA's   :1095    NA's   :1172
```

Se puede notar que hay una gran cantidad de datos faltantes. Especialmente en la columna de TOUT donde hubo 13,408 valores faltantes. Otras variables con gran cantidad de datos faltantes son *RH*, *SO₂* y *RH*.

Revisando los valores máximos y mínimos de las variables podemos notar como en varias de ellas (WDR, WSR, RAINF, etc) tienen un mínimo de -9999 y en otras como RH el máximo es de 725 cuando es una medida que va desde 0 hasta 100.

```
# Si el dato se sale del rango proporcionado por SIMA, esa celda se vuelve valor nulo
datosF <- datos %>%
  mutate(
    SO2   = ifelse(SO2 < 0 | SO2 > 405, NA, SO2),
    WDR   = ifelse(WDR < 0 | WDR > 360, NA, WDR),
    WSR   = ifelse(WSR < 0 | WSR > 40, NA, WSR),
    TOUT  = ifelse(TOUT < -4.5 | TOUT > 45, NA, TOUT),
    RH    = ifelse(RH < 0 | RH > 100, NA, RH),
    PRS   = ifelse(PRS < 688 | PRS > 740, NA, PRS),
    SR    = ifelse(SR < 0 | SR > 1.2, NA, SR),
    RAINF = ifelse(RAINF < 0 | RAINF > 25, NA, RAINF)
  )

# Ver cantidad de valores fuera de rango convertidos a NA
valores_corregidos <- colSums(is.na(datosF)) - colSums(is.na(datos))

valores_corregidos
```

Fecha y hora	SO2	WDR	WSR	TOUT	RH
0	0	0	0	18	12
PRS	SR	RAINF	Estacion	Año	
1358	28	0	0	0	

```
# Guardar cantidad de filas antes de eliminar duplicados
filas_antes <- nrow(datosF)

# Eliminar duplicados
datosF <- distinct(datosF)

# Ver cantidad de filas después de eliminar duplicados
filas_despues <- nrow(datosF)

# Calcular duplicados eliminados
duplicados_eliminados <- filas_antes - filas_despues
```

```
filas_antes
```

```
[1] 105177
```

```
filas_despues
```

```
[1] 105177
```

```
duplicados_eliminados
```

```
[1] 0
```

No se eliminaron filas, por lo que no había filas duplicadas en el dataset original.

```
# Ver cantidad y porcentaje de datos faltantes después de la limpieza
colSums(is.na(datosF))
```

Fecha y hora	S02	WDR	WSR	TOUT	RH
0	3633	2287	2625	13426	4468
PRS	SR	RAINF	Estacion	Año	
3437	1123	1172	0	0	

```
round(colMeans(is.na(datosF)) * 100, 2)
```

Fecha y hora	S02	WDR	WSR	TOUT	RH
0.00	3.45	2.17	2.50	12.77	4.25
PRS	SR	RAINF	Estacion	Año	
3.27	1.07	1.11	0.00	0.00	

Imputación de datos

```
library(VIM)
```

Loading required package: colorspace

Warning: package 'colorspace' was built under R version 4.5.2

Loading required package: grid

VIM is ready to use.

Suggestions and bug-reports can be submitted at: <https://github.com/statistikat/VIM/issues>

Attaching package: 'VIM'

The following object is masked from 'package:datasets':

sleep

```
# Preparación e imputación de datos mediante KNN

# Conservar únicamente registros completos en las variables principales
datos_imputados <- datosF %>%
  filter(
    !is.na(SO2),
    !is.na(WDR),
    !is.na(WSR)
  ) %>%
  mutate(
    # Variables temporales
    Mes = month(`Fecha y hora`),
    Hora = hour(`Fecha y hora`),

    # Transformar dirección del viento para respetar
    # su naturaleza circular
    WDR_sin = sin(WDR * pi / 180),
    WDR_cos = cos(WDR * pi / 180),

    # Transformaciones circulares de hora y mes
    Hora_sin = sin(2 * pi * Hora / 24),
    Hora_cos = cos(2 * pi * Hora / 24),
    Mes_sin = sin(2 * pi * Mes / 12),
    Mes_cos = cos(2 * pi * Mes / 12)
  )

# Imputar únicamente las variables meteorológicas secundarias
```

```

# utilizando KNN dentro de cada estación
datos_imputados <- datos_imputados %>%
  group_split(Estacion, .keep = TRUE) %>%
  map_dfr(~ VIM::kNN(
    .x,

    # Variables que se van a imputar
    variable = c("TOUT", "RH", "PRS", "SR"),

    # Variables utilizadas para buscar observaciones similares
    dist_var = c(
      "WSR",
      "WDR_sin", "WDR_cos",
      "Año",
      "Hora_sin", "Hora_cos",
      "Mes_sin", "Mes_cos",
      "TOUT", "RH", "PRS", "SR"
    ),

    k = 5,
    imp_var = FALSE,
    useImputedDist = FALSE,
    methodStand = "iqr"
  )) %>%
  arrange(Estacion, `Fecha y hora`) %>%

# Eliminar solamente las variables auxiliares
select(
  -WDR_sin, -WDR_cos,
  -Hora_sin, -Hora_cos,
  -Mes_sin, -Mes_cos
)

# Revisar datos faltantes después de la preparación
colSums(is.na(datos_imputados))

```

Fecha y hora	S02	WDR	WSR	TOUT	RH
0	0	0	0	0	0
PRS	SR	RAINF	Estacion	Año	Mes
0	0	1	0	0	0
Hora					

0

```
# Eliminar el único registro faltante de precipitación
datos_imputados <- datos_imputados %>%
  filter(!is.na(RAINF))

# Verificar que ya no existan datos faltantes
colSums(is.na(datos_imputados))
```

Fecha y hora	SO2	WDR	WSR	TOUT	RH
0	0	0	0	0	0
PRS	SR	RAINF	Estacion	Año	Mes
0	0	0	0	0	0
Hora					
0					

Tras la limpieza inicial se identificaron valores faltantes en varias variables, por lo que se aplicó un tratamiento diferenciado según su relevancia. Las variables SO2, WDR y WSR no fueron imputadas, ya que son centrales para el análisis de contaminación y su estimación podría distorsionar los patrones reales; por ello, se conservaron únicamente registros completos en estas variables.

Para TOUT, RH, PRS y SR se aplicó imputación mediante KNN con k igual a 5, realizada por estación de monitoreo, utilizando variables meteorológicas y temporales como año, mes y hora junto con variables de viento para definir la similitud entre observaciones. La dirección del viento, el mes y la hora se transformaron mediante representaciones seno y coseno para respetar su naturaleza cíclica. La variable SO2 no se incluyó en el cálculo de vecinos con el fin de evitar sesgos en la imputación, y RAINF no se imputó debido a su comportamiento altamente esporádico y a la presencia predominante de valores cero.

Tras este proceso, solo se encontró un valor faltante en RAINF, el cual fue eliminado por su impacto despreciable en el conjunto de datos.

Estandarización de los datos

```
datos_transformados <- datos_imputados %>%
  mutate(
    # Transformación circular de la dirección del viento
    WDR_sin = sin(2 * pi * WDR / 360),
    WDR_cos = cos(2 * pi * WDR / 360),

    # Transformación logarítmica de SO2
```



```

S02_log = log1p(S02),

# Variables estandarizadas
S02_z = as.numeric(scale(S02_log)),
RH_z = as.numeric(scale(RH)),
WSR_z = as.numeric(scale(WSR)),
TOUT_z = as.numeric(scale(TOUT)),
SR_z = as.numeric(scale(SR)),
PRS_z = as.numeric(scale(PRS)),
RAINF_z = as.numeric(scale(RAINF))
)

names(datos_transformados)

```

```

[1] "Fecha y hora" "S02"          "WDR"          "WSR"          "TOUT"
[6] "RH"           "PRS"          "SR"           "RAINF"        "Estacion"
[11] "Año"          "Mes"          "Hora"         "WDR_sin"      "WDR_cos"
[16] "S02_log"      "S02_z"        "RH_z"         "WSR_z"        "TOUT_z"
[21] "SR_z"         "PRS_z"        "RAINF_z"

```

```

summary(
  datos_transformados %>%
    select(
      S02, S02_log, S02_z,
      WDR, WDR_sin, WDR_cos,
      WSR, WSR_z
    )
)

```

S02		S02_log		S02_z		WDR	
Min.	: 0.50	Min.	:0.4055	Min.	:-2.6513	Min.	: 1.0
1st Qu.:	3.10	1st Qu.:	1.4110	1st Qu.:	-0.5895	1st Qu.:	89.0
Median :	4.00	Median :	1.6094	Median :	-0.1826	Median :	132.0
Mean :	5.54	Mean :	1.6985	Mean :	0.0000	Mean :	147.5
3rd Qu.:	5.20	3rd Qu.:	1.8245	3rd Qu.:	0.2585	3rd Qu.:	173.0
Max.	:404.70	Max.	:6.0056	Max.	: 8.8318	Max.	:360.0

WDR_sin		WDR_cos		WSR		WSR_z	
Min.	:-1.00000	Min.	:-1.0000	Min.	: 0.100	Min.	:-1.6597
1st Qu.:	0.06976	1st Qu.:	-0.7431	1st Qu.:	3.900	1st Qu.:	-0.7881
Median :	0.60182	Median :	-0.2588	Median :	6.800	Median :	-0.1229
Mean :	0.38453	Mean :	-0.1046	Mean :	7.336	Mean :	0.0000

3rd Qu.: 0.87462	3rd Qu.: 0.6018	3rd Qu.:10.100	3rd Qu.: 0.6340
Max. : 1.00000	Max. : 1.0000	Max. :29.700	Max. : 5.1296

La estandarización se aplicó con el fin de llevar las variables a una escala comparable, ya que presentan unidades y rangos diferentes. Este procedimiento facilita su uso conjunto en análisis estadísticos y evita que una variable tenga mayor peso únicamente por la magnitud de sus valores. Se conservaron también las variables originales para mantener una interpretación directa de los resultados.

Referencias

- Ashbaugh, L. L., Malm, W. C., & Sadeh, W. Z. (1985). A residence time probability analysis of sulfur concentrations at Grand Canyon National Park. *Atmospheric Environment*, 19(8), 1263–1270. [https://doi.org/10.1016/0004-6981\(85\)90256-2](https://doi.org/10.1016/0004-6981(85)90256-2)
- Carslaw, D. C., Beevers, S. D., Ropkins, K., & Bell, M. C. (2006). Detecting and quantifying aircraft and other on-airport contributions to ambient nitrogen oxides in the vicinity of a large international airport. *Atmospheric Environment*, 40(28), 5424–5434. <https://doi.org/10.1016/j.atmosenv.2006.04.062>
- Carslaw, D. C., & Ropkins, K. (2012). Openair—An R package for air quality data analysis. *Environmental Modelling & Software*, 27–28, 52–61. <https://doi.org/10.1016/j.envsoft.2011.09.008>
- Clarke, K., Kwon, H.-O., & Choi, S.-D. (2014). Fast and reliable source identification of criteria air pollutants in an industrial city. *Atmospheric Environment*, 95, 239–248. <https://doi.org/10.1016/j.atmosenv.2014.06.040>
- Comisión Federal para la Protección contra Riesgos Sanitarios. (s. f.). *Normas Oficiales Mexicanas (NOM) de calidad del aire ambiente*. Gobierno de México. <https://www.gob.mx/cofepris/acciones-y-programas/4-normas-oficiales-mexicanas-nom-de-calidad-del-aire-ambiente>
- Gobierno del Estado de Nuevo León. (s. f.). *Índice Aire y Salud: Reporte de la calidad del aire en la Zona Metropolitana de Monterrey*. Sistema Integral de Monitoreo Ambiental. https://aire.nl.gob.mx/icars2020/map_calidad_icars.php
- Holcim España. (s. f.). *¿Qué es la calidad del aire? Importancia y medición*. <https://www.holcim.es/que-es-la-calidad-del-aire-importancia-y-medicion>
- Instituto Nacional de Ecología y Cambio Climático. (s. f.). *Sistema Nacional de Información de la Calidad del Aire (SINAICA)*. Gobierno de México. <https://sinaica.inecc.gob.mx/scica/>
- National Environmental Satellite, Data, and Information Service. (s. f.). *How is air quality measured?* National Oceanic and Atmospheric Administration. <https://www.nesdis.noaa.gov/about/k-12-education/dust-ash-fire-smoke/how-air-quality-measured>

National Institute of Environmental Health Sciences. (s. f.).*La contaminación del aire y su salud*. National Institutes of Health. <https://www.niehs.nih.gov/health/topics/enfermedades/contaminacion>

Organización Mundial de la Salud. (2021).*Directrices mundiales de la OMS sobre la calidad del aire: Partículas en suspensión (PM_{2.5} y PM₁₀), ozono, dióxido de nitrógeno, dióxido de azufre y monóxido de carbono*.<https://www.who.int/es/news-room/questions-and-answers/item/who-global-air-quality-guidelines>

Organización Mundial de la Salud. (2024).*Contaminación del aire ambiente (exterior) y salud*.[https://www.who.int/es/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/es/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health)

Programa de las Naciones Unidas para el Medio Ambiente. (2022).*¿Cómo se mide la calidad del aire?*<https://www.unep.org/es/noticias-y-reportajes/reportajes/como-se-mide-la-calidad-del-aire>

Secretaría de Medio Ambiente y Recursos Naturales. (2023).*Proyecto de Norma Oficial Mexicana PROY-NOM-172-SEMARNAT-2023, Lineamientos para la obtención y comunicación del índice de calidad del aire y riesgos a la salud*. Diario Oficial de la Federación. https://www.diaariooficial.gob.mx/normasOficiales/9314/semarnat_1_C/semarnat_1_C.html

Uria-Tellaetxe, I., & Carslaw, D. C. (2014). Conditional bivariate probability function for source identification.*Environmental Modelling & Software*, 59, 1-9. <https://doi.org/10.1016/j.envsoft.2014.05.002>

Xue, Y., Cui, X., Li, K., Yu, Q., & Ma, W. (2023). Statistical source analysis of recurring sulfur dioxide pollution events in a chemical industrial park.*Atmospheric Environment*, 296, 119564.<https://doi.org/10.1016/j.atmosenv.2022.119564>