

Etapa 1. Conociendo el negocio

Alicia Bernádez, Omar Arzaga, Diego Medrano, Sebastián Alemán, Isaac Montaña

Parte 1: Conociendo el negocio

La calidad del aire es un aspecto fundamental para el bienestar de la población y el medio ambiente, ya que depende de la presencia y concentración de diferentes contaminantes en la atmósfera. Cuando estos alcanzan niveles elevados pueden generar efectos negativos sobre la salud y los ecosistemas. Por ello, su monitoreo permite identificar condiciones de riesgo y generar información útil para reducir la exposición de la población y apoyar la toma de decisiones públicas (HOLCIM, s.f.).

Importancia del análisis de la calidad del aire

El análisis de la calidad del aire es importante para la ciudadanía debido a sus efectos sobre la salud. La Organización Mundial de la Salud estima que la contaminación del aire exterior ocasionó aproximadamente 4.2 millones de muertes prematuras en 2019 y la relaciona con enfermedades cardiovasculares, respiratorias, accidentes cerebrovasculares y cáncer de pulmón (OMS, 2024). Además, contar con información actualizada permite emitir recomendaciones durante episodios de contaminación, industria y desarrollo urbano.

Entre los contaminantes de mayor importancia se encuentran las partículas suspendidas (PM_{10} y $PM_{2.5}$), el ozono (O_3), el dióxido de nitrógeno (NO_2), el dióxido de azufre (SO_2) y el monóxido de carbono (CO). El material particulado es especialmente relevante debido a que las partículas más pequeñas pueden penetrar profundamente en los pulmones e incluso ingresar al torrente sanguíneo, generando efectos cardiovasculares y respiratorios (OMS, 2024). La OMS establece valores guía internacionales para estos contaminantes; mientras que en México el Índice Aire y Salud comunica las condiciones mediante las categorías buena, aceptable, mala, muy mala y extremadamente mala.

Medición de la calidad del aire y variables relacionadas

La calidad del aire se evalúa mediante redes de monitoreo que registran las concentraciones de contaminantes atmosféricos. Estas mediciones permiten analizar su comportamiento temporal y espacial, además de detectar episodios que puedan representar un riesgo para la población

(PNUMA, 2022). En México, el Sistema Nacional de Información de la Calidad del Aire (SINAICA), administrado por el INEEC, integra y valida información proveniente de distintos sistemas de monitoreo del país (INECC, s.f.).

Para interpretar los resultados es necesario considerar tanto la unidad de concentración como el periodo de exposición. Las partículas suelen expresarse en microgramos por metro cúbico, mientras que algunos gases se reportan en partes por millón o partes por billón. También pueden analizarse concentraciones horarias, promedios de 8 horas, 24 horas o anuales. Además de las emisiones, variables meteorológicas como temperatura, humedad, velocidad y dirección del viento, presión, precipitación y radiación solar influyen en la dispersión, transporte y acumulación de los contaminantes.

Normas y lineamientos para la protección de la salud

A nivel internacional, las Directrices Mundiales sobre la Calidad del Aire de la OMS establecen valores recomendados para $PM_{2.5}$, PM_{10} , O_3 , NO_2 , SO_2 y CO . Estas directrices se basan en evidencia científica sobre sus efectos en la salud, pero no son legalmente obligatorias; funcionan como referencia para que cada país desarrolle sus propias regulaciones (OMS, 2021).

En México, los límites para la protección de la salud se establecen mediante Normas Oficiales Mexicanas. Para los principales contaminantes se encuentran la NOM-020-SSA1-2021, correspondiente al ozono; la NOM-021-SSA1-2021 para el monóxido de carbono; la NOM-022-SSA1-2019 para el dióxido de azufre; la NOM-023-SSA1-2021 para el dióxido de nitrógeno y la NOM-025-SSA1-2021 correspondiente a las partículas suspendidas (DOF, 2019; DOF, 2021). Asimismo, la NOM-172-SEMARNAT establece los lineamientos para comunicar el Índice de Calidad del Aire y Riesgos a la Salud (SEMARNAT, 2023). Una problemática importante es que los límites establecidos en las normas nacionales no siempre coinciden con las recomendaciones de la OMS, por lo que cumplir con una norma nacional no implica necesariamente la ausencia total de riesgo para la salud.

Dificultades en la medición de la calidad del aire

El monitoreo de la calidad del aire presenta dificultades relacionadas con la cobertura de las estaciones, la disponibilidad y calidad de los registros y la variabilidad espacial y temporal de los contaminantes. Los equipos requieren mantenimiento y calibración, pueden presentarse datos faltantes y una estación representa principalmente las condiciones de su entorno inmediato. Por ello, antes de realizar análisis estadísticos es necesario validar, depurar y evaluar la disponibilidad de los datos (INECC, s.f. ; PNUMA, 2022).

Sistema Integral de Monitoreo Ambiental de Nuevo León

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA), administrado por la Secretaría de Medio Ambiente del Estado, monitorea contaminantes atmosféricos y variables

meteorológicas en diferentes zonas del Área Metropolitana de Monterrey. Además de informar a la ciudadanía mediante el Índice Aire y Salud, sus registros históricos permiten estudiar el comportamiento y las relaciones entre contaminantes y condiciones ambientales (Gobierno de Nuevo León, s.f.).

La información generada por SIMA constituye la principal fuente de datos para este proyecto y permitirá analizar una problemática específica relacionada con el comportamiento del SO_2 y su posible relación con condiciones meteorológicas y fuentes industriales de la región.

Objetivo general del trabajo

Analizar y caracterizar la relación entre las concentraciones de dióxido de azufre (SO_2) y las condiciones meteorológicas registradas en la estación SE3 (Cadereyta), SE2 (Juárez) y SE1 (San Nicolás) durante el periodo 2022-2025, con el propósito de identificar patrones direccionales asociados con episodios de concentraciones elevadas y evaluar su posible relación con fuentes industriales localizadas en la región.

Objetivos específicos:

-

Antecedentes relacionados con el objetivo del trabajo

La infraestructura verde y áreas verdes se han asociado con mejoras en calidad del aire al reducir la concentración de contaminantes y mejorar la salud ambiental (Oliveira et al., 2025; Akaraci et al., 2022). Esto debido a su capacidad para mitigar concentraciones de PM , con estudios que demuestran una capacidad para reducir $PM_{2.5}$ en un 15-20% en su entorno inmediato (Oliveira et al., 2025). De igual manera, las zonas verdes también se asocian a mitigar islas de calor urbanas (Oliveira et al., 2025).

Como parte de la revisión de literatura relacionada con el objetivo del proyecto, se identificó un estudio realizado en el área metropolitana de São Paulo que analiza la relación entre las áreas verdes urbanas, grado de urbanización y la concentración de contaminantes atmosféricos. Este estudio es de relevancia para el desarrollo del proyecto, ya que se integran variables de vegetación y urbanización, con datos de monitoreo ambiental.

Resumen de la metodología

El estudio utilizó una combinación de datos de teledetección, mediciones de la calidad del aire y técnicas estadísticas avanzadas para analizar la relación entre las áreas verdes urbanas y la contaminación del aire en el Área Metropolitana de São Paulo. Los aspectos clave incluyen:

- Análisis de las concentraciones de PM_{10} y $PM_{2.5}$ de 27 estaciones de monitoreo en toda la zona metropolitana de São Paulo
- Cálculo del Índice de Vegetación de Diferencia Normalizada (NDVI) y del Índice de Áreas Construidas de Diferencia Normalizada (NDBI) para evaluar las áreas verdes y la urbanización
- Aplicación del algoritmo de agrupamiento K-means para identificar patrones regionales y similitudes en la calidad del aire, la urbanización y las características de la vegetación
- Utilización del análisis de pendiente de Sen para detectar tendencias temporales en $PM_{2.5}$, PM_{10} , NDVI y NDBI

Métricas y resultados

El análisis reveló una disminución general en las concentraciones de $PM_{2.5}$ y PM_{10} entre 2014 y 2023, observándose en regiones con un NDVI más alto niveles de PM hasta un 50% inferiores en comparación con las zonas industriales y de mucho tráfico. El análisis de la pendiente de Sen mostró una disminución en los niveles de contaminantes que coincide con el aumento de áreas verdes y las políticas de plantación de árboles en la zona.

Limitaciones y relaciones

Si bien el estudio destaca el papel de las zonas verdes en la mitigación de la contaminación atmosférica, reconoce que otros factores, como el tráfico, las emisiones industriales y las condiciones meteorológicas, también influyen significativamente en las concentraciones de partículas en suspensión. La distribución desigual de las estaciones de monitoreo, particularmente en la región sur, introduce incertidumbres espaciales en el análisis.

Parte 2: Comprensión y preparación de los datos

```
library(readxl)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
```

```
x dplyr::filter() masks stats::filter()
x dplyr::lag() masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(dplyr)
library(google sheets4)
```

```
library(google sheets4)
library(purrr)
library(dplyr)

options(
  gargle_oauth_cache = ".secrets"
)

gs4_auth(
  cache = ".secrets",
  email = TRUE,
  scopes = "https://www.googleapis.com/auth/spreadsheets.readonly"
)
```

i The google sheets4 package is using a cached token for 'a01562634@tec.mx'.

```
#Leer el archivo
url <- "https://docs.google.com/spreadsheets/d/1n40s3KhB_eoNonYgfjjaiDrYEUsLOG4cW1VmVp5TBTA/"

# Obtener nombres de las hojas
hojas <- sheet_names(url)
```

Auto-refreshing stale OAuth token.

```
# Unir las hojas en un solo dataframe
#Importante notar que las 15 hojas fueron incluidas en una sola, por lo que se tuvo que agregar
datos25 <- map_dfr(hojas, function(hoja) {
  df <- read_sheet(url, sheet = hoja)
  df$Estacion <- hoja
  return(df)
})
```

v Reading from "BD 2025".

v Range ''CE''.

v Reading from "BD 2025".

v Range ''NE''.

v Reading from "BD 2025".

v Range ''NE2''.

v Reading from "BD 2025".

v Range ''NE3''.

v Reading from "BD 2025".

v Range ''NO''.

v Reading from "BD 2025".

v Range ''NO2''.

v Reading from "BD 2025".

v Range ''NO3''.

v Reading from "BD 2025".

v Range ''NTE''.

v Reading from "BD 2025".

v Range ''NTE2''.

v Reading from "BD 2025".

v Range ''SE''.

```
v Reading from "BD 2025".
```

```
v Range 'SE2'.
```

```
v Reading from "BD 2025".
```

```
v Range 'SE3'.
```

```
v Reading from "BD 2025".
```

```
v Range 'S0'.
```

```
v Reading from "BD 2025".
```

```
v Range 'S02'.
```

```
v Reading from "BD 2025".
```

```
v Range 'SUR'.
```

```
#Ver a grandes rasgos el tibble  
head(datos25)
```

```
# A tibble: 6 x 17  
  date                CO    NO    NO2    NOX    O3  PM10 PM2.5  PRS RAINF  
  <dtm>              <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>  
1 2025-01-01 00:00:00  2.42  5.9  13.1  26.6   24   84  NA    NA    NA  
2 2025-01-01 01:00:00  2.12  3    7.1  10.3   42   81  75.5  714.    0  
3 2025-01-01 02:00:00  2.11  2.8  6.2   9.3   41   63  35.3  714.    0  
4 2025-01-01 03:00:00  2.1   2.6  5.6   8.5   41   46  26.9  714.    0  
5 2025-01-01 04:00:00  2.11  2.6  5.7   8.5   39   39  21.7  714.    0  
6 2025-01-01 05:00:00  2.18  2.6  12.5  15.3   29   35  20.4  714     0  
# i 7 more variables: RH <dbl>, S02 <dbl>, SR <dbl>, TOUT <dbl>, WSR <dbl>,  
#   WDR <dbl>, Estacion <chr>
```

```
#Ver las dimensiones y tipos de datos  
print(dim(datos25))
```

```
[1] 131378    17
```

```
str(datos25)
```

```
tibble [131,378 x 17] (S3: tbl_df/tbl/data.frame)
 $ date      : POSIXct[1:131378], format: "2025-01-01 00:00:00" "2025-01-
01 01:00:00" ...
 $ CO        : num [1:131378] 2.42 2.12 2.11 2.1 2.11 2.18 2.18 2.14 2.16 2.16 ...
 $ NO        : num [1:131378] 5.9 3 2.8 2.6 2.6 2.6 3 2.5 3 4.4 ...
 $ NO2       : num [1:131378] 13.1 7.1 6.2 5.6 5.7 12.5 14 9.1 19.8 17.4 ...
 $ NOX       : num [1:131378] 26.6 10.3 9.3 8.5 8.5 15.3 17.2 11.8 23 22.1 ...
 $ O3        : num [1:131378] 24 42 41 41 39 29 28 32 18 22 ...
 $ PM10      : num [1:131378] 84 81 63 46 39 35 50 54 52 56 ...
 $ PM2.5     : num [1:131378] NA 75.5 35.3 26.9 21.7 ...
 $ PRS       : num [1:131378] NA 714 714 714 714 ...
 $ RAINF     : num [1:131378] NA 0 0 0 0 0 0 0 0 ...
 $ RH        : num [1:131378] NA 56 63 67 71 77 84 83 82 76 ...
 $ SO2       : num [1:131378] 5.4 5 4.7 4.5 4.6 4.6 4.9 5.5 5.7 6.3 ...
 $ SR        : num [1:131378] NA 0 0 0 0 0 0 0 0.007 0.067 ...
 $ TOUT      : num [1:131378] 17.9 17 16.2 15.9 15.4 ...
 $ WSR       : num [1:131378] 12.2 8 7.9 8.2 7.1 6.9 5.6 3.5 1.8 2.1 ...
 $ WDR       : num [1:131378] NA 69 114 108 89 47 53 26 299 187 ...
 $ Estacion: chr [1:131378] "CE" "CE" "CE" "CE" ...
```

```
#Ver cantidad de datos faltantes
```

```
colSums(is.na(datos25))
```

	date	CO	NO	NO2	NOX	O3	PM10	PM2.5
	0	17784	19500	17398	17598	8655	6351	44797
	PRS	RAINF	RH	SO2	SR	TOUT	WSR	WDR
	7025	5955	23813	12477	6107	15548	4690	4304
Estacion	0							

```
#Ver si hay datos atípicos o sesgos
```

```
summary(datos25)
```

	date	CO	NO
Min.	:2025-01-01 00:00:00	Min. :0.050	Min. : 0.50
1st Qu.	:2025-04-02 06:00:00	1st Qu.:0.550	1st Qu.: 2.70
Median	:2025-07-02 12:00:00	Median :0.830	Median : 4.30
Mean	:2025-07-02 11:38:15	Mean :1.021	Mean : 11.92

3rd Qu.:2025-10-01 17:00:00	3rd Qu.:1.240	3rd Qu.: 9.40
Max. :2025-12-31 23:00:00	Max. :9.790	Max. :495.80
	NAs :17784	NAs :19500

NO2		NOX		O3		PM10	
Min. : 0.00	Min. :-9999.00	Min. : 0.50	Min. : 2.00				
1st Qu.: 6.00	1st Qu.: 9.20	1st Qu.: 13.00	1st Qu.: 27.00				
Median : 10.90	Median : 15.50	Median : 25.00	Median : 40.00				
Mean : 13.91	Mean : 25.21	Mean : 28.93	Mean : 49.06				
3rd Qu.: 18.70	3rd Qu.: 28.80	3rd Qu.: 40.00	3rd Qu.: 59.00				
Max. :165.10	Max. : 702.20	Max. :184.00	Max. :811.00				
NAs :17398	NAs :17598	NAs :8655	NAs :6351				

PM2.5		PRS		RAINF		RH	
Min. : 0.00	Min. : 0.0	Min. :-9999.0000	Min. :-9999.00				
1st Qu.: 9.00	1st Qu.:710.6	1st Qu.: 0.0000	1st Qu.: 40.00				
Median : 16.00	Median :714.7	Median : 0.0000	Median : 58.00				
Mean : 18.78	Mean :715.7	Mean : 0.0053	Mean : 55.48				
3rd Qu.: 25.00	3rd Qu.:721.7	3rd Qu.: 0.0000	3rd Qu.: 74.00				
Max. :340.25	Max. :750.0	Max. : 360.0000	Max. : 725.00				
NAs :44797	NAs :7025	NAs :5955	NAs :23813				

SO2		SR		TOUT		WSR	
Min. : 0.500	Min. : -0.003	Min. :-4.10	Min. :-9999.000				
1st Qu.: 3.000	1st Qu.: 0.000	1st Qu.:19.85	1st Qu.: 4.700				
Median : 4.100	Median : 0.001	Median :24.61	Median : 7.600				
Mean : 4.867	Mean : 0.138	Mean :23.76	Mean : 8.044				
3rd Qu.: 5.300	3rd Qu.: 0.206	3rd Qu.:28.75	3rd Qu.: 11.000				
Max. :404.700	Max. :604.000	Max. :43.63	Max. : 337.000				
NAs :12477	NAs :6107	NAs :15548	NAs :4690				

WDR		Estacion	
Min. :-9999.0	Length :131378		
1st Qu.: 80.0	N.unique : 15		
Median : 122.0	N.blank : 0		
Mean : 147.4	Min.nchar: 2		
3rd Qu.: 206.0	Max.nchar: 4		
Max. : 360.0			
NAs :4304			

Podemos notar que hay una gran cantidad de datos faltantes. Especialmente en la columna de PM2.5 donde hubo 44797 valores faltantes. Otras variables con gran cantidad de datos faltantes son RH, NO y CO. Podemos notar que hay una gran cantidad de datos faltantes. Especialmente en la columna de $PM_{2.5}$ donde hubo 44797 valores faltantes. Otras variables con gran cantidad de datos faltantes son RH , NO y CO .

Podemos notar que hay una gran cantidad de datos faltantes. Especialmente en la columna

de $PM_{2.5}$ donde hubo 44797 valores faltantes. Otras variables con gran cantidad de datos faltantes son *RH*, *NO* y *CO*.

Revisando los valores máximos y mínimos de las variables podemos notar como en varias de ellas (WDR, WSR, RAINF, etc) tienen un mínimo de -9999 y en otras como RH el máximo es de 725 cuando es una medida que va desde 0 hasta 100.

```
#Si el dato se sale del rango proporcionado por SIMA, esa celda se vuelve valor nulo
datos25F <- datos25 %>%
  mutate(

    PM10    = ifelse(PM10 < 0 | PM10 > 820, NA, PM10),
    `PM2.5` = ifelse(`PM2.5` < 0 | `PM2.5` > 350, NA, `PM2.5`),
    O3      = ifelse(O3 < 0 | O3 > 185, NA, O3),
    NO      = ifelse(NO < 0 | NO > 350, NA, NO),
    NO2     = ifelse(NO2 < 0 | NO2 > 175, NA, NO2),
    NOX     = ifelse(NOX < 0 | NOX > 400, NA, NOX),
    SO2     = ifelse(SO2 < 0 | SO2 > 405, NA, SO2),
    CO      = ifelse(CO < 0 | CO > 10, NA, CO),
    RH      = ifelse(RH < 0 | RH > 100, NA, RH),
    WSR     = ifelse(WSR < 0 | WSR > 40, NA, WSR),
    TOUT    = ifelse(TOUT < -4.5 | TOUT > 45, NA, TOUT),
    SR      = ifelse(SR < 0 | SR > 1.2, NA, SR),
    PRS     = ifelse(PRS < 688 | PRS > 740, NA, PRS),
    WDR     = ifelse(WDR < 0 | WDR > 360, NA, WDR),
    RAINF   = ifelse(RAINF < 0 | RAINF > 25, NA, RAINF)
  )
```

```
#Eliminar duplicados
datos25F <- distinct(datos25F)

nrow(datos25F)
```

```
[1] 131378
```

No se eliminaron filas, por lo que no había filas duplicadas