

## Etapa 2: Conociendo los datos

Alicia Bernádez A01562634      Omar Arzaga A01569294  
Diego Medrano A01254882      Sebastián Alemán A00841034  
Isaac Montaña A00841681

### Objetivo del análisis

Analizar y caracterizar las concentraciones de dióxido de azufre ( $SO_2$ ) registradas durante 2022-2025 en las estaciones SE3 (Cadereyta), SE2 (Juárez), NE (San Nicolás) y GAR (García), así como su relación con las condiciones meteorológicas, principalmente la dirección y velocidad del viento, con el propósito de identificar patrones espaciales y direccionales consistentes con una posible influencia de fuentes industriales en la zona de Cadereyta.

### Técnicas estadísticas

#### 1. Análisis espacio-temporal de $SO_2$

Esta técnica permitirá estudiar cómo cambian las concentraciones de  $SO_2$  a través del tiempo y entre las distintas estaciones de monitoreo. Se analizarán patrones por año, mes y hora, además de comparar el comportamiento de las estaciones seleccionadas. Este tipo de análisis ha sido utilizado en estudios de ciudades industriales para identificar diferencias espaciales y temporales en los niveles de contaminantes y reconocer episodios de concentraciones elevadas (Clarke et al, 2014; Xue et al, 2023). En este proyecto permitirá determinar si los valores altos de  $SO_2$  se concentran principalmente en determinadas estaciones o periodos.

#### 2. Gráficos polares bivariados

Los gráficos polares permiten analizar de manera conjunta la concentración de un contaminante, la dirección del viento y su velocidad. De esta forma, es posible identificar las condiciones del viento bajo las cuales se presentan las mayores concentraciones de  $SO_2$  y visualizar los sectores desde los que podrían transportarse las emisiones hacia cada estación. Esta metodología ha sido aplicada para diferenciar posibles contribuciones de distintas fuentes de contaminación y se encuentra implementada en el paquete openair de R (Carslaw et al, 2006;

Carslaw & Ropkins, 2012). En el presente estudio, los patrones obtenidos podrán compararse con la ubicación geográfica de la zona industrial de Cadereyta.

### 3. Conditional Bivariate Probability Function (CBPF)

La CBPF permite estimar la probabilidad de observar concentraciones elevadas de un contaminante bajo diferentes combinaciones de dirección y velocidad del viento. A diferencia del gráfico polar, que muestra principalmente la magnitud de las concentraciones, esta técnica se enfoca en identificar las condiciones meteorológicas asociadas con una mayor frecuencia de valores elevados. La metodología extiende los enfoques de probabilidad condicional utilizados previamente para la identificación de regiones potencialmente emisoras (Ashbaugh et al, 1985; Uribe-Tellaetxe & Carslaw, 2014). Su aplicación permitirá identificar sectores direccionales asociados con una mayor presencia de concentraciones altas de  $SO_2$ .

### 4. Caracterización comparativa de episodios elevados

Esta técnica podría contribuir a identificar y comparar episodios de concentraciones elevadas de  $SO_2$  considerando la estación donde ocurren, las condiciones meteorológicas presentes y su posible simultaneidad con otras estaciones. Su aplicación permitiría distinguir entre eventos con un comportamiento más localizado y aquellos que se presentan en varias zonas al mismo tiempo, lo cual podría ser indicativo de fenómenos de mayor escala. Estudios previos han utilizado el análisis individual de episodios de contaminación para explorar posibles fuentes y condiciones asociadas con eventos recurrentes de  $SO_2$  (Clarke et al, 2014; Xue et al, 2023). De manera complementaria, durante estos episodios también podría examinarse el comportamiento de otros contaminantes, sin asumir que necesariamente deben presentar incrementos simultáneos.

### Variables elegidas

Para responder al objetivo del proyecto se consideran como variables principales la concentración de  $SO_2$ , la dirección del viento (WDR), la velocidad del viento (WSR) y la estación de monitoreo. También se incluyen como variables meteorológicas complementarias la temperatura exterior (TOUT), humedad relativa (RH), presión atmosférica (PRS), radiación solar (SR) y precipitación (RAINF). Los demás contaminantes se conservan como variables complementarias para caracterizar el contexto de los registros de  $SO_2$ .

Table 1: Características descriptivas de  $SO_2$  por estación

| <b>Estación</b> | <b>Horas válidas</b> | <b>Media</b> | <b>Mediana</b> | <b>Desv. estándar</b> | <b>Máximo</b> |
|-----------------|----------------------|--------------|----------------|-----------------------|---------------|
| GAR             | 32,534               | 3.48         | 3.30           | 1.25                  | 22.80         |
| NE              | 33,185               | 4.35         | 3.80           | 2.96                  | 163.60        |
| SE2             | 33,240               | 4.98         | 3.80           | 5.32                  | 178.30        |
| SE3             | 33,977               | 7.25         | 4.40           | 11.00                 | 404.70        |

Descriptivamente, SE3 presenta las concentraciones medias y medianas de  $SO_2$  más elevadas, así como la mayor variabilidad, mientras que GAR presenta los valores más bajos y estables. Las cuatro estaciones cuentan con cantidades similares de observaciones válidas, por lo que las diferencias encontradas no parecen explicarse únicamente por una mayor cantidad de datos en alguna estación. Estos resultados son exploratorios y no permiten atribuir todavía las diferencias observadas a una fuente específica. La estación de monitoreo funciona como la principal variable de comparación espacial, ya que permite identificar si el comportamiento del  $SO_2$  cambia entre Cadereyta, Juárez, San Nicolás y García. Por su parte, WDR y WSR permiten incorporar la dirección y velocidad del viento al análisis, variables necesarias para evaluar posteriormente si las concentraciones elevadas de  $SO_2$  presentan patrones direccionales específicos.

## Gráficas

### Boxplot de $SO_2$ por estación




Figure 1: Distribución de SO<sub>2</sub> por estación de monitoreo.

Se observan diferencias en la distribución de  $SO_2$  entre las estaciones. SE3 presenta la mediana más alta y una mayor dispersión de las concentraciones, seguida por SE2 y NE, mientras que GAR muestra los valores más bajos y estables. También se identifican numerosos valores atípicos, principalmente en SE3; sin embargo, estos no se eliminaron, ya que pueden representar episodios reales de concentraciones elevadas. La visualización se limita al percentil 99 únicamente para facilitar la comparación entre estaciones, sin excluir observaciones del análisis.

### Histogramas de $SO_2$ por estación




Figure 2: Distribución de las concentraciones de SO<sub>2</sub> para cada estación.

Las cuatro estaciones presentan distribuciones asimétricas hacia la derecha, con una mayor concentración de observaciones en los valores bajos de  $SO_2$  y una cola formada por concentraciones más elevadas. Esta asimetría es especialmente evidente en SE3, donde se presentan valores extremos con mayor magnitud. Por lo tanto, la mediana resulta útil como medida representativa del comportamiento típico de  $SO_2$ , ya que es menos sensible a estos valores elevados que el promedio.

### Matriz de correlación




Figure 3: Matriz de correlación entre contaminantes y variables meteorológicas.

En general, el  $SO_2$  presenta correlaciones lineales bajas con las variables meteorológicas y con los demás contaminantes. Las asociaciones positivas más visibles son con  $O_3$ , radiación solar y presión atmosférica, aunque sus magnitudes continúan siendo débiles. Esto indica que ninguna de estas variables, de manera individual y mediante una regresión lineal simple, explica claramente el comportamiento del  $SO_2$ . Además, una correlación baja con las variables relacionadas con el viento no necesariamente implica ausencia de relación, ya que los efectos de dirección y velocidad pueden presentar patrones no lineales que deberán explorarse posteriormente con técnicas más adecuadas.

### Comportamiento anual de $SO_2$ por estación




Figure 4: Comportamiento anual de la concentración mediana de SO<sub>2</sub> por estación.

El comportamiento anual muestra una disminución general de las concentraciones medianas de  $SO_2$  entre 2022-2023, seguida de un incremento durante 2024 y 2025. SE3 mantiene la mediana más alta durante todo el periodo analizado, mientras que GAR presenta generalmente los valores más bajos. Para 2025 se observa una mayor similitud entre las estaciones, aunque SE3 continúa ligeramente por encima de las demás. Estos resultados sugieren que existen tanto diferencias espaciales como variaciones temporales en las concentraciones de  $SO_2$  que será necesario analizar con mayor profundidad en las siguientes etapas.

## Resumen

Hasta esta etapa se logró integrar, limpiar y explorar la información de las estaciones seleccionadas para el periodo 2022-2025, obteniendo una base final de 132,936 registros. El análisis descriptivo permitió identificar diferencias entre estaciones en las concentraciones de  $SO_2$ , destacando SE3 por presentar los valores medios y medianos más altos, así como una mayor variabilidad. También se observó una distribución asimétrica hacia valores altos y asociaciones lineales generalmente débiles entre  $SO_2$ , meteorología y otros contaminantes. Además, el comportamiento anual mostró variaciones temporales y diferencias persistentes entre estaciones.

Aún falta determinar qué técnica estadística resulta más adecuada para profundizar estos patrones y evaluar la posible relación entre las concentraciones de dióxido de azufre, la dirección

y velocidad del viento y la ubicación de las estaciones. Con base en la revisión bibliográfica, en las siguientes etapas se plantea evaluar métodos de análisis espacio-temporal, gráficos polares bivariados, CBPF y caracterización de episodios elevados. Entre las principales preguntas que surgen se encuentran si las concentraciones elevadas observadas en SE3 presentan una dirección de viento predominante, si estos eventos ocurren también en otras estaciones y si las diferencias encontradas se mantienen al considerar conjuntamente las condiciones meteorológicas. Estos análisis permitirán avanzar hacia una interpretación más sólida de los patrones observados sin atribuir todavía las concentraciones a una fuente específica.

## Liga Github

[https://github.com/aliciabernadez/MA2003B\\_multivariados/tree/trunk](https://github.com/aliciabernadez/MA2003B_multivariados/tree/trunk)

## Declaratoria de IA

### Opción B. Se utilizó IA de la siguiente forma:

- **Herramienta:** ChatGPT
- **Uso realizado:** Se utilizó principalmente como apoyo para la construcción, revisión y corrección de códigos en R relacionados con la limpieza, transformación y análisis exploratorio de los datos. También se utilizó como guía para organizar algunos análisis descriptivos, corregir errores durante el renderizado en Quarto y discutir el papel de los contaminantes distintos al SO<sub>2</sub>, concluyendo que era más adecuado utilizarlos como variables complementarias de contexto y no como variables de control experimental.
- **Secciones donde se utilizó:** Preparación y limpieza de la base de datos, cálculo de estadísticas descriptivas, análisis de SO<sub>2</sub> por estación, identificación de valores atípicos, histogramas, boxplots, matriz de correlación, gráfica temporal y revisión de posibles técnicas estadísticas para etapas posteriores.
- **Validación realizada por los estudiantes:** Los códigos sugeridos fueron revisados, ejecutados y ajustados por los integrantes del equipo en RStudio utilizando la base de datos del proyecto. Los resultados obtenidos fueron comparados con la estructura y características de los datos originales y las interpretaciones fueron revisadas para evitar conclusiones que no estuvieran sustentadas por la información disponible.
- **Confirmación de responsabilidad:** Se confirma que el contenido generado con apoyo de IA fue revisado y verificado por los integrantes del equipo, quienes asumen la responsabilidad del contenido final entregado.