

Etapa 3 - Código

Alicia Bernádez, Omar Arzaga, Diego Medrano, Sebastián Alemán, Isaac Montaña

ETAPA 3

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
```

```
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(lubridate)
library(ResourceSelection)
```

```
ResourceSelection 0.3-6      2023-06-27
```

```
library(pROC)
```

Type 'citation("pROC")' for a citation.

Adjuntando el paquete: 'pROC'

The following objects are masked from 'package:stats':

```
cov, smooth, var
```

```
library(splines)

datos <- read_csv(
  "baseeee_SIMA_limpia_4est_8cont_2022_2025.csv",
  locale = locale(encoding = "UTF-8"),
  show_col_types = FALSE
)

cat("Dimensiones:", nrow(datos), "filas x", ncol(datos), "columnas\n")
```

Dimensiones: 132936 filas x 21 columnas

```
cat("Columnas:", paste(names(datos), collapse = ", "), "\n\n")
```

Columnas: Fecha y hora, Estacion, Municipio, Año, CO, NO, NO2, NOX, O3, PM10, PM2.5, SO2, WDI

```
# ---- 2. Ordenar estaciones por distancia a la refinería ----
datos <- datos %>%
  mutate(
    fecha = ymd_hms(`Fecha y hora`),
    Estacion = factor(Estacion, levels = c("SE3", "SE2", "NE", "GAR"))
  )

# ---- 3. Clasificar el viento en 16 rumbos ----
rumbos <- c("N", "NNE", "NE", "ENE", "E", "ESE", "SE", "SSE",
            "S", "SSO", "SO", "OSO", "O", "ONO", "NO", "NNO")

datos <- datos %>%
  mutate(
    sector = rumbos[((floor((WDR + 11.25) / 22.5)) %% 16) + 1],
    sector = factor(sector, levels = rumbos)
  )

# ---- 4. Umbral de episodio ----
# Mismo umbral (P95) para las 4 estaciones, así son comparables.
umbral_ep <- quantile(datos$SO2, 0.95, na.rm = TRUE)

datos <- datos %>%
  mutate(episodio = as.integer(SO2 > umbral_ep))

cat("Umbral de episodio (P95 global):", round(umbral_ep, 2), "ppb\n\n")
```

Umbral de episodio (P95 global): 11.1 ppb

```
# ---- 5. Tasa de episodios por estación ----
datos %>%
  group_by(Estacion) %>%
  summarise(
    n          = n(),
    episodios  = sum(episodio, na.rm = TRUE),
    tasa_pct   = round(100 * mean(episodio, na.rm = TRUE), 2),
    P50        = median(SO2, na.rm = TRUE),
    P99        = quantile(SO2, 0.99, na.rm = TRUE),
    razon_P99_P50 = round(P99 / P50, 2),
    .groups = "drop"
  )
```

```
# A tibble: 4 x 7
  Estacion      n episodios tasa_pct   P50   P99 razon_P99_P50
  <fct>      <int>      <int>   <dbl> <dbl> <dbl>         <dbl>
1 SE3       33977       3951   11.6   4.4  55.3          12.6
2 SE2       33240       1841    5.54   3.8  27.8           7.32
3 NE        33185        746    2.25   3.8  15.1           3.97
4 GAR       32534         49    0.15   3.3   7.4           2.24
```

```
# ---- 6. Distribución de rumbos (sin NAs) ----
cat("\nNAs en sector:", sum(is.na(datos$sector)), "\n")
```

NAs en sector: 0

```
table(datos$sector) %>% sort(decreasing = TRUE) %>% head(5)
```

```
  ESE    SE    E   SSE    NE
23655 19894 19633 12246  7951
```

Regresión logística direccional (SE3)

```

library(broom)
library(splines)

# ---- 1. Tasa de episodios por rumbo en SE3 ----
tasa_sector_SE3 <- datos %>%
  filter(Estacion == "SE3") %>%
  group_by(sector) %>%
  summarise(
    n          = n(),
    episodios  = sum(episodio),
    tasa_pct   = round(100 * mean(episodio), 2),
    .groups    = "drop"
  ) %>%
  arrange(desc(tasa_pct))

print(tasa_sector_SE3, n = 16)

```

```

# A tibble: 16 x 4
  sector      n episodios tasa_pct
  <fct> <int>      <int>      <dbl>
1 E      3906        930      23.8
2 ESE    6002       1013      16.9
3 SE     5562        836      15.0
4 SSE    2536        351      13.8
5 ENE    2217        277      12.5
6 S      1070        106       9.91
7 NE     1595        116       7.27
8 SSO     547         37       6.76
9 NNE    1072         71       6.62
10 N     1161         75       6.46
11 SO     531         31       5.84
12 OSO    647         21       3.25
13 NNO    1842         37       2.01
14 ONO    1714         22       1.28
15 O       990         12       1.21
16 NO    2585         16       0.62

```

```

# ---- 2. Subconjunto SE3 ----
# Hora y mes se codifican como seno/coseno por ser variables circulares.
d_se3 <- datos %>%
  filter(Estacion == "SE3") %>%

```

```

mutate(
  sector    = relevel(sector, ref = "N"),
  Hora_sin  = sin(2 * pi * Hora / 24),
  Hora_cos  = cos(2 * pi * Hora / 24),
  Mes_sin   = sin(2 * pi * Mes / 12),
  Mes_cos   = cos(2 * pi * Mes / 12)
)

# ---- 3. Modelo logístico ----
# WSR usa spline porque su relación con los episodios no es lineal.
mod_se3 <- glm(
  episodio ~ sector + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos,
  data    = d_se3,
  family  = binomial
)

# ---- 4. Razón de momios por rumbo (IC 95%) ----
or_sector <- tidy(mod_se3) %>%
  filter(str_detect(term, "^sector")) %>%
  mutate(
    Rumbo    = str_remove(term, "^sector"),
    OR       = round(exp(estimate), 2),
    IC_inf   = round(exp(estimate - 1.96 * std.error), 2),
    IC_sup   = round(exp(estimate + 1.96 * std.error), 2),
    p        = signif(p.value, 3)
  ) %>%
  select(Rumbo, OR, IC_inf, IC_sup, p) %>%
  arrange(desc(OR))

print(or_sector, n = 15)

```

```

# A tibble: 15 x 5
  Rumbo    OR IC_inf IC_sup      p
  <chr> <dbl> <dbl> <dbl> <dbl>
1 E      6.12  4.73  7.92 3.97e-43
2 ESE    2.58  2      3.33 4.38e-13
3 ENE    1.98  1.51  2.62 1.20e- 6
4 SSE    1.53  1.17  2.01 1.93e- 3
5 SE     1.51  1.17  1.96 1.55e- 3
6 S      1.14  0.83  1.56 4.3 e- 1
7 NE     1.08  0.79  1.47 6.34e- 1
8 NNE    1.06  0.75  1.5  7.43e- 1

```

9	SO	0.83	0.53	1.29	4.09e- 1
10	SSO	0.78	0.51	1.19	2.46e- 1
11	OSO	0.54	0.33	0.9	1.75e- 2
12	ONO	0.25	0.15	0.41	2.94e- 8
13	O	0.24	0.13	0.44	6.20e- 6
14	NNO	0.23	0.15	0.35	2.35e-12
15	NO	0.08	0.04	0.13	1.19e-19

```
# ---- 5. Ajuste global ----
cat("\nDevianza nula:      ", round(mod_se3$null.deviance, 1), "\n")
```

Devianza nula: 24426.5

```
cat("Devianza residual:", round(mod_se3$deviance, 1), "\n")
```

Devianza residual: 19809.3

```
cat("Pseudo-R2 McFadden:",
    round(1 - mod_se3$deviance / mod_se3$null.deviance, 3), "\n")
```

Pseudo-R2 McFadden: 0.189

```
cat("AIC:                  ", round(AIC(mod_se3), 1), "\n")
```

AIC: 19855.3

Validación cruzada espacial y falsación multi-contaminante

```
# ---- 1. Sector Este agrupado ----
# Se unen ENE, E y ESE en un solo grupo para evitar celdas vacías en GAR.
datos <- datos %>%
  mutate(
    sector_E = factor(
      if_else(sector %in% c("ENE", "E", "ESE"), "Este", "Resto"),
      levels = c("Resto", "Este")
    ),
    Hora_sin = sin(2 * pi * Hora / 24),
    Hora_cos = cos(2 * pi * Hora / 24),
```

```

    Mes_sin = sin(2 * pi * Mes / 12),
    Mes_cos = cos(2 * pi * Mes / 12)
  )

# ---- 2. Función: momio del sector Este para cualquier contaminante ----
# El umbral (P95) se calcula dentro de cada subconjunto.
or_este <- function(df, var) {
  d <- df %>%
    filter(!is.na(.data[[var]])) %>%
    mutate(y = as.integer(.data[[var]] > quantile(.data[[var]], 0.95)))

  if (sum(d$y) < 30) return(tibble(n = nrow(d), eventos = sum(d$y),
                                   OR = NA, IC_inf = NA, IC_sup = NA))

  m <- glm(y ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
           Mes_sin + Mes_cos,
           data = d, family = binomial)

  co <- tidy(m) %>% filter(term == "sector_EEste")

  tibble(
    n      = nrow(d),
    eventos = sum(d$y),
    OR      = round(exp(co$estimate), 2),
    IC_inf  = round(exp(co$estimate - 1.96 * co$std.error), 2),
    IC_sup  = round(exp(co$estimate + 1.96 * co$std.error), 2)
  )
}

# ---- 3. Validación espacial: mismo modelo, las 4 estaciones ----
cat("=== S02: momio del sector Este por estación ===\n")

```

```

=== S02: momio del sector Este por estación ===

```

```

map_dfr(levels(datos$Estacion), function(e) {
  or_este(filter(datos, Estacion == e), "S02") %>%
    mutate(Estacion = e, .before = 1)
}) %>% print()

```

```

# A tibble: 4 x 6
  Estacion      n eventos      OR IC_inf IC_sup

```

	<chr>	<int>	<int>	<dbl>	<dbl>	<dbl>
1	SE3	33977	1699	2.66	2.39	2.95
2	SE2	33240	1655	1.61	1.45	1.79
3	NE	33185	1660	1.02	0.88	1.18
4	GAR	32534	1510	1.25	1.09	1.43

```
# ---- 4. Falsación: otros contaminantes en SE3 ----
# Si solo el S02 sube con el sector Este, la fuente es puntual.
cat("\n=== SE3: momio del sector Este por contaminante ===\n")
```

```
=== SE3: momio del sector Este por contaminante ===
```

```
d_se3 <- filter(datos, Estacion == "SE3")

map_dfr(c("S02", "NOX", "NO", "CO", "PM10", "PM2.5", "O3"), function(v) {
  or_este(d_se3, v) %>% mutate(Contaminante = v, .before = 1)
}) %>% print()
```

```
# A tibble: 7 x 6
  Contaminante   n eventos   OR IC_inf IC_sup
  <chr>         <int>   <int> <dbl>  <dbl>  <dbl>
1 S02          33977   1699  2.66   2.39   2.95
2 NOX          33682   1684  0.22   0.17   0.28
3 NO           33451   1670  0.22   0.17   0.29
4 CO           31741   1571  1.05   0.92   1.2
5 PM10         33684   1658  0.5    0.43   0.58
6 PM2.5        30686   1507  0.59   0.51   0.68
7 O3           33697   1567  0.9    0.8    1.02
```

Validación y ajuste de la regresión logística mod_SE3 (dirección de las emisiones de azufre)

```
# Modelo nulo para el modelo principal de 16 rumbos
mod_nulo_se3 <- glm(
  episodio ~ 1,
  data = d_se3,
  family = binomial
)

# Razón de verosimilitudes
anova(mod_nulo_se3, mod_se3, test = "Chisq")
```


Analysis of Deviance Table

Model 1: episodio ~ 1

Model 2: episodio ~ sector + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	33976	24427			
2	33954	19809	22	4617.2	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
# ROC y AUC
roc_se3 <- roc(
  d_se3$episodio,
  fitted(mod_se3),
  quiet = TRUE
)

auc(roc_se3)
```

Area under the curve: 0.8112

```
# Hosmer-Lemeshow
hoslem.test(
  d_se3$episodio,
  fitted(mod_se3),
  g = 10
)
```

Hosmer and Lemeshow goodness of fit (GOF) test

data: d_se3\$episodio, fitted(mod_se3)
X-squared = 56.531, df = 8, p-value = 2.223e-09

Validación y ajuste del modelo de regresión logística mod

```
library(pROC)
library(ResourceSelection)

# Modelo principal
```

```
mod <- glm(
  episodio ~ sector_E + ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_se3,
  family = binomial
)
```

```
# -----
# 1. PRUEBA DE RAZÓN DE VEROSIMILITUDES
# -----

# Modelo nulo: solamente intercepto
mod_nulo <- glm(
  episodio ~ 1,
  data = d_se3,
  family = binomial
)

anova(mod_nulo, mod, test = "Chisq")
```

Analysis of Deviance Table

Model 1: episodio ~ 1

Model 2: episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	33976	24427			
2	33968	20718	8	3708.2	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


```
# -----
# 2. Análisis de residuos
# -----

d_se3 <- d_se3 %>%
  mutate(
    prob_estimada = fitted(mod),
    residuo_dev = residuals(mod, type = "deviance")
  )
```

```
plot(
  d_se3$prob_estimada,
  d_se3$residuo_dev,
  pch = 16,
  cex = 0.4,
  xlab = "Probabilidad estimada",
  ylab = "Residuo de devianza",
  main = "Residuos de devianza vs probabilidad estimada"
)

abline(h = 0, lty = 2, col = "red")
```

Residuos de devianza vs probabilidad estimada



```
# -----
# 3. Hosmer-Lemeshow
# -----

cat("\n=== HOSMER-LEMESHOW ===\n")
```

```
=== HOSMER-LEMESHOW ===
```

```
hl <- hoslem.test(
  d_se3$episodio,
  d_se3$prob_estimada,
  g = 10
)

print(hl)
```


Hosmer and Lemeshow goodness of fit (GOF) test

```
data: d_se3$episodio, d_se3$prob_estimada
X-squared = 64.06, df = 8, p-value = 7.403e-11
```

```
# -----
# 4. ROC y AUC en muestra
# -----

roc_in <- roc(
  d_se3$episodio,
  d_se3$prob_estimada,
  quiet = TRUE
)

plot(
  roc_in,
  main = "Curva ROC del modelo logístico"
)
```



```
cat(
  "\nAUC en muestra:",
  round(as.numeric(auc(roc_in)), 3),
  "\n"
)
```

AUC en muestra: 0.783

La prueba de razón de verosimilitudes mostró que el modelo completo mejora significativamente frente al modelo nulo ($p < 0.001$). La curva ROC presentó un AUC de 0.783, indicando una capacidad razonable para distinguir entre horas con y sin episodios de SO. Por otro lado, la prueba de Hosmer-Lemeshow resultó significativa ($p < 0.001$), lo que indica diferencias entre los valores observados y las probabilidades estimadas. Debido al gran tamaño de la muestra, esta prueba puede ser sensible a desviaciones pequeñas, por lo que el resultado se interpreta en conjunto con el AUC y el objetivo inferencial del modelo.

PCA sobre la matriz química (técnica de interdependencia)

```
library(factoextra)
```

Welcome to factoextra!

Want to learn more? See two factoextra-related books at <https://www.datanovia.com/library/principal-component-methods>

```
# ---- 1. Matriz química completa en SE3 ----
# PCA necesita casos completos; se revisa cuántas filas se pierden.
mat_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  select(SO2, NO, NO2, NOX, CO, O3, PM10, `PM2.5`,
         sector_E, WSR, Hora, Mes, episodio)

completos <- mat_se3 %>% drop_na(SO2:`PM2.5`)

cat("Filas SE3:", nrow(mat_se3), "\n")
```

Filas SE3: 33977

```
cat("Casos completos:", nrow(completos),
    paste0("(", round(100 * nrow(completos) / nrow(mat_se3), 1), "%)", "\n")
```

Casos completos: 27938 (82.2%)

```
cat("Episodios conservados:", sum(completos$episodio), "de",
    sum(mat_se3$episodio), "\n\n")
```

Episodios conservados: 3304 de 3951

```
# ---- 2. Transformación logarítmica ----
# log1p reduce el peso de los valores extremos sin eliminarlos,
# para que PC1 no quede dominado por unas pocas horas de SO2 alto.
X <- completos %>%
  select(SO2:`PM2.5`) %>%
  mutate(across(everything(), log1p))

# ---- 3. PCA sobre variables estandarizadas ----
pca <- prcomp(X, scale. = TRUE)

# ---- 4. Varianza explicada ----
var_exp <- tibble(
  CP      = paste0("PC", 1:8),
  Var_pct = round(100 * pca$sdev^2 / sum(pca$sdev^2), 2),
```

```

    Acum_pct = round(cumsum(100 * pca$sdev^2 / sum(pca$sdev^2)), 2)
  )
print(var_exp)

```

```

# A tibble: 8 x 3
  CP      Var_pct Acum_pct
  <chr>    <dbl>    <dbl>
1 PC1      48.6      48.6
2 PC2      19.4      68.0
3 PC3       9.69     77.7
4 PC4       9.21     86.9
5 PC5       6.36     93.3
6 PC6       3.69     97.0
7 PC7       2.97    100.0
8 PC8       0.05     100

```

```

# ---- 5. Cargas de los primeros 3 componentes ----
cargas <- as_tibble(pca$rotation[, 1:3], rownames = "Variable") %>%
  mutate(across(where(is.numeric), ~ round(.x, 3)))
print(cargas)

```

```

# A tibble: 8 x 4
  Variable    PC1    PC2    PC3
  <chr>      <dbl> <dbl> <dbl>
1 SO2        0.029 0.604 -0.472
2 NO         -0.452 -0.141 -0.13
3 NO2        -0.437 -0.04  -0.337
4 NOX        -0.481 -0.089 -0.266
5 CO         -0.278 0.091  0.705
6 O3         0.319 0.458 -0.001
7 PM10       -0.351 0.367  0.228
8 PM2.5      -0.265 0.503  0.164

```


```

# ---- 6. Criterio de Kaiser ----
cat("\nComponentes con eigenvalor > 1:", sum(pca$sdev^2 > 1), "\n")

```

Componentes con eigenvalor > 1: 2

```
# ---- 7. Scree plot ----
fviz_eig(pca, addlabels = TRUE, barfill = "steelblue",
         main = "Varianza explicada por componente (SE3)")
```



Conglomerados sobre el espacio de componentes

```
library(cluster)

# ---- 1. Puntuaciones de los primeros 4 componentes ----
scores <- as_tibble(pca$x[, 1:4])

# ---- 2. Número de conglomerados: silueta sobre muestra ----
set.seed(2024)
muestra <- scores[sample(nrow(scores), 4000), ]

sil <- map_dfr(2:6, function(k) {
  km <- kmeans(muestra, centers = k, nstart = 20)
  tibble(k = k,
         silueta = round(mean(silhouette(km$cluster,
                                         dist(muestra))[, 3]), 3))
})
print(sil)
```



```
# A tibble: 5 x 2
      k silueta
  <int>   <dbl>
1     2   0.418
2     3   0.262
3     4   0.264
4     5   0.255
5     6   0.239
```

```
# ---- 3. k-means sobre el conjunto completo ----
set.seed(2024)
km <- kmeans(scores, centers = 4, nstart = 25, iter.max = 50)
```

Warning: Quick-TRANSfer stage steps exceeded maximum (= 1396900)
Warning: Quick-TRANSfer stage steps exceeded maximum (= 1396900)
Warning: Quick-TRANSfer stage steps exceeded maximum (= 1396900)

```
cat("Iteraciones usadas:", km$iter, "de 50\n")
```

Iteraciones usadas: 5 de 50

```
cat("Varianza explicada por la partición:",
    round(100 * km$betweenss / km$totss, 1), "%\n\n")
```

Varianza explicada por la partición: 58.3 %

```
# ---- 4. Caracterización de cada conglomerado ----
# Usa las variables originales, no las transformadas.
perfil <- completos %>%
  mutate(grupo = factor(km$cluster)) %>%
  group_by(grupo) %>%
  summarise(
    n          = n(),
    pct        = round(100 * n() / nrow(completos), 1),
    SO2_med    = round(median(SO2), 2),
    NOX_med    = round(median(NOX), 2),
    CO_med     = round(median(CO), 2),
    PM25_med   = round(median(`PM2.5`), 1),
    O3_med     = round(median(O3), 1),
    WSR_med    = round(median(WSR), 1),
```

```

    pct_Este = round(100 * mean(sector_E == "Este"), 1),
    pct_episod = round(100 * mean(episodio), 1),
    .groups = "drop"
  ) %>%
  arrange(desc(SO2_med))

print(perfil, width = Inf)

```

```

# A tibble: 4 x 11
  grupo      n  pct SO2_med NOX_med CO_med PM25_med O3_med WSR_med pct_Este
  <fct> <int> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 1      4111 14.7  16.2  10.4  1.36    22    43    8.5   50.5
2 2      3352 12    4.4  51.8  1.94    28     5    3.6    6.2
3 3      7823 28    4.2  17.7  1.49    15    17    5.8   25.4
4 4     12652 45.3  4.1   8.1  1.11     9    26    8.5   42.7
  pct_episod
  <dbl>
1      72.2
2       1.4
3       0.9
4       1.7

```

```

# ---- 5. Razón SO2/NOX por grupo ----
# Razón alta = azufre sin combustión vehicular.
perfil %>%
  mutate(razon_SO2_NOX = round(SO2_med / NOX_med, 3)) %>%
  select(grupo, SO2_med, NOX_med, razon_SO2_NOX, pct_Este, pct_episod) %>%
  print()

```

```

# A tibble: 4 x 6
  grupo SO2_med NOX_med razon_SO2_NOX pct_Este pct_episod
  <fct> <dbl> <dbl> <dbl> <dbl> <dbl>
1 1      16.2  10.4      1.56    50.5    72.2
2 2       4.4  51.8     0.085     6.2     1.4
3 3       4.2  17.7     0.237    25.4     0.9
4 4       4.1   8.1     0.506    42.7     1.7

```

diferencia de medianas por año y traducción a política pública

```
# ---- 1. Kruskal-Wallis por año: ¿difieren las 4 estaciones? ----
kw <- datos %>%
  group_split(Año) %>%
  map_dfr(function(d) {
    t <- kruskal.test(SO2 ~ Estacion, data = d)
    tibble(Año = unique(d$Año),
            chi2 = round(t$statistic, 1),
            gl   = t$parameter,
            p    = signif(t$p.value, 3))
  })
print(kw)
```

```
# A tibble: 4 x 4
  Año   chi2    gl      p
<dbl> <dbl> <int>   <dbl>
1 2022  3878.     3 0
2 2023 10338     3 0
3 2024  3799.     3 0
4 2025  1455.     3 3.63e-315
```

```
# ---- 2. Diferencia Hodges-Lehmann SE3 vs GAR, por año ----
# Diferencia típica en ppb entre ambas estaciones, con IC.
hl <- datos %>%
  filter(Estacion %in% c("SE3", "GAR")) %>%
  group_split(Año) %>%
  map_dfr(function(d) {
    w <- wilcox.test(SO2 ~ Estacion, data = d,
                     conf.int = TRUE, exact = FALSE)
    tibble(
      Año      = unique(d$Año),
      Med_SE3  = median(d$SO2[d$Estacion == "SE3"]),
      Med_GAR  = median(d$SO2[d$Estacion == "GAR"]),
      Dif_HL   = round(w$estimate, 2),
      IC_inf   = round(w$conf.int[1], 2),
      IC_sup   = round(w$conf.int[2], 2),
      p        = signif(w$p.value, 3)
    )
  })
print(hl)
```

```
# A tibble: 4 x 7
```

	Año	Med_SE3	Med_GAR	Dif_HL	IC_inf	IC_sup	p
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	2022	4.8	3.4	1.3	1.3	1.4	0
2	2023	3.9	2.4	1.5	1.5	1.5	0
3	2024	4.1	3	1	1	1	0
4	2025	4.7	4.4	0.6	0.5	0.6	0

```
# ---- 3. Horas de episodio por año (lo que la mediana no muestra) ----
# Umbral fijo (11.1 ppb) para comparar entre años.
horas <- datos %>%
  group_by(Año, Estacion) %>%
  summarise(horas_episodio = sum(episodio), .groups = "drop") %>%
  pivot_wider(names_from = Estacion, values_from = horas_episodio) %>%
  mutate(Exceso_SE3_vs_GAR = SE3 - GAR)
print(horas)
```

```
# A tibble: 4 x 6
  Año   SE3   SE2   NE   GAR Exceso_SE3_vs_GAR
  <dbl> <int> <int> <int> <int>          <int>
1  2022  1245   518   278    10          1235
2  2023   689   307   120    20           669
3  2024   845   397   122    10           835
4  2025  1172   619   226     9          1163
```

```
# ---- 4. Indicador de política pública ----
# Horas/año que se evitarían si SE3 se comportara como la estación de control.
horas %>%
  summarise(
    exceso_total = sum(Exceso_SE3_vs_GAR),
    exceso_anual = round(mean(Exceso_SE3_vs_GAR)),
    dias_equiv_anual = round(mean(Exceso_SE3_vs_GAR) / 24, 1)
  ) %>%
  print()
```

```
# A tibble: 1 x 3
  exceso_total exceso_anual dias_equiv_anual
  <int>          <dbl>          <dbl>
1    3902          976          40.6
```

sensibilidad y figura principal

```
# ---- 1. Sensibilidad del umbral: ¿el momio del Este depende de P95? ----
sens <- map_dfr(c(0.90, 0.95, 0.99), function(q) {
  u <- quantile(datos$S02, q, na.rm = TRUE)
  map_dfr(c("SE3", "SE2", "NE", "GAR"), function(e) {
    d <- datos %>% filter(Estacion == e) %>% mutate(y = as.integer(S02 > u))
    if (sum(d$y) < 30) return(tibble(Estacion = e, OR = NA,
                                     IC_inf = NA, IC_sup = NA))
    m <- glm(y ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
             Mes_sin + Mes_cos, data = d, family = binomial)
    co <- tidy(m) %>% filter(term == "sector_EEste")
    tibble(Estacion = e,
           OR      = round(exp(co$estimate), 2),
           IC_inf = round(exp(co$estimate - 1.96 * co$std.error), 2),
           IC_sup = round(exp(co$estimate + 1.96 * co$std.error), 2))
  }) %>% mutate(Percentil = paste0("P", q * 100), umbral_ppb = round(u, 1),
               .before = 1)
})
print(sens, n = 12)
```

```
# A tibble: 12 x 6
  Percentil umbral_ppb Estacion    OR IC_inf IC_sup
  <chr>          <dbl> <chr>    <dbl> <dbl> <dbl>
1 P90             7.2 SE3      3.38  3.17  3.6
2 P90             7.2 SE2      1.43  1.33  1.53
3 P90             7.2 NE       1     0.89  1.13
4 P90             7.2 GAR      1.4   1.08  1.83
5 P95            11.1 SE3      3.19  2.96  3.44
6 P95            11.1 SE2      1.58  1.43  1.74
7 P95            11.1 NE       1.01  0.81  1.26
8 P95            11.1 GAR      1.08  0.54  2.16
9 P99            30.6 SE3      2.57  2.25  2.93
10 P99            30.6 SE2      1.75  1.37  2.24
11 P99            30.6 NE       0.86  0.3   2.5
12 P99            30.6 GAR      NA     NA    NA
```


```
# ---- 2. Figura principal: divergencia mediana vs episodios ----
comp <- h1 %>%
  select(Año, Dif_HL) %>%
  left_join(select(horas, Año, Horas_SE3 = SE3), by = "Año")

coef <- max(comp$Horas_SE3) / max(comp$Dif_HL)
```

```

ggplot(comp, aes(x = Año)) +
  geom_col(aes(y = Horas_SE3), fill = "grey70") +
  geom_line(aes(y = Dif_HL * coef), colour = "firebrick", linewidth = 1.2) +
  geom_point(aes(y = Dif_HL * coef), colour = "firebrick", size = 3) +
  scale_y_continuous(
    name = "Horas de episodio en SE3 (barras)",
    sec.axis = sec_axis(~ . / coef,
                        name = "Diferencia de medianas SE3-GAR, ppb (línea)")
  ) +
  scale_x_continuous(breaks = 2022:2025) +
  labs(title = "La mediana anual no refleja la exposición aguda",
       subtitle = "SE3 (Cadereyta), umbral absoluto de episodio: 11.1 ppb",
       x = "Año") +
  theme_minimal(base_size = 12) +
  theme(axis.title.y.right = element_text(colour = "firebrick"))

```



```

# ---- Tabla geográfica para el reporte ----
geo <- tribble(
  ~Estacion, ~lat, ~lon, ~azimut, ~rumbo, ~dist_km,
  "SE3", 25.5844, -100.0011, 87.3, "E", 5.5,
  "SE2", 25.6461, -100.0956, 113.7, "ESE", 16.4,
  "NE", 25.7455, -100.2552, 119.6, "ESE", 35.7,

```

```


  "GAR",      25.7997, -100.5878, 110.1,  "ESE",  68.5
)

# ---- Figura clave: decaimiento del momio con la distancia ----
or_p95 <- tibble(
  Estacion = c("SE3", "SE2", "NE", "GAR"),
  OR        = c(3.19, 1.58, 1.01, 1.08),
  IC_inf    = c(2.96, 1.43, 0.81, 0.54),
  IC_sup    = c(3.44, 1.74, 1.26, 2.16)
)

left_join(gео, or_p95, by = "Estacion") %>%
  ggplot(aes(x = dist_km, y = OR)) +
  geom_hline(yintercept = 1, linetype = "dashed", colour = "grey40") +
  geom_errorbar(aes(ymin = IC_inf, ymax = IC_sup), width = 1.5) +
  geom_point(size = 3, colour = "firebrick") +
  geom_text(aes(label = Estacion), vjust = -1.2, size = 3.5) +
  labs(
    title = "El efecto direccional decae con la distancia a la refinерía",
    subtitle = "Razón de momios del sector Este sobre episodios de SO2 (P95 = 11.1 ppb)",
    x = "Distancia a la refinерía (km)",
    y = "Razón de momios (IC 95%)"
  ) +
  theme_minimal(base_size = 12)

```

El efecto direccional decae con la distancia a la refin  ria
 Raz  n de momios del sector Este sobre episodios de SO2 (P95 = 11)



validaci  n y supuestos

```
library(pROC)
library(sandwich)
library(lmtest)
```

Cargando paquete requerido: zoo

Adjuntando el paquete: 'zoo'

The following objects are masked from 'package:base':

as.Date, as.Date.numeric

```
library(psych)
```

Adjuntando el paquete: 'psych'

The following objects are masked from 'package:ggplot2':

%,%, alpha

```
d_se3 <- datos %>% filter(Estacion == "SE3") %>%
  mutate(dia = as.Date(fecha))

# ---- 1. Errores estándar robustos agrupados por día ----
mod <- glm(episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
  Mes_sin + Mes_cos, data = d_se3, family = binomial)

rob <- coeftest(mod, vcov = vcovCL(mod, cluster = ~ dia))
b <- rob["sector_EEste", "Estimate"]
se <- rob["sector_EEste", "Std. Error"]

cat("=== OR sector Este en SE3 ===\n")
```

=== OR sector Este en SE3 ===

```
cat("Ingenuo :", round(exp(coef(mod)["sector_EEste"]), 2), "\n")
```

Ingenuo : 3.19

```
cat("Agrupado :", round(exp(b), 2),
  " IC95: [", round(exp(b - 1.96*se), 2), ",",
  round(exp(b + 1.96*se), 2), "]\n\n")
```

Agrupado : 3.19 IC95: [2.92 , 3.48]

```
# ---- 2. Capacidad discriminante ----
auc_in <- roc(d_se3$episodio, fitted(mod), quiet = TRUE)
cat("AUC en muestra:", round(as.numeric(auc_in$auc), 3), "\n")
```

AUC en muestra: 0.783

```
# ---- 3. Validación fuera de muestra: entrenar 2022-2024, probar 2025 ----
tr <- filter(d_se3, Año <= 2024)
te <- filter(d_se3, Año == 2025)
```

```
m_tr <- glm(episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
            Mes_sin + Mes_cos, data = tr, family = binomial)
p_te <- predict(m_tr, newdata = te, type = "response")

cat("AUC fuera de muestra (2025):",
    round(as.numeric(roc(te$episodio, p_te, quiet = TRUE)$auc), 3), "\n")
```

AUC fuera de muestra (2025): 0.764

```
cat("Error Brier:", round(mean((p_te - te$episodio)^2), 4), "\n")
```

Error Brier: 0.1065

```
cat("Tasa base 2025:", round(mean(te$episodio), 4), "\n\n")
```

Tasa base 2025: 0.1371

```
# ---- 4. Matriz de confusión con punto de corte = tasa base ----
corte <- mean(tr$episodio)
tab <- table(Predicho = p_te > corte, Real = te$episodio)
print(tab)
```

	Real	
Predicho	0	1
FALSE	5025	337
TRUE	2354	835

```
cat("\nSensibilidad:", round(tab[2,2] / sum(tab[,2]), 3),
    "| Especificidad:", round(tab[1,1] / sum(tab[,1]), 3), "\n\n")
```

Sensibilidad: 0.712 | Especificidad: 0.681

```
# ---- 5. Supuestos del PCA ----
cat("=== Adecuación muestral del PCA ===\n")
```

=== Adecuación muestral del PCA ===

```
cat("KMO global:", round(KMO(X)$MSA, 3), "\n")
```

KMO global: 0.623

```
bt <- cortest.bartlett(cor(X), n = nrow(X))
cat("Bartlett: chi2 =", round(bt$chisq, 0), " p =", signif(bt$p.value, 3), "\n")
```

Bartlett: chi2 = 213445 p = 0

CBPF

```
library(openair)
```

Adjuntando el paquete: 'openair'

The following object is masked from 'package:psych':

corPlot

```
# ---- Preparación al formato openair ----
d_oa <- datos %>%
  rename(date = fecha, ws = WSR, wd = WDR)

# ---- Percentiles equivalentes al umbral de 11.1 ppb ----
# openair usa percentiles por estación, así que se calcula el percentil
# que corresponde a 11.1 ppb en cada una, para comparar el mismo umbral.
pct_eq <- datos %>%
  group_by(Estacion) %>%
  summarise(p = round(100 * mean(SO2 <= umbral_ep, na.rm = TRUE), 2),
            .groups = "drop")
print(pct_eq)
```


```
# A tibble: 4 x 2
  Estacion      p
  <fct>    <dbl>
1 SE3      88.4
2 SE2      94.5
3 NE       97.8
4 GAR      99.8
```

```
# ---- CBPF de SO2 en las tres estaciones con señal ----
# GAR se omite: no hay suficientes horas para estimar la probabilidad.
for (e in c("SE3", "SE2", "NE")) {
  p <- pct_eq$p[pct_eq$Estacion == e]
  polarPlot(
    filter(d_oa, Estacion == e),
    pollutant = "SO2",
    statistic = "cpf",
    percentile = p,
    main      = paste0("CBPF de SO2 en ", e,
                      " (umbral 11.1 ppb, P", p, ")"),
    key.title = "Probabilidad"
  )
}
```

Warning: The following lattice/base graphical parameters will be converted to ggplot2 equivalents:

```
* `main` > `title`
```

CBPF de SO₂ en SE3 (umbral 11.1 ppb, P88.37)




Radial axis shows wind spd.
CPF at the 88.37th percentile (=11)

Warning: The following lattice/base graphical parameters will be converted to ggplot2 equivalents:

```
* `main` > `title`
```


CBPF de SO₂ en SE2 (umbral 11.1 ppb, P94.46)



Warning: The following lattice/base graphical parameters will be converted to ggplot2 equivalents:

```
* `main` > `title`
```

CBPF de SO₂ en NE (umbral 11.1 ppb, P97.75)




```
# ---- Falsación visual: CBPF de NOX en SE3 ----
# Mismo percentil que el S02 para comparar los mapas.
polarPlot(
  filter(d_oa, Estacion == "SE3"),
  pollutant = "NOX",
  statistic = "cpf",
  percentile = pct_eq$p[pct_eq$Estacion == "SE3"],
  main       = "CBPF de NOX en SE3 (misma probabilidad de referencia)",
  key.title  = "Probabilidad"
)
```

Warning: The following lattice/base graphical parameters will be converted to ggplot2 equivalents:

```
* `main` > `title`
```

BPF de NO_x en SE3 (misma probabilidad de referencia)



```
# or_p95: valores del gradiente espacial para la Figura 1
or_p95 <- tibble(
  Estacion = c("SE3", "SE2", "NE", "GAR"),
  OR        = c(3.19, 1.58, 1.01, 1.08),
  IC_inf    = c(2.96, 1.43, 0.81, 0.54),
  IC_sup     = c(3.44, 1.74, 1.26, 2.16)
)
```

```

saveRDS(list(datos = datos, pca = pca, km = km, completos = completos,
            hl = hl, horas = horas, sens = sens, geo = geo,
            or_sector = or_sector, tasa_sector_SE3 = tasa_sector_SE3,
            or_p95 = or_p95),
        "objetos_etapa3.rds")

names(readRDS("objetos_etapa3.rds"))

```

```

[1] "datos"          "pca"            "km"             "completos"
[5] "hl"            "horas"          "sens"           "geo"
[9] "or_sector"      "tasa_sector_SE3" "or_p95"

```

Simulación de predicción prueba

```

# Pronóstico simulado: el viento rota hacia el Este por la tarde
pronostico_manana <- tibble(
  Hora = 0:23,
  Mes = rep(month(Sys.Date()), 24),
  WSR = c(rep(3.0, 10), rep(6.5, 8), rep(3.0, 6)), # Viento suave en la mañana, fuerte en la tarde
  WDR = c(rep(180, 10), rep(95, 8), rep(180, 6)) # Viento del Sur, luego del Este (95°), luego del Sur
)

# Preparar datos
rumbos_ref <- c("N", "NNE", "NE", "ENE", "E", "ESE", "SE", "SSE",
               "S", "SSO", "SO", "OSO", "O", "ONO", "NO", "NNO")

pronostico_predictivo <- pronostico_manana %>%
  mutate(
    Hora_sin = sin(2 * pi * Hora / 24),
    Hora_cos = cos(2 * pi * Hora / 24),
    Mes_sin = sin(2 * pi * Mes / 12),
    Mes_cos = cos(2 * pi * Mes / 12),
    sector = rumbos_ref[((floor((WDR + 11.25) / 22.5)) %% 16) + 1],
    sector_E = factor(
      if_else(sector %in% c("ENE", "E", "ESE"), "Este", "Resto"),
      levels = c("Resto", "Este")
    )
  )

```

```
# Predicción con el modelo completo
tasa_base <- mean(d_se3$episodio)

pronostico_predictivo <- pronostico_predictivo %>%
  mutate(
    prob_episodio = predict(mod, newdata = pronostico_predictivo, type = "response"),
    # Alerta de política pública:
    estado_alerta = if_else(
      prob_episodio > tasa_base,
      "ALERTA: Probabilidad de Episodio",
      "Normal"
    )
  )

cat("\n=== TABLERO DE ALERTA TEMPRANA: PRONÓSTICO 24 HORAS ===\n")
```

=== TABLERO DE ALERTA TEMPRANA: PRONÓSTICO 24 HORAS ===

```
pronostico_predictivo %>%
  select(Hora, Viento_Velocidad = WSR, Rumbo = sector,
         Probabilidad = prob_episodio, Alerta = estado_alerta) %>%
  mutate(Probabilidad = paste0(round(Probabilidad * 100, 1), "%")) %>%
  print(n = 24)
```

A tibble: 24 x 5

	Hora	Viento_Velocidad	Rumbo	Probabilidad	Alerta
	<int>	<dbl>	<chr>	<chr>	<chr>
1	0	3	S	1.2%	Normal
2	1	3	S	1%	Normal
3	2	3	S	1%	Normal
4	3	3	S	1%	Normal
5	4	3	S	1.2%	Normal
6	5	3	S	1.6%	Normal
7	6	3	S	2.1%	Normal
8	7	3	S	3%	Normal
9	8	3	S	4.3%	Normal
10	9	3	S	6.2%	Normal
11	10	6.5	E	28.9%	ALERTA: Probabilidad de Episodio
12	11	6.5	E	35.4%	ALERTA: Probabilidad de Episodio

13	12	6.5 E	40.7%	ALERTA: Probabilidad de Episodio
14	13	6.5 E	44.1%	ALERTA: Probabilidad de Episodio
15	14	6.5 E	45.1%	ALERTA: Probabilidad de Episodio
16	15	6.5 E	43.7%	ALERTA: Probabilidad de Episodio
17	16	6.5 E	39.9%	ALERTA: Probabilidad de Episodio
18	17	6.5 E	34.2%	ALERTA: Probabilidad de Episodio
19	18	3 S	8.1%	Normal
20	19	3 S	5.8%	Normal
21	20	3 S	4%	Normal
22	21	3 S	2.8%	Normal
23	22	3 S	2%	Normal
24	23	3 S	1.5%	Normal

ETAPA 4

Indice NOM-172 y punto ciego normativo

```
library(zoo)

# ---- 1. Rejilla horaria completa por estación ----
# complete() marca las horas faltantes como NA, sin imputar valores.
base_movil <- datos %>%
  select(Estacion, fecha, S02) %>%
  arrange(Estacion, fecha) %>%
  group_by(Estacion) %>%
  complete(fecha = seq(min(fecha), max(fecha), by = "hour")) %>%
  mutate(
    # ---- 2. Promedio móvil de 24 h (NOM-172) ----
    # Se requieren al menos 18 de 24 horas válidas.
    suma_24 = rollsumr(coalesce(S02, 0), k = 24, fill = NA),
    val_24 = rollsumr(!is.na(S02), k = 24, fill = NA),
    so2_mm24 = if_else(val_24 >= 18, suma_24 / val_24, NA_real_),
    anio = year(fecha)
  ) %>%
  ungroup() %>%
  mutate(
    # ---- 3. Bandas de la Tabla 8 (convertidas de ppm a ppb) ----
    banda_nom = cut(
      so2_mm24,
      breaks = c(-Inf, 8, 110, 165, 220, Inf),
```

```

      labels = c("Buena", "Aceptable", "Mala", "Muy mala", "Extrem. mala")
    )
  )

# ---- 4. ¿Qué registra el índice normativo por estación? ----
resumen_nom <- base_movil %>%
  filter(!is.na(so2_mm24)) %>%
  group_by(Estacion) %>%
  summarise(
    horas_indice      = n(),
    max_mm24          = round(max(so2_mm24), 1),
    p99_mm24          = round(quantile(so2_mm24, 0.99), 1),
    horas_no_buena     = sum(so2_mm24 > 8),
    pct_no_buena       = round(100 * mean(so2_mm24 > 8), 2),
    horas_mala         = sum(so2_mm24 > 110),
    .groups = "drop"
  )
print(resumen_nom)

```

```

# A tibble: 4 x 7
  Estacion horas_indice max_mm24 p99_mm24 horas_no_buena pct_no_buena horas_mala
  <fct>      <int>      <dbl>   <dbl>      <int>      <dbl>      <int>
1 SE3        34116      59.3     26         9872      28.9         0
2 SE2        33358      29.4    13.4         3114       9.34         0
3 NE         33335      20.3     9.7          996       2.99         0
4 GAR        31901       9.7      6           12       0.04         0

```

```

# ---- 5. Contraste: episodio horario vs banda normativa ----
contraste_nom <- base_movil %>%
  filter(!is.na(so2_mm24)) %>%
  group_by(Estacion, anio) %>%
  summarise(
    horas_ep_horario = sum(SO2 > 11.1, na.rm = TRUE),
    horas_no_buena    = sum(so2_mm24 > 8),
    horas_mala        = sum(so2_mm24 > 110),
    .groups = "drop"
  ) %>%
  filter(Estacion %in% c("SE3", "GAR"))
print(contraste_nom, n = 8)

```

```

# A tibble: 8 x 5

```

	Estacion	anio	horas_ep_horario	horas_no_buena	horas_mala
	<fct>	<dbl>	<int>	<int>	<int>
1	SE3	2022	1233	3218	0
2	SE3	2023	655	1461	0
3	SE3	2024	839	2095	0
4	SE3	2025	1156	3098	0
5	GAR	2022	10	0	0
6	GAR	2023	20	12	0
7	GAR	2024	10	0	0
8	GAR	2025	9	0	0

Interpretación para el reporte:

La aplicación de la concentración base que establece la NOM-172-SEMARNAT-2019 para el dióxido de azufre, promedio móvil de 24 horas con un mínimo de 18 horas válidas, permite evaluar si el instrumento normativo de comunicación de riesgo registra la exposición documentada. En los cuatro años analizados, ninguna de las cuatro estaciones alcanzó la banda Mala, cuyo límite inferior se ubica en 0.110 ppm. El valor máximo de la serie corresponde a SE3 con 59.3 ppb, poco más de la mitad de ese límite. El promedio móvil de 24 horas amortigua por construcción los picos horarios, de manera que un episodio de la magnitud del percentil 99 de SE3, 55.3 ppb en promedio horario, no modifica la clasificación de la banda. En consecuencia, el Índice AIRE Y SALUD difundido a la población en Cadereyta permanece en la banda Aceptable con independencia de la intensidad de los episodios registrados.

El mismo indicador resulta informativo cuando se agrega como frecuencia de excedencia en lugar de nivel. La proporción de horas que superan el límite superior de la banda Buena, 0.008 ppm, es de 28.9 por ciento en SE3 y de 0.04 por ciento en la estación de control, una diferencia de casi tres órdenes de magnitud. Su evolución anual acompaña la de las horas de episodio y no la de las medianas anuales, lo que indica que la métrica es sensible a la exposición aguda. Dado que los sistemas de monitoreo ya calculan esta concentración base de forma horaria por obligación normativa, la incorporación del porcentaje anual de horas fuera de la banda Buena, desagregado por estación, no requiere infraestructura adicional y ofrece un indicador de seguimiento compatible con los mecanismos del PIGECA 2023-2033.

Una nota: la guía de la OMS 2021 para SO₂ en 24 horas es de 40 µg/m³, del orden de 15 ppb según el factor de conversión. El P99 del promedio móvil de SE3 es 26 ppb, así que probablemente la excede; verifiquen el valor en la fuente antes de escribirlo.

Bloque 2: riesgo absoluto por escenario

Advertencia: son predicciones para escenarios fijos, no promedios poblacionales, y los intervalos son de Wald sobre el predictor lineal, sin ajuste por correlación serial. Se interpretan

como riesgo condicional bajo esas condiciones meteorológicas, no como pronóstico.

```
# ---- 1. Perfil horario de los episodios en SE3 ----
perfil_hora <- d_se3 %>%
  group_by(Hora) %>%
  summarise(tasa_pct = round(100 * mean(episodio), 1), .groups = "drop")
print(perfil_hora, n = 24)
```

A tibble: 24 x 2

	Hora	tasa_pct
	<dbl>	<dbl>
1	0	5.3
2	1	5.1
3	2	3.8
4	3	3.1
5	4	2.3
6	5	2.6
7	6	1.3
8	7	0.9
9	8	3
10	9	8.3
11	10	16.7
12	11	22.9
13	12	26.2
14	13	28.2
15	14	27.3
16	15	27.6
17	16	24.3
18	17	20.9
19	18	13.1
20	19	6.7
21	20	5.8
22	21	8.2
23	22	7.5
24	23	6

```
mes_pico <- d_se3 %>%
  group_by(Mes) %>%
  summarise(tasa = mean(episodio), .groups = "drop") %>%
  slice_max(tasa, n = 1) %>%
  pull(Mes)
```

```

hora_pico <- d_se3 %>%
  group_by(Hora) %>%
  summarise(tasa = mean(episodio), .groups = "drop") %>%
  slice_max(tasa, n = 1) %>%
  pull(Hora)

cat("Mes de mayor tasa:", mes_pico, "| Hora de mayor tasa:", hora_pico, "\n\n")

```

Mes de mayor tasa: 7 | Hora de mayor tasa: 13

```

# ---- 2. Escenarios: riesgo absoluto de episodio ----
# Mes de mayor incidencia, dos horas (mañana y pico) y tres velocidades de viento.
escenarios <- expand_grid(
  sector_E = factor(c("Resto", "Este"), levels = c("Resto", "Este")),
  WSR      = c(3, 6.5, 10),
  Hora     = c(3, hora_pico)
) %>%
  mutate(
    Mes      = mes_pico,
    Hora_sin = sin(2 * pi * Hora / 24),
    Hora_cos = cos(2 * pi * Hora / 24),
    Mes_sin  = sin(2 * pi * Mes / 12),
    Mes_cos  = cos(2 * pi * Mes / 12)
  )

pr <- predict(mod, newdata = escenarios, type = "link", se.fit = TRUE)

escenarios <- escenarios %>%
  mutate(
    prob  = round(100 * plogis(pr$fit), 1),
    ic_inf = round(100 * plogis(pr$fit - 1.96 * pr$se.fit), 1),
    ic_sup = round(100 * plogis(pr$fit + 1.96 * pr$se.fit), 1)
  )

escenarios %>%
  select(sector_E, WSR, Hora, prob, ic_inf, ic_sup) %>%
  arrange(Hora, WSR, sector_E) %>%
  print(n = 12)

```

```

# A tibble: 12 x 6
  sector_E  WSR  Hora  prob ic_inf ic_sup

```

	<fct>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	Resto	3	3	1.2	1.1	1.4
2	Este	3	3	3.8	3.3	4.3
3	Resto	6.5	3	1.6	1.5	1.9
4	Este	6.5	3	5.1	4.5	5.6
5	Resto	10	3	1.4	1.2	1.6
6	Este	10	3	4.4	3.9	4.9
7	Resto	3	13	17.4	15.8	19.2
8	Este	3	13	40.2	37.2	43.3
9	Resto	6.5	13	22.3	20.8	24
10	Este	6.5	13	47.8	45.4	50.3
11	Resto	10	13	19.8	18.5	21.2
12	Este	10	13	44	42	46.1

```
# ---- 3. Diferencia de riesgo absoluto (puntos porcentuales) ----
dif_riesgo <- escenarios %>%
  select(sector_E, WSR, Hora, prob) %>%
  pivot_wider(names_from = sector_E, values_from = prob) %>%
  mutate(
    dif_pp = round(Este - Resto, 1),
    razon_rel = round(Este / Resto, 1)
  )
print(dif_riesgo, n = 6)
```

```
# A tibble: 6 x 6
  WSR Hora Resto Este dif_pp razon_rel
  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 3 3 1.2 3.8 2.6 3.2
2 3 13 17.4 40.2 22.8 2.3
3 6.5 3 1.6 5.1 3.5 3.2
4 6.5 13 22.3 47.8 25.5 2.1
5 10 3 1.4 4.4 3 3.1
6 10 13 19.8 44 24.2 2.2
```

Perfil horario. Los episodios no se reparten parejo en el día: la tasa sube desde las 9h, alcanza su máximo a las 13h (28.2%) y se mantiene alta hasta las 17-18h, con un mínimo a las 7h (0.9%). Julio es el mes de mayor incidencia. Esto ya es un hallazgo operativo: la ventana de riesgo es la tarde, no el día completo, y coincide con las horas de mayor actividad convectiva, consistente con lo que el PCA ya había mostrado sobre la asociación de SO con horas de mezcla vertical.

Riesgo absoluto vs. razón relativa: A las 13h de julio, con viento moderado (6.5 km/h), la probabilidad de episodio es 47.8% con viento del este contra 22.3% con viento de otro sector:

una diferencia de 25.5 puntos porcentuales. A las 3am, la razón relativa es parecida o mayor (3.8% contra 1.6%, razón de 2.3 a 3.2), pero la diferencia absoluta es de apenas 2.6 a 3.5 puntos.

Esto es exactamente lo que un momio (OR) esconde: la razón de momios trata igual una diferencia de 2 puntos porcentuales que una de 25, porque ambas pueden dar una razón relativa similar cuando la base es baja. En términos de exposición poblacional real, el riesgo del sector este casi no importa de madrugada, pero es enorme en la tarde. Esa es la traducción de “interpretemos mejor”: no es que el modelo diga cosas distintas, es que el momio agregado (6.12 para el rumbo este, sin condicionar en hora) diluye un efecto que en realidad está concentrado en una franja de 6 a 8 horas al día.

para el reporte:

La descomposición horaria del riesgo revela que la asociación direccional no es constante a lo largo del día. A las 13 horas, con viento moderado del sector este, la probabilidad estimada de episodio es de 47.8 por ciento (IC 95%: 45.4 a 50.3), frente a 22.3 por ciento (IC 95%: 20.8 a 24.0) para el resto de los sectores en las mismas condiciones, una diferencia de 25.5 puntos porcentuales. A las 3 de la madrugada, bajo el mismo viento del este, la probabilidad es de apenas 3.8 por ciento frente a 1.6 por ciento, una diferencia de 2.2 puntos. La razón relativa de riesgo es comparable en ambos horarios, entre 2.1 y 3.2 veces, pero la magnitud absoluta del riesgo adicional se concentra casi en su totalidad en las horas de la tarde. Esta distinción resulta relevante para la comunicación de riesgo: un momio agregado como el reportado en el modelo direccional principal (6.12 para el rumbo este) no distingue entre un incremento de riesgo trivial y uno sustancial en términos de exposición poblacional, mientras que la probabilidad condicionada por hora sí permite identificar la franja del día en que la asociación tiene consecuencias prácticas.

Siguiente bloque: duración de los episodios

Antes de pasar al modelo con rezagos, falta una pieza para el argumento de política pública: cuánto dura, en promedio, un episodio una vez que empieza. Eso es lo que de verdad le importa a la exposición poblacional, más que el conteo de horas sueltas.

Advertencia: para no fusionar episodios que en realidad están separados por datos faltantes, la racha se corta si hay un salto temporal mayor a una hora entre registros consecutivos, no solo si episodio cambia de valor.

```
# ---- 1. Duración de episodios en SE3 (rachas horarias consecutivas) ----
d_se3_ep <- datos %>%
  filter(Estacion == "SE3") %>%
  arrange(fecha) %>%
  mutate(
    salto      = as.numeric(difftime(fecha, lag(fecha), units = "hours")),
```

```

    nuevo_bloque = is.na(salto) | salto != 1 | episodio != lag(episodio),
    bloque_id    = cumsum(nuevo_bloque)
  )

rachas <- d_se3_ep %>%
  filter(episodio == 1) %>%
  group_by(bloque_id) %>%
  summarise(duracion_h = n(), inicio = min(fecha), .groups = "drop")

cat("Episodios discretos (rachas):", nrow(rachas), "\n")

```

Episodios discretos (rachas): 1561

```
cat("Duración mediana (h):", median(rachas$duracion_h), "\n\n")
```

Duración mediana (h): 2

```
print(quantile(rachas$duracion_h, c(0.5, 0.75, 0.9, 0.95, 0.99)))
```

```

50% 75% 90% 95% 99%
2.0 3.0 5.0 6.0 8.4

```

```
cat("\nDistribución de duraciones (horas consecutivas):\n")
```

Distribución de duraciones (horas consecutivas):

```
print(table(rachas$duracion_h))
```

```

  1   2   3   4   5   6   7   8   9  10  11  12  16
582 386 237 146  94  49  32  19   9   3   1   2   1

```

```

# ---- 2. Horas con tasa por encima del promedio de SE3 ----
franja <- perfil_hora %>% filter(tasa_pct > 11.63)
print(franja)

```



```
# A tibble: 9 x 2
  Hora tasa_pct
  <dbl>   <dbl>
1     10    16.7
2     11    22.9
3     12    26.2
4     13    28.2
5     14    27.3
6     15    27.6
7     16    24.3
8     17    20.9
9     18    13.1
```

1,561 episodios discretos, mediana de **2 horas**, con cola larga: 10% duran 5 horas o más, máximo 16 horas continuas. La ventana de mayor tasa (10h-18h) coincide con las horas de mezcla convectiva ya señaladas por el PC2 del PCA (SO junto con PM2.5 y O). Esta brevedad es, en sí misma, la razón mecánica del punto ciego normativo: un episodio de 2 horas apenas mueve un promedio móvil de 24 horas, así que la magnitud del pico no es lo único que explica que el índice no lo detecte.

Prosa para el reporte:

La caracterización temporal de los episodios muestra una duración mediana de 2 horas, con el 90 por ciento de los eventos concluyendo en 5 horas o menos y un máximo observado de 16 horas continuas. Esta brevedad es relevante para interpretar el resultado anterior: un evento corto tiene, por definición aritmética, un efecto limitado sobre un promedio móvil de 24 horas, de modo que la ausencia de registros en la banda Mala del Índice AIRE Y SALUD depende también de esa brevedad relativa a la ventana de promediación, no solo de la magnitud del pico horario. La concentración de episodios entre las 10 y las 18 horas, coincidente con las horas de mayor mezcla convectiva del PCA, sugiere una ventana operativa concreta para un aviso preventivo.

Con esto queda sólida la interpretación: punto ciego normativo, riesgo absoluto por hora, y la duración que explica por qué el punto ciego existe. Siguiendo: lo que pidió Raúl.

Bloque: modelo con SO rezagado y selección AIC/BIC

Advertencias antes de correr: los lags de SO se calculan sobre la rejilla horaria completa (con NA en los huecos), no sobre el data frame filtrado, para no pegar horas separadas por un vacío de datos. El sector direccional y los controles meteorológicos se mantienen fijos (son la hipótesis central); la selección AIC/BIC se aplica solo entre los términos autorregresivos, para no arriesgarse a que el algoritmo elimine la variable de interés por conveniencia numérica.

```
# ---- 1. Lags de SO2 sobre la rejilla horaria completa de SE3 ----
# Usa la rejilla ya construida (base_movil) para no pegar horas con huecos.
se3_lags <- base_movil %>%
  filter(Estacion == "SE3") %>%
  arrange(fecha) %>%
  mutate(
    S02_lag1 = lag(S02, 1),
    S02_lag2 = lag(S02, 2),
    S02_lag3 = lag(S02, 3),
    S02_lag6 = lag(S02, 6),
    S02_lag12 = lag(S02, 12),
    S02_lag24 = lag(S02, 24),
    Hora = hour(fecha),
    Mes = month(fecha)
  ) %>%
  inner_join(
    d_se3 %>% select(fecha, episodio, sector_E, WSR, Hora_sin, Hora_cos, Mes_sin, Mes_cos),
    by = "fecha"
  ) %>%
  drop_na(S02_lag1, S02_lag2, S02_lag3, S02_lag6, S02_lag12, S02_lag24, WSR)

cat("Filas disponibles con los 6 lags completos:", nrow(se3_lags), "de", nrow(d_se3), "\n\n")
```

Filas disponibles con los 6 lags completos: 31026 de 33977

```
# ---- 2. Modelo base (sin lags) reestimado sobre el mismo subconjunto ----
# Permite comparar AIC/BIC con la misma muestra.
mod_base_sub <- glm(
  episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos,
  data = se3_lags, family = binomial
)

# ---- 3. Modelo completo con los 6 lags ----
mod_lags <- glm(
  episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos +
    S02_lag1 + S02_lag2 + S02_lag3 + S02_lag6 + S02_lag12 + S02_lag24,
  data = se3_lags, family = binomial
)
```

Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred

```
# ---- 4. Selección por AIC y BIC, forzando sector_E y meteorología ----
# El scope inferior fija la hipótesis central; solo los lags se agregan o quitan.
scope_min <- episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos

mod_aic <- step(mod_lags, scope = list(lower = scope_min, upper = formula(mod_lags)),
              direction = "backward", trace = 0)
```

```
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
```

```
mod_bic <- step(mod_lags, scope = list(lower = scope_min, upper = formula(mod_lags)),
              direction = "backward", trace = 0, k = log(nrow(se3_lags)))
```

```
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
```

```
cat("=== Términos retenidos por AIC ===\n")
```

```
=== Términos retenidos por AIC ===
```

```
print(formula(mod_aic))
```

```
episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
  Mes_cos + S02_lag1 + S02_lag2 + S02_lag3 + S02_lag6 + S02_lag12 +
  S02_lag24
```

```
cat("\n=== Términos retenidos por BIC ===\n")
```

```
=== Términos retenidos por BIC ===
```

```
print(formula(mod_bic))
```

```
episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +  
  Mes_cos + S02_lag1 + S02_lag2 + S02_lag12 + S02_lag24
```

```
# ---- 5. Comparación de ajuste ----
```

```
comparacion <- tibble(  
  Modelo = c("Base (sin lags)", "Completo (6 lags)", "Selección AIC", "Selección BIC"),  
  AIC     = round(c(AIC(mod_base_sub), AIC(mod_lags), AIC(mod_aic), AIC(mod_bic)), 1),  
  BIC     = round(c(BIC(mod_base_sub), BIC(mod_lags), BIC(mod_aic), BIC(mod_bic)), 1)  
)  
print(comparacion)
```

```
# A tibble: 4 x 3
```

Modelo	AIC	BIC
<chr>	<dbl>	<dbl>
1 Base (sin lags)	19175.	19250.
2 Completo (6 lags)	13992.	14117.
3 Selección AIC	13992.	14117.
4 Selección BIC	13996.	14104.

```
# ---- 6. Prueba de razón de verosimilitud: ¿aportan los lags? ----
```

```
cat("\n=== LRT: modelo base vs modelo con lags seleccionados por AIC ===\n")
```

```
=== LRT: modelo base vs modelo con lags seleccionados por AIC ===
```

```
print(anova(mod_base_sub, mod_aic, test = "Chisq"))
```

Analysis of Deviance Table

```
Model 1: episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +  
  Mes_cos
```

```
Model 2: episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
  Mes_cos + S02_lag1 + S02_lag2 + S02_lag3 + S02_lag6 + S02_lag12 +
  S02_lag24
```

```
Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1      31017      19157
2      31011      13962 6    5195.6 < 2.2e-16 ***
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# ---- 7. ¿Sobrevive el efecto del sector Este al controlar por S02 pasado? ----
```

```
# Si sector_E deja de ser significativo, el efecto sería redundante con la persistencia auto
```

```
cat("\n=== Coeficiente de sector_E en el modelo con lags (AIC) ===\n")
```

```
=== Coeficiente de sector_E en el modelo con lags (AIC) ===
```

```
print(tidy(mod_aic) %>% filter(str_detect(term, "sector_E")))
```

```
# A tibble: 1 x 5
```

term	estimate	std.error	statistic	p.value
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 sector_EEste	1.20	0.0500	24.0	3.54e-127

Dos resultados centrales, y uno de ellos es la mejor noticia que ha tenido el proyecto para la hipótesis de la refinería.

El ajuste mejora brutalmente con los lags. El AIC cae de 19,175 a 13,992 (con 31,026 observaciones, no 33,977: se pierden ~2,951 horas al construir los 6 rezagos). El LRT confirma que la mejora es real (χ^2 con 6 grados de libertad, $p < 2.2e-16$), no artefacto de agregar variables.

AIC retuvo los 6 lags completos; BIC pudo 2 (lag3 y lag6), quedándose con lag1, lag2, lag12 y lag24. Es un patrón razonable: BIC penaliza más por variable y descartó los rezagos intermedios, probablemente porque son redundantes con sus vecinos (SO de hace 3h correlaciona fuerte con el de hace 1h, 2h y 6h). Para el reporte conviene usar el modelo BIC como el “parsimonioso” y mencionar el AIC como referencia de que ningún lag es dañino.

El hallazgo que más importa: el sector este sigue significativo, y fuerte, después de controlar por el SO de las horas anteriores. El coeficiente reportado (1.20) es en escala logit; en momio es $\exp(1.20) = 3.32$, con $p = 3.54e-127$. Esto responde directamente a la pregunta de falsación más dura que se le puede hacer al modelo: ¿el efecto direccional es real, o es solo que el SO tiende a persistir hora tras hora y el viento del este solo “atrapa” ese

arrastre? La respuesta es que no: aun sabiendo cuánto SO₂ había en la hora anterior, hace 2 horas, hace 12 y hace 24, el viento del este en la hora actual sigue añadiendo información sobre la probabilidad de episodio. Eso es evidencia adicional, e independiente de todo lo mostrado en la etapa 3, a favor de que hay una fuente activa en esa dirección y no solo inercia estadística.

Prosa para el reporte:

Para evaluar si la asociación direccional reportada en la etapa anterior refleja únicamente la persistencia temporal del SO₂ y no una contribución adicional del viento, se incorporaron seis rezagos horarios de la concentración (1, 2, 3, 6, 12 y 24 horas previas) al modelo logístico, manteniendo fijos el sector direccional y los controles meteorológicos y temporales. El ajuste mejora de forma sustancial frente al modelo sin rezagos (reducción de AIC de 19,175 a 13,992; prueba de razón de verosimilitudes, $p < 0.001$), confirmando que la concentración reciente aporta información predictiva relevante. La selección por BIC retiene los rezagos de 1, 2, 12 y 24 horas y descarta los de 3 y 6 horas, presumiblemente redundantes con sus vecinos inmediatos. De manera crucial, el coeficiente del sector este permanece altamente significativo en presencia de esta información autorregresiva (razón de momios aproximada de 3.3; $p < 10^{-12}$), lo que indica que el efecto direccional no es un artefacto de la persistencia temporal del contaminante, sino una contribución adicional asociada a las condiciones de viento de la hora en curso.

Siguiente bloque: decaimiento de los lags y valor predictivo real

Antes de cerrar esta parte falta ver dos cosas: si los coeficientes de los lags decaen de forma sensata con el tiempo (eso da una “vida media” interpretable de la pluma), y si el modelo con lags realmente sirve para algo operativo (AUC dentro y fuera de muestra), que es lo que le da sustento al “modelo predictivo” que pidió Raúl.

Advertencia: la validación fuera de muestra se hace entrenando 2022-2024 y probando 2025, igual que en la etapa 3, para que sea comparable con el AUC de 0.764 ya reportado.

```
# ---- 1. Coeficientes de los lags: ¿decae el efecto con el tiempo? ----
coefs_lag <- tidy(mod_bic) %>%
  filter(str_detect(term, "SO2_lag")) %>%
  mutate(
    horas_atras = as.numeric(str_remove(term, "SO2_lag")),
    OR_por_ppb = round(exp(estimate), 3)
  ) %>%
  arrange(horas_atras)
print(coefs_lag %>% select(horas_atras, estimate, std.error, p.value, OR_por_ppb))
```

```
# A tibble: 4 x 5
  horas_atras estimate std.error  p.value OR_por_ppb
  <dbl>      <dbl>    <dbl>    <dbl>    <dbl>
```

		<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	1	0.172	0.00388	0		1.19
2	2	-0.0232	0.00233	2.27e-23		0.977
3	12	0.0120	0.00186	1.04e-10		1.01
4	24	0.0177	0.00151	1.23e-31		1.02

```
# ---- 2. OR e IC del sector Este, modelo con lags (BIC) ----
or_este_lag <- tidy(mod_bic) %>%
  filter(term == "sector_EEste") %>%
  mutate(
    OR      = round(exp(estimate), 2),
    IC_inf  = round(exp(estimate - 1.96 * std.error), 2),
    IC_sup  = round(exp(estimate + 1.96 * std.error), 2)
  )
print(or_este_lag %>% select(OR, IC_inf, IC_sup, p.value))
```

```
# A tibble: 1 x 4
      OR IC_inf IC_sup p.value
  <dbl> <dbl> <dbl>   <dbl>
1  3.34  3.03  3.68 7.87e-129
```

```
# ---- 3. AUC en muestra: base vs modelo con lags ----
auc_base <- as.numeric(roc(se3_lags$episodio, fitted(mod_base_sub), quiet = TRUE)$auc)
auc_lags <- as.numeric(roc(se3_lags$episodio, fitted(mod_bic),      quiet = TRUE)$auc)
cat("AUC en muestra, sin lags:", round(auc_base, 3), "\n")
```

AUC en muestra, sin lags: 0.78

```
cat("AUC en muestra, con lags:", round(auc_lags, 3), "\n\n")
```

AUC en muestra, con lags: 0.909

```
# ---- 4. Validación fuera de muestra: entrenar 2022-2024, probar 2025 ----
se3_lags <- se3_lags %>% mutate(anio = year(fecha))
tr_lag <- filter(se3_lags, anio <= 2024)
te_lag <- filter(se3_lags, anio == 2025)

m_tr_lag <- glm(formula(mod_bic), data = tr_lag, family = binomial)
```

Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred

```
p_te_lag <- predict(m_tr_lag, newdata = te_lag, type = "response")

auc_oos_lag <- as.numeric(roc(te_lag$episodio, p_te_lag, quiet = TRUE)$auc)
brier_oos_lag <- mean((p_te_lag - te_lag$episodio)^2)

cat("AUC fuera de muestra 2025, con lags:", round(auc_oos_lag, 3), "\n")
```

AUC fuera de muestra 2025, con lags: 0.897

```
cat("Error de Brier fuera de muestra, con lags:", round(brier_oos_lag, 4), "\n")
```

Error de Brier fuera de muestra, con lags: 0.0753

```
cat("(referencia etapa 3, sin lags: AUC = 0.764, Brier = 0.1065)\n")
```

(referencia etapa 3, sin lags: AUC = 0.764, Brier = 0.1065)

```
# ---- Diagnóstico de separación (aviso "0 o 1 numéricamente") ----
# Se revisa si las probabilidades extremas se concentran en horas con
# SO2_lag1 muy alto, lo cual sería esperable y no un error del modelo.
prob_aj <- fitted(mod_bic)
cat("Probabilidades ajustadas < 0.001:", sum(prob_aj < 0.001), "\n")
```

Probabilidades ajustadas < 0.001: 0

```
cat("Probabilidades ajustadas > 0.999:", sum(prob_aj > 0.999), "\n\n")
```

Probabilidades ajustadas > 0.999: 253

```
se3_lags <- se3_lags %>% mutate(prob_aj = prob_aj)

cat("SO2_lag1 en observaciones con probabilidad extrema:\n")
```

SO2_lag1 en observaciones con probabilidad extrema:


```
print(summary(filter(se3_lags, prob_aj > 0.999 | prob_aj < 0.001)$S02_lag1))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
42.5	66.4	81.2	92.7	104.4	404.7

```
cat("\nS02_lag1 en el resto de las observaciones:\n")
```

S02_lag1 en el resto de las observaciones:

```
print(summary(filter(se3_lags, prob_aj <= 0.999 & prob_aj >= 0.001)$S02_lag1))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.500	3.600	4.400	6.622	5.900	71.800

La separación es benigna, y de hecho es una buena noticia. Las 253 observaciones con probabilidad ajustada mayor a 0.999 no son un error de especificación: corresponden a horas donde el SO₂ una hora antes ya estaba entre 42.5 y 404.7 ppb (mediana 81.2), muy por encima de la mediana normal de 4.4 ppb. Es decir, el modelo está prediciendo con casi total certeza que un episodio continúa cuando la hora anterior ya estaba en un nivel extremo, algo esperable y no un problema de colinealidad ni de datos mal contruidos. No hay ninguna con probabilidad extrema hacia el cero.

Prosa breve para el reporte, si quieren dejarlo documentado:

El modelo con rezagos presenta un aviso de convergencia relacionado con probabilidades ajustadas cercanas a 1 en 253 observaciones (0.8% de la muestra). La revisión de estos casos muestra que corresponden a horas inmediatamente posteriores a concentraciones ya extremas (SO₂ una hora antes con mediana de 81.2 ppb, frente a 4.4 ppb en el resto de la muestra), un patrón de cuasi-separación esperable dado el fuerte componente autorregresivo del fenómeno, y no indicativo de un problema de especificación.

Siguiente paso: errores estándar robustos para el modelo con lags

Igual que en la etapa 3 verificaron que el momio del sector este sobreviviera al agrupar por día (por la correlación serial entre horas consecutivas), conviene hacer la misma verificación aquí, porque el modelo con lags tiene aún más dependencia temporal por construcción.

```

library(sandwich)
library(lmtest)

# ---- Errores estándar robustos agrupados por día, modelo con lags ----
se3_lags <- se3_lags %>% mutate(día = as.Date(fecha))

rob_lag <- coeftest(mod_bic, vcov = vcovCL(mod_bic, cluster = ~ día))

cat("=== OR sector Este, modelo con lags ===\n")

=== OR sector Este, modelo con lags ===

b_lag <- rob_lag["sector_EEste", "Estimate"]
se_lag <- rob_lag["sector_EEste", "Std. Error"]

cat("Ingenuo (SE del modelo):", round(exp(coef(mod_bic)["sector_EEste"]), 2), "\n")

Ingenuo (SE del modelo): 3.34

cat("Agrupado por día: ", round(exp(b_lag), 2),
    " IC95: [", round(exp(b_lag - 1.96*se_lag), 2), ", ",
    round(exp(b_lag + 1.96*se_lag), 2), "]\n")

Agrupado por día: 3.34 IC95: [ 3.03 , 3.68 ]

# ---- Comparación de tabla completa (ingenuo vs robusto) para el reporte ----
comparacion_se <- tibble(
  Termino = rownames(rob_lag),
  Estimate = round(rob_lag[, "Estimate"], 3),
  SE_robusto = round(rob_lag[, "Std. Error"], 4),
  p_robusto = signif(rob_lag[, "Pr(>|z|)"], 3)
) %>% filter(str_detect(Termino, "sector_E|S02_lag"))
print(comparacion_se)

# A tibble: 5 x 4
  Termino      Estimate SE_robusto p_robusto
  <chr>      <dbl>      <dbl>    <dbl>
1 sector_EEste 1.20      0.0494 1.36e-131
2 S02_lag1     0.172     0.0069 8.11e-136

```

3	S02_lag2	-0.023	0.0037	3.55e- 10
4	S02_lag12	0.012	0.0022	4.98e- 8
5	S02_lag24	0.018	0.0022	4.33e- 16

El resultado es limpio: el intervalo agrupado por día es **exactamente igual** al ingenuo, 3.03 a 3.68. En la etapa 3, el mismo ejercicio sobre el modelo sin lags sí movió algo el intervalo (2.96–3.44 → 2.92–3.48). Aquí no se movió nada. Tiene sentido: los rezagos de SO₂ ya están absorbiendo buena parte de la correlación serial que antes quedaba en el error del modelo, así que agrupar por día ya no aporta corrección adicional. Es una confirmación más de que el modelo con lags está mejor especificado, no solo más predictivo.

Los coeficientes de los lags (0.172, -0.023, 0.012, 0.018) son casi idénticos a los del modelo original, con la misma jerarquía de significancia. Todo consistente.

Prosa breve para el reporte:

Los errores estándar agrupados por día no modifican el intervalo de confianza del momio del sector este en el modelo con rezagos (3.03 a 3.68 en ambos casos), a diferencia del modelo direccional original de la etapa anterior, donde el ajuste produjo un ensanchamiento marginal. Esto sugiere que la incorporación de los rezagos de SO₂ captura de forma más completa la dependencia temporal de las observaciones horarias, dejando un residuo con menor correlación serial.

Con esto, el modelo con lags queda validado en tres frentes

Ajuste (AIC/BIC/LRT), desempeño predictivo (AUC dentro y fuera de muestra), y robustez a la correlación serial. Ya es un modelo defendible para lo que pidió .

Siguiente bloque natural: reconstruir el tablero de alerta temprana que ya tenían al final del código de la etapa 3, pero con el modelo de lags en vez del modelo simple. Esa es la pieza que convierte todo esto en algo que SIMA podría usar de verdad: en vez de simular un pronóstico de viento hipotético, se alimenta con el SO₂ real de las últimas 24 horas (que SIMA ya mide) para dar una probabilidad de episodio hora por hora, sin necesitar pronóstico meteorológico.

```
# ---- Tablero de alerta temprana: nowcast con S02 rezagado real ----
# A diferencia de la simulación anterior, aquí el insumo es S02 ya medido.

tasa_base_lag <- mean(tr_lag$episodio)

tablero <- te_lag %>%
  mutate(
    prob_episodio = predict(m_tr_lag, newdata = te_lag, type = "response"),
```

```

    alerta = if_else(prob_episodio > tasa_base_lag,
                     "ALERTA: Probabilidad de episodio",
                     "Normal")
  )

# ---- Desempeño del tablero: matriz de confusión en 2025 ----
tab_lag <- table(Predicho = tablero$prob_episodio > tasa_base_lag,
                 Real      = tablero$episodio)
print(tab_lag)

```

	Real	
Predicho	0	1
FALSE	5769	229
TRUE	1169	898

```

cat("\nSensibilidad:", round(tab_lag[2,2] / sum(tab_lag[,2]), 3),
    "| Especificidad:", round(tab_lag[1,1] / sum(tab_lag[,1]), 3), "\n")

```

Sensibilidad: 0.797 | Especificidad: 0.832

```

# ---- Comparación directa: tablero simple (etapa 3) vs tablero con lags ----
comparacion_tablero <- tibble(
  Modelo          = c("Sin lags (etapa 3)", "Con lags (SO2 real)"),
  AUC_oos         = c(0.764, round(auc_oos_lag, 3)),
  Brier_oos       = c(0.1065, round(brier_oos_lag, 4)),
  Sensibilidad    = c(0.712, round(tab_lag[2,2] / sum(tab_lag[,2]), 3)),
  Especificidad   = c(0.681, round(tab_lag[1,1] / sum(tab_lag[,1]), 3))
)
print(comparacion_tablero)

```

```

# A tibble: 2 x 5
  Modelo          AUC_oos Brier_oos Sensibilidad Especificidad
  <chr>          <dbl>    <dbl>        <dbl>        <dbl>
1 Sin lags (etapa 3) 0.764    0.106        0.712        0.681
2 Con lags (SO2 real) 0.897    0.0753       0.797        0.832

```

```
# ---- Ejemplo de tablero: un día representativo de 2025 con alertas reales ----
tablero <- tablero %>% mutate(dia = as.Date(fecha))

dia_ejemplo <- tablero %>%
  filter(dia == min(dia[episodio == 1], na.rm = TRUE)) %>%
  select(fecha, Hora, S02, S02_lag1, sector_E, prob_episodio, alerta, episodio)
print(dia_ejemplo, n = 24)
```

```
# A tibble: 18 x 8
```

	fecha	Hora	S02	S02_lag1	sector_E	prob_episodio	alerta
	<dtm>	<int>	<dbl>	<dbl>	<fct>	<dbl>	<chr>
1	2025-01-01 04:00:00	4	3.9	4	Resto	0.00933	Normal
2	2025-01-01 05:00:00	5	3.8	3.9	Resto	0.0105	Normal
3	2025-01-01 07:00:00	7	3.7	3.6	Resto	0.0175	Normal
4	2025-01-01 08:00:00	8	3.8	3.7	Resto	0.0239	Normal
5	2025-01-01 09:00:00	9	4	3.8	Resto	0.0320	Normal
6	2025-01-01 10:00:00	10	4.6	4	Resto	0.0429	Normal
7	2025-01-01 11:00:00	11	5.3	4.6	Resto	0.0584	Normal
8	2025-01-01 13:00:00	13	5	5.3	Resto	0.0758	Normal
9	2025-01-01 14:00:00	14	4.5	5	Este	0.241	ALERTA: Prob~
10	2025-01-01 15:00:00	15	4.2	4.5	Este	0.338	ALERTA: Prob~
11	2025-01-01 16:00:00	16	39.5	4.2	Este	0.148	ALERTA: Prob~
12	2025-01-01 17:00:00	17	19.2	39.5	Este	0.985	ALERTA: Prob~
13	2025-01-01 18:00:00	18	5	19.2	Resto	0.171	ALERTA: Prob~
14	2025-01-01 19:00:00	19	4.4	5	Resto	0.0161	Normal
15	2025-01-01 20:00:00	20	4.3	4.4	Resto	0.0169	Normal
16	2025-01-01 21:00:00	21	4.1	4.3	Resto	0.0126	Normal
17	2025-01-01 22:00:00	22	4	4.1	Resto	0.0104	Normal
18	2025-01-01 23:00:00	23	3.9	4	Resto	0.00842	Normal

```
# i 1 more variable: episodio <int>
```

Lo que pasó ese día: el sector cambia a “Este” en la hora 14, y la probabilidad empieza a subir (24.1%, luego 33.8%) *antes* de que el SO₂ se dispare. El pico real llega en la hora 16 (SO₂ = 39.5 ppb, muy por encima del umbral de 11.1). Pero en ese momento exacto, el modelo solo da 14.8% de probabilidad, porque su insumo principal (S02_lag1) todavía traía el valor bajo de la hora anterior (4.2 ppb): el modelo aún no “sabía” que el pico ya había ocurrido. Una hora después (hora 17), con S02_lag1 = 39.5 ya en el modelo, la probabilidad salta a 98.5%.

Esto ilustra el límite estructural del enfoque: el modelo con lag de 1 hora es excelente para predecir que un episodio **continúa** una vez que ya empezó, pero tiene un punto ciego inherente para el **instante exacto del arranque súbito**, porque por construcción todavía no ha visto

ese dato. Lo que sí detecta con anticipación es el cambio de sector de viento, que en este caso empezó a subir el riesgo dos horas antes del pico.

Para el reporte, esto se puede presentar como una fortaleza matizada, no como una falla:

El ejemplo ilustra el mecanismo del modelo con rezagos: la probabilidad de episodio comienza a elevarse desde que el viento rota al sector este (24.1% dos horas antes del pico), pero el salto a una probabilidad alta solo ocurre una hora después del inicio real del episodio, una vez que el propio pico queda incorporado como rezago. Esto revela una limitación inherente de un esquema basado en rezagos cortos: el modelo anticipa el riesgo asociado al viento, pero no el instante preciso de un ascenso súbito, y solo confirma con alta confianza la continuación del episodio una vez iniciado. Para fines de alerta temprana, esto sugiere que la señal del sector direccional, disponible antes del pico, tiene un valor operativo distinto y complementario al de la señal autorregresiva.

Una nota aparte, antes de seguir: el día solo muestra 18 de 24 horas — faltan las horas 0,1,2,3,6 y 12. Esto probablemente refleja huecos reales en los sensores que, al construir los rezagos de 12 y 24 horas, se propagan y eliminan esas filas por el `drop_na`. Es consistente con el panel desbalanceado que ya documentaron en la etapa 3 (cobertura real de sensores, no error de datos), pero vale la pena mencionarlo en una nota al pie si usan este ejemplo en el reporte, para que no parezca un error de código.

```
library(car)
```

```
Cargando paquete requerido: carData
```

```
Adjuntando el paquete: 'car'
```

```
The following object is masked from 'package:psych':
```

```
logit
```

```
The following object is masked from 'package:dplyr':
```

```
recode
```

```
The following object is masked from 'package:purrr':
```

```
some
```

```
# ---- Importancia por bloques: cuánto aporta cada grupo de variables ----
# Compara la devianza del modelo completo contra el modelo sin cada bloque.

mod_sin_viento <- update(mod_bic, . ~ . - sector_E)
```

Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred

```
mod_sin_meteo <- update(mod_bic, . ~ . - ns(WSR, 3) - Hora_sin - Hora_cos - Mes_sin - Mes_c)
```

Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred

```
mod_sin_lags <- update(mod_bic, . ~ . - S02_lag1 - S02_lag2 - S02_lag12 - S02_lag24)
```

```
# ---- Grados de libertad de cada bloque ----
importancia_bloques <- tibble(
  Bloque = c("Sector de viento (Este/Resto)",
             "Meteorología + ciclicidad (WSR, hora, mes)",
             "Memoria autorregresiva (lags de S02)"),
  Chi2 = c(
    mod_sin_viento$deviance - mod_bic$deviance,
    mod_sin_meteo$deviance - mod_bic$deviance,
    mod_sin_lags$deviance - mod_bic$deviance
  ),
  gl = c(
    mod_sin_viento$df.residual - mod_bic$df.residual,
    mod_sin_meteo$df.residual - mod_bic$df.residual,
    mod_sin_lags$df.residual - mod_bic$df.residual
  )
) %>%
mutate(
  Chi2 = round(Chi2, 1),
  p = signif(pchisq(Chi2, gl, lower.tail = FALSE), 3),
  aporte_pseudoR2 = round(Chi2 / mod_bic$null.deviance, 3)
) %>%
arrange(desc(Chi2))

print(importancia_bloques)
```

A tibble: 3 x 5

Bloque	Chi2	gl	p	aporte_pseudoR2
--------	------	----	---	-----------------

<chr>	<dbl>	<int>	<dbl>	<dbl>
1 Memoria autorregresiva (lags de SO ₂)	5188.	4	0	0.23
2 Meteorología + ciclicidad (WSR, hora, m~	904.	7	5.39e-191	0.04
3 Sector de viento (Este/Resto)	597.	1	8.31e-132	0.026

Confirmado, y con grados de libertad correctos. La jerarquía queda clara y todos los bloques son individualmente indispensables (los tres p-valores son astronómicamente significativos, ninguno es prescindible):

Bloque	Chi ²	gl	Pseudo-R ² marginal
Memoria autorregresiva (lags SO)	5188	4	0.23
Meteorología + ciclicidad	904	7	0.04
Sector de viento (Este/Resto)	597	1	0.026

Nótese que el sector de viento logra 0.026 de pseudo-R² **con un solo grado de libertad** (la variable binaria Este/Resto), mientras que la meteorología necesita 7 grados de libertad para lograr apenas el doble (0.04). Por parámetro invertido, el viento es sorprendentemente eficiente; no es una variable débil, es una variable barata en complejidad y con peso propio.

Prosa para el reporte:

La comparación de bloques de variables mediante pruebas de razón de verosimilitudes muestra que la memoria autorregresiva del SO₂ (rezagos de 1, 2, 12 y 24 horas) concentra la mayor contribución marginal al modelo (pseudo-R² de 0.23), seguida por el bloque meteorológico y de ciclicidad temporal (0.04, con 7 grados de libertad) y por el sector de viento Este/Resto (0.026, con un solo grado de libertad). Los tres bloques resultan individualmente indispensables ($p < 10^{-12}$ en los tres casos): ninguno es redundante frente a los otros dos. Es relevante notar que el sector de viento logra su contribución con un único parámetro, una eficiencia por grado de libertad mayor que la del bloque meteorológico, y que su significancia se mantiene aun después de controlar por el fuerte componente autorregresivo del contaminante, reforzando que se trata de una fuente de información distinta y no de una variable proxy de la persistencia temporal.

Con esto la interpretación queda completa: tienen caracterizado qué tan importante es cada pieza del modelo, no solo si es significativa.

Cierre: tabla resumen de todos los modelos

Este es el último bloque técnico antes de pasar a redactar la conclusión con las preguntas de investigación.


```
# ---- Tabla resumen: todos los modelos de la etapa de cierre ----
resumen_final <- tibble(
  Modelo = c(
    "Direccional simple (etapa 3)",
    "Con lags, selección AIC",
    "Con lags, selección BIC (final)"
  ),
  AIC = c(round(AIC(mod), 1), round(AIC(mod_aic), 1), round(AIC(mod_bic), 1)),
  BIC = c(round(BIC(mod), 1), round(BIC(mod_aic), 1), round(BIC(mod_bic), 1)),
  AUC_muestra = c(0.783, round(auc_lags, 3), round(auc_lags, 3)),
  AUC_2025 = c(0.764, NA, round(auc_oos_lag, 3)),
  Brier_2025 = c(0.1065, NA, round(brier_oos_lag, 4)),
  OR_sector_Este = c(3.19, NA, round(exp(coef(mod_bic)["sector_EEste"]), 2))
)
print(resumen_final, width = Inf)
```

```
# A tibble: 3 x 7
```

	Modelo	AIC	BIC	AUC_muestra	AUC_2025	Brier_2025
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	Direccional simple (etapa 3)	20736.	20812.	0.783	0.764	0.106
2	Con lags, selección AIC	13992.	14117.	0.909	NA	NA
3	Con lags, selección BIC (final)	13996.	14104.	0.909	0.897	0.0753
	OR_sector_Este					
	<dbl>					
1	3.19					
2	NA					
3	3.34					