

Etapas 3: Modelado y análisis multivariado

Equipo 6

Alicia Bernádez A01562634 Omar Arzaga A01569294
Diego Medrano A01254882 Sebastián Alemán A00841034
Isaac Montaña A00841681

Del diagnóstico a la cuantificación

El análisis descriptivo de la etapa 2 mostró un gradiente espacial de concentraciones ($SE3 > SE2 > NE > GAR$) consistente con esta hipótesis. Sin embargo, las diferencias entre medianas anuales son reducidas (del orden de 1 ppb) y, por sí solas, no bastan para una conclusión definitiva. Con base en los resultados de esa etapa, fue necesario reformular el objetivo. Primero, el comportamiento atípico del contaminante no se manifiesta en los niveles de fondo, sino en la frecuencia de eventos agudos. Un objetivo centrado en concentraciones promedio limitaría la capacidad de caracterizar los episodios de alta exposición que realmente ocurren en la zona. Segundo, la etapa anterior sugirió que los episodios de mayor concentración presentan un patrón espacial y direccional definido. Por ello, en esta etapa el análisis se enfoca en cuantificar dicha asociación, evaluar cómo cambia con la distancia y determinar qué métrica representa mejor la exposición observada.

Objetivo actualizado

Cuantificar el exceso de exposición aguda a SO_2 asociado al sector direccional donde se ubica la refinería de Cadereyta, para evaluar si los indicadores de tendencia central (promedios y medianas anuales) que usan actualmente los instrumentos de gestión representan adecuadamente esa exposición.

Esta formulación conserva el marco del Objetivo 4 y el enfoque en fuentes industriales puntuales, pero desplaza el análisis de una atribución causal hacia la cuantificación del exceso de exposición y su posible incorporación a los mecanismos de seguimiento del PIGECA 2023–2033.

Selección de Métodos

- Técnica de dependencia — regresión logística binaria: se utilizó para estimar la probabilidad de presentar un episodio agudo de SO_2 en función de la dirección y velocidad del viento, controlando además la hora y el mes (Gómez, 2026).
- Técnicas de interdependencia — componentes principales y conglomerados: se emplearon para explorar la estructura conjunta de los contaminantes y evaluar si el SO presenta un patrón distinto al de los contaminantes asociados con combustión urbana (Gómez Muñoz & Ruiz Hernández, 2026).
- Contraste no paramétrico: Kruskal-Wallis y el estimador de Hodges-Lehmann permitieron comparar las diferencias entre estaciones sin asumir normalidad (Kruskal & Wallis, 1952; Hodges & Lehmann, 1963).

- Verificación independiente — CBPF: se utilizó para comprobar si el patrón direccional identificado por la regresión también aparece mediante un método no paramétrico basado en dirección y velocidad del viento (Ashbaugh et al., 1985; Uria-Tellaetxe & Carslaw, 2014).

Análisis direccional

Caracterización de los episodios

Se definió como episodio toda hora con una concentración de SO_2 superior a 11.1 ppb, valor correspondiente al percentil 95 global del conjunto de las cuatro estaciones. La adopción de un umbral absoluto común resulta indispensable para garantizar la comparabilidad de las tasas de excedencia entre los distintos sitios; la aplicación de un percentil relativo, calculado de forma individual para cada estación, forzaría por construcción estadística la misma proporción de episodios en todos los puntos, lo cual ocultaría precisamente la diferencia espacial que se busca medir.

Table 1: Características de los episodios de SO_2 (umbral > 11.1 ppb) y ubicación respecto a la refinera por estación.

Estación	Distancia (km)	Azimut (°)	Rumbo	Horas válidas	Episodios	Tasa (%)	Mediana	P99	P99/Mediana
SE3	5.5	87.3	E	33977	3951	11.63	4.4	55.3	12.57
SE2	16.4	113.7	ESE	33240	1841	5.54	3.8	27.8	7.32
NE	35.7	119.6	ESE	33185	746	2.25	3.8	15.1	3.97
GAR	68.5	110.1	ESE	32534	49	0.15	3.3	7.4	2.24

Modelo logístico direccional

Se estimó un modelo de regresión logística para la probabilidad de episodio en SE3, incorporando el rumbo del viento como factor de 16 niveles, clasificado en sectores de 22.5 grados a partir de la variable circular WDR, con el norte como categoría de referencia. Se controló por velocidad del viento mediante splines naturales de tres grados de libertad y por hora y mes mediante términos armónicos, que preservan la naturaleza cíclica de ambas variables.

Se identificó que el rumbo este presenta la mayor razón de momios (6.12; IC 95%: 4.73 a 7.92), seguido por los rumbos ESE (2.58) y ENE (1.98). Por el contrario, el contraste con el cuadrante opuesto resulta pronunciado: los rumbos NO, NNO, O y ONO muestran razones de momios entre 0.08 y 0.25, lo cual representa reducciones de entre cuatro y doce veces en comparación con la categoría de referencia.

Este resultado admite una interpretación de falsación. Dado que el Área Metropolitana de Monterrey se localiza al oeste de Cadereyta, si los episodios de SO_2 fueran atribuibles a la mancha urbana o al tráfico vehicular metropolitano, se esperarían razones de momios elevadas con vientos provenientes del sector oeste. No obstante, se observó el comportamiento inverso.

La significancia global del modelo se evaluó mediante una prueba de razón de verosimilitudes, encontrándose una mejora significativa frente al modelo nulo ($\chi^2 = 4617.2$, $p < 0.001$). Además, presentó una buena

capacidad para distinguir entre horas con y sin episodios de SO_2 ($AUC = 0.811$). La prueba de Hosmer-Lemeshow resultó significativa ($p < 0.001$), indicando diferencias entre algunas probabilidades observadas y estimadas; por ello, la adecuación se interpreta en conjunto con las demás métricas y considerando que el objetivo del modelo es estimar asociaciones, no realizar pronósticos.

Verificación geográfica independiente

El sector direccional no se especificó de antemano: los 16 rumbos se introdujeron como categorías equivalentes y el modelo identificó el máximo sin recibir información sobre la ubicación de la fuente investigada. La verificación geográfica se realizó con posterioridad, calculando el azimuth geodésico desde cada estación hacia el complejo refinador.

Desde SE3, la refinería se localiza en un azimuth de 87.3 grados, correspondiente al rumbo este, a 5.5 kilómetros de distancia. El sector que el modelo identificó de forma independiente coincide con la ubicación de la fuente. Dado que el complejo ocupa 612 hectáreas, se evaluó la sensibilidad del cálculo desplazando el centroide 1.5 kilómetros en cada dirección cardinal: el azimuth resultante oscila entre 72.4 y 102.7 grados, y permanece en todos los casos dentro de la banda ENE a ESE.

Atenuación del efecto con la distancia

Las cuatro estaciones tienen el complejo refinador hacia el este o el este-sureste. Si el sector oriental estuviera asociado a concentraciones elevadas por razones meteorológicas generales, todas deberían presentar momios comparables.




Figure 1: Razón de momios del sector Este sobre la probabilidad de episodio, en función de la distancia de cada estación a la refinería. Barras: intervalo de confianza al 95%. Línea punteada: ausencia de efecto.

Una vez identificado el Este como el sector de mayor asociación, se ajustó una segunda parametrización común, Este frente al resto de direcciones, para comparar el efecto entre estaciones. La asociación disminuye conforme aumenta la distancia: $OR = 3.19$ en SE3 (5.5 km), $OR = 1.58$ en SE2 (16.4 km) y $OR = 1.01$ en NE (35.7 km), donde el intervalo de confianza incluye la unidad. El patrón indica que el aumento en episodios requiere la combinación de dirección y proximidad y es consistente con la dispersión y dilución de una pluma. El caso de GAR merece una precisión: a 68.5 kilómetros, el sector oriental de esa estación comprende la totalidad de la zona metropolitana antes que el complejo refinador. Su momio de 1.08, con intervalo amplio que incluye la unidad, resulta consistente con una influencia urbana difusa y respalda su función como estación de control.

Esta segunda especificación también fue globalmente significativa frente al modelo nulo ($\chi^2=3708.2$, $p<0.001$) y presentó una capacidad discriminante razonable (AUC = 0.783).

Análisis de sensibilidad

Se replicó el modelo con umbrales correspondientes a los percentiles 90, 95 y 99 del conjunto, con el fin de verificar que las conclusiones no dependen del corte elegido.

Los momios de SE3 se mantienen entre 2.57 y 3.38, y los de NE entre 0.86 y 1.01 con intervalos que siempre incluyen la unidad. SE2 muestra un momio creciente con la severidad del umbral, de 1.43 a 1.75, patrón compatible con la llegada de la pluma a Juárez únicamente durante los episodios de mayor intensidad. En GAR no fue posible estimar el modelo con el umbral más exigente por contar con menos de 30 horas por encima de 30.6 ppb en cuatro años, circunstancia que constituye en sí misma un resultado.

Adicionalmente, dado que las observaciones horarias consecutivas no son independientes, se recalcularon los errores estándar agrupando por día. El intervalo del momio del sector este en SE3 pasa de 2.96 a 3.44 hacia 2.92 a 3.48, variación marginal que muestra que la estimación es estable al ajustar los errores estándar por dependencia dentro del día.

Pruebas de falsación multi-contaminante

Planteamiento

Aunque la regresión identificó una asociación entre los episodios de SO_2 y el sector Este, este resultado por sí solo no permite distinguir entre una fuente industrial y otras fuentes ubicadas en la misma dirección. Por ello, se comparó el comportamiento direccional del SO_2 con otros contaminantes asociados a combustión urbana, principalmente NOX y CO.

Momios por contaminante

Se aplicó el mismo modelo logístico a siete contaminantes en SE3, definiendo en cada caso el evento como la superación del percentil 95 de la distribución propia de cada variable. Este ajuste permite comparar contaminantes medidos en unidades distintas frente a una misma probabilidad de referencia.

Table 2: Razón de momios del sector Este sobre la probabilidad de concentración elevada, por contaminante, en SE3.

Contaminante	n	Eventos	OR	IC 95%
SO2	33977	1699	2.66	[2.39, 2.95]
NOX	33682	1684	0.22	[0.17, 0.28]
NO	33451	1670	0.22	[0.17, 0.29]
CO	31741	1571	1.05	[0.92, 1.2]
PM10	33684	1658	0.50	[0.43, 0.58]
PM2.5	30686	1507	0.59	[0.51, 0.68]
O3	33697	1567	0.90	[0.8, 1.02]

El SO_2 fue el único contaminante con una razón de momios significativamente superior a uno ($OR = 2.66$; $IC95\%$: 2.39–2.95). En contraste, NO_x y NO presentaron $OR = 0.22$, mientras que CO y O_3 no mostraron un incremento significativo. Por lo tanto, la masa de aire proveniente del Este presenta una señal rica en SO_2 pero no en contaminantes típicamente asociados con tráfico, patrón poco compatible con una explicación dominada por combustión urbana.

Verificación por método no paramétrico

Como verificación independiente se aplicó la Conditional Bivariate Probability Function (CBPF), que estima la probabilidad de concentraciones elevadas en función de la dirección y velocidad del viento sin asumir una forma paramétrica (Ashbaugh et al., 1985; Uria-Tellaetxe & Carslaw, 2014).




Figure 2: CBPF en SE3. Izquierda: SO_2 , con lóbulo direccional al este. Derecha: NO_x , con máximo central en condiciones de calma. Ambos paneles emplean el mismo percentil de referencia.

La CBPF reproduce el patrón identificado por la regresión: el SO_2 presenta un máximo compacto hacia el Este a velocidades moderadas, mientras que el NO_x alcanza sus mayores probabilidades bajo condiciones de viento débil y sin una orientación equivalente. La coincidencia entre ambos métodos fortalece la evidencia de una señal direccional específica para el SO_2 .

Estructura multivariada de la matriz química

Planteamiento

Como verificación adicional, se analizó la estructura conjunta de los contaminantes sin utilizar información meteorológica. El objetivo fue evaluar si el SO_2 comparte el mismo patrón de variación que los contaminantes asociados con combustión urbana.

Componentes principales

Se aplicó PCA sobre ocho contaminantes de SE3, previa transformación logarítmica y estandarización para reducir la influencia de valores extremos y hacer comparables las escalas de las variables (Gómez Muñoz & Ruiz Hernández, 2026).

El procedimiento requiere casos completos. De las 33,977 observaciones de SE3 se conservaron 27,938 (82.2%). De los 3,951 episodios registrados se conservaron 3,304 (83.6%). La similitud entre ambas proporciones indica que la exclusión por datos faltantes no eliminó preferentemente las horas de episodio.

La adecuación muestral se verificó con el índice KMO, que alcanza 0.623, y la prueba de esfericidad de Bartlett, significativa. El KMO se ubica por encima del mínimo convencional de 0.6, aunque en el rango que Kaiser califica como mediocre. Esto es esperable y no constituye una deficiencia: el índice desciende precisamente porque el SO_2 mantiene correlaciones bajas con el resto de las variables, que es justo la estructura que el análisis busca documentar. Dos componentes superan el criterio de Kaiser. El primero explica el 48.6% de la varianza; los cuatro primeros acumulan el 86.9%.

El primer componente explicó 48.6% de la variación y agrupó principalmente a NO_x , NO, NO_2 , PM_{10} y CO, por lo que se interpretó como un eje asociado con combustión urbana. La carga del SO_2 sobre este componente fue de apenas 0.029, indicando una asociación muy baja con este patrón.

El segundo componente explicó 19.4% de la variación y estuvo encabezado por el SO_2 (carga = 0.604). En conjunto, el PCA muestra que el contaminante de interés presenta una estructura de variación distinta al principal patrón químico asociado con fuentes urbanas.

Análisis de conglomerados

Sobre los cuatro primeros componentes se aplicó k-medias para identificar perfiles químicos de las observaciones. Aunque el índice de silueta favoreció dos grupos (0.418), se utilizaron cuatro conglomerados para obtener perfiles más interpretables; esta partición explicó 58.3% de la variación en el espacio de componentes.

Table 3: Perfil de los conglomerados en SE3. Las concentraciones son medianas expresadas en ppb, salvo PM2.5 en microgramos por metro cúbico.

Grupo	n	%	SO2	NOX	PM2.5	O3	WSR			
							(km/h)	SO2/NOX	% Este	% episodios
1	4111	14.7	16.2	10.4	22	43	8.5	1.558	50.5	72.2
2	3352	12.0	4.4	51.8	28	5	3.6	0.085	6.2	1.4
3	7823	28.0	4.2	17.7	15	17	5.8	0.237	25.4	0.9
4	12652	45.3	4.1	8.1	9	26	8.5	0.506	42.7	1.7

El grupo 1 concentra las mayores concentraciones de SO_2 , una razón SO_2/NO_x elevada, 50.5% de observaciones con viento del Este y 72.2% de los episodios. En contraste, el grupo 2 presenta NO_x elevado y menor velocidad del viento, consistente con un perfil de acumulación urbana. Esta separación respalda la existencia de patrones químicos distintos entre los episodios de SO_2 y las condiciones dominadas por NO_x .

Contraste entre tendencia central y exposición aguda

Diferencia de medianas por año

Se evaluaron las diferencias entre estaciones para cada año mediante la prueba no paramétrica de Kruskal-Wallis, adecuada ante la marcada asimetría de las concentraciones de SO_2 . La prueba resultó significativa en los cuatro años. Para cuantificar específicamente la diferencia entre SE3 y GAR se utilizó el estimador

de Hodges-Lehmann, obteniéndose desplazamientos entre 0.6 y 1.5 ppb según el año (Kruskal & Wallis, 1952; Hodges & Lehmann, 1963).

La diferencia alcanzó su máximo en 2023 (1.5 ppb) y disminuyó hasta 0.6 ppb en 2025. Considerada de forma aislada, esta tendencia sugeriría una convergencia entre SE3 y GAR y una aparente mejora en Cadereyta.

Frecuencia de eventos agudos

El recuento de horas por encima del umbral de 11.1 ppb muestra una tendencia distinta. En 2023, cuando la diferencia de medianas fue máxima, SE3 registró 689 horas de episodio; en 2025, cuando la diferencia fue mínima, registró 1,172 horas. Por lo tanto, la reducción en las diferencias de tendencia central no estuvo acompañada por una reducción de los episodios agudos.




Figure 3: Evolución anual de la diferencia de medianas entre SE3 y GAR (línea, eje derecho) frente al número de horas de episodio en SE3 (barras, eje izquierdo). Ambas series evolucionan en sentidos opuestos.

La divergencia ocurre porque la mediana representa el comportamiento típico y es poco sensible a la cola superior de la distribución, donde se concentran los episodios de interés. Por ello, una reducción del nivel de fondo puede coexistir con un aumento de eventos extremos. En el periodo completo, GAR superó el umbral en apenas 0.15% de las horas, frente a 11.63% en SE3, lo que muestra que los indicadores de tendencia central por sí solos no representan adecuadamente la exposición aguda.

Exceso de horas de episodio

Durante el periodo analizado, SE3 acumuló 3,902 horas de episodio adicionales respecto a GAR, equivalentes a un promedio de 976 horas o 40.6 días por año. Mientras GAR registró entre 9 y 20 horas anuales por encima del umbral, SE3 superó las mil horas en dos de los cuatro años. Esta diferencia cuantifica la magnitud del exceso de exposición aguda observado en la estación más cercana a la refinería, sin interpretarse como una estimación causal directa de la contribución de la fuente.

Implicaciones para el seguimiento de la calidad del aire

Los resultados muestran que un seguimiento basado únicamente en medias o medianas anuales puede ocultar cambios importantes en la frecuencia de episodios agudos. En 2025, por ejemplo, la diferencia de

medianas entre SE3 y GAR fue la menor del periodo, mientras que SE3 registró 1,172 horas por encima del umbral. Por ello, el seguimiento de la calidad del aire debería incorporar métricas de frecuencia de excedencia junto con los indicadores de tendencia central.

Conclusión parcial y trabajo pendiente

Validación de los modelos

Las dos especificaciones de regresión logística resultaron globalmente significativas frente a sus respectivos modelos nulos y presentaron una capacidad discriminante razonable, con AUC de 0.811 para el modelo direccional de 16 sectores y de 0.783 para la especificación Este frente al resto. Esta última mantuvo un desempeño similar al evaluarse fuera de muestra en 2025 ($AUC = 0.764$). La prueba de Hosmer-Lemeshow fue significativa en ambos modelos, por lo que su adecuación se interpretó junto con las demás métricas y considerando que su objetivo es estimar asociaciones y no realizar pronósticos. Por su parte, el PCA presentó $KMO = 0.623$ y una prueba de Bartlett significativa. En conjunto, estas verificaciones permiten utilizar los modelos como apoyo estadístico para los patrones encontrados, reconociendo sus limitaciones.

Síntesis de resultados

El análisis permite establecer cuatro hallazgos principales. Primero, los episodios de SO_2 presentan una asociación direccional clara con el sector Este: el modelo de 16 rumbos identificó este sector como el de mayor razón de momios ($OR = 6.12$ frente al Norte), coincidiendo posteriormente con el azimut de 87.3° de la refinería. Segundo, al comparar el sector Este frente al resto de direcciones entre estaciones, la asociación se atenúa conforme aumenta la distancia, pasando de $OR = 3.19$ en SE3 (5.5 km) a $OR = 1.01$ en NE (35.7 km). Tercero, los análisis multi-contaminante, CBPF, PCA y conglomerados muestran que los episodios de SO_2 presentan un patrón distinto al de los contaminantes asociados con combustión urbana. Finalmente, el principal contraste entre estaciones se encuentra en la frecuencia de eventos agudos y no en sus niveles típicos: las diferencias de mediana no superan 1.5 ppb, mientras que SE3 registra en promedio 976 horas de episodio adicionales por año respecto a GAR.

Conclusión parcial

En conjunto, los resultados son consistentes con la influencia de una fuente puntual de SO_2 localizada en el sector Este de SE3. La asociación entre los episodios y los vientos provenientes de este sector es más fuerte en la estación más cercana y se atenúa conforme aumenta la distancia, patrón compatible con la dispersión de una pluma. Además, los análisis con otros contaminantes, CBPF, componentes principales y conglomerados muestran que el comportamiento del SO_2 difiere del principal patrón asociado con combustión urbana.

El análisis también muestra que el principal contraste entre estaciones se encuentra en la frecuencia de eventos agudos y no necesariamente en sus niveles típicos. Mientras las diferencias de mediana entre SE3 y GAR son reducidas, SE3 acumula muchas más horas por encima del umbral. Por ello, la frecuencia de episodios aporta información relevante que podría pasar desapercibida si el seguimiento se limita a indicadores de tendencia central.

El diseño es observacional y no permite establecer atribución causal en sentido estricto, ya que no se dispone de datos directos de emisión ni de un contrafactual experimental. Por lo tanto, los resultados deben interpretarse como evidencia convergente: los patrones encontrados son poco compatibles con las explicaciones alternativas evaluadas y apuntan de manera consistente hacia una misma hipótesis.

Trabajo pendiente

Como siguientes pasos se propone: contrastar los resultados con el inventario del PIGECA y la normativa aplicable; caracterizar la duración y distribución temporal de los episodios; incorporar información sobre paros y mantenimientos del complejo para aproximar un contraste operativo; y extender el análisis a años adicionales para evaluar la estabilidad del patrón direccional. También queda pendiente investigar el repunte de episodios observado en 2025 y evaluar si los datos de 2026 permiten comparar periodos de operación y paro del complejo.

Liga Github

https://github.com/aliciabernadez/MA2003B_multivariados/tree/trunk

Declaratoria de IA

Opción B. Se utilizó IA de la siguiente forma:

- **Herramienta:** Claude
- **Uso realizado:** Se utilizó como apoyo para la construcción del código en R de esta etapa, en particular la clasificación circular de la dirección del viento en 16 sectores, el análisis de componentes principales y de conglomerados, y el cálculo del azimuth entre las estaciones y la refinería. También sirvió como guía para justificar el uso de un umbral absoluto común en lugar de percentiles por estación.
- **Secciones donde se utilizó:** Definición del umbral de episodio, regresión logística direccional, análisis de sensibilidad, verificación geográfica, componentes principales, conglomerados y validación del modelo.
- **Validación realizada por los estudiantes:** Los códigos sugeridos fueron revisados cada uno, ejecutados y ajustados por los integrantes del equipo en RStudio utilizando la base de datos del proyecto. Los resultados obtenidos fueron comparados con la estructura y características de los datos originales y las interpretaciones fueron revisadas para evitar conclusiones que no estuvieran sustentadas por la información disponible
- **Confirmación de responsabilidad:** Se confirma que el contenido generado con apoyo de IA fue revisado y verificado por los integrantes del equipo, quienes asumen la responsabilidad del contenido final entregado.