

Etapas 3: Modelado y análisis multivariado

Alicia Bernádez, Omar Arzaga, Diego Medrano, Sebastián Alemán, Isaac Montaña

Del diagnóstico a la cuantificación

En las etapas 1 y 2 el objetivo se formuló como una pregunta de identificación: determinar si la refinería de Cadereyta constituye una fuente direccionalmente identificable de SO₂ en las estaciones cercanas. El análisis descriptivo de la etapa 2 mostró un gradiente monótono de concentraciones (SE3 > SE2 > NE > GAR) coherente con esa hipótesis, pero también reveló que las diferencias entre medianas anuales son pequeñas —del orden de 1 ppb— y por sí solas insuficientes para sostener una conclusión.

Los resultados de la presente etapa obligan a reformular el objetivo en dos sentidos.

Primero, el fenómeno no reside en el nivel de fondo sino en la frecuencia de eventos agudos. La mediana de SE3 supera a la de GAR en apenas 0.6–1.5 ppb según el año, mientras que la probabilidad de exceder el umbral de episodio (P95 global = 11.1 ppb) es 77 veces mayor. Un objetivo centrado en concentraciones promedio describiría un problema inexistente y omitiría el que sí existe.

Segundo, la identificación de la fuente dejó de ser el problema abierto. La confirmación geográfica —la refinería se ubica a 87.3° y 5.5 km de SE3, en el mismo sector que el modelo logístico señaló de forma independiente— y las pruebas de falsación multi-contaminante resuelven la pregunta original. Lo que permanece abierto, y es lo relevante para la gestión de la calidad del aire, es la magnitud de la exposición y su adecuada medición.

Objetivo actualizado

Cuantificar el exceso de exposición aguda a SO₂ atribuible al sector direccional donde se ubica la refinería de Cadereyta, evaluando si los indicadores basados en promedios y medianas anuales —los empleados por los instrumentos vigentes de gestión— representan adecuadamente dicha exposición.

El objetivo conserva el marco del Objetivo 4 del proyecto y el foco en fuentes industriales puntuales, pero desplaza el producto final de una afirmación de atribución hacia un indicador de exposición evitable, susceptible de incorporarse a los mecanismos de seguimiento del PIGECA 2023–2033.

Selección de Métodos

Técnica de dependencia: regresión logística binaria.

El objeto de estudio son los episodios de concentración elevada, no el nivel de fondo. Un modelo lineal sobre la concentración de SO promediaría las horas de episodio —11.6% del total en SE3— con las restantes, diluyendo la señal en la masa de observaciones de fondo. La variable además presenta una asimetría pronunciada (razón P99/mediana de 12.57 en SE3), lo que vulnera el supuesto de normalidad de los residuos. La formulación logística modela directamente la probabilidad del evento de interés y entrega razones de momios, una medida de asociación interpretable y directamente comparable entre estaciones.

Se incluyeron como covariables la velocidad del viento mediante splines naturales de tres grados de libertad, dado que su relación con los episodios no es monótona —a velocidad baja predomina el estancamiento y a velocidad alta la dispersión—, así como términos armónicos de hora y mes, que respetan la naturaleza circular de ambas variables. Este control es lo que permite separar el efecto direccional de la simple frecuencia de cada rumbo y de los ciclos diarios de actividad urbana.

El sector del viento se incorporó como factor de 16 categorías sin especificar a priori cuál correspondía a la fuente investigada. La verificación geográfica se realizó posteriormente y de forma independiente, evitando el razonamiento circular que introduciría codificar de antemano un “sector industrial”.

Técnicas de interdependencia: componentes principales y conglomerados. El PCA se aplicó sobre la matriz de los ocho contaminantes para examinar si el SO comparte estructura de variación con los trazadores de combustión vehicular. La pregunta que responde no es direccional sino composicional: si el SO formara parte del mismo factor que NO, NO₂, NO_x y CO, la hipótesis de una fuente industrial distinta quedaría debilitada con independencia de cualquier patrón de viento.

El análisis de conglomerados sobre las puntuaciones de los cuatro primeros componentes complementa el PCA al identificar tipos de hora concretos en lugar de ejes de variación. Su valor metodológico reside en que la agrupación se construye únicamente con información química, sin emplear la dirección del viento; la asociación con el sector direccional se examina solo a posteriori.

Técnica complementaria: contraste no paramétrico de medianas. La prueba de Kruskal-Wallis y el estimador de desplazamiento de Hodges-Lehmann permiten cuantificar la diferencia típica entre estaciones sin suponer normalidad. Se incorporan para contrastar explícitamente la magnitud del desplazamiento central con la frecuencia de eventos agudos, contraste que constituye el argumento central de la sección de política pública.

Verificación por método independiente. La Conditional Bivariate Probability Function (Ashbaugh et al., 1985; Uribe-Tellaetxe & Carslaw, 2014) estima la misma cantidad que el modelo logístico, la probabilidad de concentración elevada condicionada a las condiciones de

viento, por vía no paramétrica y sin control de covariables. La coincidencia entre ambos enfoques, con supuestos distintos, constituye evidencia de robustez y no una duplicación del análisis.

Análisis direccional

Caracterización de los episodios

Se definió como episodio toda hora con concentración de SO₂ superior a 11.1 ppb, valor correspondiente al percentil 95 del conjunto de las cuatro estaciones. La adopción de un umbral absoluto común, en lugar de un percentil calculado dentro de cada estación, resulta necesaria para que las tasas sean comparables entre sitios; un umbral relativo produciría por construcción la misma proporción de episodios en todas las estaciones y ocultaría precisamente la diferencia que interesa medir.

Table 1: Episodios de SO₂ por estación (umbral absoluto de 11.1 ppb).

Estacion	Horas válidas	Episodios	Tasa (%)	Mediana	P99	P99/Mediana
SE3	33977	3951	11.63	4.4	55.3	12.57
SE2	33240	1841	5.54	3.8	27.8	7.32
NE	33185	746	2.25	3.8	15.1	3.97
GAR	32534	49	0.15	3.3	7.4	2.24

Modelo logístico direccional

Se estimó un modelo de regresión logística para la probabilidad de episodio en SE3, incorporando el rumbo del viento como factor de 16 niveles, clasificado en sectores de 22.5 grados a partir de la variable circular WDR, con el norte como categoría de referencia. Se controló por velocidad del viento mediante splines naturales de tres grados de libertad y por hora y mes mediante términos armónicos, que preservan la naturaleza cíclica de ambas variables.

Table 2: Razones de momios por rumbo del viento en SE3 (referencia: N). Se presentan los cinco rumbos de mayor momio y los tres de menor; la tabla completa se encuentra en el repositorio.

Rumbo	OR	IC 95%	p
E	6.12	[4.73, 7.92]	0.00e+00
ESE	2.58	[2, 3.33]	0.00e+00
ENE	1.98	[1.51, 2.62]	1.20e-06
SSE	1.53	[1.17, 2.01]	1.93e-03
SE	1.51	[1.17, 1.96]	1.55e-03
O	0.24	[0.13, 0.44]	6.20e-06

Rumbo	OR	IC 95%	p
NNO	0.23	[0.15, 0.35]	0.00e+00
NO	0.08	[0.04, 0.13]	0.00e+00

El rumbo este presenta la razón de momios más elevada (6.12; IC 95%: 4.73 a 7.92), seguido por ESE (2.58) y ENE (1.98). El contraste con el cuadrante opuesto es pronunciado: los rumbos NO, NNO, O y ONO presentan momios entre 0.08 y 0.25, es decir, reducciones de entre cuatro y doce veces respecto de la referencia.

Este resultado admite una lectura de falsación. La zona metropolitana de Monterrey se ubica al oeste de Cadereyta; si los episodios de SO₂ obedecieran al aporte de la mancha urbana o al tráfico vehicular metropolitano, cabría esperar momios elevados con viento del oeste. Se observa el comportamiento inverso.

El modelo alcanza un pseudo R cuadrada de McFadden de 0.189. Conviene precisar que esta medida no es comparable con el coeficiente de determinación de una regresión lineal; valores entre 0.2 y 0.4 se consideran indicativos de ajuste excelente en la escala propuesta por su autor.

Verificación geográfica independiente

El sector direccional no se especificó de antemano: los 16 rumbos se introdujeron como categorías equivalentes y el modelo identificó el máximo sin recibir información sobre la ubicación de la fuente investigada. La verificación geográfica se realizó con posterioridad, calculando el azimut geodésico desde cada estación hacia el complejo refinador.

Table 3: Azimut y distancia de la refinería respecto a cada estación.

Estación	Azimut (°)	Rumbo	Distancia (km)
SE3	87.3	E	5.5
SE2	113.7	ESE	16.4
NE	119.6	ESE	35.7
GAR	110.1	ESE	68.5

Desde SE3, la refinería se localiza en un azimut de 87.3 grados, correspondiente al rumbo este, a 5.5 kilómetros de distancia. El sector que el modelo identificó de forma independiente coincide con la ubicación de la fuente. Dado que el complejo ocupa 612 hectáreas, se evaluó la sensibilidad del cálculo desplazando el centroide 1.5 kilómetros en cada dirección cardinal: el azimut resultante oscila entre 72.4 y 102.7 grados, y permanece en todos los casos dentro de la banda ENE a ESE.

Gradiente espacial

Las cuatro estaciones tienen el complejo refinador hacia el este o el este-sureste. Si el sector oriental estuviera asociado a concentraciones elevadas por razones meteorológicas generales, todas deberían presentar momios comparables.




Figure 1: Razón de momios del sector Este sobre la probabilidad de episodio, en función de la distancia de cada estación a la refinera. Barras: intervalo de confianza al 95%. Línea punteada: ausencia de efecto.

El efecto se atenúa de manera sistemática con la distancia: 3.19 a 5.5 kilómetros, 1.58 a 16.4 kilómetros y 1.01 a 35.7 kilómetros, valor este último cuyo intervalo de confianza incluye la unidad. En NE, la coincidencia direccional con la fuente no produce incremento alguno en la probabilidad de episodio. El patrón requiere la conjunción de dirección y proximidad, comportamiento característico de una pluma sujeta a dilución y no de un artefacto direccional.

El caso de GAR merece una precisión: a 68.5 kilómetros, el sector oriental de esa estación comprende la totalidad de la zona metropolitana antes que el complejo refinador. Su momio de 1.08, con intervalo amplio que incluye la unidad, resulta consistente con una influencia urbana difusa y respalda su función como estación de control.

Análisis de sensibilidad

Se replicó el modelo con umbrales correspondientes a los percentiles 90, 95 y 99 del conjunto, con el fin de verificar que las conclusiones no dependen del corte elegido.

Table 4: Sensibilidad del momio del sector Este a la definición del umbral de episodio.

Percentil	Umbral (ppb)	Estación	OR	IC 95%
P90	7.2	SE3	3.38	[3.17, 3.6]
P90	7.2	SE2	1.43	[1.33, 1.53]
P90	7.2	NE	1.00	[0.89, 1.13]
P90	7.2	GAR	1.40	[1.08, 1.83]
P95	11.1	SE3	3.19	[2.96, 3.44]
P95	11.1	SE2	1.58	[1.43, 1.74]
P95	11.1	NE	1.01	[0.81, 1.26]
P95	11.1	GAR	1.08	[0.54, 2.16]
P99	30.6	SE3	2.57	[2.25, 2.93]
P99	30.6	SE2	1.75	[1.37, 2.24]
P99	30.6	NE	0.86	[0.3, 2.5]
P99	30.6	GAR	NA	—

Los momios de SE3 se mantienen entre 2.57 y 3.38, y los de NE entre 0.86 y 1.01 con intervalos que siempre incluyen la unidad. SE2 muestra un momio creciente con la severidad del umbral, de 1.43 a 1.75, patrón compatible con la llegada de la pluma a Juárez únicamente durante los episodios de mayor intensidad. En GAR no fue posible estimar el modelo con el umbral más exigente por contar con menos de 30 horas por encima de 30.6 ppb en cuatro años, circunstancia que constituye en sí misma un resultado.

Adicionalmente, dado que las observaciones horarias consecutivas no son independientes, se recalcularon los errores estándar agrupando por día. El intervalo del momio del sector este en SE3 pasa de 2.96 a 3.44 hacia 2.92 a 3.48, variación marginal que confirma la robustez de la estimación frente a la correlación serial.

Pruebas de falsación multi-contaminante

Planteamiento

El análisis direccional establece que los episodios de SO₂ en SE3 se asocian preferentemente al sector este. Ese resultado, por sí solo, no descarta explicaciones alternativas: cualquier fuente ubicada al este de la estación produciría el mismo patrón, incluidas fuentes de combustión difusa o corredores viales.

La estrategia de falsación consiste en evaluar el comportamiento de trazadores que no proceden del complejo refinador. Si el sector este transportara emisiones de combustión, los óxidos de nitrógeno y el monóxido de carbono deberían responder junto con el SO₂, pues comparten origen en todo proceso de combustión de hidrocarburos. La ausencia de respuesta en esos

trazadores constituye evidencia en contra de las explicaciones alternativas, y es un argumento más robusto que la propia asociación positiva del SO₂.

Momios por contaminante

Se aplicó el mismo modelo logístico a siete contaminantes en SE3, definiendo en cada caso el evento como la superación del percentil 95 de la distribución propia de cada variable. Este ajuste permite comparar contaminantes medidos en unidades distintas frente a una misma probabilidad de referencia.

Table 5: Razón de momios del sector Este sobre la probabilidad de concentración elevada, por contaminante, en SE3.

Contaminante	n	Eventos	OR	IC 95%
SO ₂	33977	1699	2.66	[2.39, 2.95]
NOX	33682	1684	0.22	[0.17, 0.28]
NO	33451	1670	0.22	[0.17, 0.29]
CO	31741	1571	1.05	[0.92, 1.2]
PM ₁₀	33684	1658	0.50	[0.43, 0.58]
PM _{2.5}	30686	1507	0.59	[0.51, 0.68]
O ₃	33697	1567	0.90	[0.8, 1.02]

El SO₂ es el único contaminante con momio significativamente superior a la unidad (2.66; IC 95%: 2.39 a 2.95). El monóxido de carbono no muestra respuesta alguna, con intervalo que incluye el uno, y el ozono se comporta de manera equivalente. Los óxidos de nitrógeno presentan momios de 0.22, esto es, la probabilidad de concentración elevada de NOX y NO se reduce a menos de una cuarta parte cuando el viento procede del este. El material particulado muestra reducciones intermedias.

La razón entre el momio del SO₂ y el de los óxidos de nitrógeno es de aproximadamente doce. La masa de aire procedente del este llega empobrecida en trazadores vehiculares, lo cual concuerda con el carácter rural de esa zona, y sin embargo transporta SO₂. Ninguna explicación basada en tráfico o combustión urbana difusa reproduce esa combinación: si el sector este aportara combustión, los óxidos de nitrógeno aumentarían junto con el SO₂ en lugar de disminuir.

Verificación por método no paramétrico

La Conditional Bivariate Probability Function estima la probabilidad de concentración elevada condicionada a la dirección y velocidad del viento, sin control de covariables ni supuestos paramétricos. Constituye por ello una verificación independiente del modelo logístico. Se aplicó al SO₂ y al NOX en SE3, empleando en ambos casos el mismo percentil de referencia.




Figure 2: CBPF en SE3. Izquierda: SO₂, con lóbulo direccional al este. Derecha: NO_x, con máximo central en condiciones de calma. Ambos paneles emplean el mismo percentil de referencia.

El contraste entre ambos paneles es directo. El SO₂ presenta un lóbulo compacto orientado al este franco, con probabilidad condicional superior a 0.6, centrado en velocidades de viento moderadas. El NO_x, en la misma estación y sobre las mismas horas, alcanza su máximo en el centro del gráfico, es decir, en condiciones de calma o viento débil, sin orientación preferente alguna.

Esa diferencia morfológica es diagnóstica. Un máximo direccional corresponde a transporte desde una fuente externa; un máximo central corresponde a acumulación local bajo condiciones de estancamiento atmosférico. Los dos contaminantes, medidos por el mismo equipo en el mismo sitio, exhiben firmas de origen distinto.

Extensión al gradiente espacial




Figure 3: CBPF del SO₂ en las tres estaciones con señal. Las escalas de color son independientes en cada panel; la comparación válida es la forma del patrón.

La aplicación de la CBPF a las tres estaciones con señal confirma el gradiente obtenido por vía paramétrica. SE3 presenta el lóbulo oriental descrito. SE2 muestra dos focos de menor intensidad, hacia el noreste y el sur, sin orientación hacia el azimuth de la fuente. NE presenta su máximo hacia el sur, con probabilidad condicional un orden de magnitud menor, y sin contribución apreciable del sector este.

Debe advertirse que las escalas de color difieren entre paneles, pues cada uno se ajusta a su propio rango de probabilidad. La comparación válida entre estaciones corresponde a la forma del patrón; las magnitudes deben contrastarse mediante las razones de momios de la Tabla 5 y la Figura 1.

La coincidencia entre un método paramétrico con control de covariables y un método no paramétrico sin controles, que descansan en supuestos distintos, refuerza la robustez del hallazgo direccional.

Estructura multivariada de la matriz química

Planteamiento

Las secciones anteriores establecen que los episodios de SO₂ en SE3 se asocian a un sector direccional específico y que los trazadores de combustión no acompañan esa respuesta. Ambos resultados descansan sobre la información meteorológica.

El análisis que sigue prescinde por completo de la dirección del viento. La pregunta es composicional: si el SO₂ compartiera estructura de variación con los óxidos de nitrógeno y el monóxido de carbono, la hipótesis de una fuente distinta a la combustión urbana quedaría

debilitada con independencia de cualquier patrón direccional. Se trata, por tanto, de una vía de verificación independiente de la anterior.

Componentes principales

Se aplicó análisis de componentes principales sobre la matriz de los ocho contaminantes en SE3, previa transformación logarítmica y estandarización de las variables. La transformación logarítmica atenúa la influencia de los valores extremos sobre la matriz de covarianzas, sin eliminarlos ni modificar el conjunto de observaciones; sin ella, el primer componente quedaría dominado por unas pocas horas de concentración muy elevada y no describiría la estructura general de los datos.

El procedimiento requiere casos completos. De las 33,977 observaciones de SE3 se conservaron 27,938, equivalentes al 82.2 por ciento. De los 3,951 episodios registrados se conservaron 3,304, es decir, el 83.6 por ciento. La similitud entre ambas proporciones indica que la exclusión por datos faltantes no eliminó preferentemente las horas de episodio.

La adecuación muestral se verificó mediante el índice KMO, que alcanza un valor de 0.623, y la prueba de esfericidad de Bartlett, que resulta significativa. El valor del KMO se sitúa por encima del mínimo convencional de 0.6, aunque en el rango que Kaiser califica como mediocre. Esta circunstancia es esperable en el presente caso y no constituye una deficiencia: el índice desciende precisamente porque una de las variables, el SO₂, mantiene correlaciones bajas con el resto, que es la estructura que el análisis busca documentar.

Table 6: Cargas de los tres primeros componentes principales sobre la matriz de contaminantes en SE3.

Variable	PC1 (48.6%)	PC2 (19.4%)	PC3 (9.7%)
SO ₂	0.029	0.604	-0.472
NO	-0.452	-0.141	-0.130
NO ₂	-0.437	-0.040	-0.337
NOX	-0.481	-0.089	-0.266
CO	-0.278	0.091	0.705
O ₃	0.319	0.458	-0.001
PM ₁₀	-0.351	0.367	0.228
PM _{2.5}	-0.265	0.503	0.164

Dos componentes superan el criterio de Kaiser. El primero explica el 48.6 por ciento de la varianza y los cuatro primeros acumulan el 86.9 por ciento.

El primer componente agrupa con signo común a NOX, NO, NO₂, PM₁₀ y CO, con cargas entre 0.278 y 0.481 en valor absoluto, mientras el ozono carga en sentido opuesto, comportamiento consistente con su titulación por óxido nítrico fresco. Se trata del eje de combustión urbana.

La carga del SO₂ sobre ese componente es de 0.029. El contaminante de interés resulta prácticamente ortogonal al eje que explica cerca de la mitad de la variación química total de la estación. El segundo componente, que concentra el 19.4 por ciento de la varianza, está encabezado por el propio SO₂, con carga de 0.604, acompañado de PM_{2.5} y ozono. Esa asociación tiene sentido químico: el SO₂ se oxida a sulfato, que constituye material particulado fino secundario, y ambos procesos se favorecen durante las horas de mayor mezcla convectiva, cuando el ozono también alcanza sus valores altos.

Cabe señalar que el octavo componente explica el 0.05 por ciento de la varianza, resultado esperado dado que NO_x se define como la suma de NO y NO₂, lo que introduce una dirección redundante en la matriz. Esta circunstancia no afecta la interpretación de los primeros componentes.

Análisis de conglomerados

Sobre las puntuaciones de los cuatro primeros componentes se aplicó el algoritmo de k medias. La agrupación emplea únicamente información química; la asociación con el sector direccional se examina con posterioridad.

El índice de silueta favorece una partición en dos grupos, con valor de 0.418, y desciende a valores cercanos a 0.26 para particiones de tres a seis grupos. Se optó por cuatro conglomerados atendiendo a criterios de interpretabilidad química y no al valor del índice, decisión que conviene explicitar: la estructura más nítida de los datos es binaria, y más allá de esa partición la separación entre grupos es gradual. Los cuatro perfiles obtenidos resultan químicamente coherentes y la partición explica el 58.3 por ciento de la variación total en el espacio de componentes. La solución converge en cinco iteraciones y se verificó su estabilidad ante un aumento del número máximo de iteraciones.

Table 7: Perfil de los conglomerados en SE3. Las concentraciones son medianas expresadas en ppb, salvo PM_{2.5} en microgramos por metro cúbico.

Grupo	n	%	SO ₂	NO _x	PM _{2.5}	O ₃	WSR (km/h)	SO ₂ /NO _x	% Este	% episodios
1	4111	14.7	16.2	10.4	22	43	8.5	1.558	50.5	72.2
2	3352	12.0	4.4	51.8	28	5	3.6	0.085	6.2	1.4
3	7823	28.0	4.2	17.7	15	17	5.8	0.237	25.4	0.9
4	12652	45.3	4.1	8.1	9	26	8.5	0.506	42.7	1.7

El primer conglomerado, que agrupa el 14.7 por ciento de las horas, presenta una mediana de SO₂ de 16.2 ppb, casi cuatro veces superior a la de cualquier otro grupo, junto con una mediana de NO_x de 10.4 ppb, la más baja del conjunto. Concentra el 72.2 por ciento de todos los episodios registrados y la mitad de sus horas corresponde a viento del sector este.

El segundo conglomerado constituye su imagen especular: mediana de NO_x de 51.8 ppb, cinco veces superior a la del primer grupo, con SO₂ de apenas 4.4 ppb, velocidad de viento

de 3.6 kilómetros por hora, la menor del conjunto, y ozono de 5 ppb. El perfil corresponde a acumulación local bajo condiciones de estancamiento atmosférico. Solo el 6.2 por ciento de sus horas presenta viento del este.

La razón entre las medianas de SO₂ y NO_x resume el contraste: 1.56 en el primer conglomerado frente a 0.085 en el segundo, una diferencia de factor dieciocho. Ningún proceso de combustión produce simultáneamente concentraciones de SO₂ cuatro veces mayores y de NO_x cinco veces menores. El primer conglomerado corresponde a horas con azufre en ausencia de combustión vehicular, y el algoritmo lo identificó sin disponer de información meteorológica.

Contraste entre tendencia central y exposición aguda

Diferencia de medianas por año

Se evaluó la diferencia entre estaciones para cada año del periodo mediante la prueba de Kruskal-Wallis, alternativa no paramétrica al análisis de varianza que no requiere el supuesto de normalidad, inaplicable en este caso dada la marcada asimetría de las distribuciones de SO₂. La prueba resulta significativa en los cuatro años, con valores de p inferiores a cualquier nivel convencional.

Para cuantificar la magnitud de la diferencia entre la estación más próxima a la fuente y la estación de control se empleó el estimador de desplazamiento de Hodges-Lehmann, que corresponde a la mediana de todas las diferencias por pares entre ambas muestras y constituye el análogo no paramétrico de la diferencia de medias.

Table 8: Diferencia de medianas y horas de episodio por año. Las medianas y el desplazamiento de Hodges-Lehmann se expresan en ppb; las horas corresponden al umbral absoluto de 11.1 ppb.

Año	Mediana SE3	Mediana GAR	Dif. H-L	IC 95%	Horas ep. SE3	Horas ep. GAR	Ex- ceso
2022	4.8	3.4	1.3	[1.3, 1.4]	1245	10	1235
2023	3.9	2.4	1.5	[1.5, 1.5]	689	20	669
2024	4.1	3.0	1.0	[1, 1]	845	10	835
2025	4.7	4.4	0.6	[0.5, 0.6]	1172	9	1163

El desplazamiento entre SE3 y GAR oscila entre 0.6 y 1.5 ppb según el año, con intervalos de confianza estrechos que confirman su carácter estadísticamente distinto de cero. La magnitud, sin embargo, es reducida en términos absolutos.

El comportamiento temporal de este indicador resulta relevante. La diferencia de medianas alcanza su valor máximo en 2023, con 1.5 ppb, y desciende de manera sostenida hasta 0.6 ppb en 2025, el valor más bajo del periodo y menos de la mitad del observado tres años antes.

Interpretado de forma aislada, este resultado sugeriría una convergencia progresiva entre ambas estaciones y una mejora en la situación de Cadereyta.

Frecuencia de eventos agudos

El recuento de horas que superan el umbral absoluto de 11.1 ppb arroja una lectura opuesta. En 2023, año de máxima diferencia de medianas, SE3 registró 669 horas de episodio, la cifra más baja del periodo. En 2025, año de mínima diferencia de medianas, registró 1,172 horas, la segunda más alta. Ambas series evolucionan en sentidos contrarios.




Figure 4: Evolución anual de la diferencia de medianas entre SE3 y GAR (línea, eje derecho) frente al número de horas de episodio en SE3 (barras, eje izquierdo). Ambas series evolucionan en sentidos opuestos.

La divergencia se explica por la naturaleza del fenómeno. La mediana describe el comportamiento típico de la distribución y resulta insensible a su cola superior, que es precisamente donde reside la contribución de la fuente investigada. Una reducción del nivel de fondo acompañada de un aumento en la frecuencia de episodios produce exactamente el patrón observado: convergencia aparente en los indicadores de tendencia central y deterioro real en la exposición aguda.

Ambos resultados son simultáneamente válidos. El nivel de fondo de SO₂ difiere poco entre Cadereyta y García, mientras que la frecuencia de eventos agudos difiere en dos órdenes de magnitud: 0.15 por ciento de las horas en GAR frente a 11.63 por ciento en SE3.

Indicador de exposición evitable

El exceso de horas de episodio de SE3 respecto de la estación de control asciende a 3,902 horas en el periodo completo, equivalentes a un promedio de 976 horas anuales, es decir, 40.6 días al año en que la estación de Cadereyta supera el umbral de episodio y la estación de control no lo hace. GAR acumula entre 9 y 20 horas anuales; SE3 supera las mil en tres de los cuatro años analizados.

Esta cifra admite interpretación como indicador de exposición potencialmente evitable, bajo el supuesto de que la eliminación de la contribución del sector direccional identificado aproximaría el comportamiento de SE3 al de una estación sin influencia industrial próxima. El supuesto es fuerte y la cifra debe entenderse como una cota superior, no como una estimación de la contribución neta de la fuente.

Implicaciones para el seguimiento de la calidad del aire

El contraste documentado tiene consecuencias directas sobre la selección de indicadores en los instrumentos de gestión. Un sistema de seguimiento basado en concentraciones medias o medianas anuales habría reportado convergencia entre Cadereyta y García durante 2025, precisamente el año en que la exposición aguda repuntó de manera más pronunciada. La población de Cadereyta experimentó en ese año un mayor número de horas por encima del umbral de episodio, circunstancia que ningún indicador de tendencia central habría registrado.

La normativa vigente en materia de dióxido de azufre establece límites sobre exposiciones de corta duración, lo que resulta consistente con la evidencia toxicológica sobre efectos respiratorios agudos. Los indicadores de seguimiento empleados en los instrumentos de planeación deberían incorporar de manera explícita métricas de frecuencia de excedencia, y no únicamente promedios anuales, si se pretende que reflejen la exposición efectiva de la población.

Conclusión parcial y trabajo pendiente

Validación de los modelos

Antes de sintetizar los hallazgos conviene documentar las verificaciones aplicadas al modelo principal.

Table 9: Indicadores de validación de los modelos estimados.

Indicador	Valor
AUC en muestra	0.783
AUC fuera de muestra (2025)	0.764
Error de Brier (2025)	0.1065
Error de Brier del modelo base	0.1183
Sensibilidad	0.712
Especificidad	0.681

Indicador	Valor
Pseudo-R2 de McFadden	0.189
KMO global (PCA)	0.623
Varianza explicada por la partición (k=4)	58.3%

El modelo logístico alcanza un área bajo la curva ROC de 0.783 en la muestra de estimación. Para evaluar su comportamiento fuera de muestra se reestimó con los años 2022 a 2024 y se evaluó sobre 2025, año no empleado en el ajuste: el área bajo la curva desciende a 0.764, lo que representa una pérdida de 0.019 y descarta un sobreajuste apreciable. El error de Brier es de 0.1065, frente a 0.1183 correspondiente a un modelo que predijera únicamente la tasa base, lo que supone una mejora del diez por ciento. Con un punto de corte fijado en la tasa base de episodios, y no en 0.5, dado el desbalance de clases, el modelo alcanza una sensibilidad de 0.712 y una especificidad de 0.681.

Conviene precisar el alcance de estas cifras. El modelo no fue construido con finalidad predictiva sino para estimar una asociación direccional controlando por condiciones meteorológicas; su capacidad de discriminación, obtenida a partir de cuatro variables meteorológicas, resulta razonable para ese propósito y no pretende constituir un instrumento de pronóstico.

Respecto de los supuestos, se verificó que la correlación serial entre horas consecutivas no compromete las estimaciones, mediante errores estándar agrupados por día, y que la matriz de correlaciones admite el análisis factorial, mediante los índices KMO y la prueba de Bartlett. Ambas verificaciones se detallan en las secciones correspondientes.

Síntesis de resultados

El análisis de la presente etapa permite establecer cuatro resultados.

En primer lugar, existe una asociación direccional específica entre los episodios de SO₂ en la estación de Cadereyta y el sector este, con una razón de momios de 6.12 para el rumbo este respecto del norte, controlando por velocidad de viento, hora y mes. El sector fue identificado por el modelo sin información previa sobre la ubicación de la fuente, y coincide con el azimut de 87.3 grados que corresponde al complejo refinador.

En segundo lugar, el efecto decae de manera sistemática con la distancia, de 3.19 a 5.5 kilómetros hasta 1.01 a 35.7 kilómetros, pese a que las cuatro estaciones tienen la fuente hacia el mismo cuadrante. La conjunción necesaria de dirección y proximidad es característica de una pluma sujeta a dilución.

En tercer lugar, las pruebas de falsación resultan consistentes con un origen distinto al de la combustión urbana. El sector este eleva la probabilidad de concentración alta de SO₂ pero la reduce en óxidos de nitrógeno, con una razón entre ambos momios de aproximadamente doce. El análisis de componentes principales, que no emplea información meteorológica, sitúa al SO₂ en posición prácticamente ortogonal al eje de combustión urbana, con carga de 0.029 sobre el

primer componente. El análisis de conglomerados identifica un grupo de horas con razón SO_2 sobre NOX de 1.56, frente a 0.085 en el grupo de estancamiento urbano.

En cuarto lugar, el fenómeno reside en la frecuencia de eventos agudos y no en el nivel de fondo. La diferencia de medianas entre Cadereyta y la estación de control no supera 1.5 ppb en ningún año, mientras que el exceso de horas de episodio asciende a 976 anuales, equivalentes a 40.6 días.

Conclusión parcial

Los resultados obtenidos son consistentes con la existencia de una fuente puntual de SO_2 ubicada al este de la estación SE3, cuya influencia se atenúa con la distancia y cuya firma química difiere de la correspondiente a fuentes de combustión urbana. La coincidencia entre el sector identificado estadísticamente y la ubicación del complejo refinador, junto con el comportamiento de los trazadores de falsación, hace de la refinería la explicación más parsimoniosa del patrón observado.

Corresponde subrayar que el diseño es observacional y no permite establecer atribución causal en sentido estricto. No se dispone de datos de emisión de la fuente ni de un contrafactual experimental. Lo que el análisis establece es que los patrones documentados resultan difícilmente compatibles con las explicaciones alternativas evaluadas, y que su conjunto apunta de manera convergente hacia una misma hipótesis.

Trabajo pendiente

Quedan pendientes cuatro líneas de trabajo para la siguiente etapa.

La primera consiste en contrastar los resultados con el inventario de emisiones del PIGECA y con los límites establecidos en la NOM-172-SEMARNAT-2019, con el fin de situar las magnitudes obtenidas en el marco normativo vigente y de verificar si las emisiones declaradas resultan compatibles con las concentraciones observadas.

La segunda consiste en caracterizar temporalmente los episodios: determinar su duración típica, su distribución horaria y estacional, y si presentan agrupamiento en eventos prolongados o se distribuyen de manera dispersa. Esta caracterización resulta necesaria para traducir las horas de exceso en un indicador de exposición poblacional.

La tercera consiste en incorporar información sobre paros y mantenimientos programados del complejo, en caso de que el socio formador pueda proporcionarla. La comparación entre periodos de operación y de paro constituiría el contrafactual más próximo a un diseño experimental disponible en este contexto.

La cuarta consiste en extender el análisis al periodo 2020 y 2021, disponible en la base original, para evaluar la estabilidad temporal del patrón direccional en una ventana más amplia.