

Exposición aguda a SO_2 y su relación con el sector direccional del complejo refinador de Cadereyta

Equipo 6 · Análisis Multivariado (MA2003B) · Socio formador: Sistema Integral de Monitoreo Ambiental (SIMA)

Alicia Bernádez (A01562634) Omar Arzaga (A01569294)
Diego Medrano (A01254882) Sebastián Alemán (A00841034)
Isaac Montaña (A00841681)

12 de septiembre de 2026

1. Resumen

El presente proyecto analiza el comportamiento de las concentraciones de dióxido de azufre registradas por el Sistema Integral de Monitoreo Ambiental de Nuevo León durante el periodo 2022-2025, con el objetivo de identificar patrones espaciales, direccionales y meteorológicos consistentes con la posible influencia de fuentes industriales localizadas en la zona de Cadereyta. El análisis se enfocó en las estaciones SE3 (Cadereyta), SE2 (Juárez), NE (San Nicolás) y GAR (García), esta última utilizada como punto de comparación por su mayor distancia respecto a la zona de interés. En particular, se buscó evaluar si los indicadores de tendencia central, como promedios y medianas anuales, representan adecuadamente la exposición a episodios agudos de SO_2 .

La base inicial estuvo conformada por 140,236 registros crudos y 19 variables correspondientes a contaminantes atmosféricos y condiciones meteorológicas. Como parte de la preparación de los datos se identificaron valores faltantes, registros fuera de los rangos establecidos por SIMA y posibles valores extremos. Las variables principales SO_2 , dirección del viento y velocidad del viento no fueron imputadas, con el fin de evitar la creación artificial de concentraciones o patrones direccionales. Para algunas variables meteorológicas secundarias se utilizó imputación mediante K vecinos más cercanos.

Para estudiar las relaciones de dependencia se utilizaron modelos de regresión logística, mientras que la estructura conjunta de los contaminantes se analizó mediante componentes principales y conglomerados. Estos métodos se complementaron con análisis descriptivos, comparaciones entre estaciones y la Conditional Bivariate Probability Function (CBPF). Se definieron como episodios elevados las horas con concentraciones de SO_2 superiores a 11.1 ppb, correspondiente al percentil 95 global de las cuatro estaciones. SE3 presentó la mayor frecuencia de episodios, con 11.63 % de sus horas válidas, seguida de SE2 con 5.54 %, NE con 2.25 % y GAR con 0.15 %.

El modelo logístico direccional identificó al sector Este como el de mayor asociación con la ocurrencia de episodios en SE3, con una razón de momios de 6.12 respecto al Norte. Este sector coincide con el azimut de 87.3° correspondiente a la ubicación de la refinería respecto a la estación. Además, la asociación se redujo conforme aumentó la distancia entre las estaciones y la zona de Cadereyta. El modelo presentó una capacidad discriminante adecuada, con un AUC de 0.811, mientras que una segunda especificación Este frente al resto obtuvo un AUC de 0.783 y mantuvo un desempeño similar al evaluarse con datos de

2025. La CBPF reprodujo de manera independiente el patrón direccional observado. Por otra parte, los análisis multivariados mostraron que los episodios de SO₂ presentan una estructura distinta a la de contaminantes comúnmente asociados con combustión urbana.

En conjunto, los resultados son consistentes con la influencia de una fuente puntual de SO₂ localizada al Este de SE3, aunque el análisis no permite establecer una atribución causal directa a una instalación específica. El principal contraste entre estaciones se encontró en la frecuencia de los episodios agudos y no únicamente en sus concentraciones típicas. Por ello, se recomienda que el seguimiento de la calidad del aire incorpore indicadores de frecuencia de excedencia junto con las medias y medianas anuales, con el fin de representar de manera más completa la exposición de la población a eventos elevados de SO₂.

2. Introducción y justificación

La calidad del aire condiciona de manera directa el bienestar de la población, y su deterioro se asocia con enfermedades cardiovasculares, padecimientos respiratorios y cáncer de pulmón. La Organización Mundial de la Salud estima que la contaminación del aire exterior ocasionó alrededor de 4.2 millones de muertes prematuras en 2019 (Organización Mundial de la Salud, 2024). Entre los contaminantes criterio, el dióxido de azufre presenta una particularidad relevante para este trabajo: sus efectos documentados corresponden principalmente a exposiciones de corta duración, lo que implica que su evaluación requiere métricas sensibles a eventos agudos y no únicamente a niveles promedio (Organización Mundial de la Salud, 2021; Holcim España, s. f.).

El marco normativo refleja esa distinción de manera parcial. Las directrices internacionales establecen valores guía sin carácter vinculante (Organización Mundial de la Salud, 2021), mientras que en México los límites para la protección de la salud se definen mediante normas oficiales, entre ellas la NOM-172-SEMARNAT-2023, que fija los lineamientos para la obtención y comunicación del Índice de Calidad del Aire y Riesgos a la Salud (Secretaría de Medio Ambiente y Recursos Naturales, 2024; Comisión Federal para la Protección contra Riesgos Sanitarios, 2025). La medición enfrenta además dificultades operativas: la cobertura espacial es limitada, los equipos requieren calibración periódica y los registros presentan datos faltantes con frecuencia, de modo que cada estación representa fundamentalmente las condiciones de su entorno inmediato (Instituto Nacional de Ecología y Cambio Climático, s. f.; Programa de las Naciones Unidas para el Medio Ambiente, 2022). En Nuevo León, el Sistema Integral de Monitoreo Ambiental registra contaminantes y variables meteorológicas en distintos puntos del Área Metropolitana de Monterrey, y sus series históricas constituyen la fuente de datos de este proyecto (Gobierno del Estado de Nuevo León, s. f.).

2.1. Antecedentes

Diversos estudios han utilizado concentraciones de contaminantes y variables meteorológicas para identificar posibles fuentes de emisión. Ashbaugh et al. (1985) propusieron la función de probabilidad condicional para relacionar concentraciones elevadas con la dirección del viento, mientras que Carslaw et al. (2006) y Carslaw y Ropkins (2012) extendieron este enfoque al análisis de fuentes específicas y facilitaron su implementación mediante el paquete *openair*. Posteriormente, Uria-Tellaetxe y Carslaw (2014) desarrollaron la función de probabilidad bivariada condicional (CBPF), que incorpora simultáneamente dirección y velocidad del viento para caracterizar con mayor detalle el transporte de contaminantes. Aplicaciones en zonas industriales han mostrado que estas herramientas permiten diferenciar señales asociadas a fuentes locales. Clarke et al. (2014) identificaron patrones definidos de SO₂ vinculados con áreas industriales, mientras que Xue et al. (2023) analizaron episodios recurrentes de SO₂ y asociaron

su comportamiento con una fuente puntual mediante información meteorológica. Estos antecedentes respaldan el uso combinado de concentraciones, dirección y velocidad del viento en el presente estudio.

2.2. Justificación

Los antecedentes muestran que el análisis conjunto de concentraciones y condiciones meteorológicas permite detectar patrones compatibles con fuentes de emisión específicas. Sin embargo, para la gestión de la calidad del aire también es necesario evaluar si los indicadores de tendencia central representan adecuadamente exposiciones breves pero elevadas. Este proyecto aplica métodos direccionales a los registros de SIMA para cuantificar la exposición aguda asociada al sector identificado y contrastarla con las medidas de tendencia central utilizadas habitualmente, con el fin de valorar si los mecanismos actuales de seguimiento capturan adecuadamente este fenómeno.

3. Problemática y objetivo

3.1. Planteamiento

El Área Metropolitana de Monterrey concentra una importante actividad industrial y presenta condiciones geográficas que hacen que la dispersión de contaminantes dependa del régimen de vientos. En este contexto, el dióxido de azufre resulta especialmente relevante, ya que se relaciona principalmente con procesos de combustión de combustibles con contenido de azufre y puede actuar como indicador de fuentes industriales puntuales. El problema central es que los indicadores de tendencia central pueden ocultar episodios breves de concentraciones elevadas. Si la contribución de una fuente se manifiesta principalmente mediante eventos de pocas horas, los promedios o medianas pueden mostrar condiciones relativamente estables aun cuando la frecuencia de exposición aguda sea considerable.

3.2. Objetivo general

Cuantificar el exceso de exposición aguda a dióxido de azufre asociado al sector direccional donde se ubica el complejo refinador de Cadereyta, con el fin de evaluar si los indicadores de tendencia central que utilizan actualmente los instrumentos de gestión de la calidad del aire representan de manera adecuada dicha exposición.

3.3. Pregunta de investigación

¿Los episodios elevados de dióxido de azufre presentan un patrón de dirección del viento y distancia consistente con la influencia de una fuente industrial localizada en la zona de Cadereyta, y qué magnitud de exposición aguda queda sin registrar cuando ese fenómeno se evalúa mediante medidas de tendencia central?

3.4. Contexto geográfico de las estaciones de monitoreo

El análisis emplea cuatro estaciones de la red del Sistema Integral de Monitoreo Ambiental, seleccionadas por su posición relativa respecto al complejo refinador. El criterio de selección no fue la proximidad en sí misma, sino la posibilidad de construir un gradiente de distancia sobre el cual evaluar el comportamiento de la señal.

Tabla 1: El azimut corresponde al ángulo geodésico desde la estación hacia el centroide del complejo, medido en sentido horario desde el norte. Las coordenadas de referencia son aproximadas y su efecto sobre la identificación del sector se evalúa al final de esta sección.

Estación	Municipio	Azimut (°)	Rum- bo	Distancia (km)	Papel
SE3	Cadereyta Jiménez	87.3	E	5.5	Estación de exposición
SE2	Juárez	113.7	ESE	16.4	Distancia intermedia
NE	San Nicolás de los Garza	119.6	ESE	35.7	Distancia lejana
GAR	García	110.1	ESE	68.5	Estación de control

SE3 es la estación más cercana al complejo refinador y presenta un azimut de 87.3° , correspondiente al Este, mientras que SE2 y NE permiten evaluar la atenuación de la señal conforme aumenta la distancia. GAR, ubicada a 68.5 km, se utiliza como estación de control. Las cuatro estaciones tienen el complejo hacia el Este o Este-Sureste. Por ello, si la asociación con este sector se debiera únicamente a un fenómeno meteorológico regional, se esperaría un comportamiento similar en todas. La ubicación aproximada del centroide no modifica esta clasificación: al desplazarlo 1.5 km en cada dirección, el azimut desde SE3 permanece dentro del rango ENE-ESE.

4. Preparación de la base de datos

4.1. Origen y estructura

La información procede de los registros horarios de SIMA correspondientes a 2022-2025 y del catálogo de rangos de validación proporcionado por el socio formador. La base final integra 132,936 observaciones de las cuatro estaciones seleccionadas e incluye ocho contaminantes, así como dirección y velocidad del viento, temperatura, humedad relativa, presión, radiación solar y precipitación. SO₂ constituye la variable principal de interés; los demás contaminantes se emplearon como trazadores de contraste y las variables meteorológicas como controles.

4.2. Validación y tratamiento de datos faltantes

Los registros fuera de los rangos de validación proporcionados por SIMA se transformaron en valores faltantes. Debido a cambios en la instrumentación, estos límites varían según el año, por lo que la validación se realizó considerando simultáneamente año y variable. Las variables meteorológicas de control se imputaron mediante vecinos más cercanos, mientras que los contaminantes conservaron sus valores faltantes para evitar introducir artificialmente patrones químicos. SO₂ tampoco se depuró mediante criterios automáticos de valores extremos, ya que las concentraciones elevadas constituyen precisamente el fenómeno de interés.

4.3. Tratamiento de la dirección del viento

La dirección del viento es una variable circular, en la cual los valores cero y trescientos sesenta grados representan la misma condición física, por lo que su tratamiento como magnitud lineal produciría resultados incorrectos. Se aplicaron tres transformaciones complementarias: clasificación en dieciséis sectores de 22.5 grados, que permite incorporar el rumbo como factor categórico sin imponer orden; descomposición en componentes seno y coseno, que preserva la continuidad angular; y agrupación binaria

del sector oriental, definido como la unión de los rumbos este noreste, este y este sureste, frente al resto de direcciones. De manera análoga, la hora y el mes se incorporaron mediante términos armónicos, de modo que la vigésima tercera hora resulte contigua a la hora cero y diciembre contiguo a enero.

4.4. Estructura del panel

La base final constituye un panel no balanceado, ya que las cuatro estaciones no cuentan con exactamente el mismo número de observaciones válidas durante el periodo analizado. La disponibilidad de datos varía entre 32,534 horas en GAR y 33,977 horas en SE3, diferencias que responden principalmente a la disponibilidad efectiva de los sensores y a los registros descartados durante el proceso de validación. No se realizó ningún procedimiento para igualar artificialmente el número de observaciones entre estaciones, ya que esto habría implicado eliminar información válida. Por esta razón, los análisis se realizaron utilizando todas las mediciones disponibles para cada estación, manteniendo la estructura real de la base de datos.

5. Modelación y validación

5.1. Criterio de selección de técnicas

La selección de técnicas respondió a tres características principales del problema: la variable de interés corresponde a la ocurrencia o no de episodios elevados, SO₂ presenta una distribución fuertemente asimétrica y la dirección del viento es una variable circular. Por estas razones se utilizó regresión logística para modelar directamente la probabilidad de episodio, evitando depender de supuestos de normalidad sobre la concentración. De forma complementaria, se aplicaron componentes principales y k-means para estudiar la estructura conjunta de los contaminantes sin utilizar información meteorológica, permitiendo contrastar si SO₂ sigue un comportamiento químico similar o distinto al de los principales trazadores urbanos.

5.2. Técnica de relaciones de dependencia: regresión logística binaria

Se definió como episodio toda hora con concentración de dióxido de azufre superior a 11.1 partes por billón, valor correspondiente al percentil 95 del conjunto de las cuatro estaciones. La adopción de un umbral absoluto común resulta indispensable para la comparabilidad entre sitios. Un percentil calculado de manera individual para cada estación forzaría por construcción la misma proporción de episodios en todos los puntos, ocultando exactamente la diferencia espacial que el análisis busca medir.

Sobre esa variable binaria se estimó un modelo de regresión logística. La especificación incorpora el rumbo del viento como factor de dieciséis niveles sin jerarquía previa, controles meteorológicos mediante splines naturales de tres grados de libertad, y términos armónicos para hora y mes. El uso de splines en lugar de términos lineales obedece a que la relación entre velocidad del viento y probabilidad de episodio no es monótona: las condiciones de calma favorecen la acumulación local, mientras que las velocidades elevadas dispersan, de modo que el máximo se ubica en valores intermedios.

La regresión logística ofrece dos ventajas para este diseño. Modela directamente la probabilidad del evento, sin necesidad de transformar la variable de respuesta, y produce razones de momios que resultan interpretables y comparables entre estaciones y entre contaminantes medidos en unidades distintas.

5.3. Técnicas de relaciones de interdependencia: componentes principales y conglomerados

El análisis direccional depende enteramente de la información meteorológica. Para obtener una verificación que no comparta ese supuesto se aplicaron dos técnicas de interdependencia sobre la matriz química de los ocho contaminantes, sin utilizar en ningún momento la dirección del viento.

El análisis de componentes principales examina si el dióxido de azufre comparte estructura de variación con los trazadores vehiculares. Si el contaminante de interés cargara de manera apreciable sobre el mismo eje que los óxidos de nitrógeno y el monóxido de carbono, la hipótesis de una fuente distinta a la combustión urbana quedaría debilitada con independencia del patrón direccional observado. Las variables se transformaron logarítmicamente y se estandarizaron antes del análisis. La transformación logarítmica atenúa la influencia de los valores extremos sobre la matriz de correlaciones sin eliminarlos del conjunto de observaciones.

El análisis de conglomerados por el método de k medias se aplicó sobre las puntuaciones de los primeros cuatro componentes, con el propósito de identificar perfiles horarios concretos. La agrupación emplea exclusivamente información química, y la asociación de los grupos resultantes con el sector direccional se examina con posterioridad, de manera que el algoritmo no dispone de información que pudiera inducir el resultado buscado.

5.4. Técnicas complementarias y estrategia de validación

Como complemento al modelo principal se emplearon la prueba de Kruskal-Wallis y el estimador de Hodges-Lehmann para comparar las concentraciones entre estaciones sin asumir normalidad, así como la función de probabilidad bivariada condicional (CBPF) para verificar de forma no paramétrica la asociación entre episodios elevados y condiciones de viento. Además, se incorporaron rezagos horarios de SO₂ para evaluar si el patrón observado podía explicarse únicamente por la persistencia temporal del contaminante.

La validación se realizó mediante estimación con datos de 2022-2024 y evaluación fuera de muestra en 2025, errores estándar agrupados por día, análisis de sensibilidad con los percentiles 90, 95 y 99, diagnóstico de autocorrelación residual y evaluación de calibración. Estas verificaciones permitieron contrastar explicaciones alternativas relacionadas con meteorología, dependencia temporal y elección del umbral. El esquema completo de validación se presenta en el Anexo F.

Durante el desarrollo también se exploraron alternativas que no resultaron adecuadas. La regresión lineal sobre la concentración se descartó por la asimetría de SO₂ y el interés específico en eventos agudos; la justificación de su descarte se presenta en el Anexo A. Asimismo, aunque el índice de silueta favoreció inicialmente dos conglomerados, se seleccionaron cuatro por su mayor interpretabilidad química, decisión detallada en el Anexo B.

6. Resultados

6.1. Caracterización de los episodios

El primer resultado corresponde a la distribución de los episodios entre las cuatro estaciones. La comparación emplea el umbral absoluto común de 11.1 partes por billón.

Tabla 2: Frecuencia de episodios de dióxido de azufre por estación, con umbral absoluto de 11.1 ppb. Las concentraciones se expresan en partes por billón.

Estación	Horas válidas	Episodios	Tasa (%)	Mediana	P99	P99 / Mediana
SE3	33977	3951	11.63	4.4	55.32	12.57
SE2	33240	1841	5.54	3.8	27.80	7.32
NE	33185	746	2.25	3.8	15.10	3.97
GAR	32534	49	0.15	3.3	7.40	2.24

La frecuencia de episodios disminuye de manera marcada entre estaciones. SE3 registra 11.63 % de horas de episodio frente a 0.15 % en GAR, una diferencia cercana a 77 veces. En contraste, las medianas se mantienen entre 3.3 y 4.4 ppb, mientras que la cola superior muestra diferencias mucho mayores. Esto indica que el principal contraste entre sitios se encuentra en la frecuencia y severidad de los eventos agudos, no en sus niveles típicos.

6.2. Asociación direccional

El modelo logístico se estimó sobre la estación SE3 incorporando los dieciséis rumbos como categorías equivalentes, con el norte como referencia, y controlando por velocidad del viento, hora y mes.

Tabla 3: Razones de momios por rumbo del viento en SE3, con el norte como categoría de referencia. Se presentan los cinco rumbos de mayor y de menor asociación; la tabla completa se incluye en el Anexo C.

Rumbo	Razón de momios	IC 95 %	Valor p
E	6.12	[4.73, 7.92]	< 1e-16
ESE	2.58	[2.00, 3.33]	4.4e-13
ENE	1.98	[1.51, 2.62]	1.2e-06
SSE	1.53	[1.17, 2.01]	0.0019
SE	1.51	[1.17, 1.96]	0.0015
OSO	0.54	[0.33, 0.90]	0.0175
ONO	0.25	[0.15, 0.41]	2.9e-08
O	0.24	[0.13, 0.44]	6.2e-06
NNO	0.23	[0.15, 0.35]	2.3e-12
NO	0.08	[0.04, 0.13]	< 1e-16

El Este presentó la mayor asociación con los episodios (OR = 6.12; IC 95 %: 4.73-7.92), seguido por ESE y ENE, mientras que los rumbos occidentales mostraron razones de momios inferiores a uno. Este patrón resulta opuesto al esperado si los episodios provinieran principalmente del núcleo urbano localizado al oeste de Cadereyta. El modelo fue significativo frente al nulo (Δ devianza = 4,617.2; gl = 22) y alcanzó AUC = 0.811. El rumbo de mayor asociación coincide además con el azimut aproximado del complejo desde SE3, cercano a 87°.

6.3. Gradiente espacial

Si la asociación con el sector oriental respondiera a condiciones meteorológicas regionales y no a la presencia de una fuente puntual, las cuatro estaciones deberían presentar momios comparables, dado que todas tienen el complejo hacia el este o el este sureste.




Figura 1: Razón de momios del sector Este sobre la probabilidad de episodio, en función de la distancia de cada estación al complejo refinador. Las barras representan el intervalo de confianza al 95 por ciento y la línea punteada corresponde a la ausencia de efecto.

La asociación con el sector Este se atenúa conforme aumenta la distancia: la razón de momios disminuye de 3.19 en SE3 a 1.58 en SE2 y deja de ser significativa en NE y GAR. Este patrón sugiere que la señal depende simultáneamente de la dirección y la proximidad, en lugar de responder a un efecto meteorológico regional común a todas las estaciones.

Tabla 4: Contraste del sector Este frente al resto de direcciones, estimado por estación en el modelo conjunto con controles específicos.

Estación	Razón de momios	IC 95 %	Valor p
SE3	3.19	[2.96, 3.44]	<1e-16
SE2	1.58	[1.43, 1.75]	<1e-16
NE	1.01	[0.81, 1.25]	0.95
GAR	1.07	[0.53, 2.16]	0.84

La diferencia entre estaciones se confirmó mediante un modelo conjunto con interacción entre estación y sector (Δ devianza = 195.77; gl = 3), favorecido también por los criterios AIC y BIC. En conjunto, los resultados son consistentes con una señal que pierde intensidad conforme aumenta la distancia.

6.4. Persistencia del patrón ante controles meteorológicos

Para evaluar si la asociación direccional podía explicarse por otras condiciones meteorológicas, el modelo se amplió con temperatura, humedad relativa, presión atmosférica, radiación solar y precipitación mediante splines naturales. La selección por BIC descartó la precipitación y mantuvo las variables restantes. Aun con estos controles, el bloque direccional conservó una contribución significativa (Δ devianza = 1,192.7; gl = 15; $p < 0.001$).

Tabla 5: Desempeño fuera de muestra en 2025 del modelo direccional frente al modelo con controles meteorológicos ampliados. Ambos fueron estimados con los años 2022 a 2024.

Modelo	AUC	Error de Brier
Dirección + WSR + tiempo	0.789	0.104
Meteorología ampliada	0.794	0.106

La ampliación meteorológica apenas modificó el desempeño fuera de muestra: el AUC pasó de 0.789 a 0.794 y el error de Brier de 0.104 a 0.106. Por tanto, estas variables funcionan como controles, pero no sustituyen la información aportada por la dirección del viento.

6.5. Persistencia del patrón ante la memoria temporal del contaminante

La autocorrelación residual mostró que la dependencia temporal seguía presente: a una hora fue de 0.484 en el modelo base y de 0.471 después de incorporar controles meteorológicos. Por ello, se añadieron rezagos de SO₂ de 1, 2, 12 y 24 horas, seleccionados mediante BIC.

Los rezagos mejoraron significativamente el ajuste (Δ devianza = 5,187.7; gl = 4), pero el sector oriental mantuvo una razón de momios de 3.34 (IC 95 %: 3.03-3.68). Esto indica que la asociación direccional no se explica únicamente por la persistencia temporal del contaminante.




Figura 2: Autocorrelación de los residuos de devianza en función del rezago horario, para el modelo base, el modelo con controles meteorológicos ampliados y el modelo integrado.

6.6. Modelo integrado

Las dos explicaciones alternativas anteriores se evaluaron de manera conjunta mediante cuatro modelos anidados estimados sobre exactamente las mismas 31,745 observaciones, condición necesaria para que los criterios de información y las pruebas de razón de verosimilitudes resulten comparables.

Tabla 6: Criterios de información de los cuatro modelos anidados, estimados sobre las mismas observaciones del periodo 2022 a 2024. Valores menores indican mejor ajuste penalizado.

Modelo	AIC	BIC
Base	13873.6	13946.2
Meteorología ampliada	13200.8	13370.2
Lags SO2	10065.9	10170.8
Meteorología + lags	9844.2	10045.9

Dos pruebas establecen que los bloques son complementarios y no redundantes. Los rezagos aportan información después de controlar por meteorología, con una diferencia de devianza de 3,364.6 sobre cuatro grados de libertad. La meteorología aporta información después de controlar por la memoria temporal, con una diferencia de 245.7 sobre doce grados de libertad.

La prueba central del análisis consiste en eliminar el sector direccional del modelo integrado, conservando simultáneamente la meteorología ampliada y los rezagos. La devianza se deteriora en 600.2 puntos sobre un grado de libertad, con un valor $p < 0.001$. Esto confirma que el sector oriental aporta información adicional aun después de controlar por meteorología y dependencia temporal.

Tabla 7: Deterioro del ajuste al eliminar cada bloque del modelo integrado, manteniendo los restantes. Valores mayores indican mayor contribución del bloque.

Bloque eliminado	Δ Devianza	gl	Valor p
Memoria temporal: lags SO2	4886.2	4	<1e-16
Sector Este/Resto	600.2	1	<1e-16
Meteorología adicional: TOUT + RH + PRS + SR	281.7	12	<1e-16
Ciclicidad: hora + mes	103.7	4	<1e-16

La estimación final del efecto direccional, con errores estándar agrupados por día para corregir la dependencia entre horas de una misma jornada, arroja una razón de momios de 3.38 con intervalo de confianza entre 3.06 y 3.74.

6.7. Validación fuera de muestra

Los cuatro modelos se evaluaron sobre el año 2025, que no participó en la estimación.

Tabla 8: Desempeño de los cuatro modelos sobre el año 2025. El punto de corte para sensibilidad y especificidad se fijó en la tasa base observada durante el entrenamiento.

Modelo	AUC	Error de Brier	Sensibilidad	Especificidad
Base	0.761	0.108	0.701	0.679
Meteorología	0.768	0.110	0.570	0.788
Lags	0.897	0.075	0.795	0.833
Meteorología + lags	0.896	0.076	0.734	0.876

El modelo integrado alcanza un área bajo la curva de 0.896 frente a 0.761 del modelo base, con una reducción del error de Brier de 0.108 a 0.076. Con el punto de corte fijado en la tasa base del periodo de entrenamiento, obtiene una sensibilidad de 0.734 y una especificidad de 0.876.




Figura 3: Calibración del modelo integrado por deciles de riesgo predicho. La línea punteada representa la calibración perfecta.

La prueba de Hosmer-Lemeshow resulta significativa, resultado esperable dado el tamaño de muestra, ya que esta prueba tiende a rechazar la hipótesis de buen ajuste ante desviaciones triviales cuando el número de observaciones es elevado. El examen por deciles muestra que las diferencias entre probabilidad predicha y proporción observada se mantienen por debajo de 3.5 puntos porcentuales en todos los casos, con la mayor desviación en el noveno decil. El modelo subestima ligeramente el riesgo en las categorías intermedias y recupera precisión en el decil de mayor riesgo, comportamiento favorable para un eventual uso como herramienta de alerta.

6.8. Sensibilidad al umbral de episodio

Tabla 9: Razón de momios del sector Este bajo tres definiciones del umbral de episodio, en las dos estaciones con señal significativa. El detalle de las cuatro estaciones se presenta en el Anexo D.

Percentil	Umbral (ppb)	Estación	Razón de momios	IC 95 %
P90	7.20	SE3	3.38	[3.17, 3.60]
P90	7.20	SE2	1.43	[1.33, 1.53]
P95	11.10	SE3	3.19	[2.96, 3.44]
P95	11.10	SE2	1.58	[1.43, 1.74]
P99	30.56	SE3	2.57	[2.25, 2.93]
P99	30.56	SE2	1.75	[1.37, 2.24]

La conclusión direccional no depende del umbral seleccionado. En SE3 la razón de momios se mantiene entre 2.57 y 3.38 a lo largo de los tres percentiles. En SE2 el momio crece con la severidad del umbral, de 1.43 a 1.75, patrón compatible con que la pluma alcance esa estación únicamente durante los episodios de mayor intensidad.

En la estación de control no fue posible estimar el modelo con el umbral más exigente, dado que registra menos de treinta horas por encima de 30.6 partes por billón en cuatro años. Esta imposibilidad constituye un resultado por derecho propio: el fenómeno que se estudia sencillamente no ocurre en ese sitio con intensidad suficiente para ser modelado.

6.9. Falsación multicontaminante

El análisis anterior establece que los episodios de dióxido de azufre se asocian al sector oriental. Resta verificar si ese comportamiento es específico de este contaminante o si aparece de manera similar en los demás.

Tabla 10: Razón de momios del sector Este sobre la probabilidad de concentración elevada, por contaminante, en SE3. El evento se define en cada caso como la superación del percentil 95 de la distribución propia de la variable.

Contaminante	n	Eventos	Razón de momios	IC 95 %
SO2	33977	1699	2.66	[2.39, 2.95]
NOX	33682	1684	0.22	[0.17, 0.28]
NO	33451	1670	0.22	[0.17, 0.29]
CO	31741	1571	1.05	[0.92, 1.20]
PM10	33684	1658	0.50	[0.43, 0.58]
PM2.5	30686	1507	0.59	[0.51, 0.68]
O3	33697	1567	0.90	[0.80, 1.02]

SO2 fue el único contaminante con una asociación significativamente positiva con el sector Este (OR = 2.66). CO y O3 no mostraron asociación significativa, mientras que NO y NOX presentaron razones de momios cercanas a 0.22. Este comportamiento opuesto al de los principales trazadores vehiculares es consistente con un perfil distinto al de la combustión urbana difusa.

6.10. Verificación por método no paramétrico



Figura 4: Función de probabilidad bivariada condicional en SE3: SO2 (izquierda) y NOx (derecha).

La CBPF confirmó el contraste direccional: SO2 presenta un lóbulo definido hacia el Este y velocidades moderadas, mientras que NOX alcanza su máximo en condiciones de calma y sin orientación preferente. La coincidencia entre este método no paramétrico y la regresión logística refuerza la robustez del patrón. Los resultados para SE2 y NE se presentan en el Anexo E.

6.11. Estructura multivariada de la matriz química

Los resultados anteriores dependen enteramente de la información meteorológica. El análisis que sigue prescinde por completo de la dirección del viento y plantea una pregunta de naturaleza composicional: si el dióxido de azufre compartiera estructura de variación con los óxidos de nitrógeno y el monóxido de carbono, la hipótesis de una fuente distinta a la combustión urbana quedaría debilitada con independencia del patrón direccional documentado.

6.11.1. Componentes principales

El análisis se aplicó sobre la matriz de los ocho contaminantes en SE3, con transformación logarítmica y estandarización previas. El procedimiento requiere casos completos: se conservaron 27,938 de las 33,977 observaciones, equivalentes al 82.2 por ciento, y 3,304 de los 3,951 episodios, es decir, el 83.6 por ciento. La similitud entre ambas proporciones indica que la exclusión por datos faltantes no eliminó de manera preferente las horas de episodio. La adecuación muestral se verificó mediante el índice de Kaiser-Meyer-Olkin, que alcanza 0.623, y la prueba de esfericidad de Bartlett, significativa. El índice se sitúa por encima del mínimo convencional aunque en el rango calificado como mediocre, resultado que no constituye una deficiencia sino una consecuencia del objeto de estudio, ya que desciende precisamente porque el dióxido de azufre mantiene correlaciones bajas con el resto de las variables.

Tabla 11: Cargas de los tres primeros componentes principales sobre la matriz de contaminantes en SE3. El porcentaje entre paréntesis indica la varianza explicada por cada componente.

Variable	PC1 (48.6 %)	PC2 (19.4 %)	PC3 (9.7 %)
SO2	0.029	0.604	-0.472
NO	-0.452	-0.141	-0.130
NO2	-0.437	-0.040	-0.337
NOX	-0.481	-0.089	-0.266
CO	-0.278	0.091	0.705
O3	0.319	0.458	-0.001
PM10	-0.351	0.367	0.228
PM2.5	-0.265	0.503	0.164

El primer componente explica 48.6 % de la variabilidad y está dominado por los principales trazadores de combustión urbana, mientras que SO2 presenta una carga prácticamente nula de 0.029. En contraste, en el segundo componente, que explica 19.4 %, SO2 presenta la mayor carga (0.604). Esto indica que las horas con aumentos de SO2 siguen una estructura de variación distinta a la de los principales trazadores urbanos.

6.11.2. Análisis de conglomerados

Sobre las puntuaciones de los cuatro primeros componentes se aplicó el algoritmo de k medias, empleando exclusivamente información química. El índice de silueta favorece una partición en dos grupos, con 0.418 frente a valores cercanos a 0.26 para particiones mayores; se optó por cuatro conglomerados atendiendo a criterios de interpretabilidad química y no al valor del índice, decisión detallada en el Anexo B. La partición seleccionada explica el 58.3 por ciento de la variación en el espacio de componentes y converge en cinco iteraciones.

Tabla 12: Perfil de los cuatro conglomerados en SE3. Las concentraciones corresponden a medianas, expresadas en partes por billón salvo PM2.5 en microgramos por metro cúbico y la velocidad del viento en kilómetros por hora. La razón SO2/NOX se calcula sobre las medianas de cada grupo.

Grupo	n	%	SO2	NOX	PM2.5	O3	WSR	SO2/NOX	% Este	% episodios
1	4111	14.7	16.2	10.4	22	43	8.5	1.56	50.5	72.2
2	3352	12.0	4.4	51.8	28	5	3.6	0.08	6.2	1.4
3	7823	28.0	4.2	17.7	15	17	5.8	0.24	25.4	0.9
4	12652	45.3	4.1	8.1	9	26	8.5	0.51	42.7	1.7

Los conglomerados muestran perfiles químicos claramente diferenciados. El grupo 1 concentra 72.2 % de los episodios y presenta SO2 elevado (16.2 ppb), NOX bajo (10.4 ppb) y 50.5 % de horas con viento del Este. El grupo 2 presenta el comportamiento opuesto, con SO2 de 4.4 ppb, NOX de 51.8 ppb y solo 6.2 % de horas del Este. La razón SO2/NOX es 1.56 frente a 0.085, respectivamente, reforzando la existencia de un perfil de SO2 distinto al de la acumulación urbana.

6.12. Contraste entre tendencia central y exposición aguda

Los resultados precedentes establecen la especificidad del fenómeno. La sección siguiente aborda su magnitud y la capacidad de los indicadores habituales para representarla.

6.12.1. Diferencia de medianas frente a frecuencia de eventos

Se evaluó la diferencia entre estaciones para cada año mediante la prueba de Kruskal-Wallis, significativa en los cuatro años, y se cuantificó la magnitud mediante el estimador de Hodges-Lehmann.

Tabla 13: Diferencia de medianas anuales entre SE3 y la estación de control, estimada mediante el desplazamiento de Hodges-Lehmann. Los valores se expresan en partes por billón.

Año	Mediana SE3	Mediana GAR	Diferencia H-L	IC 95 %
2022	4.8	3.4	1.3	[1.3, 1.4]
2023	3.9	2.4	1.5	[1.5, 1.5]
2024	4.1	3.0	1.0	[1.0, 1.0]
2025	4.7	4.4	0.6	[0.5, 0.6]

Las diferencias de medianas entre SE3 y GAR son estadísticamente significativas, pero pequeñas en términos absolutos: varían entre 0.6 y 1.5 ppb y disminuyen hasta su mínimo en 2025. Sin embargo, la frecuencia de episodios muestra el comportamiento opuesto: SE3 registró 689 horas en 2023, cuando la diferencia de medianas fue máxima, y 1,172 en 2025, cuando fue mínima. Esto evidencia que la tendencia central describe el nivel habitual, pero representa de forma limitada los cambios en la cola superior de la distribución.

6.12.2. Duración de los episodios




Figura 5: Distribución de la duración de los episodios de dióxido de azufre en SE3, medida en horas consecutivas por encima del umbral.

Se identificaron 1,561 episodios en SE3 durante el periodo, con duración mediana de dos horas, percentil 75 en tres y percentil 95 en seis. Se trata de eventos breves y recurrentes antes que de periodos prolongados, característica con consecuencia directa sobre las métricas de evaluación: el percentil 99 horario en SE3 alcanza 55.3 partes por billón, mientras que el del promedio móvil de veinticuatro horas desciende a 26.0, prácticamente la mitad. Un episodio de dos horas queda diluido entre veintidós horas de concentración habitual.

El exceso de horas de episodio de SE3 respecto de la estación de control asciende a 3,902 en el periodo completo, equivalentes a 976 anuales, es decir, 40.6 días al año en que Cadereyta supera el umbral mientras la estación de control no lo hace. GAR acumula entre 9 y 20 horas anuales; SE3 supera las mil en tres de los cuatro años. Esta cifra puede interpretarse como indicador de exposición potencialmente evitable, bajo el supuesto de que eliminar la contribución del sector identificado aproximaría el comportamiento de SE3 al de una estación sin influencia industrial próxima. El supuesto es fuerte, por lo que debe entenderse como cota superior y no como contribución neta de la fuente.

7. Discusión y conclusiones

7.1. Síntesis de los hallazgos

En conjunto, los resultados muestran que los episodios elevados de SO₂ en SE3 presentan una asociación específica con el sector Este, cuya intensidad disminuye con la distancia y persiste después de controlar por meteorología y dependencia temporal. La ausencia de un patrón equivalente en los principales trazadores urbanos, junto con los resultados de PCA, conglomerados y CBPF, respalda la existencia de un perfil químico y direccional diferenciado. El principal hallazgo práctico es que esta señal se manifiesta en la frecuencia de eventos agudos: mientras las medianas entre estaciones son similares, SE3 registra un exceso aproximado de 976 horas de episodio al año respecto de GAR.

7.2. Alcance de las conclusiones

Debido al carácter observacional del estudio, los resultados no permiten atribuir causalidad directa a una instalación específica. Sin embargo, la combinación del gradiente espacial, los controles meteorológicos y temporales, la especificidad química y la concordancia entre métodos independientes reduce la plausibilidad de las explicaciones alternativas evaluadas. Persisten como limitaciones la ausencia de un inventario georreferenciado de emisiones y el uso de coordenadas aproximadas del complejo.

7.3. Implicaciones para el seguimiento de la calidad del aire

El contraste entre tendencia central y exposición aguda tiene consecuencias operativas. En 2025, las medianas sugieren convergencia entre SE3 y GAR, aunque la frecuencia de episodios aumentó. Además, dado que los eventos duran dos horas en mediana, el promedio móvil de 24 horas reduce el percentil 99 de 55.3 a 26.0 ppb. Por ello, las métricas agregadas describen adecuadamente el comportamiento general, pero deben complementarse con indicadores sensibles a eventos breves, especialmente para un contaminante asociado con exposiciones de corta duración (Secretaría de Medio Ambiente del Estado de Nuevo León, 2024).

7.4. Recomendaciones

Del análisis se derivan cuatro recomendaciones para el socio formador. Primero, incorporar métricas de frecuencia de excedencia como complemento de los promedios anuales, utilizando la información que la red ya genera (Secretaría de Medio Ambiente del Estado de Nuevo León, 2024). Segundo, evaluar un esquema de alerta horaria condicionado a la dirección del viento en SE3, considerando que el modelo integrado alcanzó $AUC = 0.896$ fuera de muestra. Tercero, utilizar el exceso de horas de episodio respecto de una estación de control como indicador complementario de exposición aguda. Finalmente, reforzar el monitoreo entre Cadereyta y Juárez para caracterizar con mayor detalle la atenuación espacial de la señal.

7.5. Preguntas que surgen del análisis

Los resultados abren varias líneas de investigación: identificar las causas del repunte de episodios observado en 2025; evaluar la estabilidad temporal del patrón direccional; comparar periodos de operación normal y mantenimiento del complejo; estimar la población potencialmente expuesta; e incorporar un inventario georreferenciado de emisiones para distinguir entre posibles fuentes ubicadas en el mismo sector oriental.

7.6. Conclusión

Los resultados son consistentes con la influencia de una fuente puntual de SO_2 ubicada al Este de SE3, cuya señal disminuye con la distancia y presenta una firma química distinta a la de la combustión urbana. La coincidencia entre el sector identificado, la ubicación del complejo refinador y los análisis de falsación hace de esta fuente la explicación más parsimoniosa del patrón observado.

El hallazgo de mayor relevancia práctica es que las medidas de tendencia central representan de forma limitada la exposición aguda: una diferencia de medianas inferior a 1 ppb puede coexistir con un exceso aproximado de 976 horas anuales de episodio. Por ello, la frecuencia de eventos elevados aporta información que no se observa únicamente mediante medias o medianas.

8. Referencias

- Ashbaugh, L. L., Malm, W. C., & Sadeh, W. Z. (1985). A residence time probability analysis of sulfur concentrations at Grand Canyon National Park. *Atmospheric Environment*, 19(8), 1263–1270.
[https://doi.org/10.1016/0004-6981\(85\)90256-2](https://doi.org/10.1016/0004-6981(85)90256-2)
- Carslaw, D. C., Beevers, S. D., Ropkins, K., & Bell, M. C. (2006). Detecting and quantifying aircraft and other on-airport contributions to ambient nitrogen oxides in the vicinity of a large international airport. *Atmospheric Environment*, 40(28), 5424–5434.
<https://doi.org/10.1016/j.atmosenv.2006.04.062>
- Carslaw, D. C., & Ropkins, K. (2012). *openair—An R package for air quality data analysis*. *Environmental Modelling & Software*, 27–28, 52–61.
<https://doi.org/10.1016/j.envsoft.2011.09.008>
- Clarke, K., Kwon, H.-O., & Choi, S.-D. (2014). Fast and reliable source identification of criteria air pollutants in an industrial city. *Atmospheric Environment*, 95, 239–248.
<https://doi.org/10.1016/j.atmosenv.2014.06.040>
- Comisión Federal para la Protección contra Riesgos Sanitarios. (2025, 1 de julio). *Normas Oficiales Mexicanas (NOM) de calidad del aire ambiente*. Gobierno de México.
<https://www.gob.mx/cofepris/acciones-y-programas/4-normas-oficiales-mexicanas-nom-de-calidad-del-aire-ambiente>
- Gobierno del Estado de Nuevo León. (s. f.). *Índice Aire y Salud: Reporte de la calidad del aire en la Zona Metropolitana de Monterrey*. Sistema Integral de Monitoreo Ambiental.
https://aire.nl.gob.mx/icars2020/map_calidad_icars.php
- Hodges, J. L., Jr., & Lehmann, E. L. (1963). Estimates of location based on rank tests. *The Annals of Mathematical Statistics*, 34(2), 598–611.
<https://doi.org/10.1214/aoms/1177704172>
- Holcim España. (s. f.). *¿Qué es la calidad del aire y por qué es importante?*
<https://www.holcim.es/que-es-la-calidad-del-aire-importancia-y-medicion>
- Instituto Nacional de Ecología y Cambio Climático. (s. f.). *Sistema Nacional de Información de la Calidad del Aire (SINAICA)*. Gobierno de México.
<https://sinaica.inecc.gob.mx/index.php>
- Kruskal, W. H., & Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583–621.
<https://doi.org/10.1080/01621459.1952.10483441>
- Organización Mundial de la Salud. (2021). *Directrices mundiales de la OMS sobre la calidad del aire: Materia particulada (MP2,5 y MP10), ozono, dióxido de nitrógeno, dióxido de azufre y monóxido de carbono: Resumen ejecutivo*.
<https://www.who.int/es/publications/i/item/9789240034433/>
- Organización Mundial de la Salud. (2024, 24 de octubre). *Contaminación del aire ambiente (exterior) y salud*.
[https://www.who.int/es/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/es/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health)
- Programa de las Naciones Unidas para el Medio Ambiente. (2022, 22 de septiembre). *¿Cómo se mide la*

calidad del aire?

<https://www.unep.org/es/noticias-y-reportajes/reportajes/como-se-mide-la-calidad-del-aire>

Secretaría de Medio Ambiente del Estado de Nuevo León. (2024). *Programa Integral de Gestión Estratégica de la Calidad del Aire 2023–2033 para el Área Metropolitana de Monterrey (PIGECA)*. Gobierno del Estado de Nuevo León.

https://aire.nl.gob.mx/docs/reportes/PIGECA_2023_2033.pdf

Secretaría de Medio Ambiente y Recursos Naturales. (2024). *Norma Oficial Mexicana NOM-172-SEMARNAT-2023, Lineamientos para la obtención y comunicación del índice de calidad del aire y riesgos a la salud. Diario Oficial de la Federación*.

[NOM-172-SEMARNAT-2023 en el Diario Oficial de la Federación](#)

Uria-Tellaetxe, I., & Carslaw, D. C. (2014). Conditional bivariate probability function for source identification. *Environmental Modelling & Software*, 59, 1–9.

<https://doi.org/10.1016/j.envsoft.2014.05.002>

Xue, Y., Cui, X., Li, K., Yu, Q., & Ma, W. (2023). Statistical source analysis of recurring sulfur dioxide pollution events in a chemical industrial park. *Atmospheric Environment*, 296, 119564.

<https://doi.org/10.1016/j.atmosenv.2022.119564>

9. Declaratoria de IA

Se utilizó inteligencia artificial generativa como herramienta de apoyo durante el desarrollo del presente proyecto.

1. Herramienta utilizada: ChatGPT

2. Uso realizado: La herramienta se utilizó como apoyo para la generación, revisión y depuración de código en R; propuesta de alternativas de modelación y validación; organización de resultados; y revisión de redacción, claridad y estructura del documento. La IA también se utilizó para apoyar la búsqueda de errores, comparar posibles enfoques metodológicos y facilitar la interpretación de resultados obtenidos por el equipo.

3. Secciones donde se utilizó: Principalmente en la preparación y tratamiento de los datos, modelación y validación estadística, interpretación de resultados, elaboración de gráficos y tablas mediante código, discusión, conclusiones y revisión de la redacción general del reporte y sus anexos.

4. Validación realizada por los estudiantes: Todo el código utilizado fue ejecutado por los integrantes del equipo sobre las bases de datos del proyecto. Los resultados numéricos, modelos, gráficos y pruebas estadísticas fueron revisados y contrastados con las salidas obtenidas directamente en R. Asimismo, el equipo verificó la congruencia entre los resultados obtenidos, su interpretación estadística y las conclusiones presentadas. Las decisiones metodológicas finales fueron tomadas por los integrantes del equipo.

5. Responsabilidad sobre el contenido: Los integrantes del equipo revisaron y verificaron el contenido generado o sugerido mediante inteligencia artificial antes de incorporarlo al documento. El equipo asume la responsabilidad académica por el análisis, las decisiones metodológicas, las interpretaciones, las fuentes utilizadas y el contenido final entregado.

6. Otro: La inteligencia artificial se utilizó únicamente como herramienta de apoyo y no sustituyó la ejecución de los análisis, la revisión de los resultados ni el criterio académico de los integrantes del

equipo. No se consideraron como resultados válidos afirmaciones, cálculos o referencias generadas por IA que no pudieran ser verificadas mediante los datos, el código ejecutado o las fuentes consultadas.

10. Liga al GitHub

https://github.com/aliciabernadez/MA2003B_multivariados/tree/trunk

11. Anexos

11.1. Anexo A. Regresión lineal sobre la concentración

Durante la definición de la estrategia de modelado se consideró estimar un modelo de regresión lineal que tomara como variable de respuesta la concentración horaria de dióxido de azufre, en lugar de la ocurrencia de episodio. La especificación se descartó por tres razones que conviene documentar.

La primera es de correspondencia entre el método y el objeto de estudio. El fenómeno de interés consiste en eventos discretos y poco frecuentes, que representan el 11.63 por ciento de las horas en la estación más próxima a la fuente. Un modelo que estima la media condicional de la concentración distribuye el peso de la estimación entre todas las observaciones, de modo que las horas de comportamiento regular, ampliamente mayoritarias, dominan el ajuste y la contribución de los episodios queda diluida.

La segunda es el incumplimiento del supuesto de normalidad de los residuos. La distribución del dióxido de azufre presenta una asimetría pronunciada, con una razón entre el percentil 99 y la mediana de 12.57 en SE3. Una variable con esa estructura genera residuos con cola derecha extensa, lo que invalida las pruebas de significancia y los intervalos de confianza construidos bajo el supuesto gaussiano. Las transformaciones habituales para corregir asimetría, como la logarítmica, comprimen precisamente el rango superior de la distribución, es decir, la región donde se manifiesta el fenómeno estudiado.

La tercera es de interpretación de los resultados. Un coeficiente de regresión lineal asociado al sector oriental expresaría el incremento promedio en partes por billón atribuible a esa dirección del viento. Esa magnitud resulta de escaso valor operativo, ya que la pregunta relevante para la gestión de la calidad del aire no es cuánto aumenta la concentración media, sino con qué frecuencia se supera un umbral de riesgo. La razón de momios de un modelo logístico responde directamente a esa pregunta y permite además comparar entre contaminantes medidos en unidades distintas, comparación indispensable para las pruebas de falsación.

Por estas razones la regresión lineal se descartó en la fase de diseño y no llegó a estimarse de manera definitiva.

11.2. Anexo B. Selección del número de conglomerados

La determinación del número de grupos en el análisis de k medias se evaluó mediante el índice de silueta, que mide la cohesión interna de los conglomerados frente a su separación.

Tabla 14: Índice de silueta promedio para particiones de dos a seis grupos sobre las puntuaciones de los cuatro primeros componentes principales.

Número de grupos	Índice de silueta
2	0.418

Tabla 14: Índice de silueta promedio para particiones de dos a seis grupos sobre las puntuaciones de los cuatro primeros componentes principales.

Número de grupos	Índice de silueta
3	0.262
4	0.264
5	0.255
6	0.239

El índice favorece de manera clara la partición en dos grupos, con un valor de 0.418, frente a valores cercanos a 0.26 para las particiones de tres a seis. Pese a ello se adoptó la partición en cuatro conglomerados, decisión que responde a criterios de interpretabilidad química.

La partición en dos grupos separa las horas según su nivel general de contaminación, distinguiendo esencialmente entre condiciones limpias y condiciones cargadas. Esa separación, aunque estadísticamente más nítida, no permite distinguir entre mecanismos de origen distinto: agrupa en una misma clase las horas de acumulación urbana bajo estancamiento atmosférico y las horas de transporte desde el sector oriental, que son precisamente las dos situaciones que el análisis busca diferenciar.

La partición en cuatro grupos sí las separa, y produce dos conglomerados con perfiles químicos opuestos, uno con razón entre dióxido de azufre y óxidos de nitrógeno de 1.56 y otro con 0.085. Esa diferencia de factor dieciocho constituye el resultado de interés, y se pierde por completo bajo la partición de dos grupos.

El descenso del índice de silueta al aumentar el número de grupos era esperable dada la estructura de los datos, ya que los perfiles de contaminación atmosférica no forman clases discretas bien separadas sino un continuo con regiones de mayor densidad. En contextos de este tipo, el criterio de interpretabilidad resulta preferible a la optimización de un índice de separación geométrica.

11.3. Anexo C. Razones de momios por rumbo del viento

Tabla 15: Razones de momios de los quince rumbos estimados en SE3, con el norte como categoría de referencia. El modelo controla por velocidad del viento mediante splines naturales y por hora y mes mediante términos armónicos.

Rumbo	Razón de momios	IC 95 %	Valor p
E	6.123	[4.731, 7.924]	< 1e-16
ESE	2.579	[1.996, 3.332]	4.38e-13
ENE	1.985	[1.505, 2.617]	1.20e-06
SSE	1.532	[1.170, 2.007]	0.00193
SE	1.513	[1.171, 1.955]	0.00155
S	1.137	[0.826, 1.564]	0.43013
NE	1.078	[0.791, 1.470]	0.63380
NNE	1.059	[0.750, 1.496]	0.74337
SO	0.830	[0.533, 1.292]	0.40883
SSO	0.781	[0.514, 1.186]	0.24567
OSO	0.543	[0.328, 0.899]	0.01754

Tabla 15: Razones de momios de los quince rumbos estimados en SE3, con el norte como categoría de referencia. El modelo controla por velocidad del viento mediante splines naturales y por hora y mes mediante términos armónicos.

Rumbo	Razón de momios	IC 95 %	Valor p
ONO	0.251	[0.154, 0.409]	2.94e-08
O	0.238	[0.128, 0.444]	6.20e-06
NNO	0.231	[0.153, 0.348]	2.35e-12
NO	0.077	[0.045, 0.135]	< 1e-16

11.4. Anexo D. Sensibilidad al umbral de episodio

Tabla 16: Razón de momios del sector Este bajo tres definiciones del umbral de episodio, en las cuatro estaciones. Los valores ausentes en GAR bajo el percentil 99 corresponden a la imposibilidad de estimación por número insuficiente de eventos.

Percentil	Umbral (ppb)	Estación	Razón de momios	IC 95 %
P90	7.20	SE3	3.38	[3.17, 3.60]
P90	7.20	SE2	1.43	[1.33, 1.53]
P90	7.20	NE	1.00	[0.89, 1.13]
P90	7.20	GAR	1.40	[1.08, 1.83]
P95	11.10	SE3	3.19	[2.96, 3.44]
P95	11.10	SE2	1.58	[1.43, 1.74]
P95	11.10	NE	1.01	[0.81, 1.26]
P95	11.10	GAR	1.08	[0.54, 2.16]
P99	30.56	SE3	2.57	[2.25, 2.93]
P99	30.56	SE2	1.75	[1.37, 2.24]
P99	30.56	NE	0.86	[0.30, 2.50]
P99	30.56	GAR	NA	[NA, NA]

La estación GAR no admite estimación bajo el percentil 99, dado que registra menos de treinta horas por encima de 30.6 partes por billón durante los cuatro años analizados. Esta limitación no constituye una deficiencia del procedimiento sino una consecuencia de la propia distribución de la variable en esa estación.

11.5. Anexo E. Verificación direccional no paramétrica en SE2 y NE




Figura 6: Función de probabilidad bivariada condicional del dióxido de azufre en las estaciones intermedia y lejana.

Las escalas de color son independientes en cada panel, por lo que la comparación válida es la forma del patrón y no la magnitud absoluta.

La estación SE2 presenta dos focos de intensidad moderada, orientados hacia el nor noreste y el sur, sin correspondencia con el azimuth del complejo refinador. La estación NE muestra su máximo hacia el sur, con probabilidad condicional un orden de magnitud menor que la observada en SE3 y sin contribución apreciable del sector oriental. Ambos resultados son consistentes con el gradiente obtenido mediante el modelo logístico.

11.6. Anexo F. Matriz de sustento metodológico

Tabla 17: Correspondencia entre cada pregunta de validación, el método empleado para responderla y la explicación alternativa que permite descartar.

Pregunta	Método	Qué comprueba
¿Existe patrón direccional?	Logística de 16 rumbos	La probabilidad de episodio cambia según rumbo controlando WSR, hora y mes.
¿El patrón espacial es igual en todas las estaciones?	Modelo conjunto flexible + interacción Estación $\times$ sector	Permite que dirección, WSR y ciclos temporales tengan efectos distintos por estación.
¿La dirección sobrevive a otros factores meteorológicos?	Modelo meteorológico ampliado + AIC/BIC + LRT	Evalúa dirección controlando TOUT, RH, PRS, SR, WSR y precipitación candidata.

Tabla 17: Correspondencia entre cada pregunta de validación, el método empleado para responderla y la explicación alternativa que permite descartar.

Pregunta	Método	Qué comprueba
¿La meteorología elimina la memoria temporal?	Autocorrelación de residuos	Determina si todavía existe dependencia entre horas consecutivas.
¿El patrón direccional es solo persistencia del SO ₂ ?	Regresión logística con rezagos	Controla explícitamente la concentración de SO ₂ de horas anteriores.
¿Meteorología y memoria temporal son complementarias?	Modelo integrado	Compara bloques sobre la misma muestra y prueba cada contribución condicional a las demás.
¿La inferencia depende de asumir independencia horaria?	Errores estándar robustos agrupados por día	Corrige la incertidumbre ante dependencia dentro del día.
¿Generaliza a datos futuros?	Entrenamiento 2022-2024 / prueba 2025	Evalúa AUC y Brier fuera de muestra.
¿Depende del umbral P95?	Sensibilidad P90/P95/P99	Verifica estabilidad ante distintos niveles de severidad.
¿Es un patrón general de contaminación?	Falsación multi-contaminante + CBPF	Contrasta SO ₂ contra otros contaminantes y con una técnica direccional independiente.
¿Por qué los picos pueden quedar ocultos en métricas agregadas?	Duración de rachas + promedio móvil 24 h	Relaciona episodios cortos con amortiguación por ventanas de 24 horas.

11.7. Anexo G. Validación del modelo meteorológico

Tabla 18: Desempeño fuera de muestra en 2025 del modelo direccional frente al modelo con controles meteorológicos ampliados. Ambos fueron estimados con los años 2022 a 2024.

Modelo	AUC	Error de Brier
Dirección + WSR + tiempo	0.789	0.104
Meteorología ampliada	0.794	0.106

La ampliación meteorológica produce una mejora marginal en la capacidad de discriminación, con un incremento del área bajo la curva de 0.789 a 0.794, y un ligero deterioro en la calibración, con un aumento del error de Brier de 0.104 a 0.106. La interpretación relevante es que las variables meteorológicas adicionales no explican los episodios de manera autónoma. Su incorporación al modelo resulta pertinente como control estadístico, ya que permite verificar que la asociación direccional persiste al mantenerlas constantes, pero no constituye por sí misma una mejora predictiva sustantiva.