

SIMA — Modelo integrado Omar + Sebas

Validación espacial, meteorológica y temporal de episodios de SO

Alicia Bernádez Omar Arzaga Diego Medrano
Sebastián Alemán Isaac Montaña

Table of contents

Propósito del archivo	2
1. Preparación general	3
1.1 Variables comunes	3
1.2 Caracterización inicial	4
2. Evidencia direccional base en SE3	5
2.1 Significancia global y capacidad discriminante	6
3. Comparación espacial: modelo conjunto flexible	7
3.1 Controles comunes vs controles específicos por estación	8
3.2 ¿La asociación Este–Resto cambia entre estaciones?	9
3.3 Contrastes Este vs Resto por estación	10
4. Extensión meteorológica en SE3	11
4.1 Modelo meteorológico completo	12
4.2 Selección AIC y BIC	13
4.3 ¿La dirección aporta información después de la meteorología?	14
5. Validación temporal del modelo meteorológico en 2025	15
6. Diagnóstico de dependencia temporal residual	17
7. Construcción correcta de rezagos horarios	19
8. Modelo temporal con rezagos de SO	20
8.1 Selección BIC de los rezagos	21
8.2 ¿Sobrevive el sector Este?	22

9. MODELO INTEGRADO NUEVO: meteorología + memoria temporal + dirección	23
9.1 Cuatro modelos anidados sobre exactamente las mismas filas	24
9.2 Pruebas que demuestran complementariedad	26
¿Los rezagos aportan después de controlar meteorología?	26
¿La meteorología adicional aporta después de controlar la memoria del SO ? . .	26
¿El sector Este sigue aportando después de controlar AMBAS cosas?	27
10. OR del sector Este con inferencia robusta agrupada por día	28
11. Validación fuera de muestra 2025: comparación justa	29
11.1 Sensibilidad y especificidad con corte definido en entrenamiento	31
12. ¿Queda autocorrelación después del modelo integrado?	32
13. Importancia incremental de los bloques	33
14. Sensibilidad al umbral de episodio	35
15. Falsación multi-contaminante	37
16. Verificación independiente CBPF	39
17. Duración de episodios	43
18. Punto ciego de promedios móviles de 24 horas	44
19. Matriz de sustento del proyecto	46
20. Resumen automático del modelo integrado	47
21. Guardado reproducible	49
22. Interpretación para defensa	50

Propósito del archivo

Este QMD integra en una sola secuencia reproducible dos líneas de trabajo complementarias:

1. **Validación espacial y meteorológica:** comprobar que el patrón direccional de los episodios de SO persiste al controlar por meteorología y que su magnitud puede cambiar entre estaciones.
2. **Validación temporal:** comprobar que el patrón direccional no es un artefacto de la persistencia del SO entre horas consecutivas.

La lógica confirmatoria es:

dirección → meteorología → diferencias entre estaciones → memoria temporal → modelo integrado → robustez → validación fuera de muestra.

El análisis es observacional. Los resultados permiten hablar de **asociación espacial, meteorológica y temporal consistente con la hipótesis del proyecto**, pero no de atribución causal definitiva a una fuente específica.

1. Preparación general

```
library(tidyverse)
library(lubridate)
library(splines)
library(broom)
library(sandwich)
library(lmtest)
library(pROC)
library(ResourceSelection)
library(emmeans)
```

```
datos <- read_csv(
  "baseeee_SIMA_limpia_4est_8cont_2022_2025.csv",
  locale = locale(encoding = "UTF-8"),
  show_col_types = FALSE
)

cat("Dimensiones originales:", nrow(datos), "x", ncol(datos), "\n")
```

Dimensiones originales: 132936 x 21

1.1 Variables comunes

```
rumbos <- c(
  "N", "NNE", "NE", "ENE", "E", "ESE", "SE", "SSE",
  "S", "SSO", "SO", "OSO", "O", "ONO", "NO", "NNO"
)
```

```

datos <- datos %>%
  mutate(
    fecha = ymd_hms(`Fecha y hora`),
    Estacion = factor(Estacion, levels = c("SE3", "SE2", "NE", "GAR")),
    sector = rumbos[((floor((WDR + 11.25) / 22.5)) %% 16) + 1],
    sector = factor(sector, levels = rumbos),
    Hora = hour(fecha),
    Mes = month(fecha),
    Año = year(fecha),
    Hora_sin = sin(2 * pi * Hora / 24),
    Hora_cos = cos(2 * pi * Hora / 24),
    Mes_sin = sin(2 * pi * Mes / 12),
    Mes_cos = cos(2 * pi * Mes / 12)
  )

# Umbral absoluto común a las cuatro estaciones
umbral_ep <- quantile(datos$S02, 0.95, na.rm = TRUE)

datos <- datos %>%
  mutate(
    episodio = as.integer(S02 > umbral_ep),
    sector_E = factor(
      if_else(sector %in% c("ENE", "E", "ESE"), "Este", "Resto"),
      levels = c("Resto", "Este")
    )
  )

cat("Umbral P95 global:", round(umbral_ep, 2), "ppb\n")

```

Umbral P95 global: 11.1 ppb

1.2 Caracterización inicial

```

resumen_estaciones <- datos %>%
  group_by(Estacion) %>%
  summarise(
    n = n(),
    episodios = sum(episodio, na.rm = TRUE),
    tasa_pct = 100 * mean(episodio, na.rm = TRUE),
    P50 = median(S02, na.rm = TRUE),

```

```

P99 = quantile(S02, 0.99, na.rm = TRUE),
razon_P99_P50 = P99 / P50,
.groups = "drop"
) %>%
mutate(across(where(is.numeric), ~ round(.x, 2)))

print(resumen_estaciones)

```

```

# A tibble: 4 x 7
  Estacion      n episodios tasa_pct    P50    P99 razon_P99_P50
  <fct>      <dbl>      <dbl>    <dbl> <dbl> <dbl>      <dbl>
1 SE3      33977      3951    11.6    4.4  55.3      12.6
2 SE2      33240      1841     5.54    3.8  27.8       7.32
3 NE       33185       746     2.25    3.8  15.1       3.97
4 GAR      32534       49      0.15    3.3   7.4       2.24

```

2. Evidencia direccional base en SE3

Este bloque reproduce la especificación direccional de 16 rumbos. La pregunta es si, aun controlando por velocidad del viento, hora y mes, ciertos rumbos presentan una asociación mayor con los episodios.

```

d_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  mutate(
    sector = relevel(sector, ref = "N"),
    dia = as.Date(fecha)
  )

mod_dir_16 <- glm(
  episodio ~
    sector +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_se3,
  family = binomial
)

or_dir_16 <- tidy(mod_dir_16) %>%

```

```

filter(str_detect(term, "^sector")) %>%
transmute(
  Rumbo = str_remove(term, "^sector"),
  OR = exp(estimate),
  IC_inf = exp(estimate - 1.96 * std.error),
  IC_sup = exp(estimate + 1.96 * std.error),
  p = p.value
) %>%
arrange(desc(OR))

print(or_dir_16, n = 15)

```

```

# A tibble: 15 x 5
  Rumbo      OR IC_inf IC_sup      p
  <chr>   <dbl> <dbl> <dbl>   <dbl>
1 E      6.12  4.73  7.92 3.97e-43
2 ESE    2.58  2.00  3.33 4.38e-13
3 ENE    1.98  1.51  2.62 1.20e- 6
4 SSE    1.53  1.17  2.01 1.93e- 3
5 SE     1.51  1.17  1.96 1.55e- 3
6 S      1.14  0.826 1.56 4.30e- 1
7 NE     1.08  0.791 1.47 6.34e- 1
8 NNE    1.06  0.750 1.50 7.43e- 1
9 SO     0.830 0.533 1.29 4.09e- 1
10 SSO   0.781 0.514 1.19 2.46e- 1
11 OSO   0.543 0.328 0.899 1.75e- 2
12 ONO   0.251 0.154 0.409 2.94e- 8
13 O     0.238 0.128 0.444 6.20e- 6
14 NNO   0.231 0.153 0.348 2.35e-12
15 NO    0.0775 0.0446 0.135 1.19e-19

```

2.1 Significancia global y capacidad discriminante

```

mod_dir_nulo <- glm(
  episodio ~ 1,
  data = d_se3,
  family = binomial
)

print(anova(mod_dir_nulo, mod_dir_16, test = "Chisq"))

```

Analysis of Deviance Table

Model 1: episodio ~ 1

Model 2: episodio ~ sector + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	33976	24426			
2	33954	19809	22	4617.2	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
roc_dir <- roc(  
  d_se3$episodio,  
  fitted(mod_dir_16),  
  quiet = TRUE  
)  
  
cat("AUC modelo direccional de 16 rumbos:",  
    round(as.numeric(auc(roc_dir)), 3), "\n")
```

AUC modelo direccional de 16 rumbos: 0.811

3. Comparación espacial: modelo conjunto flexible

La pregunta ya no es solamente si existe asociación con el sector oriental, sino si esa asociación y los controles temporales/meteorológicos se comportan igual en las cuatro estaciones.

```
d_conjunto <- datos %>%  
  select(  
    fecha, Estacion, episodio, sector_E,  
    WSR, Hora_sin, Hora_cos, Mes_sin, Mes_cos  
  ) %>%  
  drop_na() %>%  
  mutate(  
    Estacion = factor(Estacion, levels = c("SE3", "SE2", "NE", "GAR")),  
    sector_E = factor(sector_E, levels = c("Resto", "Este"))  
  )
```

3.1 Controles comunes vs controles específicos por estación

```
mod_conjunto_comun <- glm(
  episodio ~
    Estacion * sector_E +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_conjunto,
  family = binomial
)

mod_conjunto_flexible <- glm(
  episodio ~
    Estacion * (
      sector_E +
      ns(WSR, 3) +
      Hora_sin + Hora_cos +
      Mes_sin + Mes_cos
    ),
  data = d_conjunto,
  family = binomial
)

comparacion_flexibilidad <- tibble(
  Modelo = c(
    "Controles comunes",
    "Controles específicos por estación"
  ),
  AIC = c(
    AIC(mod_conjunto_comun),
    AIC(mod_conjunto_flexible)
  ),
  BIC = c(
    BIC(mod_conjunto_comun),
    BIC(mod_conjunto_flexible)
  )
) %>%
  mutate(across(c(AIC, BIC), ~ round(.x, 1)))

print(comparacion_flexibilidad)
```



```
# A tibble: 2 x 3
  Modelo                                AIC    BIC
  <chr>                                <dbl> <dbl>
1 Controles comunes                    40568. 40714.
2 Controles específicos por estación 40177  40530.
```

3.2 ¿La asociación Este–Resto cambia entre estaciones?

```
mod_flexible_sin_interaccion_sector <- glm(
  episodio ~
    Estacion * (
      ns(WSR, 3) +
      Hora_sin + Hora_cos +
      Mes_sin + Mes_cos
    ) +
    sector_E,
  data = d_conjunto,
  family = binomial
)

prueba_interaccion_flexible <- anova(
  mod_flexible_sin_interaccion_sector,
  mod_conjunto_flexible,
  test = "Chisq"
)

print(prueba_interaccion_flexible)
```

Analysis of Deviance Table

```
Model 1: episodio ~ Estacion * (ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
  Mes_cos) + sector_E
Model 2: episodio ~ Estacion * (sector_E + ns(WSR, 3) + Hora_sin + Hora_cos +
  Mes_sin + Mes_cos)
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1    132903      40301
2    132900      40105  3    195.77 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```

comparacion_interaccion <- tibble(
  Modelo = c(
    "Sin interacción Estación × sector",
    "Con interacción Estación × sector"
  ),
  AIC = c(
    AIC(mod_flexible_sin_interaccion_sector),
    AIC(mod_conjunto_flexible)
  ),
  BIC = c(
    BIC(mod_flexible_sin_interaccion_sector),
    BIC(mod_conjunto_flexible)
  )
) %>%
  mutate(across(c(AIC, BIC), ~ round(.x, 1)))

print(comparacion_interaccion)

```

```

# A tibble: 2 x 3
  Modelo                                AIC    BIC
  <chr>                                <dbl> <dbl>
1 Sin interacción Estación × sector 40367. 40690
2 Con interacción Estación × sector 40177  40530.

```

3.3 Contrastes Este vs Resto por estación

```

emm_sector <- emmeans(
  mod_conjunto_flexible,
  ~ sector_E | Estacion
)

contrastes_estacion <- contrast(
  emm_sector,
  method = list("Este vs Resto" = c(-1, 1)),
  adjust = "holm"
)

print(summary(contrastes_estacion, infer = TRUE))

```

Estacion = SE3:

contrast	estimate	SE	df	asympt.LCL	asympt.UCL	z.ratio	p.value
Este vs Resto	1.15968	0.0384	Inf	1.084	1.235	30.232	<0.0001

Estacion = SE2:

contrast	estimate	SE	df	asympt.LCL	asympt.UCL	z.ratio	p.value
Este vs Resto	0.45832	0.0505	Inf	0.359	0.557	9.081	<0.0001

Estacion = NE:

contrast	estimate	SE	df	asympt.LCL	asympt.UCL	z.ratio	p.value
Este vs Resto	0.00661	0.1120	Inf	-0.212	0.226	0.059	0.9529

Estacion = GAR:

contrast	estimate	SE	df	asympt.LCL	asympt.UCL	z.ratio	p.value
Este vs Resto	0.07134	0.3560	Inf	-0.627	0.770	0.200	0.8413

Results are given on the log odds ratio (not the response) scale.

Confidence level used: 0.95

Interpretación esperada: si la interacción es significativa y AIC/BIC favorecen el modelo flexible, no debe obligarse a que el efecto de dirección, WSR, hora y mes sea idéntico entre estaciones.

4. Extensión meteorológica en SE3

Este bloque incorpora las variables meteorológicas adicionales para comprobar si el patrón direccional persiste después de controlar por temperatura, humedad, presión, radiación y precipitación.

La selección se realiza con **2022–2024**. El año **2025 queda fuera** y se utiliza únicamente para validación temporal.

```
d_met_se3 <- datos %>%
  filter(Estacion == "SE3") %>%
  select(
    fecha, Año, episodio, sector,
    WSR, TOUT, RH, PRS, SR, RAINF,
    Hora_sin, Hora_cos, Mes_sin, Mes_cos
  ) %>%
  drop_na() %>%
  mutate(
    sector = factor(sector, levels = rumbos),
```

```

    sector = relevel(sector, ref = "N"),
    dia = as.Date(fecha)
  )

d_met_tr <- d_met_se3 %>% filter(Año <= 2024)
d_met_te <- d_met_se3 %>% filter(Año == 2025)

cat("Train 2022-2024:", nrow(d_met_tr), "\n")

```

Train 2022-2024: 25426

```
cat("Test 2025:", nrow(d_met_te), "\n")
```

Test 2025: 8551

4.1 Modelo meteorológico completo

```

formula_met_completa <- episodio ~
  sector +
  ns(WSR, 3) +
  ns(TOUT, 3) +
  ns(RH, 3) +
  ns(PRS, 3) +
  ns(SR, 3) +
  log1p(RAINF) +
  Hora_sin + Hora_cos +
  Mes_sin + Mes_cos

formula_met_minima <- episodio ~
  sector +
  Hora_sin + Hora_cos +
  Mes_sin + Mes_cos

mod_met_completo_tr <- glm(
  formula_met_completa,
  data = d_met_tr,
  family = binomial
)

```

4.2 Selección AIC y BIC

```
mod_met_aic_tr <- step(
  mod_met_completo_tr,
  scope = list(
    lower = formula_met_minima,
    upper = formula_met_completa
  ),
  direction = "backward",
  k = 2,
  trace = 0
)

mod_met_bic_tr <- step(
  mod_met_completo_tr,
  scope = list(
    lower = formula_met_minima,
    upper = formula_met_completa
  ),
  direction = "backward",
  k = log(nobs(mod_met_completo_tr)),
  trace = 0
)

comparacion_seleccion_meteo <- tibble(
  Modelo = c("Completo", "AIC", "BIC"),
  AIC = c(
    AIC(mod_met_completo_tr),
    AIC(mod_met_aic_tr),
    AIC(mod_met_bic_tr)
  ),
  BIC = c(
    BIC(mod_met_completo_tr),
    BIC(mod_met_aic_tr),
    BIC(mod_met_bic_tr)
  ),
  Parametros = c(
    length(coef(mod_met_completo_tr)),
    length(coef(mod_met_aic_tr)),
    length(coef(mod_met_bic_tr))
  )
) %>%
```

```
mutate(across(c(AIC, BIC), ~ round(.x, 1)))

print(comparacion_seleccion_meteo)
```

```
# A tibble: 3 x 4
  Modelo      AIC      BIC Parametros
  <chr>      <dbl> <dbl>      <int>
1 Completo 13525. 13818.         36
2 AIC      13524. 13809         35
3 BIC      13524. 13809         35
```

```
cat("\nFórmula BIC meteorológica:\n")
```

Fórmula BIC meteorológica:

```
print(formula(mod_met_bic_tr))
```

```
episodio ~ sector + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) + ns(PRS,
  3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos
```

4.3 ¿La dirección aporta información después de la meteorología?

Se compara el modelo meteorológico seleccionado con el mismo modelo eliminando solamente el bloque de dirección.

```
mod_met_sin_direccion_tr <- update(
  mod_met_bic_tr,
  . ~ . - sector
)

cat("=== LRT: meteorología seleccionada, con vs sin dirección ===\n")
```

```
=== LRT: meteorología seleccionada, con vs sin dirección ===
```

```
print(
  anova(
    mod_met_sin_direccion_tr,
    mod_met_bic_tr,
    test = "Chisq"
  )
)
```

Analysis of Deviance Table

```
Model 1: episodio ~ ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) + ns(PRS, 3) +
  ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos
Model 2: episodio ~ sector + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) + ns(PRS,
  3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos
Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1      25406      14647
2      25391      13454 15    1192.7 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

5. Validación temporal del modelo meteorológico en 2025

Para hacer la predicción de 2025 se reajusta en 2022–2024 la especificación elegida por BIC.

```
formula_met_final <- formula(mod_met_bic_tr)

mod_met_final_tr <- glm(
  formula_met_final,
  data = d_met_tr,
  family = binomial
)

mod_base_16_tr <- glm(
  episodio ~
    sector +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_met_tr,
  family = binomial
)
```

```

)

p_base_2025 <- predict(
  mod_base_16_tr,
  newdata = d_met_te,
  type = "response"
)

p_met_2025 <- predict(
  mod_met_final_tr,
  newdata = d_met_te,
  type = "response"
)

metricas_binarias <- function(y, p) {
  tibble(
    AUC = as.numeric(auc(roc(y, p, quiet = TRUE))),
    Brier = mean((p - y)^2)
  )
}

validacion_meteo_2025 <- bind_rows(
  metricas_binarias(d_met_te$episodio, p_base_2025) %>%
    mutate(Modelo = "Dirección + WSR + tiempo", .before = 1),
  metricas_binarias(d_met_te$episodio, p_met_2025) %>%
    mutate(Modelo = "Meteorología ampliada", .before = 1)
) %>%
  mutate(
    AUC = round(AUC, 3),
    Brier = round(Brier, 4)
  )

print(validacion_meteo_2025)

```

```

# A tibble: 2 x 3
  Modelo                AUC Brier
  <chr>                <dbl> <dbl>
1 Dirección + WSR + tiempo 0.789 0.104
2 Meteorología ampliada    0.794 0.106

```


6. Diagnóstico de dependencia temporal residual

La meteorología puede explicar parte de la variación, pero no necesariamente la memoria temporal del contaminante. Este diagnóstico conecta directamente el trabajo meteorológico con el modelo de rezagos.

```
mod_base_16_misma_muestra <- glm(
  episodio ~
    sector +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d_met_se3,
  family = binomial
)
```

```
mod_met_final <- glm(
  formula_met_final,
  data = d_met_se3,
  family = binomial
)
```

```
acf_residuo_real <- function(modelo, datos_modelo, etiqueta,
                             lags = c(1, 2, 3, 6, 12, 24, 48)) {

  resid_base <- tibble(
    fecha = datos_modelo$fecha,
    residuo = residuals(modelo, type = "deviance")
  )

  map_dfr(lags, function(k) {

    anterior <- resid_base %>%
      transmute(
        fecha = fecha + hours(k),
        residuo_anterior = residuo
      )

    pares <- resid_base %>%
      transmute(
        fecha,
        residuo_actual = residuo
      )
```

```

    ) %>%
    inner_join(anterior, by = "fecha")

tibble(
  Modelo = etiqueta,
  Rezago_horas = k,
  N_pares = nrow(pares),
  Autocorrelacion = if (nrow(pares) > 2) {
    cor(
      pares$residuo_actual,
      pares$residuo_anterior,
      use = "complete.obs"
    )
  } else {
    NA_real_
  }
)
})
}

acf_meteo <- bind_rows(
  acf_residuo_real(
    mod_base_16_misma_muestra,
    d_met_se3,
    "Base: dirección + WSR + tiempo"
  ),
  acf_residuo_real(
    mod_met_final,
    d_met_se3,
    "Meteorología ampliada"
  )
)

print(
  acf_meteo %>%
  mutate(Autocorrelacion = round(Autocorrelacion, 3)),
  n = Inf
)

```

A tibble: 14 x 4

Modelo	Rezago_horas	N_pares	Autocorrelacion
<chr>	<dbl>	<int>	<dbl>

1 Base: dirección + WSR + tiempo	1	33607	0.484
2 Base: dirección + WSR + tiempo	2	33468	0.253
3 Base: dirección + WSR + tiempo	3	33389	0.134
4 Base: dirección + WSR + tiempo	6	33268	0.042
5 Base: dirección + WSR + tiempo	12	33142	0.078
6 Base: dirección + WSR + tiempo	24	33072	0.165
7 Base: dirección + WSR + tiempo	48	32922	0.106
8 Meteorología ampliada	1	33607	0.471
9 Meteorología ampliada	2	33468	0.242
10 Meteorología ampliada	3	33389	0.13
11 Meteorología ampliada	6	33268	0.05
12 Meteorología ampliada	12	33142	0.06
13 Meteorología ampliada	24	33072	0.151
14 Meteorología ampliada	48	32922	0.09

Lectura clave: si persiste una autocorrelación importante en lag 1, la meteorología adicional no sustituye un tratamiento explícito de la memoria del SO .

7. Construcción correcta de rezagos horarios

Los rezagos se calculan sobre una **rejilla horaria completa**. Esto evita tratar como consecutivas dos mediciones separadas por una hora faltante.

```
se3_grid <- datos %>%
  filter(Estacion == "SE3") %>%
  select(
    fecha, SO2, episodio, sector, sector_E,
    WSR, TOUT, RH, PRS, SR, RAINF
  ) %>%
  arrange(fecha) %>%
  complete(
    fecha = seq(
      min(fecha, na.rm = TRUE),
      max(fecha, na.rm = TRUE),
      by = "hour"
    )
  ) %>%
  arrange(fecha) %>%
  mutate(
    Año = year(fecha),
    Hora = hour(fecha),
```

```

    Mes = month(fecha),
    Hora_sin = sin(2 * pi * Hora / 24),
    Hora_cos = cos(2 * pi * Hora / 24),
    Mes_sin = sin(2 * pi * Mes / 12),
    Mes_cos = cos(2 * pi * Mes / 12),
    S02_lag1 = lag(S02, 1),
    S02_lag2 = lag(S02, 2),
    S02_lag3 = lag(S02, 3),
    S02_lag6 = lag(S02, 6),
    S02_lag12 = lag(S02, 12),
    S02_lag24 = lag(S02, 24),
    dia = as.Date(fecha)
)

```

8. Modelo temporal con rezagos de SO

Este bloque reproduce la idea de Sebastián: preguntar si el sector Este continúa aportando información después de conocer el SO de horas anteriores.

```

d_lags <- se3_grid %>%
  select(
    fecha, Año, dia, episodio, sector_E,
    WSR,
    Hora_sin, Hora_cos, Mes_sin, Mes_cos,
    S02_lag1, S02_lag2, S02_lag3,
    S02_lag6, S02_lag12, S02_lag24
  ) %>%
  drop_na()

formula_lag_base <- episodio ~
  sector_E +
  ns(WSR, 3) +
  Hora_sin + Hora_cos +
  Mes_sin + Mes_cos

formula_lag_completa <- update(
  formula_lag_base,
  . ~ . +
  S02_lag1 + S02_lag2 + S02_lag3 +
  S02_lag6 + S02_lag12 + S02_lag24
)

```

```
)

mod_lag_base <- glm(
  formula_lag_base,
  data = d_lags,
  family = binomial
)

mod_lag_completo <- glm(
  formula_lag_completa,
  data = d_lags,
  family = binomial
)
```

8.1 Selección BIC de los rezagos

```
# Para continuidad con el análisis previo:
formula_lag_minima <- formula_lag_base

mod_lag_bic <- step(
  mod_lag_completo,
  scope = list(
    lower = formula_lag_minima,
    upper = formula_lag_completa
  ),
  direction = "backward",
  k = log(nobs(mod_lag_completo)),
  trace = 0
)

cat("Fórmula temporal BIC:\n")
```

Fórmula temporal BIC:

```
print(formula(mod_lag_bic))
```

```
episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
  Mes_cos + S02_lag1 + S02_lag2 + S02_lag12 + S02_lag24
```

```
cat("\nLRT: sin lags vs con lags seleccionados\n")
```

LRT: sin lags vs con lags seleccionados

```
print(
  anova(
    mod_lag_base,
    mod_lag_bic,
    test = "Chisq"
  )
)
```

Analysis of Deviance Table

Model 1: episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos

Model 2: episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos + S02_lag1 + S02_lag2 + S02_lag12 + S02_lag24

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	31017	19157			
2	31013	13970	4	5187.7	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

8.2 ¿Sobrevive el sector Este?

```
print(
  tidy(mod_lag_bic) %>%
    filter(term == "sector_EEste") %>%
    mutate(
      OR = exp(estimate),
      IC_inf = exp(estimate - 1.96 * std.error),
      IC_sup = exp(estimate + 1.96 * std.error)
    ) %>%
    select(term, estimate, OR, IC_inf, IC_sup, p.value)
)
```

```
# A tibble: 1 x 6
  term          estimate    OR IC_inf IC_sup  p.value
  <chr>          <dbl> <dbl> <dbl> <dbl>    <dbl>
1 sector_EEste    1.21  3.34  3.03  3.68 7.87e-129
```

9. MODELO INTEGRADO NUEVO: meteorología + memoria temporal + dirección

Esta es la pieza que une directamente ambos trabajos.

Se construye sobre **la misma muestra** para que AIC, BIC y las pruebas de razón de verosimilitud sean comparables.

La especificación confirmatoria combina:

- sector Este/Resto;
- meteorología retenida en el trabajo meteorológico: WSR, TOUT, RH, PRS y SR;
- hora y mes cíclicos;
- rezagos seleccionados en el trabajo temporal: 1, 2, 12 y 24 horas.

RAINF no se fuerza porque en la selección meteorológica previa no fue retenida.

```
d_integrado <- se3_grid %>%
  select(
    fecha, Año, día, episodio, sector_E,
    WSR, TOUT, RH, PRS, SR,
    Hora_sin, Hora_cos, Mes_sin, Mes_cos,
    S02_lag1, S02_lag2, S02_lag12, S02_lag24
  ) %>%
  drop_na() %>%
  mutate(
    sector_E = factor(sector_E, levels = c("Resto", "Este"))
  )

d_int_tr <- d_integrado %>% filter(Año <= 2024)
d_int_te <- d_integrado %>% filter(Año == 2025)

cat("Muestra integrada total:", nrow(d_integrado), "\n")
```

Muestra integrada total: 31745

```
cat("Train 2022-2024:", nrow(d_int_tr), "\n")
```

Train 2022-2024: 23563

```
cat("Test 2025:", nrow(d_int_te), "\n")
```

Test 2025: 8182

9.1 Cuatro modelos anidados sobre exactamente las mismas filas

```
f_base_int <- episodio ~
  sector_E +
  ns(WSR, 3) +
  Hora_sin + Hora_cos +
  Mes_sin + Mes_cos

f_meteo_int <- episodio ~
  sector_E +
  ns(WSR, 3) +
  ns(TOUT, 3) +
  ns(RH, 3) +
  ns(PRS, 3) +
  ns(SR, 3) +
  Hora_sin + Hora_cos +
  Mes_sin + Mes_cos

f_lags_int <- episodio ~
  sector_E +
  ns(WSR, 3) +
  Hora_sin + Hora_cos +
  Mes_sin + Mes_cos +
  S02_lag1 + S02_lag2 + S02_lag12 + S02_lag24

f_full_int <- episodio ~
  sector_E +
  ns(WSR, 3) +
  ns(TOUT, 3) +
  ns(RH, 3) +
  ns(PRS, 3) +
```



```

ns(SR, 3) +
  Hora_sin + Hora_cos +
  Mes_sin + Mes_cos +
  S02_lag1 + S02_lag2 + S02_lag12 + S02_lag24

m_base_int_tr <- glm(f_base_int, data = d_int_tr, family = binomial)
m_meteo_int_tr <- glm(f_meteo_int, data = d_int_tr, family = binomial)
m_lags_int_tr <- glm(f_lags_int, data = d_int_tr, family = binomial)
m_full_int_tr <- glm(f_full_int, data = d_int_tr, family = binomial)

comparacion_integrada_train <- tibble(
  Modelo = c(
    "Base",
    "Meteorología ampliada",
    "Lags S02",
    "Meteorología + lags"
  ),
  AIC = c(
    AIC(m_base_int_tr),
    AIC(m_meteo_int_tr),
    AIC(m_lags_int_tr),
    AIC(m_full_int_tr)
  ),
  BIC = c(
    BIC(m_base_int_tr),
    BIC(m_meteo_int_tr),
    BIC(m_lags_int_tr),
    BIC(m_full_int_tr)
  )
) %>%
  mutate(across(c(AIC, BIC), ~ round(.x, 1)))

print(comparacion_integrada_train)

```

```

# A tibble: 4 x 3
  Modelo          AIC    BIC
  <chr>         <dbl> <dbl>
1 Base         13874. 13946.
2 Meteorología ampliada 13201. 13370.
3 Lags S02      10066. 10171.
4 Meteorología + lags   9844. 10046.

```

9.2 Pruebas que demuestran complementariedad

¿Los rezagos aportan después de controlar meteorología?

```
cat("=== LRT: meteorología vs meteorología + lags ===\n")
```

```
=== LRT: meteorología vs meteorología + lags ===
```

```
print(
  anova(
    m_meteo_int_tr,
    m_full_int_tr,
    test = "Chisq"
  )
)
```

Analysis of Deviance Table

Model 1: episodio ~ sector_E + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) +
ns(PRS, 3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos

Model 2: episodio ~ sector_E + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) +
ns(PRS, 3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos + SO2_lag1 + SO2_lag2 + SO2_lag12 + SO2_lag24

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	23542	13158.8			
2	23538	9794.2	4	3364.6	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

¿La meteorología adicional aporta después de controlar la memoria del SO ?

```
cat("=== LRT: lags vs meteorología + lags ===\n")
```

```
=== LRT: lags vs meteorología + lags ===
```

```
print(
  anova(
    m_lags_int_tr,
    m_full_int_tr,
    test = "Chisq"
  )
)
```

Analysis of Deviance Table

```
Model 1: episodio ~ sector_E + ns(WSR, 3) + Hora_sin + Hora_cos + Mes_sin +
  Mes_cos + S02_lag1 + S02_lag2 + S02_lag12 + S02_lag24
Model 2: episodio ~ sector_E + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) +
  ns(PRS, 3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin +
  Mes_cos + S02_lag1 + S02_lag2 + S02_lag12 + S02_lag24
Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1      23550      10039.9
2      23538      9794.2 12    245.69 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

¿El sector Este sigue aportando después de controlar AMBAS cosas?

```
m_full_sin_sector_tr <- update(
  m_full_int_tr,
  . ~ . - sector_E
)

cat("=== LRT: modelo integrado con vs sin sector Este ===\n")
```

```
=== LRT: modelo integrado con vs sin sector Este ===
```

```
print(
  anova(
    m_full_sin_sector_tr,
    m_full_int_tr,
    test = "Chisq"
  )
)
```

Analysis of Deviance Table

Model 1: episodio ~ ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) + ns(PRS, 3) +
ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin + Mes_cos + S02_lag1 +
S02_lag2 + S02_lag12 + S02_lag24

Model 2: episodio ~ sector_E + ns(WSR, 3) + ns(TOUT, 3) + ns(RH, 3) +
ns(PRS, 3) + ns(SR, 3) + Hora_sin + Hora_cos + Mes_sin +
Mes_cos + S02_lag1 + S02_lag2 + S02_lag12 + S02_lag24

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	23539	10196.0			
2	23538	9794.2	1	401.8	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Esta es la prueba central del modelo integrado. Si el contraste es significativo, el sector Este aporta información adicional incluso después de controlar simultáneamente por meteorología y memoria temporal del SO .

10. OR del sector Este con inferencia robusta agrupada por día

Se reajusta el modelo integrado sobre toda la muestra disponible para estimar la asociación final, y se recalcula la incertidumbre agrupando las observaciones por día.

```
m_full_int <- glm(  
  f_full_int,  
  data = d_integrado,  
  family = binomial  
)  
  
V_full_rob <- vcovCL(  
  m_full_int,  
  cluster = ~ dia  
)  
  
rob_full <- coeftest(  
  m_full_int,  
  vcov. = V_full_rob  
)  
  
b_E <- rob_full["sector_EEste", "Estimate"]  
se_E <- rob_full["sector_EEste", "Std. Error"]
```

```

resultado_sector_integrado <- tibble(
  beta = b_E,
  OR = exp(b_E),
  IC_inf = exp(b_E - 1.96 * se_E),
  IC_sup = exp(b_E + 1.96 * se_E),
  p_robusto = rob_full["sector_EEste", "Pr(>|z|)"]
)

print(
  resultado_sector_integrado %>%
    mutate(
      across(c(beta, OR, IC_inf, IC_sup), ~ round(.x, 3)),
      p_robusto = signif(p_robusto, 3)
    )
)

```

```

# A tibble: 1 x 5
  beta      OR IC_inf IC_sup p_robusto
<dbl> <dbl> <dbl> <dbl> <dbl>
1  1.22  3.38   3.06   3.74 1.88e-128

```

11. Validación fuera de muestra 2025: comparación justa

Los cuatro modelos se entrenan con 2022–2024 y se evalúan sobre las mismas observaciones de 2025.

```

pred_base <- predict(
  m_base_int_tr,
  newdata = d_int_te,
  type = "response"
)

pred_meteo <- predict(
  m_meteo_int_tr,
  newdata = d_int_te,
  type = "response"
)

pred_lags <- predict(
  m_lags_int_tr,

```

```

newdata = d_int_te,
type = "response"
)

pred_full <- predict(
  m_full_int_tr,
  newdata = d_int_te,
  type = "response"
)

metricas_oos <- function(y, p, nombre) {
  tibble(
    Modelo = nombre,
    AUC_2025 = as.numeric(auc(roc(y, p, quiet = TRUE))),
    Brier_2025 = mean((p - y)^2)
  )
}

validacion_integrada_2025 <- bind_rows(
  metricas_oos(d_int_te$episodio, pred_base, "Base"),
  metricas_oos(d_int_te$episodio, pred_meteo, "Meteorología"),
  metricas_oos(d_int_te$episodio, pred_lags, "Lags"),
  metricas_oos(d_int_te$episodio, pred_full, "Meteorología + lags")
) %>%
  mutate(
    AUC_2025 = round(AUC_2025, 3),
    Brier_2025 = round(Brier_2025, 4)
  )

print(validacion_integrada_2025)

```

```

# A tibble: 4 x 3
  Modelo          AUC_2025 Brier_2025
  <chr>          <dbl>     <dbl>
1 Base          0.761      0.108
2 Meteorología  0.768      0.110
3 Lags          0.897      0.0751
4 Meteorología + lags 0.896      0.0764

```

11.1 Sensibilidad y especificidad con corte definido en entrenamiento

```
corde_train <- mean(d_int_tr$episodio)

metricas_clasificacion <- function(y, p, corde, nombre) {

  tab <- table(
    Predicho = p > corde,
    Real = y
  )

  # asegurar matriz 2 x 2
  if (!all(c("FALSE", "TRUE") %in% rownames(tab)) ||
      !all(c("0", "1") %in% colnames(tab))) {
    return(
      tibble(
        Modelo = nombre,
        Sensibilidad = NA_real_,
        Especificidad = NA_real_
      )
    )
  }

  tibble(
    Modelo = nombre,
    Sensibilidad = tab["TRUE", "1"] / sum(tab[, "1"]),
    Especificidad = tab["FALSE", "0"] / sum(tab[, "0"])
  )
}

clasificacion_2025 <- bind_rows(
  metricas_clasificacion(
    d_int_te$episodio, pred_base, corde_train, "Base"
  ),
  metricas_clasificacion(
    d_int_te$episodio, pred_meteo, corde_train, "Meteorología"
  ),
  metricas_clasificacion(
    d_int_te$episodio, pred_lags, corde_train, "Lags"
  ),
  metricas_clasificacion(
    d_int_te$episodio, pred_full, corde_train, "Meteorología + lags"
  )
}
```

```

)
) %>%
  mutate(
    Sensibilidad = round(Sensibilidad, 3),
    Especificidad = round(Especificidad, 3)
  )

print(clasificacion_2025)

```

```

# A tibble: 4 x 3
  Modelo          Sensibilidad Especificidad
  <chr>          <dbl>         <dbl>
1 Base          0.701         0.679
2 Meteorología  0.57           0.788
3 Lags          0.795         0.833
4 Meteorología + lags 0.734         0.876

```

12. ¿Queda autocorrelación después del modelo integrado?

```

acf_integrado <- acf_residuo_real(
  m_full_int,
  d_integrado,
  "Modelo integrado"
) %>%
  mutate(
    Autocorrelacion = round(Autocorrelacion, 3)
  )

print(acf_integrado, n = Inf)

```

```

# A tibble: 7 x 4
  Modelo          Rezago_horas N_pares Autocorrelacion
  <chr>          <dbl>    <int>         <dbl>
1 Modelo integrado      1   30840         0.137
2 Modelo integrado      2   30360         0.046
3 Modelo integrado      3   29988         0.035
4 Modelo integrado      6   29727         0.021
5 Modelo integrado     12   30446         0.013
6 Modelo integrado     24   29838         0.048

```


7 Modelo integrado	48	29088	0.033
--------------------	----	-------	-------

La comparación útil es:

- autocorrelación residual del modelo base;
- autocorrelación residual del modelo meteorológico;
- autocorrelación residual del modelo integrado.

Una reducción clara en los primeros rezagos apoyaría que el modelo integrado captura mejor la dependencia temporal.

13. Importancia incremental de los bloques

Este análisis cuantifica cuánto empeora el modelo cuando se elimina cada bloque, manteniendo los demás.

```
m_int_sin_sector <- update(  
  m_full_int,  
  . ~ . - sector_E  
)  
  
m_int_sin_meteo_extra <- update(  
  m_full_int,  
  . ~ . -  
    ns(TOUT, 3) -  
    ns(RH, 3) -  
    ns(PRS, 3) -  
    ns(SR, 3)  
)  
  
m_int_sin_lags <- update(  
  m_full_int,  
  . ~ . -  
    S02_lag1 -  
    S02_lag2 -  
    S02_lag12 -  
    S02_lag24  
)  
  
m_int_sin_tiempo <- update(  
  m_full_int,
```

```

. ~ . -
  Hora_sin - Hora_cos -
  Mes_sin - Mes_cos
)

comparar_bloque <- function(modelo_reducido, modelo_completo, nombre) {

  chi2 <- modelo_reducido$deviance - modelo_completo$deviance
  gl <- modelo_reducido$df.residual - modelo_completo$df.residual

  tibble(
    Bloque = nombre,
    Delta_deviance = chi2,
    gl = gl,
    p = pchisq(chi2, gl, lower.tail = FALSE)
  )
}

importancia_bloques_integrada <- bind_rows(
  comparar_bloque(
    m_int_sin_sector,
    m_full_int,
    "Sector Este/Resto"
  ),
  comparar_bloque(
    m_int_sin_meteo_extra,
    m_full_int,
    "Meteorología adicional: TOUT + RH + PRS + SR"
  ),
  comparar_bloque(
    m_int_sin_lags,
    m_full_int,
    "Memoria temporal: lags S02"
  ),
  comparar_bloque(
    m_int_sin_tiempo,
    m_full_int,
    "Ciclicidad: hora + mes"
  )
) %>%
  arrange(desc(Delta_deviance)) %>%
  mutate(

```

```

    Delta_deviance = round(Delta_deviance, 1),
    p = signif(p, 3)
  )

print(importancia_bloques_integrada)

```

```

# A tibble: 4 x 4
  Bloque                                Delta_deviance    gl      p
  <chr>                                <dbl> <int>   <dbl>
1 Memoria temporal: lags S02          4886.     4 0
2 Sector Este/Resto                   600.     1 1.51e-132
3 Meteorología adicional: TOUT + RH + PRS + SR 282.    12 3.25e- 53
4 Ciclicidad: hora + mes              104.     4 1.59e- 21

```

14. Sensibilidad al umbral de episodio

Esta verificación comprueba que la conclusión direccional no dependa exclusivamente de haber elegido P95.

```

sensibilidad_umbral <- map_dfr(
  c(0.90, 0.95, 0.99),
  function(q) {

    u <- quantile(datos$S02, q, na.rm = TRUE)

    map_dfr(
      levels(datos$Estacion),
      function(est) {

        d <- datos %>%
          filter(Estacion == est) %>%
          mutate(
            y = as.integer(S02 > u)
          ) %>%
          drop_na(
            y, sector_E, WSR,
            Hora_sin, Hora_cos,
            Mes_sin, Mes_cos
          )
      }
    )
  }
)

```

```

if (sum(d$y) < 30) {
  return(
    tibble(
      Estacion = est,
      OR = NA_real_,
      IC_inf = NA_real_,
      IC_sup = NA_real_
    )
  )
}

m <- glm(
  y ~
    sector_E +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d,
  family = binomial
)

co <- tidy(m) %>%
  filter(term == "sector_EEste")

tibble(
  Estacion = est,
  OR = exp(co$estimate),
  IC_inf = exp(co$estimate - 1.96 * co$std.error),
  IC_sup = exp(co$estimate + 1.96 * co$std.error)
)
}
) %>%
mutate(
  Percentil = paste0("P", 100 * q),
  Umbral_ppb = u,
  .before = 1
)
}
)

print(
  sensibilidad_umbral %>%

```

```

mutate(
  across(c(Umbral_ppb, OR, IC_inf, IC_sup), ~ round(.x, 2))
),
n = Inf
)

```

A tibble: 12 x 6

	Percentil	Umbral_ppb	Estacion	OR	IC_inf	IC_sup
	<chr>	<dbl>	<chr>	<dbl>	<dbl>	<dbl>
1	P90	7.2	SE3	3.38	3.17	3.6
2	P90	7.2	SE2	1.43	1.33	1.53
3	P90	7.2	NE	1	0.89	1.13
4	P90	7.2	GAR	1.4	1.08	1.83
5	P95	11.1	SE3	3.19	2.96	3.44
6	P95	11.1	SE2	1.58	1.43	1.74
7	P95	11.1	NE	1.01	0.81	1.26
8	P95	11.1	GAR	1.08	0.54	2.16
9	P99	30.6	SE3	2.57	2.25	2.93
10	P99	30.6	SE2	1.75	1.37	2.24
11	P99	30.6	NE	0.86	0.3	2.5
12	P99	30.6	GAR	NA	NA	NA

15. Falsación multi-contaminante

La lógica es comprobar si el patrón del sector Este es específico de SO o aparece de la misma manera en otros contaminantes.

```

or_este_contaminante <- function(df, var) {

  d <- df %>%
    filter(!is.na(.data[[var]])) %>%
    mutate(
      y = as.integer(
        .data[[var]] >
          quantile(.data[[var]], 0.95, na.rm = TRUE)
      )
    ) %>%
    drop_na(
      y, sector_E, WSR,
      Hora_sin, Hora_cos,

```

```

      Mes_sin, Mes_cos
    )

    if (sum(d$y) < 30) {
      return(
        tibble(
          n = nrow(d),
          eventos = sum(d$y),
          OR = NA_real_,
          IC_inf = NA_real_,
          IC_sup = NA_real_
        )
      )
    }
  }

m <- glm(
  y ~
    sector_E +
    ns(WSR, 3) +
    Hora_sin + Hora_cos +
    Mes_sin + Mes_cos,
  data = d,
  family = binomial
)

co <- tidy(m) %>%
  filter(term == "sector_EEste")

tibble(
  n = nrow(d),
  eventos = sum(d$y),
  OR = exp(co$estimate),
  IC_inf = exp(co$estimate - 1.96 * co$std.error),
  IC_sup = exp(co$estimate + 1.96 * co$std.error)
)
}

falsacion_multicontaminante <- map_dfr(
  c("SO2", "NOX", "NO", "CO", "PM10", "PM2.5", "O3"),
  function(v) {
    or_este_contaminante(
      filter(datos, Estacion == "SE3"),

```

```

      v
    ) %>%
      mutate(Contaminante = v, .before = 1)
  }
) %>%
  mutate(
    across(c(OR, IC_inf, IC_sup), ~ round(.x, 2))
  )

print(falsacion_multicontaminante)

```

```

# A tibble: 7 x 6
  Contaminante      n eventos      OR IC_inf IC_sup
  <chr>          <int>    <int> <dbl> <dbl> <dbl>
1 SO2            33977     1699  2.66  2.39  2.95
2 NOX            33682     1684  0.22  0.17  0.28
3 NO             33451     1670  0.22  0.17  0.29
4 CO             31741     1571  1.05  0.92  1.2
5 PM10           33684     1658  0.5   0.43  0.58
6 PM2.5          30686     1507  0.59  0.51  0.68
7 O3             33697     1567  0.9   0.8   1.02

```

16. Verificación independiente CBPF

Este bloque es opcional. Solo se ejecuta si openair está instalado.

```

if (requireNamespace("openair", quietly = TRUE)) {

  d_oa <- datos %>%
    rename(
      date = fecha,
      ws = WSR,
      wd = WDR
    )

  pct_eq <- datos %>%
    group_by(Estacion) %>%
    summarise(
      p = 100 * mean(SO2 <= umbral_ep, na.rm = TRUE),
      .groups = "drop"
    )
}

```

```

)


for (est in c("SE3", "SE2", "NE")) {

  p_est <- pct_eq$p[pct_eq$Estacion == est]

  print(
    openair::polarPlot(
      filter(d_oa, Estacion == est),
      pollutant = "SO2",
      statistic = "cpf",
      percentile = p_est,
      main = paste0(
        "CBPF SO2 - ", est,
        " | umbral ", round(umbral_ep, 1), " ppb"
      ),
      key.title = "Probabilidad"
    )
  )
}

```


CBPF SO₂ – SE3 | umbral 11.1 ppb



Radial axis shows wind spd.

CPF at the 88.3715454572211th percentile (=11)


CBPF SO₂ – SE3 | umbral 11.1 ppb



Radial axis shows wind spd.

CPF at the 88.3715454572211th percentile (=11)


CBPF SO₂ – SE2 | umbral 11.1 ppb



Radial axis shows wind spd.

CPF at the 94.4614921780987th percentile (=11)


CBPF SO₂ – SE2 | umbral 11.1 ppb



Radial axis shows wind spd.

CPF at the 94.4614921780987th percentile (=11)


CBPF SO₂ – NE | umbral 11.1 ppb



Radial axis shows wind spd.

CPF at the 97.7519963839084th percentile (=11)

CBPF SO₂ – NE | umbral 11.1 ppb



Radial axis shows wind spd.

CPF at the 97.7519963839084th percentile (=11)

17. Duración de episodios

La duración ayuda a explicar por qué un promedio móvil de 24 horas puede amortiguar eventos agudos cortos.

```
d_se3_ep <- datos %>%
  filter(Estacion == "SE3") %>%
  arrange(fecha) %>%
  mutate(
    salto_h = as.numeric(
      difftime(fecha, lag(fecha), units = "hours")
    ),
    nuevo_bloque =
      is.na(salto_h) |
      salto_h != 1 |
      episodio != lag(episodio),
    bloque_id = cumsum(nuevo_bloque)
  )

rachas <- d_se3_ep %>%
  filter(episodio == 1) %>%
```

```
group_by(bloque_id) %>%
  summarise(
    duracion_h = n(),
    inicio = min(fecha),
    .groups = "drop"
  )

cat("Número de rachas:", nrow(rachas), "\n")
```

Número de rachas: 1561

```
cat("Duración mediana:", median(rachas$duracion_h), "h\n")
```

Duración mediana: 2 h

```
print(
  quantile(
    rachas$duracion_h,
    c(0.50, 0.75, 0.90, 0.95, 0.99)
  )
)
```

```
50% 75% 90% 95% 99%
2.0 3.0 5.0 6.0 8.4
```

18. Punto ciego de promedios móviles de 24 horas

Este bloque documenta por qué episodios horarios pueden no traducirse en categorías altas cuando se utiliza una ventana de promediación de 24 horas.

```
if (requireNamespace("zoo", quietly = TRUE)) {

  base_movil <- datos %>%
    select(Estacion, fecha, S02) %>%
    arrange(Estacion, fecha) %>%
    group_by(Estacion) %>%
    complete(
      fecha = seq(
```

```

      min(fecha),
      max(fecha),
      by = "hour"
    )
  ) %>%
  mutate(
    suma_24 = zoo::rollsumr(
      coalesce(SO2, 0),
      k = 24,
      fill = NA
    ),
    val_24 = zoo::rollsumr(
      !is.na(SO2),
      k = 24,
      fill = NA
    ),
    so2_mm24 = if_else(
      val_24 >= 18,
      suma_24 / val_24,
      NA_real_
    )
  ) %>%
  ungroup()

resumen_24h <- base_movil %>%
  filter(!is.na(so2_mm24)) %>%
  group_by(Estacion) %>%
  summarise(
    n = n(),
    max_mm24 = max(so2_mm24),
    p99_mm24 = quantile(so2_mm24, 0.99),
    .groups = "drop"
  ) %>%
  mutate(
    across(c(max_mm24, p99_mm24), ~ round(.x, 2))
  )

print(resumen_24h)
}

```

```

# A tibble: 4 x 4
  Estacion      n max_mm24 p99_mm24

```

	<fct>	<int>	<dbl>	<dbl>
1	SE3	34116	59.3	26.0
2	SE2	33358	29.4	13.4
3	NE	33335	20.3	9.69
4	GAR	31901	9.68	6.02

19. Matriz de sustento del proyecto

Esta tabla resume qué pregunta responde cada bloque. No sustituye la interpretación de los resultados; sirve como mapa de defensa.

```
matriz_sustento <- tribble(
  ~Pregunta, ~Metodo, ~Que_comprueba,
  "¿Existe patrón direccional?",
  "Logística de 16 rumbos",
  "La probabilidad de episodio cambia según rumbo controlando WSR, hora y mes.",

  "¿El patrón espacial es igual en todas las estaciones?",
  "Modelo conjunto flexible + interacción Estación × sector",
  "Permite que dirección, WSR y ciclos temporales tengan efectos distintos por estación.",

  "¿La dirección sobrevive a otros factores meteorológicos?",
  "Modelo meteorológico ampliado + AIC/BIC + LRT",
  "Evalúa dirección controlando TOUT, RH, PRS, SR, WSR y precipitación candidata.",

  "¿La meteorología elimina la memoria temporal?",
  "Autocorrelación de residuos",
  "Determina si todavía existe dependencia entre horas consecutivas.",

  "¿El patrón direccional es solo persistencia del S02?",
  "Regresión logística con rezagos",
  "Controla explícitamente la concentración de S02 de horas anteriores.",

  "¿Meteorología y memoria temporal son complementarias?",
  "Modelo integrado",
  "Compara bloques sobre la misma muestra y prueba cada contribución condicional a las demás",

  "¿La inferencia depende de asumir independencia horaria?",
  "Errores estándar robustos agrupados por día",
  "Corrige la incertidumbre ante dependencia dentro del día.",
```

```

"¿Generaliza a datos futuros?",
"Entrenamiento 2022-2024 / prueba 2025",
"Evalúa AUC y Brier fuera de muestra.",

"¿Depende del umbral P95?",
"Sensibilidad P90/P95/P99",
"Verifica estabilidad ante distintos niveles de severidad.",

"¿Es un patrón general de contaminación?",
"Falsación multi-contaminante + CBPF",
"Contrasta SO2 contra otros contaminantes y con una técnica direccional independiente.",

"¿Por qué los picos pueden quedar ocultos en métricas agregadas?",
"Duración de rachas + promedio móvil 24 h",
"Relaciona episodios cortos con amortiguación por ventanas de 24 horas."
)

print(matriz_sustento, n = Inf)

```

```
# A tibble: 11 x 3
```

	Pregunta <chr>	Metodo	Que_comprueba <chr> <chr>
1	¿Existe patrón direccional?	Logís~	La probabili~
2	¿El patrón espacial es igual en todas las estaciones?	Model~	Permite que ~
3	¿La dirección sobrevive a otros factores meteorológicos?	Model~	Evalúa direc~
4	¿La meteorología elimina la memoria temporal?	Autoc~	Determina si~
5	¿El patrón direccional es solo persistencia del SO2?	Regre~	Controla exp~
6	¿Meteorología y memoria temporal son complementarias?	Model~	Compara bloq~
7	¿La inferencia depende de asumir independencia horaria?	Error~	Corrige la i~
8	¿Generaliza a datos futuros?	Entre~	Evalúa AUC y~
9	¿Depende del umbral P95?	Sensi~	Verifica est~
10	¿Es un patrón general de contaminación?	Falsa~	Contrasta SO~
11	¿Por qué los picos pueden quedar ocultos en métricas ag~	Durac~	Relaciona ep~

20. Resumen automático del modelo integrado

```

resumen_final_integrado <- list(
  comparacion_train = comparacion_integrada_train,
  validacion_2025 = validacion_integrada_2025,

```

```

clasificacion_2025 = clasificacion_2025,
sector_este_robusto = resultado_sector_integrado,
importancia_bloques = importancia_bloques_integrada,
acf_integrado = acf_integrado
)

print(resumen_final_integrado)

```

\$comparacion_train

A tibble: 4 x 3

	Modelo	AIC	BIC
	<chr>	<dbl>	<dbl>
1	Base	13874.	13946.
2	Meteorología ampliada	13201.	13370.
3	Lags S02	10066.	10171.
4	Meteorología + lags	9844.	10046.

\$validacion_2025

A tibble: 4 x 3

	Modelo	AUC_2025	Brier_2025
	<chr>	<dbl>	<dbl>
1	Base	0.761	0.108
2	Meteorología	0.768	0.110
3	Lags	0.897	0.0751
4	Meteorología + lags	0.896	0.0764

\$clasificacion_2025

A tibble: 4 x 3

	Modelo	Sensibilidad	Especificidad
	<chr>	<dbl>	<dbl>
1	Base	0.701	0.679
2	Meteorología	0.57	0.788
3	Lags	0.795	0.833
4	Meteorología + lags	0.734	0.876

\$sector_este_robusto

A tibble: 1 x 5

	beta	OR	IC_inf	IC_sup	p_robusto
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	1.22	3.38	3.07	3.74	1.88e-128

\$importancia_bloques


```
# A tibble: 4 x 4
```

	Bloque <chr>	Delta_deviance <dbl>	gl <int>	p <dbl>
1	Memoria temporal: lags S02	4886.	4	0
2	Sector Este/Resto	600.	1	1.51e-132
3	Meteorología adicional: TOUT + RH + PRS + SR	282.	12	3.25e- 53
4	Ciclicidad: hora + mes	104.	4	1.59e- 21

```
$acf_integrado
```

```
# A tibble: 7 x 4
```

	Modelo <chr>	Rezago_horas <dbl>	N_pares <int>	Autocorrelacion <dbl>
1	Modelo integrado	1	30840	0.137
2	Modelo integrado	2	30360	0.046
3	Modelo integrado	3	29988	0.035
4	Modelo integrado	6	29727	0.021
5	Modelo integrado	12	30446	0.013
6	Modelo integrado	24	29838	0.048
7	Modelo integrado	48	29088	0.033

21. Guardado reproducible

```
saveRDS(
  list(
    datos = datos,
    mod_dir_16 = mod_dir_16,
    mod_conjunto_flexible = mod_conjunto_flexible,
    mod_met_bic_tr = mod_met_bic_tr,
    mod_met_final = mod_met_final,
    mod_lag_bic = mod_lag_bic,
    m_full_int = m_full_int,
    V_full_rob = V_full_rob,
    validacion_integrada_2025 = validacion_integrada_2025,
    clasificacion_2025 = clasificacion_2025,
    importancia_bloques_integrada = importancia_bloques_integrada,
    sensibilidad_umbral = sensibilidad_umbral,
    falsacion_multicontaminante = falsacion_multicontaminante,
    matriz_sustento = matriz_sustento
  ),
  "objetos_SIMA_modelo_integrado.rds"
```

```
)

cat("Objetos integrados guardados en objetos_SIMA_modelo_integrado.rds\n")
```

Objetos integrados guardados en objetos_SIMA_modelo_integrado.rds

22. Interpretación para defensa

La secuencia correcta para defender el proyecto es:

1. **Primero se identificó el patrón direccional** sin imponer de antemano cuál rumbo debía ser el relevante.
2. **Después se verificó espacialmente** que la relación no debía forzarse a ser idéntica en todas las estaciones.
3. **Se añadieron controles meteorológicos** para descartar que la asociación direccional fuera simplemente una consecuencia de temperatura, humedad, presión, radiación o velocidad del viento.
4. **El diagnóstico residual mostró que la meteorología no sustituye la memoria temporal**, por lo que se incorporaron rezagos del propio SO .
5. **El modelo integrado prueba simultáneamente ambas explicaciones alternativas:** condiciones meteorológicas y persistencia del contaminante.
6. **El efecto del sector Este debe interpretarse con errores estándar robustos por día** y comprobarse fuera de muestra en 2025.
7. Las pruebas de sensibilidad, falsación multi-contaminante y CBPF funcionan como evidencia independiente adicional.

La conclusión debe mantenerse en términos de **asociación**. Una persistencia del efecto direccional después de todos estos controles fortalece la hipótesis espacial del proyecto, pero no sustituye una atribución causal formal de fuente.

```
library(dplyr)
library(ggplot2)

calibracion <- tibble(
  y_obs = m_full_int_tr$y,
  p_pred = fitted(m_full_int_tr)
) %>%
  mutate(decil = ntile(p_pred, 10)) %>%
  group_by(decil) %>%
  summarise(
    n = n(),
```

```

    p_promedio_predicho = mean(p_pred),
    prop_observada = mean(y_obs),
    .groups = "drop"
  ) %>%
  mutate(
    diferencia_pp = round(100 * (prop_observada - p_promedio_predicho), 2)
  )

print(calibracion)

```


A tibble: 10 x 5

	decil	n	p_promedio_predicho	prop_observada	diferencia_pp
	<int>	<int>	<dbl>	<dbl>	<dbl>
1	1	2357	0.00620	0.000424	-0.58
2	2	2357	0.00992	0.00467	-0.53
3	3	2357	0.0144	0.00509	-0.93
4	4	2356	0.0206	0.00976	-1.08
5	5	2356	0.0298	0.0140	-1.57
6	6	2356	0.0433	0.0369	-0.64
7	7	2356	0.0622	0.0492	-1.3
8	8	2356	0.0950	0.116	2.13
9	9	2356	0.185	0.220	3.46
10	10	2356	0.638	0.649	1.04

```

ggplot(calibracion, aes(x = p_promedio_predicho, y = prop_observada)) +
  geom_point(size = 2) +
  geom_line() +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed", color = "gray50") +
  labs(
    x = "Probabilidad promedio predicha (por decil)",
    y = "Proporción observada de episodios",
    title = "Calibración del modelo integrado por deciles de riesgo"
  ) +
  theme_minimal()

```



La prueba de Hosmer-Lemeshow resultó significativa ($p < 0.05$), resultado esperable dado el tamaño de muestra, ya que esta prueba es conocida por rechazar la hipótesis de buen ajuste incluso ante desviaciones triviales cuando N es grande. Al examinar la calibración por deciles de riesgo, las diferencias entre probabilidad predicha y proporción observada se mantuvieron por debajo de 3.5 puntos porcentuales en todos los casos, con la mayor desviación en el noveno decil (predicho 18.5%, observado 22.0%). El modelo tiende a subestimar ligeramente el riesgo en las categorías de riesgo medio-alto y recupera buena precisión en el decil de mayor riesgo, lo cual es relevante para su uso como herramienta de alerta temprana.